



**PROGRES
PROYEK AKHIR**

**SENTIMEN ANALISIS BERBASIS ASPEK PADA
PERUMDA AIR MINUM SURYA SEMBADA
SURABAYA MENGGUNAKAN KOMPUTASI
KORELASI**

Dicky Syarif Renaldi
NRP. 3322600009

DOSEN PEMBIMBING
Entin Martiana K, S.Kom., M.Kom.
NIP. 197505302003121001

Aliridho Barakbah S.Kom, Ph.D
NIP. 197308162001121001

**PROGRAM STUDI SARJANA TERAPAN
SAINS DATA TERAPAN
DEPARTEMEN TEKNIK INFORMATIKA DAN
KOMPUTER
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2025**

“Halaman Ini Sengaja Dikosongkan”

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

PDAM (Perusahaan Daerah Air Minum) merupakan usaha milik daerah yang berfokus pada penyediaan dan distribusi air bersih serta air minum bagi masyarakat. Mengingat air merupakan kebutuhan esensial bagi kehidupan seluruh makhluk hidup, ketersediaannya memiliki peranan krusial dalam menunjang kesejahteraan dan kemakmuran rakyat. Pasokan air yang memadai turut berkontribusi dalam mendorong laju pembangunan di berbagai sektor masyarakat. Sebagai bentuk implementasinya, pemenuhan sebagian besar kebutuhan air bersih di Indonesia dilakukan oleh PDAM yang tersebar di seluruh provinsi, kabupaten, dan kota. Melalui berbagai program, baik di wilayah perkotaan maupun pedesaan, PDAM bertujuan memberikan layanan penyediaan air bersih yang layak dan sehat bagi masyarakat. Layanan ini ditujukan untuk memenuhi kebutuhan rumah tangga dan sektor industri, sekaligus mendukung peningkatan kesehatan masyarakat dan pertumbuhan ekonomi.

Pada pasal UUD 1945 Pasal 33 menyatakan bahwa “Bumi, air dan kekayaan alam yang terkandung di dalamnya dikuasai oleh negara dan dipergunakan untuk sebesar-besarnya kemakmuran rakyat” [8]. Pasal tersebut menjadi dasar filosofis dalam menentukan arah pengelolaan sumber daya alam oleh negara, yang ditujukan sepenuhnya untuk kesejahteraan rakyat. Pengelolaan ini harus dilandasi oleh prinsip keadilan sosial dan keberlanjutan lingkungan, sesuai dengan semangat demokrasi ekonomi yang menjamin kedaulatan negara dalam pemanfaatan sumber daya demi kemakmuran bersama.

Sebagai perusahaan penyedia air yang digunakan oleh seluruh masyarakat, PDAM diwajibkan untuk menjaga kualitas layanan dan pelayanan agar mampu bertahan serta tetap mendapat kepercayaan konsumen. Upaya memberikan pelayanan yang baik akan meminimalisir keluhan yang masuk pada instansi. Fluktuasi jumlah pengaduan ini menjadi data krusial yang merefleksikan performa pelayanan PDAM, sehingga penting untuk dianalisis lebih lanjut guna memahami efektivitas layanan yang diberikan.

Namun, dalam praktiknya, berbagai aduan pelanggan yang disampaikan melalui kanal digital seperti media sosial sering kali didominasi oleh opini negatif, seperti keluhan terhadap air yang tidak mengalir, kualitas air yang keruh, kebocoran, maupun keterlambatan penanganan gangguan. Kondisi ini menunjukkan adanya kesenjangan antara ekspektasi pelanggan dengan layanan yang diberikan PDAM. Tingginya opini negatif tersebut menandakan urgensi untuk dilakukan analisis yang lebih mendalam terhadap keluhan pelanggan agar PDAM dapat mengidentifikasi aspek layanan yang paling sering menjadi sumber permasalahan dan memperbaikinya secara tepat sasaran.

1.2 PERMASALAHAN

Ragam layanan yang disediakan oleh PDAM sering kali memunculkan berbagai keluhan, baik terkait dengan kualitas pelayanan maupun jasa yang diberikan. Meskipun PDAM telah memberikan media berupa website untuk mengajukan pengaduan dalam mengetahui kualitas jasa atau layanan mereka dengan cara melihat aktivitas pelanggan, namun nyatanya masih banyak pelanggan yang melakukan pengaduan pada kolom komentar postingan Instagram PDAM Surya Sembada.



Gambar 1. 1. Postingan pada Instagram PDAM Surya Sembada

Pada Gambar 1.1 merupakan salah satu postingan pada Instagram PDAM Surya Sembada pada tanggal 17 Februari 2025 yang membahas mengenai perbaikan pipa bocor diameter 450mm di Jl Made, Lakarsantri. Meskipun PDAM telah menyediakan website dan aplikasi sebagai wadah untuk pelanggan melaporkan pengaduan mengenai layanan yang ada di PDAM, masih banyak pelanggan yang melakukan pengaduan melalui kolom komentar pada postingan Instagram PDAM Surya Sembada.

Dengan banyaknya pelanggan PDAM yang melakukan pengaduan pada setiap kolom komentar akun Instagram PDAM Surya Sembada, membuat analisis data pengaduan menjadi tidak efektif. Kesulitan dalam melakukan pembagian pengaduan ke dalam aspek-aspek layanan yang telah ditentukan di dalam website menjadi hambatan utama, terutama karena data yang masuk sangat beragam dan ditulis dalam bahasa yang tidak terstruktur. Selain itu, memahami makna atau kesimpulan dari sudut pandang masing-masing pelanggan juga menjadi tantangan tersendiri. Oleh karena itu, tidak hanya dibutuhkan pemetaan komentar berdasarkan aspek layanan, tetapi juga analisis sentimen untuk mengetahui sikap atau perasaan pelanggan terhadap masing-masing aspek tersebut. Tanpa adanya pemahaman yang jelas mengenai aspek mana yang paling banyak dikeluhkan dan bagaimana sentimen pelanggan terhadap aspek tersebut, proses pengambilan keputusan akan terhambat dan dapat berdampak pada pemahaman yang keliru mengenai kualitas layanan serta tingkat kepuasan pelanggan terhadap PDAM.

1.3 TUJUAN

Penelitian ini bertujuan untuk mengembangkan sebuah pendekatan baru dalam menganalisis komentar masyarakat terkait layanan PDAM Surya Sembada yang disampaikan melalui media sosial, khususnya Instagram. Pendekatan yang digunakan difokuskan pada analisis sentimen berbasis aspek, di mana setiap komentar pengguna akan dipetakan ke dalam aspek layanan tertentu, seperti air kotor/bau, kebocoran, meter (macet/buram), pemakaian, air tidak keluar, perubahan kode tarif, hingga kebocoran pipa.

Untuk mengelompokkan komentar ke dalam aspek-aspek tersebut, penelitian ini menggunakan metode korelasi antar teks yang dihitung melalui teknik *cosine similarity*. Melalui metode ini, sistem dapat mengenali hubungan antara kata-kata dalam komentar dengan kata-kata kunci yang mewakili tiap aspek, lalu menentukan aspek mana yang paling relevan untuk setiap komentar. Proses ini dilakukan secara otomatis tanpa memerlukan pelatihan model. Selain itu, penggunaan *cosine similarity* dinilai lebih akurat dan efisien dibandingkan dengan pendekatan berbasis *machine learning*, terutama dalam konteks data komentar yang bersifat pendek dan tidak terstruktur.

Setelah komentar dikelompokkan ke dalam aspek tertentu, langkah selanjutnya adalah menganalisis sentimen dari masing-masing komentar tersebut. Analisis ini dilakukan menggunakan pendekatan *rule-based*, yaitu dengan mendeteksi kata-kata yang memiliki muatan sentimen positif, negatif, atau netral. Dengan cara ini, sistem dapat mengetahui bagaimana sikap atau perasaan masyarakat terhadap aspek layanan yang mereka keluhkan.

1.4 MANFAAT

Penelitian ini memberikan manfaat dalam memudahkan pemahaman terhadap berbagai bentuk susunan kalimat dalam komentar pengguna media sosial, khususnya yang berkaitan dengan pengaduan layanan. Dengan menggunakan pendekatan *correlation computing* berbasis *cosine similarity*, komentar dapat dikelompokkan secara otomatis ke dalam aspek-aspek layanan PDAM yang relevan dan menjadikan proses klasifikasi lebih efisien.

Selain itu, analisis sentimen berbasis aturan (*rule-based*) memungkinkan pendeteksian makna sentimen dari setiap komentar, baik itu bernada positif, negatif, ataupun netral. Hasil ini memudahkan PDAM dalam memahami isi pengaduan dan opini pelanggan dengan hasil yang lebih akurat.

Pengelompokan komentar berdasarkan aspek layanan juga membantu PDAM dalam mengidentifikasi jenis pengaduan yang paling banyak disampaikan oleh masyarakat. Dengan informasi tersebut, PDAM dapat melakukan evaluasi kinerja dan merancang perbaikan pelayanan yang lebih terarah sesuai dengan kebutuhan pelanggan.

Melalui penelitian ini, diharapkan dapat dibangun sebuah sistem yang mampu membantu pihak PDAM memahami keluhan dan opini masyarakat secara lebih terstruktur. Dengan mengetahui aspek yang paling sering dikomentari serta sentimennya, PDAM dapat merespons kebutuhan masyarakat secara lebih bijak dan sesuai dengan harapan pelanggan.

1.5 SISTEMATIKA PENULISAN

Jelaskan tentang sistematika pembahasan dalam buku proyek akhir yang meliputi :

Bab 1 Pendahuluan

Bab ini menjelaskan latar belakang permasalahan yang mendasari dilakukannya penelitian, rumusan masalah yang akan dijawab, tujuan dari penelitian, manfaat yang diharapkan dari hasil penelitian, serta sistematika penulisan dari keseluruhan laporan. Bab ini menjadi pondasi awal untuk memahami arah dan ruang lingkup penelitian.

Bab 2 Kajian Pustaka

Bab ini memuat kajian teoritis dan penelitian terdahulu yang relevan. Di dalamnya dibahas konsep dasar mengenai PDAM, media sosial sebagai sumber data opini publik, sentiment analysis, aspect-based sentiment analysis (ABSA), metode *correlation computing* yang digunakan untuk klasifikasi aspek, serta *rule based* yang digunakan untuk analisis sentimen. Bab ini juga mengulas beberapa penelitian terdahulu sebagai landasan dan pembanding pendekatan yang digunakan dalam penelitian ini.

Bab 3 Desain Sistem

Bab ini menjelaskan rancangan sistem yang digunakan dalam penelitian. Termasuk di dalamnya adalah arsitektur sistem, alur proses analisis, metode ekstraksi data dari Instagram, preprocessing teks, TF-IDF, metode *correlation computing* yang digunakan untuk klasifikasi aspek, serta *rule based* yang digunakan untuk analisis sentimen. Desain sistem secara umum juga disertakan di bab ini..

Bab 4 Eksperimen dan Analisis

Jelaskan tentang apa saja yang dibahas pada Bab 4. Penjelasan memuat bagian-bagian penting pada Eksperimen dan Analisis.

Bab 5 Penutup

Jelaskan tentang apa saja yang dibahas pada Bab 5. Penjelasan memuat bagian-bagian penting pada Penutup.

BAB 2

KAJIAN PUSTAKA

Dengan banyaknya pelanggan PDAM yang melakukan pengaduan pada setiap kolom komentar akun Instagram PDAM Surya Sembada, membuat analisa data pengaduan menjadi tidak efektif. Kesulitan dalam melakukan pembagian pengaduan menjadi aspek-aspek yang telah ditentukan di dalam website serta mendapatkan makna atau kesimpulan dari perbedaan sudut pandang manusia adalah hambatan untuk proses pengambilan keputusan serta memengaruhi pemahaman mengenai sejauh mana kualitas pelayanan PDAM dan tingkat kepuasan pelanggan terhadap layanan yang telah diberikan. Pada bab ini akan dibahas kajian teori mengenai pengaduan layanan PDAM dan beberapa penelitian berusaha menyelesaikan masalah menggunakan pendekatan *aspect based sentiment analysis*.

2.1 DESKRIPSI PERMASALAHAN

Sebagai perusahaan yang bertanggung jawab dalam penyediaan air bersih untuk masyarakat, PDAM memiliki kewajiban untuk memastikan bahwa layanan yang diberikan berjalan optimal dan memuaskan. Namun, pada kenyataannya, keluhan dari pelanggan masih kerap muncul, terutama melalui media sosial seperti Instagram. Meskipun PDAM telah menyediakan kanal pengaduan resmi, banyak pelanggan yang tetap memilih menyampaikan keluhan secara langsung di kolom komentar media sosial karena dianggap lebih cepat dan mudah dijangkau.

Permasalahan muncul ketika komentar-komentar tersebut menumpuk dan tidak terstruktur, sehingga sulit untuk dianalisis secara manual. Keluhan pelanggan juga sangat bervariasi dalam gaya bahasa, sering kali menggunakan singkatan, bahasa informal, atau bahkan emosi. Kondisi ini menyulitkan PDAM untuk memahami secara jelas aspek layanan mana yang paling sering dikeluhkan, serta bagaimana sentimen pelanggan terhadap aspek tersebut.

Untuk mengatasi hal ini, diperlukan sebuah sistem yang mampu memproses komentar-komentar pelanggan secara otomatis. Berdasarkan desain sistem yang ditampilkan pada Gambar 3.1, proses dimulai dari pengambilan data komentar menggunakan Instaloader, dilanjutkan dengan tahapan *preprocessing* seperti pembersihan data, tokenisasi, normalisasi, hingga stemming. Selanjutnya, data akan melalui tahap perhitungan TF-IDF, kemudian diklasifikasikan berdasarkan aspek layanan seperti air tidak keluar, tagihan, atau kebocoran. Setelah aspek ditemukan, dilakukan analisis sentimen untuk mengetahui apakah komentar tersebut bernada positif, negatif, atau netral. Hasil akhirnya divalidasi dan divisualisasikan agar dapat dimanfaatkan oleh PDAM dalam mengevaluasi dan meningkatkan kualitas layanan.

Dengan adanya sistem otomatis berbasis klasifikasi aspek dan analisis sentimen ini, PDAM diharapkan dapat memahami keluhan pelanggan dengan lebih cepat, akurat, dan menyeluruh sehingga pengambilan keputusan dapat dilakukan secara tepat dan berbasis data..

2.2 TEORI PENUNJANG

Berikut adalah beberapa teori penunjang yang berhubungan dengan penelitian ini:

2.2.1 *Aspect Based Sentiment Analysis (ABSA)*

Aspect-Based Sentiment Analysis (ABSA) adalah pendekatan analisis sentimen yang fokus pada aspek-aspek spesifik dalam teks. Setiap aspek diekstraksi dan dianalisis sentimennya secara terpisah, lalu digabungkan untuk menentukan sentimen keseluruhan dari teks [8]. ABSA dapat diterapkan di berbagai bidang seperti ulasan produk, media sosial, dan layanan publik. ABSA bekerja pada tiga tingkat analisis: dokumen, kalimat, dan entitas, dengan tujuan

mengidentifikasi polaritas sentimen (positif, negatif, netral) terhadap aspek-aspek spesifik. Pendekatan ini memungkinkan pemahaman yang lebih mendalam dan terfokus terhadap opini pengguna dalam teks.

2.2.2 Correlation Computing

Correlation computing adalah metode yang digunakan untuk mengukur sejauh mana dua entitas dalam teks, misalnya kata-kata atau frasa yang berkaitan satu sama lain. Dalam konteks analisis berbasis aspek, teknik ini berguna untuk menentukan seberapa erat hubungan antara komentar pengguna dan aspek layanan tertentu yang ingin dianalisis, seperti kualitas air atau layanan pelanggan.

Pada penelitian ini, metode *cosine similarity* digunakan untuk menghitung kedekatan atau hubungan antara kata dalam komentar dengan kata kunci tiap aspek. *Cosine similarity* sendiri merupakan salah satu bentuk perhitungan korelasi yang sederhana namun efektif, karena mampu mengidentifikasi seberapa kuat dua vektor (representasi kata) saling terkait secara numerik.

Algoritma korelasi teks yang menggabungkan ekstraksi event terstruktur dan representasi vektor terbukti mampu mengukur hubungan antar teks secara efektif melalui pemetaan vektor dan teknik klusterisasi. Pendekatan ini memberikan wawasan yang lebih mendalam dalam proses ekstraksi informasi dari data berbasis teks [1].

Dengan menerapkan korelasi komputasi berbasis *cosine similarity*, penelitian ini dapat secara otomatis memetakan komentar masyarakat ke aspek layanan PDAM yang relevan tanpa perlu melatih model pembelajaran mesin, menjadikannya pendekatan yang efisien dan ringan secara komputasi.

2.2.3 Cosine Similarity

Cosine similarity adalah algoritma yang digunakan untuk mengukur seberapa mirip dua buah teks dengan menghitung sudut antara dua vektor, misalnya vektor A dan B. Vektor ini bisa merepresentasikan kata, kalimat, paragraf, atau bahkan satu dokumen penuh. Semakin kecil sudut antara kedua vektor, maka nilai *cosine*-nya akan semakin mendekati 1, yang menandakan tingkat kemiripan yang tinggi. Ketika algoritma ini diterapkan pada data teks, *cosine similarity* dapat membantu menilai seberapa mirip isi dari dua dokumen atau kalimat secara matematis [2].

$$\cos \theta = \frac{A \cdot B}{||A|| ||B||} \quad (2.1)$$

Keterangan:

- $\cos \theta$: Kesamaan antara dua vektor A dan B. Nilainya berada di antara -1 hingga 1, tetapi konteks teks biasanya berkisar antara 0 (tidak mirip) hingga 1 (sangat mirip).
- $A \cdot B$: *Dot product* antara vektor A dan vektor B. Ini menunjukkan jumlah perkalian antara komponen-komponen yang bersesuaian dari kedua vektor
- $||A||$: Panjang atau *magnitude* dari vektor A, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor A.
- $||B||$: Panjang atau *magnitude* dari vektor B, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor B.

2.2.4 Rule Based

Pendekatan *rule based* dalam analisis sentimen merupakan metode yang mengandalkan serangkaian aturan atau pola linguistik yang telah ditentukan sebelumnya untuk mengklasifikasikan emosi dalam sebuah teks. Sistem ini bekerja dengan mencocokkan kata-kata dalam komentar atau dokumen dengan *rule* yang telah dibuat, seperti kata positif (baik, bagus) atau negatif (buruk, mengecewakan), kemudian menghitung skor untuk menentukan apakah sentimen teks tersebut positif, negatif, atau netral.

2.2.5 Web Scraping

Web scraping merupakan salah satu metode pengumpulan data yang digunakan untuk mengekstraksi informasi dari halaman web yang dibangun menggunakan bahasa markup seperti HTML atau XHTML. Meskipun halaman web umumnya dirancang untuk dibaca oleh manusia, teknik *web scraping* memungkinkan sistem atau perangkat lunak otomatis untuk menelusuri, menyalin, dan menyimpan informasi secara sistematis dari situs web tersebut [3]. Teknik ini sangat berguna dalam pengumpulan data tekstual berskala besar seperti komentar pengguna, ulasan produk, atau opini publik di media sosial.

Dalam konteks teknis, proses *scraping* bekerja dengan cara mengakses alamat URL tertentu, mengambil struktur halaman yang dimuat, dan mengekstrak bagian tertentu dari dokumen seperti teks dalam elemen HTML tertentu yang sesuai dengan tujuan analisis. Proses ini dapat dilakukan menggunakan berbagai bahasa pemrograman, seperti Python, dengan menggunakan *library* seperti BeautifulSoup, Selenium, atau Instaloader untuk platform *social media* seperti Instagram.

Perbedaan antara *web scraping* dan *web crawling* juga penting untuk dipahami. *Web scraping* bersifat spesifik dan diarahkan untuk mengambil informasi dari halaman web, sedangkan *crawling* dirancang untuk menjelajah banyak halaman melalui tautan dan mengambil informasi umum dari berbagai sumber secara luas [3]. Untuk keperluan penelitian ini, pendekatan *scraping* lebih sesuai karena fokus data berada pada komentar pengguna dalam akun Instagram PDAM Surya Sembada, yang perlu dikumpulkan secara spesifik berdasarkan waktu dan konten.

Dengan memanfaatkan teknik *scraping*, penelitian ini dapat memperoleh data komentar pelanggan secara efisien dan masif, yang kemudian menjadi dasar penting dalam melakukan analisis aspek dan sentimen.

2.2.6 Text Preprocessing

Text preprocessing adalah langkah awal yang dilakukan untuk merapikan data teks mentah yang masih berantakan menjadi format yang lebih rapi dan konsisten. Tujuan utamanya adalah agar data tersebut bisa dipahami dan diproses dengan baik. Proses ini biasanya dibantu oleh berbagai *library* pemrosesan teks yang tersedia di Python dan proses-proses tersebut adalah:

1. Drop Duplicate

Dalam pengolahan data teks, khususnya data hasil *scraping* dari media sosial, sering ditemukan komentar yang sama muncul lebih dari satu kali. Keberadaan data ganda dapat mengganggu proses analisis karena memberi bobot yang tidak semestinya pada informasi tertentu.

Langkah *drop duplicate* bertujuan untuk menghapus komentar yang identik agar data yang dianalisis benar-benar mewakili opini yang beragam dari pengguna. Dengan hanya mempertahankan data unik, hasil analisis menjadi lebih akurat dan tidak bias terhadap komentar yang berulang.

2. *Cleansing Data*

Tahap *cleansing* data dilakukan untuk membersihkan data dari karakter-karakter yang tidak relevan terhadap proses klasifikasi. Data dari media sosial seperti Instagram sering kali mengandung banyak *noise*, seperti singkatan, angka yang menggantikan huruf, mention (@), hashtag (#), tautan HTML (seperti <http://...>).

3. *Case Folding*

Tahapan *case folding* dilakukan dengan mengubah semua huruf dalam data menjadi huruf kecil. Ini penting karena dalam analisis sentimen, perbedaan huruf besar dan kecil tidak mempengaruhi makna kata. Misalnya, kata “Hitung” dan “hitung” akan diperlakukan sama, sehingga hasil analisis menjadi lebih konsisten dan tidak membedakan kata hanya berdasarkan format penulisannya.

4. *Tokenizing*

Tokenizing adalah salah satu tahap penting dalam proses analisis teks. Secara sederhana, *tokenizing* berarti memecah kalimat atau paragraf menjadi bagian-bagian kecil yang disebut token yang berupa kata atau frasa. Tahap ini penting karena memungkinkan sistem untuk memahami dan mengolah teks dalam bentuk yang lebih terstruktur.

Dalam konteks analisis sentimen, *tokenizing* membantu sistem mengenali kata-kata penting yang mengandung emosi atau opini. Misalnya, dalam sebuah komentar pengguna seperti "pelayanannya sangat buruk", proses *tokenizing* akan memecah kalimat tersebut menjadi ["pelayanannya", "sangat", "buruk"], sehingga sistem bisa mengidentifikasi kata “buruk” sebagai indikator sentimen negatif.

Beberapa penelitian menunjukkan bahwa pendekatan *tokenizing* bisa mempengaruhi hasil analisis secara signifikan. Erkan dan Güngör, dalam studi mereka, membandingkan berbagai metode tokenisasi dan menemukan bahwa metode sub-kata seperti WordPiece atau SentencePiece cenderung menghasilkan performa yang lebih baik dalam klasifikasi sentimen, karena mampu menangani variasi kata yang lebih kompleks [4]. Ini sangat berguna terutama ketika teks mengandung kata tidak baku, singkatan, atau bahasa media sosial yang tidak standar.

5. *Normalization*

Normalization atau formalisasi teks adalah proses mengubah teks alami yang tidak terstruktur menjadi bentuk yang lebih terstruktur dan dapat diproses secara otomatis oleh komputer. Dalam konteks analisis bahasa alami, formalisasi ini penting karena memungkinkan sistem untuk mengenali makna, pola, dan struktur dari teks yang kompleks.

Secara sederhana, ketika seseorang menulis komentar menggunakan bahasa yang tidak baku dan tidak sesuai dengan struktur KBBI (Kamus Besar Bahasa Indonesia), sistem cenderung tidak bisa langsung memahami maksudnya jika teks tersebut dibiarkan dalam bentuk mentah. Proses ini mempermudah sistem dalam menilai, mengelompokkan, dan mengambil keputusan berbasis data.

Transformasi teks dari bentuk naratif ke format numerik seperti vektor diperlukan agar teks tersebut dapat digunakan dalam algoritma pembelajaran mesin maupun sistem berbasis aturan, mengingat komputer bekerja berdasarkan representasi simbolik atau angka, bukan bahasa alami manusia [5]. Hal ini karena komputer tidak memahami bahasa manusia secara langsung mereka membutuhkan representasi angka atau simbol yang bisa dihitung dan dianalisis.

Tabel 2. 1. Daftar Kata Pada Kamus Lokal

Informal	Formal	Informal	Formal
takon	tanya	banget	sangat
rek	teman	buk	ibu
lyn	angkutan umum	buesar	besar
niku	itu	dadi	jadi
warnae	warnanya	gag, ga, g, gk	tidak
iki	ini	monggo	silahkan

6. *Stopword Removal*

Stop-words adalah kata-kata yang sering digunakan dalam bahasa sehari-hari, namun tidak memiliki makna yang penting dalam analisis teks. Pada tahap ini, kata-kata seperti “yang”, “di”, “ke”, dan sejenisnya dihapus dari teks. Tujuannya adalah untuk menyederhanakan isi teks dan lebih menyoroti kata-kata yang benar-benar membawa informasi penting bagi analisis [6].

7. *Stemming*

Stemming adalah proses untuk mengubah kata yang memiliki imbuhan menjadi bentuk dasarnya. Tujuan utamanya adalah mengurangi jumlah variasi kata yang muncul tanpa mengubah makna dari kata tersebut [6]. Misalnya, kata "membantu" akan dikembalikan ke bentuk dasar "bantu". Namun, tidak semua kata perlu diubah, contohnya kata "unduh" dalam kalimat "unduh kartu vaksin", karena kata tersebut sudah merupakan bentuk dasar.

2.2.7 *Data Split*

Data split adalah proses membagi *dataset* menjadi beberapa bagian sesuai kebutuhan penelitian, umumnya menjadi *data training* dan *data testing*. *Data training* digunakan untuk membentuk pola atau aturan pada sistem, sedangkan data testing digunakan untuk menguji kinerja sistem terhadap data yang tidak dipakai pada saat pembentukan model [7]. Dengan adanya pemisahan ini, hasil pengujian dapat memberikan gambaran yang lebih objektif terhadap kemampuan sistem dalam menangani data baru.

Pada penelitian berbasis teks, pembagian data juga penting untuk menjaga proses eksperimen tetap terarah dan terukur. Beberapa penelitian menunjukkan bahwa komposisi pembagian data dapat dibuat dalam beberapa rasio, seperti 50:50, 70:30, 80:20, atau 90:10, sesuai dengan kebutuhan eksperimen dan karakteristik data yang digunakan [8]. Oleh karena itu, data split menjadi salah satu dasar penting dalam penyusunan alur eksperimen, karena berpengaruh terhadap proses pelatihan, pengujian, dan evaluasi hasil sistem.

2.2.8. Segmentasi Teks

Segmentasi teks adalah proses membagi teks menjadi bagian-bagian yang lebih kecil, seperti kalimat, klausa, atau segmen makna, agar isi teks lebih mudah dianalisis. Dalam pengolahan bahasa alami, segmentasi teks membantu sistem memahami struktur informasi di dalam suatu kalimat, terutama ketika satu teks memuat lebih dari satu topik atau lebih dari satu opini [9].

Pada penelitian aspect-based sentiment analysis, segmentasi teks menjadi penting karena opini pengguna sering kali tidak disampaikan secara tunggal, melainkan terdiri dari beberapa bagian yang membahas aspek berbeda dalam satu komentar. Dengan memecah teks ke dalam segmen yang lebih fokus, hubungan antara aspek dan opini dapat dikenali dengan lebih jelas, sehingga proses analisis menjadi lebih terarah [10], [11].

Dalam konteks penelitian ini, segmentasi teks digunakan untuk membagi komentar pelanggan yang telah melalui tahap normalisasi menjadi beberapa bagian berdasarkan kata hubung atau konjungsi. Tahap ini dilakukan agar komentar yang mengandung lebih dari satu keluhan, misalnya mengenai air tidak mengalir dan tagihan, dapat dipisahkan terlebih dahulu sebelum masuk ke proses tokenisasi, stemming, dan klasifikasi multi aspek. Dengan demikian, segmentasi teks menjadi landasan penting untuk membantu sistem mengenali konteks keluhan secara lebih spesifik dan terstruktur.

2.2.9 TF-IDF

Setelah data melalui tahap *preprocessing*, langkah selanjutnya adalah proses perhitungan TF-IDF. Tahap ini sangat penting karena berfungsi untuk mengubah teks menjadi representasi numerik yang bisa dipahami oleh algoritma klasifikasi. TF-IDF bekerja dengan memberikan bobot pada setiap kata berdasarkan seberapa sering kata tersebut muncul dalam satu dokumen dibandingkan dengan seluruh dokumen dalam dataset, pembobotan ini membantu sistem mengenali kata-kata yang benar-benar penting dalam membedakan satu dokumen dengan yang lain [12].

$$TF \times IDF(d, t) = TF(d, t) \times \log \frac{N}{df(t)} \quad (2.2)$$

Keterangan:

TF : Merupakan nilai dari term frequency

IDF(d,t) : Merupakan nilai dari inverse document frequency

(d,t): Merupakan banyaknya term t pada dokumen d

N : Jumlah dari semua kumpulan dokumen

df(t): Merupakan jumlah dokumen yang memiliki term t

2.2.10 Validasi

Tahapan ini bertujuan untuk mengevaluasi seberapa baik metode klasifikasi yang digunakan dalam sistem. Salah satu cara umum untuk mengukurnya adalah dengan menghitung nilai akurasi, yaitu membandingkan jumlah prediksi yang benar dengan jumlah data keseluruhan.

Semakin tinggi nilai akurasi yang diperoleh, berarti metode tersebut semakin sesuai dengan karakteristik data yang digunakan, sehingga hasil prediksinya pun lebih mendekati kondisi sebenarnya. Sebaliknya, jika nilai akurasinya rendah, maka metode yang digunakan

kemungkinan kurang cocok dengan data, dan hasil prediksinya pun cenderung tidak menggambarkan kenyataan.

$$Accuracy = \frac{\sum pb}{num_{data}} \quad (2.3)$$

Keterangan:

pb : Hasil klasifikasi (prediksi) yang sesuai dengan kelas sebenarnya

num_data : Jumlah data keseluruhan

Meskipun akurasi sering digunakan untuk menilai kinerja sistem klasifikasi, nilai ini saja terkadang belum cukup untuk mengetahui penyebab rendahnya performa model. Hanya melihat akurasi tidak bisa langsung menunjukkan letak kesalahan atau penyimpangan data yang terjadi. Oleh karena itu, dalam penelitian ini juga digunakan dua metrik tambahan, yaitu *recall* dan *precision*, untuk mendapatkan gambaran yang lebih detail tentang kinerja klasifikasi terhadap masing-masing kelas.

Recall mengukur seberapa banyak data yang benar-benar relevan berhasil ditemukan oleh sistem dari seluruh data yang seharusnya termasuk dalam suatu kelas. Sederhananya, *recall* menunjukkan seberapa baik sistem dalam menemukan data yang tepat. Sementara itu, *precision* mengukur seberapa akurat hasil prediksi sistem, yaitu seberapa besar dari semua data yang diprediksi masuk ke suatu kelas ternyata benar-benar relevan. Dengan kata lain, *precision* menunjukkan seberapa tepat sistem dalam memilih data yang benar.

$$recall = \frac{\sum pb}{\sum total_{kelas}} \quad (2.4)$$

$$precision = \frac{\sum pb}{\sum total_{pisah}} \quad (2.5)$$

Keterangan:

$total_kelas$: Jumlah keseluruhan data pada kelas tertentu

$total_pisah$: Jumlah data yang dipisahkan *classifier* sebagai anggota kelas tertentu

Untuk menghitung nilai *recall* dan *precision*, kita bisa menggunakan bantuan *confusion matrix*, seperti yang ditampilkan pada Tabel 2.2. Dalam *confusion matrix*, terdapat empat istilah penting yang perlu dipahami:

1. **True Positive (TP)**: Data diprediksi benar dan memang benar.
2. **True Negative (TN)**: Data diprediksi salah dan memang salah.
3. **False Positive (FP)**: Data diprediksi benar, tapi sebenarnya salah.
4. **False Negative (FN)**: Data diprediksi salah, padahal sebenarnya benar.

Nilai *recall* dihitung dengan membandingkan jumlah TP dengan total TP dan FN. Artinya, *recall* menunjukkan seberapa banyak data benar yang berhasil ditemukan oleh sistem dari semua data yang seharusnya benar.

Sedangkan *precision* dihitung dengan membandingkan jumlah TP dengan total TP dan FP. Ini menunjukkan seberapa akurat prediksi sistem dalam menentukan data yang benar dari semua yang diprediksi sebagai benar.

Tabel 2. 2. *Confusion Matrix*

		<i>Kelas Prediksi</i>	
		<i>TRUE</i>	<i>FALSE</i>
<i>Kelas Sebenarnya</i>	<i>TRUE</i>	TP (<i>True Positive</i>)	FP (<i>False Positive</i>)
	<i>FALSE</i>	FN (<i>False Negative</i>)	TN (<i>True Negative</i>)

$$recall = \frac{TP}{TP + FN} \quad (2.6)$$

$$precision = \frac{TP}{TP + FP} \quad (2.7)$$

Keterangan:

TP (True Positive) :Jumlah data dari kelas yang diprediksi benar dan hasilnya benar

FN (False Negative): Jumlah data dari kelas yang diprediksi salah atau hasilnya benar

FP (False Positive): Jumlah data dari kelas yang diprediksi salah dan hasilnya salah

2.3 PENELITIAN TERKAIT

Penelitian mengenai *aspect-based sentiment analysis* terus berkembang dan sebenarnya cukup banyak dipublikasi. Berbagai pendekatan telah digunakan untuk menyelesaikan permasalahan serupa, mulai dari metode *machine learning* dan *deep learning* hingga menggunakan pendekatan *rule-based*. Meskipun permasalahan yang dihadapi relatif sama yaitu mengidentifikasi aspek dan menentukan sentimen dalam komentar pengguna, namun masing-masing penelitian memiliki pendekatan yang berbeda-beda. Bagian ini membahas beberapa penelitian terkait yang menjadi landasan dalam merancang sistem *aspect based sentiment analysis* berbasis *correlation computing*. Berikut adalah detail mengenai penelitian-penelitian yang telah dilakukan sebelumnya:

2.3.1 *Analysis Sentiment to Religious Based Issues Netizen Comments on President Jokowi's Instagram Using the Naive Bayes Classifier Method*

Ramadhani dan Widyaningrum (2024) melakukan analisis sentimen terhadap komentar publik di Instagram Presiden Joko Widodo yang berkaitan dengan isu keagamaan, seperti ucapan Selamat Natal dan kunjungan ke gereja. Penelitian ini bertujuan untuk mengukur opini publik terhadap isu sensitif berbasis agama di Indonesia, menggunakan algoritma *Naïve Bayes* untuk mengklasifikasikan sentimen menjadi positif dan negatif. Dataset berjumlah 2.600

komentar, yang 1.309 di antaranya dilabeli secara manual oleh ahli komunikasi dan linguistik sebagai data latih.

Tahapan *preprocessing* melibatkan pembersihan data dan normalisasi sebelum dilakukan pelatihan model. Hasil pelatihan model dengan data latih menunjukkan tingkat akurasi sebesar 97,63%, yang termasuk sangat tinggi untuk konteks analisis sentimen berbasis opini publik. Dari 1.291 data uji yang belum diklasifikasikan, ditemukan bahwa 70,56% komentar ber sentimen positif dan 29,44% negatif. Penelitian ini menunjukkan bahwa *Naïve Bayes* sangat efektif dalam mengklasifikasi opini publik terhadap konten pemerintah di media sosial, serta bisa diadaptasi untuk analisis sentimen pada sektor pelayanan publik lainnya seperti PDAM [13].

2.3.2 Sentiment Analysis of Student Satisfaction on Telkom University Language Center (LaC) Service on Instagram Using the RNN Method

Pada jurnal ini melakukan penelitian terhadap komentar mahasiswa di akun Instagram *Language Center* (LaC) Telkom University untuk mengetahui tingkat kepuasan terhadap layanan tersebut. Penelitian ini bertujuan untuk mengklasifikasikan sentimen mahasiswa menjadi positif, negatif, dan netral dengan memanfaatkan metode *Recurrent Neural Network* (RNN), yang dikenal efektif dalam memahami konteks sekuensial dari teks. Dataset diperoleh langsung dari komentar di unggahan akun resmi LaC.

Dalam tahap *preprocessing*, dilakukan pembersihan data melalui *case folding*, *tokenization*, dan *stopwords removal*. Setelah itu, data diklasifikasikan menggunakan arsitektur RNN dan dievaluasi menggunakan *confusion matrix*. Hasil yang diperoleh menunjukkan akurasi sebesar 79%, membuktikan bahwa RNN mampu menangkap nuansa opini dalam komentar Instagram meskipun ditulis dalam bahasa informal atau tidak terstruktur. Studi ini memberikan bukti kuat bahwa pendekatan deep learning dapat diterapkan secara efektif untuk menilai kepuasan pelanggan berbasis media sosial [14].

2.3.3 Sentiment Analysis on Social Media Instagram of Depression Issues Using Naive Bayes Method

Penelitian ini melakukan analisis sentimen terhadap komentar publik terkait isu depresi di media sosial Instagram. Penelitian ini bertujuan untuk memahami opini masyarakat terhadap isu kesehatan mental menggunakan metode *Naïve Bayes* (NB). Dataset terdiri dari 1.300 komentar yang dikumpulkan melalui web crawling dengan kata kunci terkait depresi dan kesehatan mental. Data ini kemudian diklasifikasikan secara manual menjadi positif, negatif, dan netral oleh para ahli sebelum dilakukan pelatihan model. Analisis dilakukan dengan mengembangkan aplikasi yang mampu menampilkan visualisasi hasil analisis dalam bentuk grafik batang dan *pie*.

Tahapan *preprocessing* mencakup pembersihan teks dari simbol-simbol tidak penting, normalisasi, dan penghapusan stopword. Setelah itu, data dianalisis menggunakan algoritma NB yang menghasilkan akurasi prediksi sebesar 82,55%. Penelitian ini menegaskan efektivitas NB dalam menangani data komentar publik pada isu sosial yang sensitif, terutama karena keakuratannya yang tinggi meskipun pada data berbahasa informal. Sistem ini juga berpotensi menjadi alat pendukung pengambilan keputusan dalam isu-isu kesehatan publik berbasis opini netizen [15].

2.3.4 Sentiment Analysis to Assess Customer Retention on Instagram Social Media Using Naive Bayes Classifier and Support Vector Machine

Pada jurnal ini meneliti komentar pelanggan terhadap akun Instagram bisnis lokal bernama Mr. Cream Puff untuk mengevaluasi potensi retensi pelanggan melalui analisis sentimen. Tujuan utama penelitian ini adalah memahami bagaimana opini pelanggan dapat mempengaruhi strategi Customer Relationship Management (CRM) dalam konteks media sosial. Dataset dikumpulkan dari komentar publik di Instagram dan dianalisis menggunakan dua algoritma pembelajaran mesin: *Naïve Bayes* dan *Support Vector Machine* (SVM).

Komentar yang dikumpulkan kemudian melalui proses *preprocessing* berupa normalisasi, penghapusan tanda baca, dan stopword removal. Hasil analisis menunjukkan bahwa SVM memiliki performa lebih tinggi dibandingkan Naïve Bayes, dengan akurasi 76,59% berbanding 74,81%. Temuan ini memperlihatkan bahwa pemanfaatan sentimen pelanggan dari Instagram tidak hanya relevan untuk perusahaan komersial, tetapi juga bisa diterapkan dalam pelayanan publik, seperti PDAM, untuk memahami persepsi pelanggan secara lebih terstruktur dan responsif [16].

2.3.5 Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data Using Machine Learning

Jurnal ini melakukan penelitian untuk mengidentifikasi aspek keluhan publik dan sentimen dari data pengaduan masyarakat Indonesia yang diperoleh dari situs ulas.surakarta.go.id. Penelitian ini berfokus pada penerapan *Aspect-Based Sentiment Analysis* (ABSA) menggunakan pendekatan machine learning untuk memetakan komentar ke dalam aspek layanan seperti pendidikan, bantuan sosial, dan ketenagakerjaan. Tujuannya adalah untuk membantu pemerintah dalam mempercepat pengambilan keputusan berbasis isu-isu yang paling banyak dikritik masyarakat.

Metode *preprocessing* yang digunakan dalam penelitian ini mencakup tokenisasi, penghapusan stopwords, dan konversi teks ke dalam bentuk numerik menggunakan teknik representasi fitur. Tiga algoritma yang diuji adalah *Support Vector Machine* (SVM), *Complement Naive Bayes*, dan *Decision Tree*. Dari ketiganya, SVM menunjukkan performa terbaik dengan akurasi sebesar 85,65%, lebih tinggi dibandingkan metode lainnya. Hasil ini menegaskan bahwa pendekatan machine learning dapat secara efektif memisahkan sentimen dan aspek dari komentar masyarakat [17].

Dari keseluruhan penelitian terkait, terdapat beberapa perbedaan dalam pengumpulan dataset, tahap preprocessing dan metode penelitian yang digunakan. Perbedaan ini dapat dilihat pada Tabel 2.3 di bawah ini.

Tabel 2. 3 Perbandingan Penelitian Terkait

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
1	<i>Analysis Sentiment to Religious Based Issues Netizen Comments on President</i>	Komentar Instagram	Cleansing, Tokenization, Case Folding, Filtering	Naive Bayes	97.63%

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
	<i>Jokowi's Instagram Using the Naive Bayes Classifier Method</i>				
2	<i>Sentiment Analysis of Student Satisfaction on Telkom University Language Center (LaC) Service on Instagram Using the RNN Method</i>	Komentar Instagram	<i>Case Folding, Data Cleaning, Stopwords Removal, Tokenization</i>	RNN	79%
3	<i>Sentiment Analysis on Social Media Instagram of Depression Issues Using NB Method</i>	Data dari komentar Instagram dengan hastag #MentalHealth dan #Depression	Data Cleaning, Case Folding, Tokenization, Stopword, Stemming	Lexicon Based, Naive Bayes	82.55%
4	<i>Sentiment Analysis to Assess Customer Retention on Instagram Social Media Using Naive Bayes Classifier and Support Vector Machine</i>	Komentar Instagram	Normalisasi, penghapusan tanda baca, dan stopword removal	SVM, Naive Bayes	76.59% (SVM), 74,81% (Naive Bayes)
5	<i>Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data</i>	Aspirasi publik dari website ulas.surakarta.go.id	tokenisasi, penghapusan stopwords, dan konversi teks ke dalam bentuk numerik	SVM, Naive Bayes, Decision Tree	85.65% (SVM), 81% (Naive Bayes), 82.77% (Decision Tree)

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
	<i>Using Machine Learning</i>				
6	<i>Aspect Based Sentiment Analysis Menggunakan Correlation Computing</i>	Komentar Instagram	<i>Drop duplicate, cleaning data, case folding, tokenizing, normalization, stopword removal, stemming</i>	<i>Cosine similarity, rule based</i>	Skenario 1: 69.46% Skenario 2: 71.07% Skenario 3: 68.76% Skenario 4: 67.71%

BAB 3 DESAIN SISTEM

3.1 DESKRIPSI SOLUSI


Solusi yang ditawarkan dalam penelitian ini adalah pengembangan sistem *aspect-based sentiment analysis* yang mampu mengelompokkan komentar masyarakat terhadap layanan PDAM Surya Sembada ke dalam aspek-aspek tertentu secara otomatis, kemudian menentukan sentimen dari setiap komentar tersebut. Sistem ini dirancang untuk membantu PDAM memahami keluhan dan opini publik secara lebih terstruktur, akurat, dan efisien tanpa memerlukan pelatihan model machine learning yang kompleks.

Fitur utama dari sistem ini adalah pemetaan aspek menggunakan metode *correlation computing* berbasis *cosine similarity*. Setiap komentar yang masuk akan direpresentasikan dalam bentuk vektor kata, kemudian dihitung tingkat kemiripannya dengan daftar kata kunci yang telah didefinisikan untuk setiap aspek layanan. Dengan menggunakan *cosine similarity*, sistem dapat mengenali keterkaitan antara isi komentar dan aspek tertentu secara matematis. Pendekatan ini dipilih karena memiliki keunggulan dalam kesederhanaan perhitungan dan tidak membutuhkan data latih, sehingga cocok untuk kasus dengan keterbatasan dataset.

Fitur kedua adalah analisis sentimen menggunakan *rule based*. Setelah komentar dikelompokkan ke dalam aspek yang sesuai, sistem akan memeriksa kata-kata dalam komentar tersebut dan mencocokkannya dengan aturan-aturan yang telah dibuat (positif, negatif, atau netral). Sistem kemudian menentukan sikap atau emosi yang terkandung dalam komentar terhadap aspek yang bersangkutan. Keuntungan pendekatan ini adalah transparansi dan kemudahan dalam penyesuaian daftar kata dan aturan dapat diperluas atau dimodifikasi sesuai kebutuhan tanpa mempengaruhi kinerja sistem secara keseluruhan.

Dengan dua fitur utama ini, sistem diharapkan mampu menghasilkan analisis yang tidak hanya mengenali topik yang dibahas oleh masyarakat, tetapi juga memahami bagaimana perasaan mereka terhadap aspek tersebut. Hal ini sangat penting dalam konteks pelayanan publik, karena membantu pihak PDAM dalam mengambil keputusan berbasis data, merespons keluhan secara tepat, dan meningkatkan kualitas layanan secara berkelanjutan.

3.2 DESAIN SISTEM



Gambar 3. 1. Desain Sistem

3.2.1 Scraping Instagram Comment

Data yang digunakan pada penelitian ini merupakan komentar aduan pelanggan dari sosial media Instagram milik PDAM Surya Sembada. Data komentar diambil menggunakan *library python* yaitu Instaloader. Seluruh data hasil *crawling* disimpan dalam format Excel CSV (*Comma Separated Value*).

3.2.2 Preprocessing

Tahap *preprocessing* data adalah langkah kritis dalam mempersiapkan data untuk analisis. Pada tahap *preprocessing*, data yang diperoleh diolah untuk menemukan informasi yang diperlukan dan membuang data yang tidak berguna untuk analisis. Data transformasi melibatkan beberapa tahap, yaitu: *drop duplicates*, *cleansing data*, *case folding*, *tokenizing*, *normalization*, *stopword removal*, dan *stemming*.

1. Drop Duplicates

Drop duplicate bertujuan untuk menghapus komentar yang identik agar data yang dianalisis benar-benar mewakili opini yang beragam dari pengguna. Dengan hanya mempertahankan data unik, hasil analisis menjadi lebih akurat dan tidak bias terhadap komentar yang berulang.

2. Cleansing Data

Cleansing dalam tahap *preprocessing* melibatkan langkah-langkah untuk membersihkan teks dari elemen-elemen yang tidak relevan atau mengganggu dalam analisis teks. Ini termasuk:

- Penghapusan karakter khusus: Menghapus karakter khusus seperti *mention* (@), *hashtag* (#), tautan HTML (<http://...>).
- Penghapusan karakter angka: Menghapus angka dari teks, kecuali jika angka tersebut penting.

Namun terdapat pengecualian pada simbol *dot* (.), *comma* (,), tanda seru (!), dan tanda tanya (?). Simbol ini tidak dihapus agar tidak menghilangkan konteks dari kalimat pada saat *sentiment analysis*.

3. Case Folding

Case folding adalah proses mengubah semua huruf menjadi huruf kecil atau huruf besar. Pada penelitian ini, *case folding* yang dilakukan yaitu mengubah seluruh dataset menjadi huruf kecil.

4. Stopword Removal

Stopword removal adalah proses menghapus kata-kata yang dianggap tidak penting dalam analisis, seperti kata sambung atau kata umum yang sering muncul. Tujuannya adalah menyaring kata-kata yang tidak memberikan banyak makna agar yang tersisa hanya kata-kata yang benar-benar relevan untuk pelatihan data. Contoh kata-kata yang biasanya dihapus antara lain ‘di’, ‘yang’, ‘dan’, ‘ke’, serta kata-kata lain yang ada dalam daftar stopwords yang telah disiapkan.

5. Normalization

Pada tahap ini kata-kata yang tidak sesuai dengan kaidah Bahasa Indonesia diubah menjadi kata-kata yang sesuai dengan kaidah Bahasa Indonesia.

6. Segmentasi Teks

Setelah proses *normalization* selesai, teks dibagi menjadi beberapa bagian berdasarkan kata hubung atau konjungsi yang muncul pada komentar. Tahap ini digunakan untuk memisahkan satu komentar yang membahas lebih dari satu keluhan agar setiap bagian kalimat dapat diproses secara lebih fokus.

Pada penelitian ini, konjungsi yang digunakan dalam proses segmentasi adalah sedang, sedangkan, lalu, tapi, karena, tetapi, padahal, akan, dan sehingga. Kata-kata tersebut dipilih karena sering muncul sebagai penghubung antarbagian kalimat pada komentar pelanggan, sehingga dapat membantu sistem mengenali batas perpindahan konteks di dalam satu komentar.

Sebagai contoh, kata tapi, tetapi, dan padahal biasanya menghubungkan dua keluhan atau dua kondisi yang berbeda. Kata karena dan sehingga umumnya menunjukkan hubungan sebab dan akibat. Kata lalu dan sedangkan sering menjadi penanda perpindahan informasi ke bagian kalimat berikutnya. Sementara itu, kata sedang dan akan tetap dimasukkan karena pada beberapa komentar kata tersebut muncul di tengah kalimat dan dapat menjadi penanda perubahan konteks pembahasan.

Hasil segmentasi disimpan ke dalam dua kolom, yaitu *sentence_1* dan *sentence_2*. Jika komentar mengandung salah satu konjungsi tersebut, maka teks sebelum konjungsi akan menjadi *sentence_1* dan bagian setelahnya menjadi *sentence_2*. Namun, jika komentar tidak memiliki konjungsi yang sesuai, maka seluruh teks tetap disimpan sebagai satu segmen utama.

Dengan adanya segmentasi teks, proses *tokenizing*, *stemming*, dan klasifikasi multi aspek dapat dilakukan pada tiap segmen secara terpisah. Langkah ini membantu sistem mengenali konteks keluhan dengan lebih jelas, terutama ketika satu komentar memuat lebih dari satu aspek layanan

7. Tokenizing

Setelah proses segmentasi teks selesai, langkah berikutnya adalah tokenisasi. Pada tahap ini, teks akan dipecah menjadi bagian-bagian kecil seperti kata atau token, sehingga lebih mudah untuk dianalisis atau diproses lebih lanjut.

8. Stemming

Di tahap akhir *preprocessing*, dilakukan proses stemming, yaitu mengubah setiap kata dalam teks menjadi bentuk dasarnya dengan cara menghapus imbuhan. Imbuhan yang dihilangkan bisa berupa awalan, akhiran, sisipan, atau kombinasi dari awalan dan akhiran. Dalam penelitian ini, proses *stemming* dilakukan menggunakan *library* Python bernama Sastrawi.

3.2.3 Data Split

Pada penelitian ini, proses data split dilakukan setelah tahap *preprocessing* selesai. Data dibagi menjadi dua bagian, yaitu *data train* dan *data test*. *Data train* dibentuk dari komentar

yang tidak mengalami segmentasi atau hanya memiliki satu segmen kalimat, yaitu data yang nilai *sentence_2*-nya kosong. Dengan cara ini, data train hanya berisi komentar yang mewakili satu konteks utama sehingga dapat digunakan sebagai acuan awal dalam proses pembelajaran pola aspek.

Sementara itu, *data test* menggunakan seluruh data yang tersedia, baik komentar yang hanya memiliki satu segmen maupun komentar yang terpecah menjadi dua segmen. Pendekatan ini dipilih karena tujuan utama penelitian adalah menguji kemampuan sistem dalam mengenali aspek pada seluruh komentar, termasuk komentar *multi-aspect*.


3.2.4 TF-IDF

TF-IDF (*Term Frequency–Inverse Document Frequency*) bekerja dengan memberikan bobot pada setiap kata berdasarkan seberapa sering kata tersebut muncul dalam satu dokumen dibandingkan dengan seluruh dokumen dalam dataset, pembobotan ini membantu sistem mengenali kata-kata yang benar-benar penting dalam membedakan satu dokumen dengan yang lain.

3.2.5 Aspect Based Menggunakan Cosine Similarity

Pada tahap ini dilakukan klasifikasi berdasarkan aspek. Metode yang digunakan dalam tahap ini adalah *cosine similarity*. Algoritma ini akan mengukur seberapa mirip dua buah teks dengan menghitung sudut antara dua vektor. Vektor ini bisa merepresentasikan kata, kalimat, paragraf, atau bahkan satu dokumen penuh. Semakin kecil sudut antara dua vektor, maka *cosine*-nya akan semakin mendekati 0, yang menandakan tingkat kemiripan yang tinggi. Ketika algoritma ini diterapkan pada data teks, *cosine similarity* dapat membantu menilai seberapa mirip isi dari dua dokumen atau kalimat secara matematis.

3.2.6 Sentiment Analysis Menggunakan Rule Based



Gambar 3. 2. Desain Sistem *Sentiment Analysis*

Sistem analisis sentimen yang akan dikembangkan dalam penelitian ini menggunakan pendekatan *rule-based*. Dalam metode ini, peneliti menetapkan sejumlah aturan untuk menganalisis kombinasi kata berdasarkan jenis katanya di dalam konten media sosial. Setiap kata dalam komentar akan diperiksa jenis katanya (*part-of-speech*) untuk melihat apakah ada rangkaian kata yang cocok dengan aturan yang telah dibuat. Jika ditemukan rangkaian yang sesuai, sistem akan menggabungkan dan menghitung nilai sentimennya berdasarkan aturan tersebut.

Setelah semua rangkaian kata yang cocok diproses, sistem kemudian akan menjumlahkan nilai sentimen dari seluruh kata yang ada dalam konten. Hasil akhir dari penjumlahan ini akan menentukan sentimen komentar tersebut. Jika nilainya lebih dari nol, maka sentimennya dianggap positif; jika nol berarti netral; dan jika kurang dari nol maka dikategorikan sebagai sentimen negatif. Berikut adalah aturan *part-of-speech* pada *sentiment analysis* pada penelitian ini:

1. Adjektif Tunggal

Jika dalam suatu kalimat terdapat kata sifat (adjektif) tanpa adanya kata kerja (verb) atau kata depan (preposisi), maka nilai sentimen kalimat tersebut akan mengikuti nilai dari kata sifat yang muncul. Misalnya pada kalimat:

“saya kecewa”

Kata “saya” tidak termasuk dalam aturan karena merupakan kata benda (nomina), sehingga tidak diperhitungkan. Yang akan dianalisis adalah kata “kecewa”, karena sesuai dengan aturan sebagai kata sifat. Kata “kecewa” memiliki nilai sentimen -1, sehingga nilai ini akan menjadi representasi dari sentimen keseluruhan kalimat.

2. Verb Tunggal

Jika sebuah kalimat mengandung kata kerja (verba) tanpa disertai kata sifat (adjektif) atau kata depan (preposisi), maka nilai sentimen kalimat tersebut akan mengikuti nilai dari kata kerja tersebut. Sebagai contoh, dalam kalimat

“pelayanan PDAM merugikan saya”

Kata “merugikan” adalah verba yang memiliki nilai sentimen -1. Sementara itu, kata “pelayanan” dan “PDAM” tidak tercantum dalam kamus sentimen, dan kata “saya” adalah nomina yang juga tidak termasuk dalam aturan. Oleh karena itu, sentimen kalimat ini ditentukan oleh kata “merugikan”, sehingga nilai sentimennya adalah -1 atau bersifat negatif.

3. Preposisi + Adjektif

Jika sebuah kalimat memiliki kata sifat (adjektif) yang muncul setelah kata depan (preposisi), maka nilai sentimen kalimat tersebut dihitung menggunakan aturan *AND operator*. Tabel 3.1 menunjukkan kombinasi nilai antara preposisi dan adjektif beserta hasil akhirnya.

Tabel 3. 1. *AND Operator*

Preporisisi	Adjektif	Nilai
1	1	1
1	-1	-1
-1	1	-1
-1	-1	1

Sebagai contoh, dalam kalimat “penanganan aduan saya kenapa sangat lama ya min?”, kata “sangat” merupakan preposisi dengan nilai sentimen 1, sedangkan kata “lama” adalah adjektif dengan nilai sentimen -1. Berdasarkan aturan dalam tabel AND operator, kombinasi preposisi bernilai 1 dan adjektif bernilai -1 akan menghasilkan nilai sentimen -1. Maka, kalimat tersebut dikategorikan sebagai sentimen negatif.

4. Preposisi + Verb

Jika dalam sebuah kalimat terdapat kata kerja (verba) yang muncul setelah kata depan (preposisi), maka nilai sentimen kalimat tersebut dihitung menggunakan aturan *AND operator*. Sebagai contoh

“air di rumah saya sudah mati 3 hari, kenapa PDAM tidak menangani dengan cepat”

Kata “tidak” berfungsi sebagai preposisi dengan nilai sentimen -1, sedangkan kata “menangani” merupakan verba dengan nilai sentimen 1 (berasal dari kata dasar “tangani”). Berdasarkan aturan pada tabel AND operator, kombinasi nilai -1 (preposisi) dan 1 (verba) menghasilkan nilai sentimen -1. Oleh karena itu, kalimat ini dikategorikan sebagai sentimen negatif.

5. Verb + Adjektif

Aturan *NAND operator* digunakan untuk menentukan nilai sentimen dari kalimat yang mengandung kata kerja (verb) yang diikuti oleh kata sifat (adjektif). Cara perhitungannya dijelaskan dalam Tabel 3.2, yang menunjukkan kombinasi nilai dari kedua jenis kata tersebut dan hasil akhirnya.

Tabel 3. 2. *NAND Operator*

Verb	Adjektif	Nilai
1	1	1
1	-1	-1
-1	1	-1
-1	-1	-1

Sebagai contoh, pada kalimat:

“saya rasa kinerja PDAM bagus dan tanggap”

kata “kinerja” merupakan verba dengan nilai sentimen 1, dan kata “bagus” adalah adjektif juga dengan nilai sentimen 1. Kombinasi ini sesuai dengan aturan dalam tabel *NAND operator*, sehingga menghasilkan nilai sentimen 1. Selain itu, ada kata “tanggap” yang juga merupakan adjektif dengan nilai sentimen 1, dan termasuk dalam aturan adjektif tunggal. Karena terdapat dua aturan yang terpenuhi dalam kalimat ini, nilainya dijumlahkan: 1 (dari kombinasi verb-adjektif) + 1 (dari adjektif tunggal) = 2. Karena hasilnya lebih dari nol, maka sentimen kalimat ini dikategorikan sebagai positif.

6. Preposisi + Verb + Adjektif

Dalam beberapa kasus, sebuah kalimat bisa mengandung preposisi, verba, dan adjektif secara bersamaan. Untuk menentukan nilai sentimen dari kalimat seperti ini, sistem akan melakukan dua tahap perhitungan. Pertama, nilai dari kata kerja (verba) dan kata sifat (adjektif) dihitung menggunakan *NAND operator*, seperti yang dijelaskan pada Tabel 3.2. Kedua, hasil dari perhitungan tersebut kemudian digabungkan dengan nilai preposisi menggunakan *AND operator*, sesuai dengan Tabel 3.1. Sebagai contoh, dalam kalimat

“PDAM tidak paham dengan baik, apa sebenarnya kebutuhan pelanggan”

Kata “tidak” merupakan preposisi dengan nilai sentimen -1, “paham” adalah verba dengan nilai 1, dan “baik” adalah adjektif dengan nilai 1. Karena ketiganya termasuk dalam aturan

kombinasi, maka langkah pertama adalah menghitung “paham” dan “baik” dengan *NAND operator*, yaitu $1 \text{ NAND } 1$ menghasilkan nilai 1. Selanjutnya, nilai dari preposisi “tidak” (-1) dihitung bersama hasil sebelumnya (1) dengan *AND operator*, yaitu $-1 \text{ AND } 1 = -1$. Maka, sentimen dari kalimat ini secara keseluruhan adalah negatif dengan nilai -1.

7. Semua simbol pada komentar dihapus kecuali *dot* (.), *comma* (,), tanda seru (!), dan tanda tanya (?)
8. *Dot and comma* parameter untuk memisahkan kalimat

Setiap komentar atau tanggapan dari pengguna biasanya terdiri dari beberapa kalimat yang dipisahkan oleh tanda baca seperti koma atau titik. Misalnya, pada kalimat

“pipa bocor, apakah tidak segera ditangani?”

Komentar ini akan dipisah menjadi dua kalimat terpisah. Kalimat pertama, “pipa bocor”, memiliki nilai sentimen -1. Kalimat kedua, setelah melalui proses pemrosesan menjadi “tidak segera ditangani”, juga memiliki nilai sentimen -1. Untuk menentukan sentimen dari seluruh komentar, nilai sentimen dari masing-masing kalimat dijumlahkan. Dalam contoh ini, -1 ditambah -1 menghasilkan -2, yang berarti komentar tersebut secara keseluruhan bersentimen negatif.

9. Frase Kata terdiri dari dua kata yang memiliki satu makna tidak dapat dipisah

Dalam penelitian ini, frasa didefinisikan sebagai gabungan dua kata yang membentuk satu makna utuh dan sering ditemukan dalam kalimat berbahasa Indonesia. Contohnya antara lain "terima kasih", "air mata", dan "minta tolong". Meskipun terdiri dari dua kata, frasa seperti ini dianggap satu kesatuan makna dan hanya diberi satu nilai sentimen.

10. Nilai sentiment “terima kasih” atau pujian bergantung pada posisi letak kata tersebut dalam kalimat.

Jika frasa “terima kasih” muncul di awal kalimat, maka frasa tersebut diberi nilai sentimen positif sebesar 1. Namun, jika letaknya berada di tengah atau di akhir kalimat, maka nilainya dianggap netral atau 0. Sebagai contoh, dalam kalimat “terima kasih sudah menangani dengan baik”, karena frasa “terima kasih” berada di awal, maka nilai sentimennya adalah 1.

11. Penggunaan kata tidak sesuai kamus Bahasa Indonesia akan diabaikan.

Dalam teks percakapan, sering kali ditemukan kata-kata yang ditulis dengan bahasa tidak formal, ejaan yang salah, atau bahkan menggunakan bahasa Inggris. Kata-kata seperti ini sebenarnya bisa diperbaiki saat proses *preprocessing* dalam text mining. Namun, jika setelah diperbaiki kata tersebut masih tidak cocok atau tidak ditemukan dalam kamus bahasa Indonesia, maka kata tersebut akan diabaikan dan tidak digunakan dalam analisis.

12. Konjungsi Tunggal

Metode *conjunction rule* memiliki sejumlah aturan khusus untuk menangani kalimat yang mengandung kata hubung (konjungsi), guna menentukan nilai sentimennya. Namun sebelum masuk ke aturan konjungsi, kalimat atau query akan terlebih dahulu diproses menggunakan beberapa aturan yang telah dijelaskan sebelumnya.

Konjungsi sendiri terbagi menjadi dua jenis, yaitu konjungsi koordinatif dan konjungsi subordinatif. Mengacu pada Kamus Besar Bahasa Indonesia (KBBI), konjungsi koordinatif adalah kata hubung yang menggabungkan dua kata atau klausa yang memiliki kedudukan setara. Sementara itu, konjungsi subordinatif berfungsi menghubungkan dua bagian kalimat yang tidak setara, di mana salah satunya bergantung pada yang lain.

Untuk aturan konjungsi, terdapat beberapa aturan didalamnya, seperti berikut:

1. Konjungsi Koordinatif Bertentangan

Sebuah kalimat pengaduan dapat tersusun dari beberapa klausa yang dipisahkan dengan (.), (,), (!) dan (?). Konjungsi koordinatif bertentangan digunakan untuk menghubungkan dua klausa yang memiliki makna bertentangan, seperti: tetapi, akan tetapi, namun, padahal dan sedangkan. Aturan yang digunakan untuk konjungsi koordinatif bertentangan sebagai berikut :

```
if (konjungsi = tetapi/tapi/akan tetapi AND konj_pos = tengah)
if(klausa 1 == -1 or klausa 2 == -1)
    sentiment = -1
Else if (klausa 1 == 1 and klausa 2 == 1)
    sentiment = 1
else 0
```

Struktur kalimat yang dimaksud dalam aturan ini adalah kalimat yang terdiri dari beberapa bagian atau klausa yang dipisahkan oleh koma. Klausa kedua adalah bagian yang mengandung kata hubung (konjungsi), sementara klausa pertama adalah bagian kalimat yang terletak sebelum klausa tersebut.

Sebagai contoh, dalam kalimat “Air di rumah tersebut tidak keluar sama sekali, tetapi tetangga kanan-kiri keluar air semua, mohon bantuannya”, terdapat tiga klausa. Klausa 1 adalah “Air di rumah tersebut tidak keluar sama sekali”, klausa 2 adalah “tetapi tetangga kanan-kiri keluar air semua”, dan klausa 3 adalah “mohon bantuannya”. Klausa pertama memiliki nilai sentimen -1 karena mengandung kombinasi preposisi dan verba (“tidak keluar”), sedangkan klausa kedua memiliki nilai +1 karena mengandung verba tunggal (“keluar”) dan terdapat kata hubung “tetapi”. Karena kalimat ini memenuhi aturan konjungsi subordinatif dengan makna pertentangan, dan salah satu klausa bernilai negatif, maka sentimen keseluruhan kalimat dianggap negatif dengan nilai -1.

2. Konjungsi Subordinatif yang menyatakan Hubungan Makna Harapan

Konjungsi subordinatif jenis ini terdiri dari empat kata, yaitu “agar”, “agar supaya”, “biar”, dan “supaya” [(14)]. Ada empat jenis struktur kalimat yang termasuk dalam aturan ini, yaitu kalimat permintaan, kalimat harapan, kalimat kondisi, dan kalimat yang mengandung verba. Kalimat permintaan ditandai dengan adanya kata-kata seperti “tolong” atau “mohon”. Kalimat harapan adalah kalimat yang mengandung salah satu dari kata konjungsi tadi. Sementara itu, kalimat kondisi merupakan bagian kalimat yang muncul sebelum kalimat harapan atau permintaan. Jika dalam kalimat tersebut terdapat kata kerja (verba), maka kalimat itu juga dikategorikan sebagai kalimat verba.

● Rule Pertama

```
if kalimat = [kalimat kondisi, supaya/agar/biar, kalimat harapan] or [kalimat kondisi,
    kalimat permintaan, supaya/agar/biar, kalimat harapan]
```

then *nilai sentiment* = *sent_kalimat kondisi*

Pada aturan pertama ini, kata hubung subordinatif seperti “supaya”, “agar”, atau “biar” muncul di tengah kalimat. Jika struktur kalimat sesuai dengan pola tersebut, maka nilai sentimen dari seluruh kalimat ditentukan oleh sentimen dari bagian kalimat kondisi.

Sebagai contoh pertama:

“sudah 10 hari airnya masih keruh, mohon secepatnya diperbaiki, supaya air kembali bersih.”

Kalimat ini terdiri dari tiga bagian, yaitu kalimat kondisi: “sudah 10 hari airnya masih keruh” yang bernilai -1 karena mengandung kata “keruh” (adjektif negatif), kalimat permintaan: “mohon secepatnya diperbaiki”, dan kalimat harapan: “supaya air kembali bersih” yang bernilai 1 karena mengandung kata “bersih” (adjektif positif). Karena kalimat ini sesuai dengan aturan pertama, maka nilai sentimen utamanya diambil dari kalimat kondisi, yaitu -1 (negatif).

Contoh kedua:

“Kalo beberapa hari ke depan tidak ada respon dari PDAM maka saya akan memasang pompa air supaya air bisa mengalir ke kamar mandi.”

Kalimat ini memiliki dua bagian, yaitu kalimat kondisi: “Kalo beberapa hari ke depan tidak ada respon dari PDAM maka saya akan memasang pompa air”, yang bernilai -1 karena mengandung frasa “tidak ada respon” (frasa negatif), dan kalimat harapan: “supaya air bisa mengalir ke kamar mandi”, yang bernilai 1 karena mengandung kombinasi verba dan adjektif (“bisa mengalir”). Karena struktur kalimat sesuai dengan aturan pertama, maka nilai sentimen diambil dari kalimat kondisi, yaitu -1 (negatif).

- Rule Kedua

```
if kalimat = [verba, supaya/agar/biar k.harapan] or [supaya/agar/biar k.harapan]
if (sent_k.harapan == -1) then sentiment = 1
if (sent_k.harapan == 1) then sentiment = -1
else sentiment = 0
```

Contoh pada aturan kedua ini menjelaskan struktur kalimat yang mengandung kata kerja (verba) dan diikuti oleh konjungsi harapan seperti “supaya”, “agar”, atau “biar”, yang kemudian disambung dengan kalimat harapan.

Sebagai ilustrasi:

“Air tidak bisa keluar sama sekali. Pakai pompa air pun tidak bisa keluar. Hanya untung-untungan saja. Apakah warga harus bangun pagi-pagi buta supaya bisa mendapatkan air?????????”

Mengandung verba “bangun” yang kemudian diikuti dengan frasa tujuan “supaya bisa mendapatkan air”. Kalimat harapan tersebut memiliki nilai sentimen -1 karena memenuhi aturan kombinasi verba dan adjektif (“bisa mendapatkan”). Sesuai dengan *rule* kedua untuk konjungsi subordinatif yang menunjukkan hubungan makna harapan, nilai sentimen dari kalimat ini diambil dari kalimat harapannya, sehingga keseluruhan kalimat dikategorikan sebagai negatif dengan nilai -1.

3. Konjungsi Subordinatif yang Menyatakan Hubungan Makna Syarat

Konjungsi jenis ini terdiri dari enam kata, yaitu: apabila, bila, bilamana, jika, jikalau, dan kalau. Struktur kalimat yang mengikuti aturan ini terbagi menjadi tiga jenis, yaitu kalimat syarat, kalimat kondisi, dan kalimat permintaan.

Kalimat syarat adalah bagian kalimat yang mengandung konjungsi subordinatif yang menyatakan suatu kondisi atau syarat. Kalimat kondisi bisa berada sebelum kalimat syarat, atau bisa juga muncul setelahnya dengan ditandai oleh kata “maka”. Sementara itu, kalimat permintaan adalah kalimat yang mengandung kata-kata seperti “tolong” atau “mohon”.

- Rule Pertama

if kalimat = [jika k.syarat, maka k.kondisi] or jika k.syarat]

Sentiment = sent_k.syarat

Contoh kalimat:

“jika keluhan kami tidak diperhatikan, maka jangan ada kotak keluhan”

Bagian “jika keluhan kami tidak diperhatikan” merupakan kalimat syarat dengan nilai sentimen -1 karena mengandung unsur verba negatif (sesuai dengan aturan verba tunggal untuk “keluhan”). Sedangkan bagian “maka jangan ada kotak keluhan” berfungsi sebagai kalimat kondisi. Karena kalimat ini mengikuti struktur aturan konjungsi syarat, maka nilai sentimen keseluruhan ditentukan berdasarkan nilai dari kalimat syarat, yaitu -1 atau negatif.

- Rule Kedua

If kalimat = [k.kondisi, jika k.syarat] or [k.kondisi, k.permintaan, jika k.syarat]

Sentiment = sent_k.kondisi

Contoh kalimat:

“Seminggu terakhir ini dirumah saya tidak ada air yang masuk. Jika air diputar yang keluar hanya angin, tetapi tagihan terus berjalan, mohon jawabannya????”

Susunan kalimat diatas memiliki kalimat kondisi “Seminggu terakhir ini dirumah saya tidak ada air masuk” bernilai -1 (memenuhi *rule* preposisi + verba [tidak + ada] -1, dan verba tunggal [air] 0) dan kalimat syarat “jika air diputar yang keluar hanya angin” dengan kalimat syarat memiliki nilai sentimen -1 sehingga nilai sentimen dari kalimat tersebut diambil dari kalimat syarat yakni -1 (negatif).


3.2.7 Validasi

Untuk mengetahui seberapa baik kinerja sistem atau metode klasifikasi yang digunakan, dilakukan pengukuran menggunakan tiga metrik utama, yaitu *accuracy*, *recall*, dan *precision*.

Nilai *accuracy* dihitung dengan membandingkan jumlah prediksi yang benar terhadap total seluruh data yang diuji. Semakin tinggi nilainya, maka semakin baik hasil klasifikasi yang dilakukan oleh sistem. Namun, hanya mengandalkan nilai akurasi saja tidak cukup untuk mendeteksi adanya kesalahan atau ketidaksesuaian data.

Oleh karena itu, *recall* dan *precision* juga dihitung. ***Recall*** mengukur seberapa banyak data yang benar-benar relevan berhasil ditemukan oleh sistem dari seluruh data relevan yang tersedia. Sedangkan *precision* mengukur ketepatan sistem dalam memprediksi, yaitu berapa banyak dari data yang diprediksi sebagai benar ternyata memang benar.

3.2.8 Visualisasi



Gambar 3.3. Monitoring Page

Gambar di atas adalah *mockup* untuk menampilkan *output* dari hasil proses analisis sentimen, pengklasifikasian berdasarkan aspek dari aduan pelanggan PDAM Surya Sembada. Gambar 3.3 merupakan halaman *Monitoring*, pada gambar tersebut menampilkan visualisasi data dari analisis sentimen dan pengklasifikasian aduan pelanggan.

3.3 Rancangan Skenario Uji Coba

3.3.1 Tujuan Uji Coba

Mencari skenario yang memiliki nilai akurasi tertinggi dan *similarity score* terendah

3.3.2 Skenario Uji Coba

Tabel 3.3. Skenario Uji Coba

Skenario	Nama Skenario	Deskripsi Singkat	Fitur
Skenario 1	Aspek “Lainnya” Tidak Diabaikan dan Menggunakan TF-IDF Untuk Pemilihan <i>Keyword</i> Pada Tiap Aspek	Pemilihan <i>keyword</i> aspek berdasarkan hasil perhitungan TF-IDF dan menggunakan aspek “Lainnya” untuk menampung komentar yang tidak cocok dengan 6 aspek lainnya	- Menggunakan aspek “Lainnya” - Menggunakan TF-IDF untuk pemilihan <i>keyword</i>

Skenario	Nama Skenario	Deskripsi Singkat	Fitur
Skenario 2	Aspek “Lainnya” Tidak Diabaikan dan Tidak Menggunakan TF-IDF Untuk Pemilihan <i>Keyword</i> Pada Tiap Aspek	Pemilihan <i>keyword</i> aspek berdasarkan interpretasi penulis dari hasil membaca seluruh isi dataset dan menggunakan aspek “Lainnya” untuk menampung komentar yang tidak cocok dengan 6 aspek lainnya	- Menggunakan aspek “Lainnya” - Tidak menggunakan TF-IDF untuk pemilihan <i>keyword</i>
Skenario 3	Aspek “Lainnya” Diabaikan dan Menggunakan TF-IDF Untuk Pemilihan <i>Keyword</i> Pada Tiap Aspek	Pemilihan <i>keyword</i> aspek berdasarkan hasil perhitungan TF-IDF dan mengecualikan data dengan <i>true aspect</i> “Lainnya” dari poses klasifikasi aspek	- Tidak menggunakan aspek “Lainnya” - Menggunakan TF-IDF untuk pemilihan <i>keyword</i>
Skenario 4	Aspek “Lainnya” Diabaikan dan Tidak Menggunakan TF-IDF Untuk Pemilihan <i>Keyword</i> Pada Tiap Aspek	Pemilihan <i>keyword</i> aspek berdasarkan interpretasi penulis dari hasil membaca seluruh isi dataset dan mengecualikan data dengan <i>true aspect</i> “Lainnya” dari poses klasifikasi aspek	- Tidak Menggunakan Aspek “Lainnya” - Tidak menggunakan TF-IDF untuk pemilihan <i>keyword</i>

BAB 4 EKSPERIMEN DAN ANALISIS

Bab ini membahas proses eksperimen dan analisis kinerja sistem yang dikembangkan untuk melakukan multi aspect based classification dan sentiment analysis pada komentar pelanggan PDAM Surya Sembada. Uraian pada bab ini mencakup parameter eksperimen, karakteristik data, serta hasil analisis dari setiap tahap, mulai dari text preprocessing, segmentasi teks, perhitungan TF-IDF, klasifikasi multi aspek dengan cosine similarity, hingga sentiment analysis menggunakan rule based. Eksperimen ini dilakukan untuk mengetahui kemampuan sistem dalam mengenali aspek layanan dan sentimen komentar pelanggan secara lebih tepat dan terstruktur.

4.1 PARAMETER EKSPERIMEN

Pada Bab ini, dilakukan identifikasi sejumlah parameter eksperimen untuk mengukur keberhasilan sistem yang telah dikembangkan. Pengujian tidak hanya berfokus pada klasifikasi aspek, tetapi juga mencakup seluruh alur proses mulai dari *text preprocessing*, perhitungan TF-IDF, *multi aspect based classification* menggunakan *cosine similarity*, hingga *sentiment analysis* menggunakan *rule based*.

Tahap awal yang diuji adalah *text preprocessing*. Pada tahap ini, data diproses melalui beberapa langkah, yaitu *drop duplicate*, *cleansing data*, *case folding*, *stopword removal*, *normalization*, segmentasi teks, *tokenizing*, dan *stemming*. Penambahan segmentasi teks dilakukan setelah *normalization* dan sebelum *tokenizing* agar komentar yang mengandung lebih dari satu keluhan dapat dipisahkan menjadi beberapa bagian kalimat yang lebih fokus untuk diproses pada tahap berikutnya. Pada proses ini, teks hanya dipecah menjadi dua segmen, yaitu *sentence_1* dan *sentence_2*, berdasarkan konjungsi sedang, sedangkan, lalu, tapi, karena, tetapi, padahal, akan, dan sehingga yang digunakan sebagai pemisah segmen.

Setelah *preprocessing* selesai, dilakukan pengujian perhitungan TF-IDF untuk mengubah teks ke dalam representasi numerik. Sistem dinyatakan berhasil pada tahap ini apabila teks hasil *preprocessing* dapat ditransformasikan menjadi vektor yang dapat digunakan pada proses perhitungan *similarity*.

Tahap berikutnya adalah *multi aspect based classification* menggunakan *cosine similarity*. Pada tahap ini, setiap segmen teks dibandingkan dengan data latih untuk menentukan aspek yang paling relevan. Keberhasilan sistem pada tahap ini dievaluasi berdasarkan kemampuannya memprediksi aspek komentar secara tepat, baik untuk komentar yang hanya memiliki satu aspek maupun komentar yang memuat lebih dari satu aspek. Namun, pada penelitian ini hasil segmentasi dibatasi hanya sampai dua bagian kalimat, sehingga sistem hanya dapat menangani maksimal dua aspek dalam satu komentar dan belum dapat memproses komentar yang mengandung lebih dari dua aspek.

Tahap akhir berfokus pada *sentiment analysis* menggunakan *rule based*. Setelah aspek komentar diperoleh, sistem menganalisis sentimen komentar ke dalam kategori positif, netral, atau negatif berdasarkan aturan dan kamus *part of speech (POS)/polarity* yang digunakan. Keberhasilan eksperimen pada tahap ini diukur dari kemampuan sistem dalam memberikan aspek yang sesuai dengan *true aspect* dan kemampuan sistem dalam memberikan label sentimen yang sesuai dengan *true sentiment* pada data yang telah diberi anotasi.

4.2 KARATERISTIK DATA

Data yang digunakan dalam penelitian ini berupa komentar aduan pelanggan dari akun Instagram resmi PDAM Surya Sembada yang diambil menggunakan *library* Python Instaloader dan disimpan dalam format CSV. Proses scraping data penulis lakukan sejak bulan Juli 2025 hingga bulan Agustus 2025. Jumlah data yang diperoleh pada tahap awal sebanyak 1851 data. Setelah dilakukan penghapusan data duplikat serta penghapusan data kosong yang hanya berisi *emoticon*, jumlah data yang digunakan dalam penelitian ini berkurang menjadi 1670 data. Data bersifat teks tidak terstruktur dengan variasi panjang kalimat, ditulis menggunakan bahasa Indonesia informal yang sering mengandung emotikon, singkatan, serta kesalahan ejaan. Pemilihan data ini didasarkan pada pertimbangan bahwa komentar media sosial mencerminkan opini spontan dan jujur pelanggan, sehingga relevan untuk digunakan dalam analisis *Aspect-Based Sentiment Analysis* (ABSA) guna mengidentifikasi sentimen publik terhadap aspek layanan PDAM Surya Sembada.

4.3 TEMPAT UJICOBA

Pengujian dilakukan di rumah dan di Laboratorium Knowledge Engineering PENS menggunakan Visual Studio Code.

4.4 WAKTU UJICOBA

Uji coba dilaksanakan mulai dari awal bulan Desember 2025 hingga awal bulan April 2026.

4.5 SPESIFIKASI PERALATAN UJICOBA

Pada proses pembuatan dilakukan pada laptop pribadi. Spesifikasi laptop serta *software* yang digunakan ditunjukkan pada tabel berikut:

Tabel 4. 1. Informasi *Hardware*

Deskripsi	Spesifikasi
Model Laptop	ASUS TUF Gaming F15 FX506HC FX506HC
<i>Processor</i>	11th Gen Intel(R) Core(TM) i5-11400H @ 2.70GHz (12 CPUs), ~2.7GHz
RAM	16 GB
SSD	512 GB
<i>Graphics</i>	NVIDIA GeForce RTX 2050 Laptop GPU
<i>Operating System</i>	Microsoft Windows 11 Home

Tabel 4. 2. Informasi *Software*

Deskripsi	Spesifikasi
Python <i>Version</i>	3.11.2
<i>Library</i>	pandas, numpy, NLTK, Sastrawi, Sklearn,
<i>Code Editor</i>	Visual Studio Code

4.6 HASIL EKSPERIMEN

4.6.1 Text Preprocessing

Pada tahap *preprocessing* dataset, langkah utama yang diterapkan untuk memastikan kualitas dan konsistensi data sebelum digunakan. Pada tahap ini meliputi 8 proses sistematis yang dirancang untuk mengoptimalkan data yang akan digunakan. Berikut adalah tahapan dari *preprocessing* yang dilakukan:

Tabel 4. 3. Input dan Output *Text Preprocessing*

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
Case Folding	Pemasangan baru tidak ada kelanjutan setelah survey. Padahal katanya bisa komplain CS lewat WA. Sedangkan di WA gak ada tanggapan		pemasangan baru tidak ada kelanjutan setelah survey. padahal katanya bisa komplain cs lewat wa. sedangkan di wa gak ada tanggapan	
	Min kalau puteran PDAM dol itu sya ngadu kesiapa ya		min kalau puteran pdam dol itu sya ngadu kesiapa ya	
Normalization	pemasangan baru tidak ada kelanjutan setelah survey. padahal katanya bisa komplain cs lewat wa. sedangkan di wa gak ada tanggapan		pemasangan baru tidak ada kelanjutan survey. padahal katanya bisa komplain pelayanan pelanggan lewat whatsapp. sedangkan di whatsapp tidak ada tanggapan	
	min kalau puteran pdam dol itu sya ngadu kesiapa ya		admin kalau keran pdam rusak itu saya mengadu ke siapa ya	
Stop Word Removal	pemasangan baru tidak ada kelanjutan survey. padahal katanya bisa komplain pelayanan pelanggan lewat whatsapp. sedangkan di		pemasangan tidak ada kelanjutan survey. padahal katanya komplain pelayanan pelanggan whatsapp.	

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
	whatsapp tidak ada tanggapan.		sedangkan whatsapp tidak ada tanggapan.	
	admin kalau keran pdam rusak itu saya mengadu ke siapa ya		admin keran pdam rusak mengadu ke siapa	
Segmentasi Teks	pemasangan tidak ada kelanjutan survey. padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.		pemasangan tidak ada kelanjutan survey.	padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.
	admin keran pdam rusak mengadu ke siapa		admin keran pdam rusak mengadu ke siapa	
Tokenizing	pemasangan tidak ada kelanjutan survey.	padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.	['pemasangan', 'tidak', 'ada', 'kelanjutan', 'survey', '!.']	['padahal', 'katanya', 'komplain', 'pelayanan', 'pelanggan', 'whatsapp', '!', 'sedangkan', 'whatsapp', 'tidak', 'ada', 'tanggapan', '!.']
	admin keran pdam rusak mengadu ke siapa		['admin', 'keran', 'pdam', 'rusak', 'mengadu', 'ke', 'siapa']	[]
Stemming	['pemasangan', 'tidak', 'ada', 'kelanjutan', 'survey', '!.']	['padahal', 'katanya', 'komplain', 'pelayanan', 'pelanggan', 'whatsapp', '!', 'sedangkan', 'whatsapp', 'tidak', 'ada', 'tanggapan', '!.']	['pasang', 'tidak', 'ada', 'lanjut', 'survey', '!.']	['padahal', 'kata', 'komplain', 'layan', 'langgan', 'whatsapp', '!', 'sedang', 'whatsapp', 'tidak', 'ada', 'ada',

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
				'tanggap', '.'
	['admin', 'keran', 'pdam', 'rusak', 'mengadu', 'ke', 'siapa']	[]	['admin', 'keran', 'pdam', 'rusak', 'adu', 'ke', 'siapa']	[]

1. Drop Duplicates

Pada tahap ini penulis menghapus data yang terduplikasi. Dari data yang dimiliki oleh penulis, terdapat 2 data duplikat yang telah dihapus.

2. Cleansing Data

Setelah dilakukan *drop duplicate*, data dibersihkan dari emoji, karakter khusus (contoh: *mention* (@), *hashtag* (#)), menghapus angka. Namun terdapat pengecualian pada simbol *dot* (.), *comma* (,), tanda seru (!), dan tanda tanya (?). Simbol ini tidak dihapus agar tidak menghilangkan konteks dari kalimat pada saat *sentiment analysis*.

3. Case Folding

Berdasarkan Tabel 4.3, dapat diketahui bahwa proses pengubahan semua karakter alfabet menjadi huruf kecil (*case-folding*) dapat memberikan keluaran yang sesuai, dimana semua karakter alfabet dalam data akan diubah menjadi huruf kecil.

4. Normalization

Dari Tabel 4.3, dapat dilihat proses *normalization* dapat memberikan keluaran yang sesuai ekspektasi, dimana kata-kata yang disingkat dapat diubah menjadi kata-kata yang sesuai dengan kaidah Bahasa Indonesia.

Proses *normalization* dilakukan dengan mencocokkan setiap kata pada data dengan daftar kata tidak baku (*slang word dictionary*) yang telah didefinisikan sebelumnya. Kata tidak baku bisa berupa slang, bahasa daerah, singkatan kata, dan typo. Jika ditemukan kecocokan, maka kata pada teks akan diganti dengan padanan kata baku yang terdapat di dalam *dictionary*. Penyusunan *slang word dictionary* dilakukan dengan menggabungkan dua sumber, yaitu daftar kata tidak baku yang diperoleh dari repositori di GitHub dan hasil observasi terhadap teks pada dataset komentar pelanggan. Dengan demikian, *dictionary* yang digunakan lebih kontekstual terhadap gaya bahasa pengguna dalam dataset.

Tabel 4. 4. Contoh Pasangan Kata *Slang Word Dictionary*

Kata Tidak Baku	Kata Baku
Skrng	Sekarang
Ksntor	Kantor
Banyu	Air

Tabel 4.4 diatas adalah contoh beberapa pasangan kata dalam *slang word dictionary*. Melalui proses ini, teks yang semula berisi bentuk singkatan, slang, bahasa daerah, dan typo diubah menjadi bentuk formal.

5. Stop Word Removal

Dari Tabel 4.3, dapat dilihat bahwa proses *stop word removal* dapat memberikan keluaran yang sesuai ekspektasi, dimana kata-kata yang dianggap tidak penting seperti kata sambung atau kata umum yang sering muncul (contoh: 'di', 'yang', 'ke') dihapus. Proses *stop word removal* dilakukan dengan mencocokkan setiap kata pada data komentar dengan kumpulan kata pada *stop word list*. *Stop word list* ini berisi daftar kata umum dalam Bahasa Indonesia yang tidak memiliki makna penting dalam konteks analisis sentimen, seperti kata sambung, kata depan, dan kata ganti. Apabila kata pada data komentar cocok dengan kata yang terdapat pada *stop word list*, maka kata tersebut akan dihapus dari teks. Daftar *stop word list* yang digunakan diperoleh dari repositori di GitHub, yang kemudian disesuaikan dengan konteks Bahasa Indonesia agar proses pembersihan data menjadi lebih akurat. Dengan penerapan metode ini, hanya kata-kata bermakna yang relevan terhadap analisis dapat dipertahankan, sehingga meningkatkan efisiensi dan akurasi pada tahap analisis berikutnya.

Tabel 4. 5. Contoh *Stop Word*

<i>Stop Word</i>
Boleh
Ke
Yang
Di

Tabel 4.5 diatas adalah contoh beberapa *stop word* pada *stop word list* yang dijadikan rujukan pada proses *stop word removal*.

6. Segmentasi Teks

Dari hasil pengujian pada Tabel 4.3, proses segmentasi teks dapat memberikan keluaran yang sesuai dengan ekspektasi, yaitu komentar berhasil dipecah menjadi dua bagian berdasarkan konjungsi yang telah didaftarkan. Sistem terlebih dahulu memuat daftar konjungsi, kemudian mencari konjungsi yang muncul paling awal pada setiap komentar hasil normalisasi. Jika ditemukan konjungsi yang sesuai, maka teks akan dipisahkan menjadi *sentence_1* sebagai bagian sebelum konjungsi dan *sentence_2* sebagai bagian mulai dari konjungsi hingga akhir kalimat. Namun, jika komentar tidak memiliki konjungsi yang terdaftar, maka seluruh teks tetap disimpan pada *sentence_1* dan *sentence_2* dibiarkan kosong.

Tabel 4. 6. Daftar Konjungsi Segmentasi Teks

Konjungsi
Sedang
Sedangkan
Lalu
Tapi
Karena
Tetapi
Padahal
Akan
Sehingga

Tabel 4.6 diatas adalah daftar konjungsi yang didaftarkan untuk memisahkan satu komentar yang membahas lebih dari satu keluhan agar setiap bagian kalimat dapat diproses secara lebih fokus. Kata-kata tersebut dipilih karena sering muncul sebagai penghubung antarbagian

kalimat pada komentar pelanggan, sehingga dapat membantu sistem mengenali batas perpindahan konteks di dalam satu komentar

Evaluasi segmentasi teks dilakukan dengan membandingkan hasil pemisahan program terhadap hasil pemisahan yang diharapkan berdasarkan posisi konjungsi pertama pada komentar. Dari total 1670 data, terdapat 293 komentar yang mengandung konjungsi. Hasil evaluasi menunjukkan bahwa seluruh data berhasil dipisahkan dengan benar, sehingga jumlah pemisahan benar adalah 1670 data dengan akurasi segmentasi sebesar 100,00%. Hasil ini menunjukkan bahwa aturan segmentasi berbasis konjungsi yang diterapkan sudah berjalan sangat baik pada data komentar yang digunakan dalam penelitian ini.

7. *Tokenizing*

Dari Tabel 4.3, dapat dilihat bahwa proses *tokenizing* dapat memberikan keluaran yang sesuai ekspektasi, dimana teks akan dipecah menjadi per kata yang kemudian disimpan dalam bentuk *array*.

8. *Stemming*

Dari Tabel 4.3, dapat dilihat bahwa proses *stemming* dapat memberikan keluaran yang sesuai ekspektasi, dimana setiap kata dalam teks diubah menjadi bentuk dasarnya dengan menghapus imbuhan. Imbuhan yang dihilangkan dapat berupa awalan, akhiran, sisipan, atau kombinasi dari awalan dan akhiran. Proses *stemming* ini dilakukan dengan memanfaatkan library Sastrawi, yang merupakan *tools stemmer* Bahasa Indonesia. *Library* ini secara otomatis mengenali struktur morfologis kata dan mengubahnya menjadi bentuk dasar yang baku. Penggunaan Sastrawi memungkinkan hasil *stemming* menjadi lebih akurat dan konsisten, terutama dalam konteks Bahasa Indonesia yang memiliki banyak variasi imbuhan dan bentuk kata.

4.6.2 *Data Split*

Pada tahap *data split*, pembagian data dilakukan setelah proses *preprocessing* selesai.. Pada penelitian ini, data uji menggunakan seluruh data yang tersedia, yaitu sebanyak 1670 data. Pemilihan seluruh data sebagai *data test* dilakukan karena sistem ingin diuji pada semua komentar pelanggan, baik komentar yang hanya memiliki satu konteks maupun komentar yang mengandung lebih dari satu konteks keluhan.

Sementara itu, *data train* dibentuk dari komentar yang tidak mengalami segmentasi atau hanya memiliki satu segmen kalimat. Secara teknis, *data train* diambil dari data yang nilai *sentence_2*-nya kosong, sehingga komentar tersebut hanya memiliki *sentence_1*. Setelah proses ini dilakukan, diperoleh sebanyak 1377 *data train*. *Data train* ini kemudian digunakan sebagai acuan dalam proses penggolongan aspek, karena setiap data di dalamnya mewakili satu konteks utama yang lebih sederhana dan lebih stabil untuk dibandingkan dengan data uji.

Pendekatan ini dipilih agar proses penggolongan multi aspek dapat berjalan lebih terarah. Komentar yang sudah tersegmentasi pada data test akan dibandingkan dengan data train yang tidak tersegmentasi, sehingga sistem dapat mencari aspek yang paling relevan untuk masing-masing segmen komentar. Dengan skema ini, proses pembentukan *data train* dan *data test* sudah sesuai dengan kebutuhan eksperimen, yaitu melatih sistem menggunakan komentar satu segmen dan mengujinya pada seluruh data komentar yang tersedia.

4.6.3 TF-IDF

Pengujian TF-IDF adalah pengujian yang dilakukan untuk mengetahui apakah sistem berhasil mengubah teks input menjadi vektor bilangan desimal.

Tabel 4. 7. Sampel Data Perhitungan TF-IDF

	Input	Vektor
<i>Sentence 1</i>	['pasang', 'tidak', 'ada', 'lanjut', 'survey']	0.304617 0.215181 0.240960 0.431406 0.441414
<i>Sentence 2</i>	['padahal', 'kata', 'komplain', 'layan', 'langgan', 'whatsapp', 'sedang', 'whatsapp', 'tidak', 'ada', 'tanggap']	- 0.317079 0.198214 0.351224 0.241194 0.557980 - 0.557980 0.132566 0.148448 0.275340

Berdasarkan Tabel 4.7, terlihat bahwa proses pemvektorisasian menggunakan metode Frekuensi Istilah Frekuensi Dokumen Terbalik (*Term Frequency-Inverse Document Frequency* atau TF-IDF) telah berjalan dengan baik. Hal ini terbukti dari keberhasilan sistem dalam membentuk vektor dari masukan teks yang diberikan.

4.6.4 Aspect Based Menggunakan Cosine Similarity

Tabel 4.8 Daftar Aspek yang Digunakan

Aspek yang Digunakan
Air Tidak Mengalir
Meteran (Macet/Bermasalah)
Harga
Pelayanan
Pemasangan
Air Kotor/Bau
Kebocoran
Pemakaian
Perubahan Kode Tarif
Lainnya

Pada tahap ini penulis menentukan 10 aspek seperti pada Tabel 4.8 berdasarkan:

- Aspek yang ada pada aplikasi CIS milik PDAM (Aspek: Air Kotor/Bau, Kebocoran, Meteran (Macet/Bermasalah), Air Tidak Mengalir, Pemakaian, Perubahan Kode Tarif)
- Pendapat penulis setelah membaca data yang dimiliki (Aspek: Pemasangan, Pelayanan, Harga, Lainnya)

Proses klasifikasi aspek dilakukan menggunakan pendekatan *multi aspect based* berbasis *cosine similarity*. Setelah komentar melalui tahap *normalization*, segmentasi teks, *tokenizing*, dan *stemming*, setiap komentar direpresentasikan ke dalam bentuk vektor menggunakan TF-IDF. Data train dibentuk dari komentar yang hanya memiliki satu segmen kalimat, yaitu data yang tidak memiliki *sentence_2*, sedangkan seluruh data digunakan sebagai data uji. Setelah itu, setiap segmen pada data uji dibandingkan dengan seluruh *data train* untuk mencari aspek yang memiliki nilai kemiripan tertinggi.

Alur klasifikasinya dimulai dengan mengambil dua segmen hasil *preprocessing*, yaitu *sentence_1* dan *sentence_2*. Masing-masing segmen kemudian dihitung nilai *cosine similarity*-nya terhadap seluruh *data train*. Dari hasil tersebut, sistem mengambil satu aspek dengan *similarity score* tertinggi untuk *sentence_1* dan satu aspek dengan *similarity score* tertinggi untuk *sentence_2*. Jika *sentence_2* kosong, maka prediksi hanya dilakukan dari *sentence_1*. Pada penelitian ini, karena proses segmentasi hanya dibatasi menjadi dua segmen, maka sistem hanya dapat menghasilkan maksimal dua aspek dalam satu komentar.

Untuk klasifikasi satu aspek, perhitungan *cosine similarity* dilakukan antara vektor segmen pertama dengan seluruh vektor *data train*. Persamaan yang digunakan dapat dituliskan sebagai berikut:

$$\text{Sim}(S1, Di) = \frac{(S1 \cdot Di)}{([S1] \times [Di])} \quad (4.1)$$

Keterangan:

- $\text{Sim}(S1, Di)$: Nilai *cosine similarity* antara *sentence_1* dan *data train* ke-i.
- $S1$: Vektor TF-IDF dari *sentence_1*.
- Di : Vektor TF-IDF dari *data train* ke-i.
- $S1 \cdot Di$: *Dot product* antara dua vektor, yaitu hasil perkalian bobot TF-IDF pada fitur yang sama.
- $|S1|$: Panjang atau *magnitude* dari vektor *sentence_1*, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *sentence_1*.
- $|Di|$: Panjang atau *magnitude* dari vektor *data train* ke-i, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *data train* ke i.

Nilai *similarity* tertinggi dari seluruh data train dipilih sebagai kandidat aspek pertama. Jika *similarity score* tertinggi dari *sentence_1* lebih besar atau sama dengan 0,30 dan aspek yang diperoleh bukan "Lainnya", maka aspek tersebut ditetapkan sebagai hasil klasifikasi. Namun, jika nilainya lebih kecil dari 0,18, maka komentar akan diarahkan ke aspek "Lainnya".

Untuk klasifikasi dua aspek, proses yang sama juga dilakukan pada *sentence_2*. Dengan demikian, perhitungannya menjadi:

$$\text{Sim}(S1, Di) = \frac{(S1 \cdot Di)}{([S1] \times [Di])} \quad (4.2)$$

$$\text{Sim}(S_2, D_i) = \frac{(S_2 \cdot D_i)}{(|S_2| \times |D_i|)} \quad (4.3)$$

Keterangan:

- $\text{Sim}(S_2, D_i)$: Nilai *cosine similarity* antara *sentence_2* dan *data train* ke-i.
- S_2 : Vektor TF-IDF dari *sentence_2*.
- D_i : Vektor TF-IDF dari *data train* ke-i.
- $S_2 \cdot D_i$: *Dot product* antara dua vektor, yaitu hasil perkalian bobot TF-IDF pada fitur yang sama.
- $|S_2|$: Panjang atau *magnitude* dari vektor *sentence_2*, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *sentence_2*.
- $|D_i|$: Panjang atau *magnitude* dari vektor *data train* ke-i, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *data train* ke-i.

Aspek pertama diambil dari hasil *similarity* tertinggi pada *sentence_1*, sedangkan aspek kedua diambil dari hasil *similarity* tertinggi pada *sentence_2*. Aspek pertama dimasukkan ke hasil akhir jika *similarity score*-nya minimal 0,30. Aspek kedua dimasukkan jika *similarity score*-nya minimal 0,40, hasil prediksinya bukan "Lainnya", dan aspek tersebut tidak sama dengan aspek pertama. Jika tidak ada aspek yang memenuhi kondisi tersebut, maka sistem akan memilih aspek dengan *similarity score* tertinggi dari kedua segmen. Jika nilai terbaiknya masih di bawah 0,18, maka hasil akhirnya ditetapkan sebagai "Lainnya".

Tabel 4. 9. Kata yang Digunakan Dalam Perhitungan *Similarity sentence_1*

	Kata-Kata
<i>Sentence 1</i>	['pasang', 'tidak', 'ada', 'lanjut', 'survey']
<i>Data Train</i>	['pasang', 'tidak', 'ada', 'biaya', 'tambah']

Tabel 4. 10. Perhitungan TF-IDF *Sentence 1* dan *Data Train*

	pasang	tidak	ada	pasang tidak	tidak ada
<i>Sentence 1</i>	0.304617	0.215181	0.240960	0.547104	0.350091
<i>Data Train</i>	0.267715	0.189113	0.211769	0.480826	0.307680

Tabel 4.9 adalah kalimat yang digunakan pada contoh perhitungan *similarity sentence_1* dan Tabel 4.10 adalah hasil perhitungan TF-IDF *sentence 1* dan *data train*. Selain itu, kata-kata dari *data train* yang tercantum didalam Tabel 4.10 adalah data dengan *similarity* tertinggi untuk *sentence_1* dengan aspek Pemasangan. Munculnya fitur dua kata seperti “pasang tidak” dan “tidak ada” disebabkan karena *vectorizer* menggunakan *ngram_range*=(1,2), sehingga sistem tidak hanya membentuk fitur dari satu kata (unigram), tetapi juga dari dua kata yang berurutan (bigram). Dengan cara ini, konteks lokal antar kata dapat ikut diperhitungkan pada proses klasifikasi.

Maka perhitungan *cosine similarity* untuk *sentence_1* adalah sebagai berikut:

$$\text{Sim}(S_1, D_{1180}) = \frac{((0.304617 \times 0.267715) + (0.215181 \times 0.189113) + (0.240960 \times 0.211769) + (0.547104 \times 0.480826) + (0.350091 \times 0.307680))}{\sqrt{0.304617^2 \times 0.267715^2 \times 0.215181^2 \times 0.240960^2 \times 0.547104^2 \times 0.350091^2} \times \sqrt{0.267715^2 \times 0.189113^2 \times 0.211769^2 \times 0.480826^2 \times 0.307680^2}} \quad (4.4)$$

$$\text{Sim}(S1, D1180) = 0.544049 \quad (4.5)$$

Nilai *similarity* sebesar 0,544049 lebih besar dari *threshold* utama 0,30, sehingga *sentence_1* diprediksi sebagai aspek Pemasangan.

Tabel 4. 11. Kata-Kata yang Digunakan Dalam Perhitungan *similarity sentence_2*

	Kata-Kata
<i>Sentence 2</i>	['padahal', 'kata', 'komplain', 'layan', 'langgan', 'whatsapp', 'sedang', 'whatsapp', 'tidak', 'ada', 'tanggap']
<i>Data Train</i>	['informasi', 'admin', 'sudah', 'adu', 'langgan', 'loh', 'via', 'aplikasi', 'belum', 'ada', 'respon', 'pesan', 'tidak', 'ada', 'respon', 'alih', 'call', 'center', 'telepon', 'whatsapp', 'whatsapp', 'tidak', 'ada', 'layan', 'belum', 'ada', 'respon', 'langgan']

Tabel 4. 12. Perhitungan TF-IDF *Sentence 2* dan *Data Train*

	whatsapp	whatsapp tidak	layan langgan	langgan
<i>Sentence_2</i>	0.557980	0.337053	0.302907	0.241194
<i>Data Train</i>	0.299227	0.180751	0.162440	0.258689

	ada	tidak	Layan	Tidak ada
<i>Sentence_2</i>	0.148448	0.132566	0.198214	0.215679
<i>Data Train</i>	0.238823	0.142182	0.212592	0.231324

Tabel 4.11 adalah kalimat yang digunakan pada contoh perhitungan *similarity sentence_2* dan Tabel 4.12 adalah hasil perhitungan TF-IDF *sentence 2* dan *data train*. Selain itu, kata-kata dari *data train* yang tercantum didalam Tabel 4.12 adalah data dengan *similarity* tertinggi untuk *sentence_2* dengan aspek pelayanan. Kata padahal dan sedang sebenarnya tetap terbaca sebagai token, namun tidak masuk ke vektor akhir karena tidak termasuk ke dalam vocabulary TF-IDF yang dibentuk dari data train. Hal ini terjadi karena vectorizer menggunakan parameter *ngram_range*=(1,2) dan *min_df*=2, sehingga hanya kata atau gabungan kata yang muncul minimal pada dua dokumen train yang akan dipertahankan sebagai fitur. Sama seperti pada *sentence_1*, keberadaan fitur dua kata seperti “whatsapp tidak”, “layan langgan”, dan “tidak ada” menunjukkan bahwa proses vektorisasi pada penelitian ini memang mempertimbangkan unigram dan bigram sekaligus. Maka perhitungan *cosine similarity* untuk *sentence_2* adalah sebagai berikut:

$$\text{Sim}(S2, D34) = \frac{((0.557980 \times 0.299227) + (0.337053 \times 0.180751) + (0.302907 \times 0.162440) + (0.241194 \times 0.258689) + (0.215679 \times 0.231324) + (0.198214 \times 0.212592) + (0.148448 \times 0.238823) + (0.132566 \times 0.142182))}{\sqrt{0.557980^2 \times 0.337053^2 \times 0.302907^2 \times 0.241194^2 \times 0.215679^2 \times 0.198214^2 \times 0.148448^2 \times 0.132566^2} \times \sqrt{0.299227^2 \times 0.180751^2 \times 0.162440^2 \times 0.258689^2 \times 0.231324^2 \times 0.212592^2 \times 0.238823^2 \times 0.142182^2}} \quad (4.6)$$

$$\text{Sim}(S2, D34) = 0.485815 \quad (4.7)$$

Nilai *similarity* sebesar 0,485815 lebih besar dari *threshold* kedua 0,40, sehingga *sentence_2* diprediksi sebagai aspek Pelayanan. Karena hasil prediksi *sentence_1* dan *sentence_2* berbeda, maka hasil akhir komentar ini menjadi dua aspek, yaitu Pemasangan | Pelayanan.

Berdasarkan hasil eksperimen, sistem berhasil melakukan klasifikasi aspek pada 1670 data uji dengan memanfaatkan 1377 data train. Hasil prediksi menunjukkan bahwa sistem mampu mengenali komentar satu aspek maupun komentar yang mengandung dua aspek. Aspek yang paling banyak muncul pada hasil prediksi adalah Lainnya, Air Tidak Mengalir, Meteran (Macet/Bermasalah), dan Harga. Hal ini menunjukkan bahwa sistem sudah mampu memetakan komentar pelanggan ke dalam aspek layanan yang sesuai, termasuk pada komentar yang memiliki lebih dari satu konteks keluhan.

Berdasarkan hasil evaluasi, sistem memperoleh total akurasi sebesar 89,28% dari 1670 data uji. Dari jumlah tersebut, sebanyak 1491 data berhasil diprediksi dengan benar, sedangkan 179 data lainnya masih mengalami kesalahan prediksi. Selain itu, hasil evaluasi juga menunjukkan nilai *F1 Score* sebesar 0,9321. Hasil ini menunjukkan bahwa sistem *multi aspect based classification* yang dikembangkan sudah mampu memberikan performa yang baik dalam mengelompokkan komentar pelanggan ke aspek layanan yang sesuai.

Secara keseluruhan, hasil eksperimen ini menunjukkan bahwa pendekatan *multi aspect based classification* menggunakan *cosine similarity* sudah mampu memberikan hasil yang baik untuk mengidentifikasi aspek layanan pada komentar Instagram PDAM Surya Sembada. Meskipun demikian, sistem masih memiliki keterbatasan karena hanya dapat memproses maksimal dua aspek dalam satu komentar, sesuai dengan jumlah segmen yang dibentuk pada tahap segmentasi teks.

4.6.5 Sentiment Analysis Menggunakan Rule Based

Pada tahap ini, analisis sentimen dilakukan menggunakan pendekatan *rule based* dengan memanfaatkan aturan kombinasi *part of speech* (POS) dan kamus polarity yang telah disusun. Berbeda dengan proses klasifikasi aspek yang menggunakan teks hasil *stemming*, pada analisis sentimen penelitian ini digunakan kolom *normalized_text* sebagai input utama. Pemilihan *normalized_text* dilakukan agar makna kata-kata domain seperti pengajuan, peremajaan, dan tindak lanjut tetap terjaga dan tidak berubah akibat proses *stemming*.

Alur proses *sentiment analysis* dimulai dengan mengambil teks yang telah dinormalisasi, kemudian teks dibersihkan dan dipecah menjadi beberapa bagian kalimat berdasarkan tanda baca seperti titik, koma, tanda seru, dan tanda tanya. Setelah itu, sistem melakukan pengecekan frasa, pencocokan kata ke kamus POS, dan perhitungan nilai sentimen berdasarkan aturan yang sesuai. Nilai sentimen dari setiap bagian kalimat kemudian dijumlahkan untuk memperoleh

skor sentimen akhir pada satu komentar. Jika skor akhir lebih besar dari nol maka komentar diberi label Positif, jika sama dengan nol maka diberi label Netral, dan jika lebih kecil dari nol maka diberi label Negatif.

Pada implementasinya, sistem juga menerapkan beberapa penyesuaian tambahan. Pertama, jika sebuah komentar berbentuk pertanyaan dan tidak memiliki sinyal negatif yang kuat, maka komentar tersebut cenderung diberi nilai netral. Kedua, sistem mengenali beberapa frasa negatif yang kuat seperti tidak ada respon, tidak ada tanggapan, air tidak mengalir, air mati, air tidak keluar, tagihan melonjak, dan frasa sejenis agar keluhan pelanggan yang bersifat tegas dapat langsung diberi penalti sentimen negatif. Ketiga, sistem juga menambahkan *complaint context penalty* ketika dalam satu kalimat ditemukan kata-kata keluhan seperti komplain, adu, lapor, mohon, atau tolong yang muncul bersama kata-kata masalah layanan seperti air, meter, tagihan, bocor, keruh, mati, rusak, atau lonjak. Penyesuaian ini dibuat agar pola pengaduan pelanggan dapat lebih mudah dikenali oleh sistem.

Dalam program, terdapat dua operator utama yang digunakan. Operator *AND* dipakai pada pasangan preposisi dan kata berikutnya. Jika salah satu nilai adalah 0, maka hasilnya mengikuti penjumlahan biasa. Namun jika kedua nilai tidak 0, maka hasilnya menjadi 1 jika tandanya sama dan -1 jika tandanya berbeda. Sementara itu, operator *NAND* dipakai pada pasangan verba dan adjektiva. Jika salah satu nilainya 0, maka hasilnya juga berupa penjumlahan biasa. Namun jika kedua nilai tidak 0, maka hasilnya menjadi 1 jika jumlah keduanya positif dan -1 jika jumlah keduanya tidak positif.

1. Adjektiva Tunggal

Aturan pertama adalah adjektiva tunggal. Jika pada kalimat ditemukan kata sifat yang memiliki nilai sentimen dan tidak terlibat dalam kombinasi aturan lain, maka nilai sentimennya langsung diambil sebagai nilai sentimen kalimat.

Contoh yang diambil dari data adalah klausa lama pada komentar:

“pergantian meter bayar via indomaret, bayar via indomaret h masuk, h masuk jadwalkan kunjungan. lama, air sudah bocor deras tanggung pemilik rumah. lama prosesnya??.”

Pada klausa ini, kata lama termasuk Adjektiva dengan nilai -1, sehingga perhitungannya adalah

$$score = sentiment(lama) = -1.$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen negatif.

2. Verba Tunggal

Aturan kedua adalah verba tunggal. Jika pada kalimat ditemukan kata kerja yang memiliki nilai sentimen dan tidak berpasangan dengan aturan lain, maka nilai sentimennya langsung digunakan.

Contoh dari data adalah klausa bayar pada komentar

“ada perbaikan ta. air keluar rumah kecil kadang tidak. nyala. bayar.”

Pada klausa ini, kata bayar termasuk Verba dengan nilai -1, sehingga perhitungannya adalah

$$score = sentiment(bayar) = -1.$$

Hasil akhirnya adalah sentimen negatif.

3. Preposisi + Adjektiva

Aturan ketiga adalah kombinasi preposisi dan adjektiva. Contoh dari data adalah klausa air dalam keruh yang berasal dari komentar

“airnya dalam keruh, hampir air beras.”

Pada klausa ini, kata dalam termasuk Preposisi dengan nilai 1, sedangkan kata keruh termasuk Adjektiva dengan nilai -1. Maka nilai pasangan tersebut dihitung dengan $AND(1, -1) = -1$. Selain itu, kata air pada klausa ini juga memiliki nilai -1 di dalam kamus, sehingga total skor kalimat menjadi

$$score = sentiment(air) + AND(dalam, keruh) = -1 + (-1) = -2.$$

Oleh karena itu, klausa ini dikategorikan sebagai sentimen negatif.

4. Preposisi + Verba

Aturan keempat adalah kombinasi preposisi dan verba. Pada implementasi program, pola ini banyak muncul dalam bentuk negasi seperti tidak ada atau tidak keluar.

Contoh dari data adalah klausa pemasangan tidak ada kelanjutan survey yang berasal dari komentar.

“pemasangan tidak ada kelanjutan survey. padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.”

Pada klausa ini, model juga memberikan *complaint context penalty* sebesar -1 karena terdapat konteks keluhan layanan. Setelah itu, kata tidak diberi nilai -1, sedangkan kata ada bernilai 0. Maka skor yang diperoleh adalah

$$score = complaint\ penalty + sentiment(tidak) + sentiment(ada) = -1 + (-1) + 0 = -2.$$

Dengan demikian, klausa ini dikategorikan sebagai sentimen negatif.

5. Verba + Adjektiva

Aturan kelima adalah kombinasi verba dan adjektiva. Contoh dari data dapat dilihat pada klausa padahal bayar mahal tapi air keruh bau, yang berasal dari komentar

“air pdam surabaya pusat penyaku keruh air sumur. padahal bayarnya mahal tapi airnya keruh bau.”

Pada bagian bayar mahal, kata bayar termasuk Verba dengan nilai -1 dan kata mahal termasuk Adjektiva dengan nilai -1. Maka nilai pasangan tersebut dihitung dengan $NAND(-1, -1) = -1$. Pada klausa lengkap ini, sistem juga menemukan frasa air keruh yang bernilai -1 serta kata bau yang bernilai -1, sehingga total skor klausa menjadi

$$score = NAND(bayar, mahal) + sentiment(air\ keruh) + sentiment(bau) = -1 + (-1) + (-1) = -3.$$

Oleh karena itu, klausa ini dikategorikan sebagai sentimen negatif.

6. Preposisi + Verba + Adjektiva

Aturan keenam adalah kombinasi preposisi, verba, dan adjektiva. Contoh dari data adalah klausa

“air tidak keluar mati.”

Secara konsep, pola ini memuat preposisi tidak, verba keluar, dan adjektiva mati. Jika dihitung berdasarkan susunan aturannya, pasangan verba-adjektiva dihitung terlebih dahulu, kemudian digabungkan dengan preposisi. Namun, pada implementasi program saat ini, pola tidak keluar sudah terdeteksi sebagai frasa negatif kuat dengan nilai -1. Setelah itu, kata mati masih dihitung sebagai adjektiva tunggal dengan nilai -1. Maka total skor klausa tersebut adalah

$$score = sentiment(tidak\ keluar) + sentiment(mati) = -1 + (-1) = -2.$$

Dengan demikian, klausa ini dikategorikan sebagai sentimen negatif.

7. Frasa terdiri dari dua kata memiliki satu makna dan tidak bisa dipisah

Selain aturan POS di atas, sistem juga mendukung rule berbasis frasa. Frasa yang terdapat pada kamus frasa akan diperlakukan sebagai satu kesatuan makna.

Contoh dari data adalah klausa terima kasih pada komentar

“maaf air pdam daerah surabaya wiyung kotor satu minggu lebih. cek tandon stok air. terima kasih.”

Karena frasa terima kasih berada di awal klausa, sistem memberikan nilai +1. Maka perhitungannya adalah

$$score = sentiment(terima\ kasih) = 1$$

Sehingga klausa tersebut dikategorikan sebagai sentimen positif.

8. Frasa Negatif Kuat

Model juga memiliki aturan frasa negatif kuat. Contoh dari data adalah klausa sedangkan whatsapp tidak ada tanggapan pada komentar

“pemasangan tidak ada kelanjutan survey. padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.”

Pada klausa ini, frasa tidak ada tanggapan langsung dikenali sebagai frasa negatif dengan nilai -1. Sisa kata lain pada klausa tersebut tidak menambah nilai sentimen. Maka perhitungannya adalah

$$score = sentiment(tidak\ ada\ tanggapan) = -1$$

Sehingga klausa tersebut dikategorikan sebagai sentimen negatif.

9. Rule Komentar Berbentuk Pertanyaan

Selain itu, sistem juga mempunyai *rule* untuk komentar berbentuk pertanyaan. Contoh dari data adalah kalimat

“pdam naik selalu?”

Karena kalimat ini berbentuk pertanyaan dan tidak memiliki sinyal negatif yang kuat menurut daftar frasa negatif maupun *complaint words*, maka sistem langsung memberikan $score = 0$. Dengan demikian, kalimat tersebut dikategorikan sebagai netral.

10. Complaint Context Penalty

Contoh lain dari penyesuaian tambahan adalah *complaint context penalty*. Pada klausa aliran air daerah Mojo tidak lancar, yang berasal dari komentar

“aliran air daerah mojo tidak lancar, ditindaklanjuti kantornya didatangi”

Sistem mendeteksi adanya konteks keluhan sehingga memberikan *penalty* sebesar -1. Setelah itu, kata air memberi nilai -1, dan pasangan tidak lancar diproses sebagai *negation shortcut* dengan nilai -1. Maka perhitungannya menjadi

$$\text{score} = \text{complaint penalty} + \text{sentiment}(\text{air}) + \text{negation}(\text{tidak lancar}) = -1 + (-1) + (-1) = -3.$$

Hasil akhirnya adalah sentimen negatif.

Berdasarkan hasil eksperimen, model *sentiment analysis rule based* diuji pada 1670 data. Distribusi label asli terdiri dari 827 data Negatif, 568 data Netral, dan 275 data Positif. Dari seluruh data tersebut, sistem berhasil memprediksi 1340 data dengan benar dan 330 data dengan salah. Total akurasi yang diperoleh sebesar 80,24% dengan error rate sebesar 19,76%. Selain itu, hasil evaluasi juga menunjukkan nilai F1 Score sebesar 0,8027. Nilai ini menunjukkan bahwa model yang dibuat sudah cukup baik dalam mengenali polaritas sentimen komentar pelanggan.

Berdasarkan *confusion matrix*, sebagian besar data Negatif berhasil diprediksi dengan benar sebanyak 668 data, data Netral sebanyak 447 data, dan data Positif sebanyak 225 data. Kesalahan prediksi masih ditemukan terutama pada perpindahan label dari Negatif ke Netral dan dari Netral ke Negatif. Hal ini menunjukkan bahwa komentar pelanggan yang memiliki makna keluhan tidak langsung atau menggunakan kalimat ambigu masih menjadi tantangan bagi pendekatan *rule based*.

Secara keseluruhan, hasil eksperimen ini menunjukkan bahwa pendekatan sentiment analysis menggunakan rule based sudah mampu memberikan hasil yang cukup baik untuk memetakan sentimen komentar pelanggan PDAM Surya Sembada. Kelebihan pendekatan ini adalah alur perhitungannya jelas dan mudah ditelusuri, sehingga setiap keputusan sentimen dapat dijelaskan berdasarkan aturan yang digunakan. Namun, performa model masih sangat bergantung pada kelengkapan kamus kata, frasa, serta cakupan aturan yang diterapkan terhadap variasi bahasa pada komentar pelanggan.

4.7 ANALISIS HASIL EKSPERIMEN

Berdasarkan hasil eksperimen yang telah dilakukan, solusi yang diajukan dalam penelitian ini sudah mampu menjawab permasalahan utama, yaitu mengelompokkan komentar pelanggan PDAM ke dalam aspek layanan yang relevan dan menentukan sentimennya secara otomatis. Pada tahap *multi aspect based classification*, sistem memperoleh total akurasi sebesar 89,28% dengan 1491 prediksi benar dari 1670 data uji. Hasil ini menunjukkan bahwa pendekatan cosine similarity yang dipadukan dengan segmentasi teks sudah cukup efektif untuk mengenali komentar yang memuat satu aspek maupun dua aspek sekaligus, meskipun sistem masih memiliki keterbatasan karena hanya dapat memproses maksimal dua aspek dalam satu komentar.

Pada tahap *sentiment analysis*, model *rule based* yang dikembangkan juga menunjukkan hasil yang baik dengan akurasi 80,24% dan F1 Score 0,8027. Hasil ini menunjukkan bahwa aturan berbasis POS, frasa, negasi, dan konteks keluhan sudah mampu menangkap polaritas sentimen pelanggan secara cukup konsisten. Secara keseluruhan, eksperimen ini membuktikan bahwa rancangan sistem yang diusulkan dapat digunakan untuk membantu PDAM memahami isi keluhan pelanggan secara lebih terstruktur, baik dari sisi aspek layanan yang dibahas maupun dari sisi sentimen yang terkandung di dalam komentar.

BAB 5

PENUTUP

5.1 BAGIAN YANG SUDAH DIKERJAKAN

Bagian-bagian yang sudah diselesaikan dalam penelitian proyek akhir ini antara lain:

1. Mengumpulkan Dataset

Penulis telah menyelesaikan tahapan pengumpulan dataset. Dataset diperoleh dari proses *scraping* komentar Instagram menggunakan *library* *instaloader* menggunakan bahasa pemrograman Python.

2. Text Preprocessing

Pada tahap ini penulis telah berhasil melakukan 8 proses *text preprocessing* yang sistematis dengan tujuan untuk memastikan kualitas dan konsistensi data sebelum digunakan.

3. Data Split

Pada tahap ini, penulis telah berhasil melakukan pembagian data menjadi *data train* dan *data test* sesuai dengan kebutuhan sistem. Data train dibentuk dari komentar yang tidak tersegmentasi, sedangkan data test menggunakan seluruh data komentar. Hasil pembagian ini menghasilkan 1377 *data_train* dan 1670 *data_test*, sehingga proses penggolongan aspek dapat dilakukan dengan membandingkan setiap segmen pada *data test* terhadap *data train* yang mewakili satu konteks utama.

4. Mengembangkan dan Menguji Segmentasi Teks

Evaluasi segmentasi teks dilakukan dengan membandingkan hasil pemisahan program terhadap hasil pemisahan yang diharapkan berdasarkan posisi konjungsi pertama pada komentar. Dari total 1670 data, terdapat 293 komentar yang mengandung konjungsi. Hasil evaluasi menunjukkan bahwa seluruh data berhasil dipisahkan dengan benar, sehingga jumlah pemisahan benar adalah 1670 data dengan akurasi segmentasi sebesar 100,00%. Hasil ini menunjukkan bahwa aturan segmentasi berbasis konjungsi yang diterapkan sudah berjalan sangat baik pada data komentar yang digunakan dalam penelitian ini.

5. Mengembangkan dan Menguji Model *Aspect Based* Menggunakan *Cosine Similarity*

Berdasarkan hasil evaluasi, sistem memperoleh total akurasi sebesar 89,28% dari 1670 data uji. Dari jumlah tersebut, sebanyak 1491 data berhasil diprediksi dengan benar, sedangkan 179 data lainnya masih mengalami kesalahan prediksi. Selain itu, hasil evaluasi juga menunjukkan nilai *F1 Score* sebesar 0,9321. Hasil ini menunjukkan bahwa sistem *multi aspect based classification* yang dikembangkan sudah mampu memberikan performa yang baik dalam mengelompokkan komentar pelanggan ke aspek layanan yang sesuai.

Secara keseluruhan, hasil eksperimen ini menunjukkan bahwa pendekatan *multi aspect based classification* menggunakan *cosine similarity* sudah mampu memberikan hasil yang baik untuk mengidentifikasi aspek layanan pada komentar Instagram PDAM Surya Sembada. Meskipun demikian, sistem masih memiliki keterbatasan karena hanya dapat memproses maksimal dua aspek dalam satu komentar, sesuai dengan jumlah segmen yang dibentuk pada tahap segmentasi teks.

6. Mengembangkan dan Menguji Model *Sentiment Analysis* Menggunakan *Rule Based*

Model sentiment analysis berbasis rule based telah berhasil dikembangkan dan diuji. Berdasarkan hasil evaluasi pada 1670 data, sistem mampu memprediksi 1340 data dengan benar dan 330 data dengan salah. Total akurasi yang diperoleh sebesar 80,24% dengan error rate sebesar 19,76%. Selain itu, hasil evaluasi juga menunjukkan nilai F1 Score sebesar 0,8027.

Hasil tersebut menunjukkan bahwa model yang dibuat sudah cukup baik dalam mengenali sentimen komentar pelanggan. Meskipun demikian, masih terdapat beberapa kesalahan prediksi pada komentar yang ambigu, tidak langsung, atau memiliki susunan kalimat yang lebih kompleks.

5.2 BAGIAN YANG BELUM DIKERJAKAN

Untuk merampungkan sistem secara keseluruhan, terdapat beberapa tahapan pengembangan lanjutan yang akan menjadi fokus pengerjaan selanjutnya.

1. Pengembangan Aplikasi

Seluruh model yang telah dibuat (*Aspect Based* menggunakan *cosine similarity* dan *Sentiment Analysis* menggunakan *rule based*) akan disatukan dalam dashboard berbasis web dengan memanfaatkan *framework* Streamlit.

5.3 KENDALA

Berdasarkan perkembangan pekerjaan proyek, penulis mengalami beberapa kendala, di antaranya adalah

1. Sistem yang digunakan saat ini hanya membagi komentar menjadi dua segmen, sehingga komentar yang mengandung lebih dari dua aspek belum dapat diproses secara optimal.
2. Pendekatan Rule Based masih sangat bergantung pada kelengkapan kamus kata, frasa, dan aturan yang dibuat, sehingga beberapa komentar dengan bahasa tidak baku, makna implisit, atau konteks yang ambigu masih dapat menghasilkan prediksi yang kurang tepat.
3. Komentar yang mengandung ironi, sindiran, atau susunan kalimat yang kompleks juga masih menjadi tantangan, karena makna sentimennya tidak selalu dapat ditangkap hanya dari pencocokan aturan secara langsung.

DAFTAR PUSTAKA

1. Wu, J., Wang, Y. (2021). A Text Correlation Algorithm for Stock Market News Event Extraction. In: Zeng, J., Qin, P., Jing, W., Song, X., Lu, Z. (eds) Data Science. ICPCSEE 2021. Communications in Computer and Information Science, vol 1452. Springer, Singapore.
2. Chiny M., Chihab M., Bencharef O. and Chihab Y. Netflix Recommendation System based on TF-IDF and Cosine Similarity Algorithms. In *Proceedings of the 2nd International Conference on Big Data, Modelling and Machine Learning - Volume 1: BML*, ISBN 978-989-758-559-3, 2021.
3. Sahria Y. Implementasi Teknik Web Scraping Pada Jurnal SINTA Untuk Analisis Topik Penelitian Kesehatan Indonesia. University Research Colloquium. (pp 297–306), 2022.
4. A. Erkan and T. Güngör, "Analysis of Deep Learning Model Combinations and Tokenization Approaches in Sentiment Classification," *IEEE Access*, vol. 11, pp. 134951–134968, 2023.
5. Zong, C., Xia, R., Zhang, J.. Text Representation. In: Text Data Mining, 2021.
6. Suryatin. Aspect-based Sentiment Analysis pada Aplikasi Pelacakan Kasus Covid-19 (studi kasus: pedulilindungi.id) [Tesis, Universitas Islam Indonesia]. UII Repository, 2023.
7. Ni Putu Gita Naraswati, Rani Nooraeni, Delvira Cindy Rosmilda, Dinda Desinta, Fadhilatul Khairi, dan Riska Damaiyanti. Analisis Sentimen Publik dari Twitter Tentang Kebijakan Penanganan Covid-19 di Indonesia dengan Naive Bayes Classification. Sistemasi: Jurnal Sistem Informasi, Vol. 10, No. 1, hlm. 222-238, 2021. DOI: 10.32520/stmsi.v10i1.1179.
8. Lusiana Efrizoni, Sarjon Defit, Muhammad Tajuddin, dan Anthony Anggrawan. Komparasi Ekstraksi Fitur dalam Klasifikasi Teks Multilabel Menggunakan Algoritma Machine Learning. MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer, Vol. 21, No. 3, hlm. 653-666, 2022. DOI: 10.30812/matrik.v21i3.1851.
9. Magriyanti, A. A. Maximum Marginal Relevance Berbasis Boolean Model pada Peringkasan Artikel Berita Pendek. Jurnal Ilmiah Teknik Informatika dan Komunikasi, vol. 1, no. 3, pp. 77-88, 2021.
10. Said, F. dan Manik, L. P. Aspect-Based Sentiment Analysis on Indonesian Presidential Election Using Deep Learning. Paradigma, vol. 24, no. 2, pp. 160-167, 2022.
11. Wahyudi, D. dan Sibaroni, Y. Deep Learning for Multi-Aspect Sentiment Analysis of TikTok App using the RNN-LSTM Method. Building of Informatics, Technology and Science (BITS), vol. 4, no. 1, pp. 169-177, 2022.
12. M. H. Wicaksono, M. D. Purbolaksono, dan S. A. Faraby, "Perbandingan Algoritma Machine Learning untuk Analisis Sentimen Berbasis Aspek pada Review Female Daily," e-Proceeding of Engineering, vol. 10, no. 3, pp. 3591–3597, Jun. 2023.
13. Pradhyksa, D. P. Pengaturan Pendayagunaan Sumber Daya Air dalam Undang-Undang Cipta Kerja dan Korelasinya dengan Pasal 33 UUD 1945. *Ascarya: Journal of Islamic Science, Culture, and Social Studies*, 1(2), 70–92, 2021.
14. L. Kurnia Ramadhani and B. Nurul Widyaningrum, "Analysis Sentiment to Religious Based Issues Netizen Comments on President Jokowi 's Instagram using the Naive Bayes Classifier Method", *Jl*, vol. 9, no. 1, pp. 59-66, Feb. 2024.
15. V. A. S. Putri, A. V. Vitianingsih, R. Hamidan, A, L, Maukar, N. T. Pratitis, "Sentiment Analysis on Social Media Instagram of Depression Issues Using Naïve Bayes Method", *ISI*, vol. 9, no. 2, pp. 802–813, Oct. 2024
16. F. R. Halim, R. Novita, Mustakim and M. Afdal, "Sentiment Analysis to Assess Customer Retention on Instagram Social Media Using Naïve Bayes Classifier and

Support Vector Machine," *2024 4th International Conference on Emerging Smart Technologies and Applications (eSmarTA)*, Sana'a, Yemen, 2024.

17. M. A. Khadija, I. S. D. Jayanti and F. U. Nimah, "Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data Using Machine Learning," *2024 7th International Conference on Informatics and Computational Sciences (ICICoS)*, Semarang, Indonesia, 2024