



**PROGRES
PROYEK AKHIR**

**Augmentasi Data Citra Mikroskopis Bakteri Gram
Positif dan Gram Negatif Menggunakan Generative
Adversarial Network (GAN)**

Andrey Pratama Gunawan
NRP. 3122600049

DOSEN PEMBIMBING

Tita Karlita S.Kom., M.Kom.
NIP. 197910142002122002

Nana Ramadijanti, S.Kom., M.Kom.
NIP. 197111091998022001

Ira Prasetyaningrum S.Si., MT.
NIP. 198005292008122005

**PROGRAM STUDI SARJANA TERAPAN TEKNIK
INFORMATIKA
DEPARTEMEN TEKNIK INFORMATIKA DAN
KOMPUTER
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2025**

(halaman sengaja dikosongkan)

DAFTAR ISI

DAFTAR ISI.....	3
DAFTAR GAMBAR	5
DAFTAR TABEL.....	7
BAB 1	9
1.1 LATAR BELAKANG.....	9
1.2 PERMASALAHAN	9
1.3 TUJUAN	10
1.4 MANFAAT	10
1.5 SISTEMATIKA PENULISAN	11
BAB 2	13
2.1 DESKRIPSI PERMASALAHAN.....	13
2.1.1 Durasi Proses Identifikasi yang Lama	13
2.1.2 Ketergantungan pada Subjektivitas dan Keahlian Analis.....	13
2.1.3 Tuntutan Keahlian Spesifik dalam Diferensiasi Bakteri.....	13
2.2 TEORI PENUNJANG.....	13
2.2.1 <i>Deep Learning</i>	13
2.2.2 Augmentasi Data.....	14
2.2.3 Generative Adversarial Networks (GAN)	14
2.2.4 Bakteri dan Pewarnaan Gram	16
2.2.5 Normalisasi Warna pada Citra Mikroskopis.....	18
2.3 PENELITIAN TERKAIT	19
2.3.1 Data Augmentation for Gram-stain Images based on Vector Quantized Variational AutoEncoder.....	19
2.3.2 Virtual Gram Staining of Label-free Bacteria using Dark-field Microscopy and Deep Learning	20
2.3.3 CT-Based Pelvic T1-Weighted MR Image Synthesis Using UNet, UNet++ and Cycle-Consistent Generative Adversarial Network (Cycle-GAN)	20
BAB 3	21
3.1 DESKRIPSI SOLUSI.....	21
3.2 DESAIN SISTEM	22
3.2.1 DESAIN PENELITIAN	22
3.2.2 OBJEK DAN SUMBER DATA.....	23
3.2.3 PROSEDUR PENELITIAN	25

3.2.4 ANALISIS DATA	28
3.2.5 Diagram Sistem	29
3.2.6 RENCANA PENGUJIAN	35
BAB 4	39
4.1 Parameter Eksperimen.....	39
4.2 Karakteristik Data	40
4.2.1 Sumber Data Asli.....	40
4.2.2 Pra-pemrosesan dan Pengelompokan Kelas	41
4.2.3 Distribusi Dataset Eksperimen	42
4.2.4 Contoh Dataset	44
4.3 Tempat Ujicoba	44
4.4 Waktu Ujicoba.....	45
4.5 Spesifikasi Peralatan Ujicoba.....	45
4.5.1 <i>Hardware</i>	45
4.5.2 <i>Software</i>	46
4.6 Hasil Eksperimen dan Analisis Sementara.....	46
4.6.1 Metrik Pelatihan	47
4.6.2 Sampel Citra Sintetis	48
4.6.3 Status Implementasi Metrik Evaluasi	50
4.7 Analisis Hasil Eksperimen	50
4.7.1 Analisis Dinamika Pelatihan	50
4.7.2 Analisis Kualitatif Citra.....	51
4.7.3 Kesimpulan Interim terhadap Hipotesis	51
4.7.4 Rencana Lanjutan	52
BAB 5	53
5.1 Kesimpulan.....	53
5.2 Saran.....	53
DAFTAR PUSTAKA	55

DAFTAR GAMBAR

Gambar 2.1. Arsitektur U-Net	15
Gambar 2.2. Arsitektur PatchGAN.....	16
Gambar 3.1. Diagram Alur	30
Gambar 3.2. Diagram use case sistem	34
Gambar 4.1 Grafik Training Loss (Epoch 1-55).....	48

(halaman sengaja dikosongkan)

DAFTAR TABEL

Tabel 3.1 Komposisi Dataset DIBaS	25
Tabel 3.2 Contoh Konfigurasi Hyperparameter Model cGAN.....	27
Tabel 3.3 Skenario uji coba	37
Tabel 4.1 Parameter Pelatihan Model cGAN	39
Tabel 4.2 Distribusi Dataset Berdasarkan Himpunan Data	42
Tabel 4.3 Distribusi Data Latih Berdasarkan Kelas.....	43
Tabel 4.4 Contoh Citra dari Dataset	44
Tabel 4.5 Spesifikasi Perangkat Keras.....	46
Tabel 4.6 Spesifikasi Perangkat Lunak.....	46
Tabel 4.7 Rentang Nilai Function Loss	47
Tabel 4.8 Sampel Epoch	49

(halaman sengaja dikosongkan)

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

Di bidang medis, khususnya mikrobiologi, pewarnaan gram adalah prosedur penting yang dilakukan oleh analis untuk mengidentifikasi bakteri. Namun, ada kelemahan yang signifikan pada proses manual tersebut. Contoh nyata dari masalah ini, yaitu waktu yang dibutuhkan untuk menemukan bakteri yang lama, tidak objektif, dan bergantung pada kemampuan analis, sehingga menghasilkan hasil yang tidak konsisten [2], mengingat infeksi bakteri merupakan salah satu penyebab kematian tertinggi secara global [1]. *Deep Learning* dapat menyelesaikan masalah ini. Namun, pengembangan *Deep Learning* tersebut terhambat oleh suatu masalah dasar di bidang medis, yaitu kelangkaan data. Faktor-faktor seperti privasi pasien, biaya akuisisi, dan proses anotasi oleh ahli yang memakan waktu membuat proses pengumpulan dataset citra mikroskopis dalam jumlah besar menjadi sebuah tantangan [3].

Cara augmentasi data tradisional, seperti rotasi atau *flip*, biasanya digunakan sebagai cara pertama untuk menangani keterbatasan data. Namun demikian, metode ini tidak cocok untuk gambar bakteri yang berukuran mikro. Perubahan sederhana ini tidak hanya tidak dapat menghasilkan variasi data yang sesuai seperti data aslinya, tetapi data hasil augmentasi tradisional tersebut juga berpotensi mengubah karakteristik penting untuk proses diagnosis. Sebagai contoh, bentuk sel bakteri dan pola pewarnaan dari hasil augmentasi dengan cara tradisional dapat berubah, sehingga informasi dari bakteri tersebut tidak lagi relevan untuk proses diagnostik [3]. Supaya penambahan data relevan untuk proses diagnostik, karakteristik / ciri-ciri penting dari bakteri tentunya harus sesuai seperti gambar aslinya.

Model generatif seperti *Generative Adversarial Networks* merupakan pilihan yang lebih baik karena model tersebut dapat membuat gambar bakteri buatan yang lebih realistis. Namun, gambar yang terlihat realistis belum tentu akurat untuk diagnosis. Situasi ini diperburuk oleh kurangnya tolok ukur penilaian kuantitatif yang umum digunakan, seperti Fréchet Inception Distance (FID). Studi sebelumnya menunjukkan bahwa FID seringkali kurang peka terhadap detail morfologis dan dapat memberikan skor yang terlalu optimis, yang dapat membuat evaluasi kualitas model menjadi salah [10].

Karena itu, terdapat *validation gap* antara tuntutan validasi dari pakar mikrobiologi dengan kemampuan model generatif [11]. Saat ini, belum ada kerangka penilaian yang terstruktur dan formal guna menilai kelayakan diagnosis serta mutu gambar bakteri buatan. Dataset sintetis hasil dari model generatif yang digunakan untuk melatih model *Deep Learning* demi keperluan klinis akan amat berisiko dan tidak bisa dipertanggungjawabkan apabila tidak didukung oleh prosedur validasi yang kokoh dari para ahli.

1.2 PERMASALAHAN

1. Pembentukan model *Deep Learning* bergantung pada ketersediaan dataset yang besar dan beragam. Namun, masalah seperti privasi pasien menghambat pengumpulan data citra mikroskopis bakteri.
2. Proses pelabelan atau anotasi data oleh ahli mikrobiologi untuk membuat dataset yang siap pakai membutuhkan biaya akuisisi dan waktu yang lama untuk melakukan proses

anotasi sehingga menjadi penghambat dalam pengembangan model *Deep Learning* yang bagus.

3. Metode augmentasi tradisional dapat merusak ciri-ciri visual yang penting untuk diagnosis, seperti warna dan morfologi sel bakteri, sehingga metode tersebut tidak dapat menghasilkan keragaman data yang realistis. Dengan demikian, data yang berasal dari hasil augmentasi tradisional tersebut tidak lagi dapat diandalkan secara klinis.
4. Kegagalan dalam mengevaluasi validitas citra sintetis dengan metrik evaluasi kuantitatif yang umum digunakan, seperti FID, menunjukkan bahwa metrik tersebut kurang peka terhadap detail diagnostik penting dan dapat memberikan penilaian kualitas yang salah.
5. Belum adanya sebuah kerangka kerja evaluasi yang sistematis untuk memvalidasi kualitas dan kelayakan diagnostik dari citra bakteri sintetis yang dibuat oleh model generatif.

1.3 TUJUAN

1. Mengimplementasi dan melatih model *Conditional Generative Adversarial Network* untuk membuat citra sintetis bakteri Gram-positif dan Gram-negatif yang beragam dan terkontrol secara kelas.
2. Membangun instrumen evaluasi kualitatif yang sistematis dengan menggunakan kuesioner berbasis Skala Likert dan protokol *Visual Turing Test* untuk mengukur persepsi ahli terhadap kualitas citra sintetis secara sistematis.
3. Memvalidasi reliabilitas instrumen evaluasi melalui analisis statistik *Inter-Rater Reliability* menggunakan *expert panel*, kemudian menggunakan instrumen yang telah tervalidasi untuk mengevaluasi realisme, kelayakan diagnostik, dan ketiadaan artefak pada citra sintetis.

1.4 MANFAAT

Penelitian ini diharapkan dapat memberikan manfaat signifikan baik secara keilmuan maupun praktis. Secara keilmuan, penelitian ini menyediakan sebuah metodologi validasi berbasis *expert-in-the-loop* yang teruji untuk menilai kualitas diagnostik citra medis sintetis. Metodologi ini dapat direplikasi oleh penelitian lain untuk memastikan bahwa dataset sintetis layak digunakan dalam konteks klinis sebelum diimplementasikan pada *downstream tasks* seperti klasifikasi. Secara praktis, penelitian ini menghasilkan sebuah aset dataset augmentasi yang telah tersertifikasi. Manfaat utama dari dataset ini adalah sebagai sumber data latih berkualitas tinggi yang siap pakai untuk penelitian selanjutnya. Dengan adanya validasi dari ahli, peneliti di masa depan dapat langsung memanfaatkan dataset ini untuk mengembangkan model klasifikasi yang andal tanpa perlu melakukan validasi kualitas data dari awal, sehingga secara signifikan mempercepat siklus pengembangan dan meningkatkan kepercayaan terhadap hasil model *Deep Learning*.

1.5 SISTEMATIKA PENULISAN

Proposal Proyek Akhir ini disusun dengan sistematika penulisan sebagai berikut:

Bab 1 Pendahuluan

Bab ini menguraikan latar belakang yang mendasari pentingnya validasi data sintetis, merumuskan masalah terkait celah validasi antara metrik teknis dan kebutuhan klinis, menetapkan tujuan dan manfaat penelitian, serta menjelaskan sistematika penulisan.

Bab 2 Kajian Pustaka

Bab ini berisi tinjauan literatur mengenai teori dasar *Deep Learning*, *Generative Adversarial Networks*, augmentasi data, serta metodologi evaluasi citra sintetis. Bagian ini secara khusus akan membahas kelemahan metrik teknis dan membangun landasan teoretis untuk evaluasi berbasis ahli, termasuk konsep *Visual Turing Test* dan pentingnya *Inter-Rater Reliability* sebagai standar validitas ilmiah.

Bab 3 Metodologi

Bab ini menjelaskan pendekatan dan tahapan penelitian secara rinci. Cakupannya meliputi pengumpulan data, desain dan implementasi model *Conditional Generative Adversarial Networks*, serta perancangan instrumen evaluasi. Bagian ini juga merinci prosedur pelaksanaan evaluasi yang melibatkan sebuah *expert panel* untuk memungkinkan analisis reliabilitas.

Bab 4 Eksperimen dan Analisis

Bab ini menyajikan hasil dari evaluasi oleh *expert panel*. Analisis akan mencakup dua bagian utama. Pertama, hasil perhitungan *Inter-Rater Reliability* untuk menetapkan konsistensi penilaian. Kedua, setelah reliabilitas terbukti, analisis akan dilanjutkan pada skor rata-rata untuk setiap kriteria kualitas. Selain itu, bab ini akan menyajikan analisis komparatif dengan skor FID, bukan untuk mencari korelasi, melainkan untuk secara empiris mendemonstrasikan celah validasi antara metrik evaluasi otomatis dan penilaian ahli yang relevan secara klinis.

Bab 5 Penutup

Bab ini berisi kesimpulan dari seluruh rangkaian penelitian, merangkum temuan utama terkait kualitas data sintetis yang divalidasi melalui metodologi yang reliabel, serta memberikan saran untuk penelitian selanjutnya.

(halaman sengaja dikosongkan)

BAB 2

KAJIAN PUSTAKA

2.1 DESKRIPSI PERMASALAHAN

Fondasi dari pengembangan sistem diagnostik otomatis yang andal adalah pemahaman mendalam terhadap permasalahan yang ada pada metode manual. Terdapat beberapa tantangan fundamental dalam proses identifikasi bakteri secara konvensional yang mendorong kebutuhan akan data berkualitas tinggi untuk melatih model kecerdasan buatan.

2.1.1 Durasi Proses Identifikasi yang Lama

Proses identifikasi manual melibatkan serangkaian tahapan yang panjang, mulai dari persiapan sampel, prosedur pewarnaan berlapis, hingga pengamatan di bawah mikroskop [2]. Akumulasi waktu dari setiap tahapan ini menjadi signifikan, terutama dalam lingkungan klinis dengan volume sampel yang tinggi. Keterlambatan ini menjadi hambatan dalam diagnosis cepat, yang pada akhirnya memotivasi pengembangan solusi otomatis yang dapat mempercepat alur kerja. Namun, pengembangan solusi tersebut memerlukan data latih yang masif untuk dapat meniru proses ini secara efisien.

2.1.2 Ketergantungan pada Subjektivitas dan Keahlian Analis

Interpretasi citra mikroskopis sangat dipengaruhi oleh persepsi dan pengalaman individual analis. Penilaian terhadap intensitas warna, morfologi sel, dan artefak pewarnaan dapat bervariasi antar analis [2]. Subjektivitas ini menyoroti kebutuhan akan sistem objektif berbasis deep learning. Akan tetapi, untuk membangun sistem yang objektif, model deep learning harus dilatih pada dataset yang tidak hanya besar, tetapi juga mencakup berbagai variasi yang mungkin ditemui, sehingga model tidak hanya meniru subjektivitas dari satu analis saja.

2.1.3 Tuntutan Keahlian Spesifik dalam Diferensiasi Bakteri

Pembedaan antara bakteri Gram-positif dan Gram-negatif menuntut keahlian tinggi, terutama pada langkah dekolorisasi yang kritis [2]. Kesalahan pada tahap ini dapat menyebabkan misklasifikasi yang berdampak pada pemilihan terapi. Tantangan ini menegaskan bahwa setiap data yang digunakan untuk melatih model deep learning harus memiliki fitur diagnostik yang akurat dan jelas. Oleh karena itu, memastikan validitas setiap sampel data, baik asli maupun sintesis, menjadi prasyarat mutlak sebelum dapat digunakan untuk mengembangkan alat bantu diagnostik.

2.2 TEORI PENUNJANG

2.2.1 Deep Learning

Deep Learning merupakan cabang dari *Machine Learning* yang menjadi dasar bagi banyak sistem analisis citra modern. Arsitektur DL, seperti *Convolutional Neural Networks* (CNN), memiliki kapasitas untuk mempelajari fitur-fitur kompleks dari data visual. Namun, kinerjanya sangat bergantung pada ketersediaan data latih yang besar, beragam, dan representatif. Kelangkaan data dalam domain medis inilah yang menjadi motivasi utama di balik penelitian ini. Meskipun penelitian ini tidak bertujuan untuk membangun atau mengevaluasi model klasifikasi, pemahaman tentang DL tetap krusial untuk memberikan

konteks mengapa augmentasi data berkualitas tinggi sangat dibutuhkan sebagai fondasi untuk *downstream tasks* di masa depan.

2.2.2 Augmentasi Data

Augmentasi data adalah serangkaian teknik yang digunakan untuk meningkatkan jumlah dan keragaman data pelatihan secara artifisial dengan membuat versi modifikasi dari data yang sudah ada. Tujuan fundamental dari augmentasi data adalah untuk mengurangi *overfitting*, yaitu sebuah kondisi di mana model belajar terlalu spesifik pada data latih sehingga gagal memberikan prediksi yang akurat pada data baru. Dengan menyajikan variasi data yang lebih kaya kepada model selama pelatihan, augmentasi memaksa model untuk mempelajari fitur-fitur yang lebih robust dan invarian. Oleh karena itu, augmentasi menjadi strategi yang sangat penting untuk membangun model yang andal dan memiliki kemampuan generalisasi yang baik, terutama dalam skenario kelangkaan data seperti pada citra medis.

Meskipun bermanfaat, teknik augmentasi konvensional seperti rotasi dan flipping atau perubahan kecerahan dan kontras memiliki keterbatasan yang signifikan. Teknik-teknik ini seringkali gagal menciptakan variasi data yang benar-benar kompleks dan realistis sebagaimana yang dibutuhkan oleh model untuk mempelajari representasi fitur yang mendalam. Dalam konteks citra pewarnaan Gram, transformasi yang tidak hati-hati bahkan berisiko merusak integritas informasi diagnostik yang krusial, misalnya mengubah fitur warna yang menjadi pembeda utama antara bakteri Gram-positif dan Gram-negatif [3]. Keterbatasan augmentasi konvensional inilah yang mendorong perlunya eksplorasi metode augmentasi data yang lebih canggih seperti model generatif.

2.2.3 Generative Adversarial Networks (GAN)

2.2.3.1 Prinsip Dasar dan Arsitektur GAN

GAN adalah kelas model generatif yang merevolusi bidang *Deep Learning* dengan kemampuannya menghasilkan data sintesis yang sangat realistis. Arsitektur GAN terdiri dari dua jaringan saraf yang saling bersaing, yaitu Generator dan Diskriminator. Generator bertugas untuk mempelajari distribusi data asli dan menghasilkan sampel data baru yang palsu, sementara Diskriminator bertugas untuk membedakan antara data asli dan data palsu dari Generator. Proses *adversarial* ini secara terus-menerus mendorong Generator untuk menghasilkan data yang semakin berkualitas tinggi dan secara statistik tidak dapat dibedakan dari data asli. Mekanisme inilah yang menjadi inti dari solusi augmentasi data yang diusulkan dalam penelitian ini.

2.2.3.2 Conditional Generative Adversarial Networks (cGAN)

cGAN merupakan pengembangan dari arsitektur GAN standar yang memungkinkan proses generasi data dapat dikontrol dengan memberikan informasi tambahan atau kondisi, seperti label kelas [5]. Perbedaan utama ini sangat krusial bagi penelitian ini, karena memungkinkan model untuk secara spesifik diarahkan untuk menghasilkan citra dari kelas tertentu, misalnya Gram-positif atau Gram-negatif. Dengan kemampuan ini, augmentasi data dapat dilakukan secara terarah untuk mengatasi masalah *class imbalance* dan meningkatkan


keragaman data intra-kelas secara strategis. Oleh karena itu, cGAN menawarkan kontrol yang jauh lebih baik dibandingkan GAN standar untuk tugas augmentasi data.

2.2.3.3 U-Net

Untuk menghasilkan citra bakteri yang realistis, jaringan generator didesain menggunakan arsitektur U-Net. Arsitektur ini dinamakan U-Net karena strukturnya secara visual membentuk huruf "U". U-Net sangat efektif untuk tugas-tugas yang berkaitan dengan citra medis karena kemampuannya mempertahankan detail-detail penting selama proses generasi citra.

1. **Jalur Encoder:** Bagian ini berfungsi sebagai *downsampling* yang secara bertahap mengurangi ukuran lebar dan tinggi citra sambil memperdalam representasi fiturnya. Tujuannya adalah untuk menangkap informasi kontekstual atau inti dari citra input. Setiap langkah pada jalur ini biasanya terdiri dari lapisan konvolusi yang diikuti oleh fungsi aktivasi dan lapisan pooling atau konvolusi dengan stride untuk mengurangi dimensi.
2. **Jalur Decoder:** Bagian ini bekerja sebagai *upsampling*. Tujuannya adalah untuk merekonstruksi citra dari representasi fitur yang telah dipelajari oleh encoder, hingga kembali ke ukuran resolusi aslinya. Proses ini dilakukan menggunakan lapisan *transposed convolution*.

Karakteristik kunci dari U-Net adalah adanya *skip connections*. Koneksi ini menghubungkan secara langsung *output* dari lapisan di jalur encoder ke lapisan yang bersesuaian di jalur decoder. Mekanisme ini memungkinkan informasi fitur level rendah yang mungkin hilang selama proses *downsampling* untuk dapat digunakan kembali selama proses rekonstruksi, sehingga citra yang dihasilkan memiliki detail yang tajam dan akurat [7].



Sumber: <https://translate.google.com/translate?u=https://viso.ai/deep-learning/u-net-a-comprehensive-guide-to-its-architecture-and-applications/&hl=id&sl=en&tl=id&client=imgs>

Gambar 2.1. Arsitektur U-Net


2.3.3.4 PatchGAN

Untuk melengkapi generator, jaringan discriminator dibangun menggunakan arsitektur PatchGAN [7]. Berbeda dengan arsitektur discriminator standar yang menganalisis seluruh citra dan menghasilkan satu nilai tunggal untuk menentukan asli atau palsu, PatchGAN bekerja dengan cara yang lebih lokal dan efisien.

Mekanisme kerja PatchGAN adalah sebagai berikut:

1. **Evaluasi Berbasis Patch:** PatchGAN memindai citra dan membaginya menjadi serangkaian potongan-potongan kecil berukuran $N \times N$ piksel yang saling tumpang tindih.
2. **Penilaian Lokal:** Jaringan ini kemudian menilai realisme dari setiap patch secara independen.
3. **Output Berupa Matriks:** Hasil akhir dari PatchGAN bukanlah satu nilai probabilitas, melainkan sebuah matriks di mana setiap elemennya merepresentasikan tingkat "keaslian" dari setiap patch lokal pada citra. Nilai-nilai dalam matriks ini kemudian dirata-ratakan untuk mendapatkan keputusan akhir.

Arsitektur ini sangat efektif karena memaksa generator untuk fokus menghasilkan detail dan tekstur yang realistis di seluruh bagian citra. Untuk citra mikroskopis, di mana detail halus seperti tekstur dinding sel dan konsistensi pewarnaan sangat penting, PatchGAN menjadi arsitektur pilihan yang ideal.



Sumber: https://www.researchgate.net/figure/The-architecture-of-PatchGAN-discriminator_fig4_366627726

Gambar 2.2. Arsitektur PatchGAN

2.3.3.5 Fungsi Loss pada GAN/cGAN

Pelatihan GAN dan cGAN dioptimalkan melalui fungsi *loss* yang bersifat *adversarial*. Proses ini seperti permainan antara Generator dan Diskriminator, yang diatur oleh sebuah fungsi tujuan. Menurut penelitian oleh Qadir et al. [7], fungsi *loss* untuk cGAN dapat dirumuskan sebagai berikut:


$$\text{LcGAN}(G, D) = \mathbb{E}_{x \sim P_{\text{data}}(x)} [\log D(X, Y)] + \mathbb{E}_{x \sim P_{\text{data}}(x)} [\log(1 - D(X, G(X)))]$$

Fungsi *loss* ini terdiri dari dua komponen utama. Bagian pertama, $\mathbb{E}_{x \sim P_{\text{data}}(x)} [\log D(X, Y)]$, bertujuan memaksimalkan probabilitas bahwa Diskriminator akan mengklasifikasikan data asli (X) dengan benar sesuai labelnya (Y). Sementara itu, bagian kedua, $\mathbb{E}_{x \sim P_{\text{data}}(x)} [\log(1 - D(X, G(X)))]$, melatih Generator (G) untuk meminimalkan probabilitas Diskriminator mengenali data palsu ($G(X)$) sebagai data palsu. Dengan menambahkan label kelas (Y) sebagai informasi kondisional, model dapat diarahkan untuk menghasilkan citra yang tidak hanya realistis tetapi juga sesuai dengan kelas yang diinginkan.

2.2.4 Bakteri dan Pewarnaan Gram

Pewarnaan Gram merupakan metode fundamental dalam mikrobiologi yang dikembangkan oleh Hans Christian Gram untuk mengklasifikasikan bakteri. Namun, sebelum

pewarnaan dilakukan, terdapat serangkaian langkah persiapan sampel yang krusial untuk memastikan kualitas hasil akhir.



Sumber: <https://biologydictionary.net/wp-content/uploads/2021/01/gram-positive-vs.-gram-negative.jpg>

Gambar 2.3. Bakteri Gram Negatif dan Positif

- **Persiapan Sampel**

Tahapan persiapan menjadi fondasi dari keseluruhan proses diagnostik dan secara langsung memengaruhi kualitas citra yang dihasilkan. Tiga langkah utamanya adalah:

1. **Pengambilan Sampel:** Sampel biologis diambil dari lokasi yang diduga terinfeksi, seperti usapan dari luka, cairan tubuh, atau dahak.
2. **Pembuatan Apusan:** Sampel kemudian disebar dalam lapisan tipis di atas kaca objek yang bersih. Tujuannya adalah agar sel-sel bakteri individual dapat diamati dengan jelas tanpa tumpang tindih.
3. **Fiksasi:** Setelah apusan mengering, dilakukan fiksasi. Umumnya dengan melewati kaca objek di atas api. Proses ini bertujuan untuk membunuh bakteri, melekatkannya dengan kuat pada kaca objek, dan meningkatkan kemampuannya menyerap pewarna. Setelah sampel siap, barulah prosedur pewarnaan Gram dapat dimulai.

- **Prinsip Dasar**

Dasar dari metode ini terletak pada perbedaan struktural dinding sel bakteri.

- Bakteri Gram-Positif memiliki lapisan peptidoglikan yang tebal. Struktur ini mampu menahan kompleks pewarna utama (ungu kristal-iodin) bahkan setelah proses dekolorisasi dengan alkohol. Hasilnya, bakteri akan mempertahankan warna ungu gelap.
- Bakteri Gram-Negatif memiliki lapisan peptidoglikan yang jauh lebih tipis dan dilindungi oleh membran luar. Saat dekolorisasi, alkohol akan melarutkan membran luar dan menghilangkan pewarna utama. Oleh karena itu, bakteri ini akan menyerap safranin dan tampak berwarna merah atau merah muda.

- **Prosedur dan Interpretasi Hasil**

Prosedur pewarnaan melibatkan empat langkah penting yang menghasilkan perbedaan warna yang jelas:

- **Pewarnaan Primer:** Semua bakteri akan menyerap pewarna ini dan menjadi ungu.

- **Mordant:** Iodin membentuk kompleks yang lebih besar dengan ungu kristal, menguncinya di dalam sel.
- **Dekolorisasi:** Dekolorasi adalah langkah paling kritis. Pada bakteri Gram-positif, kompleks warna terperangkap. Sebaliknya, pada bakteri Gram-negatif, kompleks warna tercuci bersih.
- **Pewarnaan Tandingan:** Mewarnai bakteri Gram-negatif yang telah kehilangan warna menjadi merah/merah muda, sementara bakteri Gram-positif tetap ungu.

Interpretasi hasil tidak hanya melihat warna, tetapi juga morfologi dan susunannya. Informasi ini krusial untuk diagnosis awal infeksi dan memandu pemilihan antibiotik, yang menegaskan pentingnya akurasi dalam klasifikasi citra berbasis *Deep Learning*.

2.2.5 Normalisasi Warna pada Citra Mikroskopis

Dalam domain medis, validasi kualitas citra sintetis menghadapi tantangan unik yang tidak dapat dijawab sepenuhnya oleh metrik kuantitatif otomatis. Metrik populer seperti FID, meskipun umum digunakan, memiliki keterbatasan fundamental. Sebuah studi komprehensif oleh Deo et al. (2024) secara empiris menunjukkan bahwa metrik-metrik ini tidak hanya berkorelasi buruk dengan kegunaan diagnostik, tetapi juga dapat memberikan skor yang terlalu optimis dan menyesatkan. Lebih mengkhawatirkan lagi, penelitian tersebut menunjukkan ketidakpekaan yang mendalam terhadap perubahan morfologis lokal yang relevan secara klinis [10]. Artinya, sebuah citra sintetis bisa mendapatkan skor FID yang tinggi meskipun mengandung artefak halus atau distorsi yang dapat mengubah diagnosis secara total, menciptakan risiko keamanan yang tidak dapat diterima.

Kegagalan metrik otomatis ini menegaskan bahwa validasi *expert-in-the-loop* adalah *gold standard* yang tak tergantikan untuk menilai kualitas dan kelayakan citra medis sintetis [11]. Namun, sebuah *gold standard* hanya bernilai jika pengukurannya konsisten, objektif, dan dapat direproduksi. Memperlakukan opini seorang ahli tunggal sebagai kebenaran absolut adalah sebuah kelemahan metodologis yang fatal, karena penilaian subjektif secara inheren rentan terhadap variasi antar individu yang dapat timbul dari perbedaan pengalaman, kriteria internal, atau bahkan kelelahan [3].

Untuk mengatasi kelemahan ini, penelitian yang ketat harus beralih dari penilaian oleh satu ahli menjadi evaluasi oleh *expert panel* dan mengukur konsistensi mereka secara statistik. Di sinilah konsep *Inter-Rater Reliability* (IRR) menjadi pilar fundamental. IRR adalah ukuran statistik yang secara kuantitatif menilai tingkat kesepakatan di antara beberapa penilai independen yang mengevaluasi objek yang sama. Tingkat IRR yang tinggi memberikan bukti empiris bahwa skor yang diberikan oleh para ahli benar-benar mencerminkan kualitas intrinsik dari citra yang dinilai, bukan sekadar *random noise* yang berasal dari variabilitas penilai. Dengan kata lain, IRR adalah prasyarat untuk menetapkan objektivitas dari sebuah instrumen evaluasi kualitatif.

Kerangka kerja evaluasi dalam penelitian ini mengadopsi pendekatan *Visual Turing Test* [12], di mana *expert panel* akan menilai serangkaian citra campuran secara dengan cara *blind test*. Untuk mengkuantifikasi penilaian subjektif secara terstruktur, instrumen kuesioner dengan skala Likert akan digunakan. Dimensi evaluasi, seperti realisme, kelayakan diagnostik, dan ketiadaan artefak dipilih berdasarkan jurnal penelitian terdahulu. Ketiganya merupakan

dimensi evaluasi yang umum digunakan dalam literatur sintesis citra medis untuk memastikan kualitas citra secara komprehensif [13]. Dimensi-dimensi ini adalah sebagai berikut:

- **Realisme Gambar:** Dimensi ini menilai apakah citra sintetis secara visual tidak dapat dibedakan dari citra asli. Dalam studi evaluasi GAN untuk sintesis citra MRI panggul oleh Kalantar et al., empat orang ahli radiologi diminta untuk menilai citra dengan cara *blindly classify* untuk membedakan citra asli dan sintetis yang secara langsung mendukung penggunaan dimensi ini sebagai fondasi evaluasi [14].
- **Kelayakan Diagnostik:** Dimensi ini mengukur nilai praktis dari citra. Sebuah citra bisa saja terlihat realistis, tetapi mungkin tidak berguna jika karakter / ciri-ciri yang menjadi kunci untuk diagnosis kabur atau hilang. Kerangka kerja evaluasi SPINE yang diusulkan oleh Ntampakis et al. untuk citra paru-paru sintetis secara eksplisit menekankan pentingnya kriteria klinis untuk memastikan citra tersebut mempertahankan integritas dan kegunaan diagnostik [13].
- **Ketiadaan Artefak:** Model GAN dikenal dapat menghasilkan anomali visual atau halusinasi yang tidak ada di dunia nyata. Studi oleh Kalantar et al. secara spesifik mengidentifikasi beberapa jenis artefak pada citra MRI panggul sintetis berdasarkan tinjauan ahli, termasuk kontras yang tidak realistis, tekstur grainy, dan anomali lainnya yang menegaskan krusialnya penilaian terhadap artefak untuk mencegah potensi misdiagnosis [14].

Dengan membangun kerangka evaluasi yang tidak hanya melibatkan *expert panel* tetapi juga secara eksplisit mengukur konsistensi penilaian mereka pada ketiga dimensi di atas melalui IRR, penelitian ini memastikan bahwa kesimpulan yang ditarik tentang kualitas citra sintetis tidak hanya didasarkan pada persepsi, tetapi pada data yang telah terbukti valid dan reliabel secara ilmiah. Pendekatan ini secara langsung menjawab kelemahan metodologis dalam validasi citra medis dan memperkuat kontribusi penelitian secara signifikan.

2.3 PENELITIAN TERKAIT

2.3.1 Data Augmentation for Gram-stain Images based on Vector Quantized Variational AutoEncoder

Penelitian yang dilakukan oleh Shwetha et al. [3] mengatasi masalah yang sangat identik dengan penelitian ini, yaitu kelangkaan data citra mikroskopis bakteri Gram. Para peneliti menyoroti bahwa performa model *Deep Learning* sangat bergantung pada dataset yang besar dan beragam, yang sulit diperoleh di bidang medis. Untuk mengatasi masalah ini, mengusulkan penelitian tersebut penggunaan *Vector Quantized Variational AutoEncoder* (VQ-VAE), sebuah model generatif, untuk melakukan augmentasi data. Model ini dilatih untuk menghasilkan citra bakteri Gram-positif dan kultur *direct smear* yang realistis. Temuan utama dalam penelitian tersebut menunjukkan bahwa augmentasi menggunakan VQ-VAE berhasil meningkatkan kinerja klasifikasi secara signifikan, dengan akurasi model klasifikasi yang dikembangkan meningkat rata-rata sebesar 20%, yang divalidasi menggunakan metrik *Area Under the Curve*.

Penelitian ini sangat relevan karena memiliki tujuan yang sama, yaitu menggunakan model generatif untuk augmentasi data citra bakteri Gram. Namun, perbedaan fundamental terletak pada cara validasinya. Penelitian tersebut mengukur keberhasilan augmentasi melalui peningkatan kinerja pada *downstream tasks*. Penelitian yang diusulkan ini akan mengambil

langkah yang lebih mendasar dengan berfokus pada validasi kualitas, realisme, dan kelayakan diagnostik dari citra sintetis itu sendiri melalui penilaian ahli, sebuah aspek yang tidak dibahas secara mendalam pada penelitian tersebut.

2.3.2 Virtual Gram Staining of Label-free Bacteria using Dark-field Microscopy and Deep Learning

Selanjutnya, penelitian oleh Işıl et al. [2] menunjukkan kemampuan cGAN untuk menghasilkan citra bakteri yang sangat realistis dengan karakteristik pewarnaan yang benar, meskipun untuk tujuan yang berbeda. Penelitian ini berfokus pada konsep pewarnaan virtual, di mana model cGAN dilatih untuk mengubah citra mikroskopis medan *dark-field* dari bakteri yang tidak diwarnai menjadi citra seolah-olah telah melalui proses pewarnaan Gram. Penelitian tersebut menggunakan bakteri *Escherichia coli* (Gram-negatif) dan *Listeria innocua* (Gram-positif) sebagai objek penelitian. Hasilnya menunjukkan bahwa model berhasil menghasilkan citra pewarnaan virtual dengan akurasi yang sangat tinggi (presisi 95.5% dan F1-score 96%).

Studi ini sangat mendukung kelayakan penelitian yang diusulkan karena memberikan bukti kuat bahwa cGAN mampu mempelajari dan mereplikasi fitur visual yang sangat kompleks dan spesifik yang membedakan bakteri Gram-positif dan Gram-negatif. Perbedaanannya terletak pada fokus aplikasi. Sementara penelitian tersebut bertujuan untuk pewarnaan virtual, penelitian ini akan memanfaatkan kemampuan generasi citra cGAN secara langsung untuk augmentasi data. Lebih penting lagi, penelitian ini akan merancang sebuah metodologi untuk memvalidasi secara kualitatif apakah citra yang dihasilkan dapat diterima untuk penggunaan diagnostik oleh analis laboratorium, mengisi kesenjangan antara kemampuan teknis generasi citra dan validasi klinisnya.

2.3.3 CT-Based Pelvic T1-Weighted MR Image Synthesis Using UNet, UNet++ and Cycle-Consistent Generative Adversarial Network (Cycle-GAN)

Penelitian oleh Kalantar et al. [14] memberikan contoh penerapan GAN untuk sintesis citra medis, yaitu MRI dari CT scan, yang dievaluasi dengan pendekatan yang sangat relevan dengan fokus baru penelitian ini. Para peneliti menggunakan beberapa arsitektur, termasuk Cycle-GAN, untuk menghasilkan citra MRI panggul sintetis dari data CT scan dengan tujuan utama menciptakan data latih MRI. Salah satu temuan penting dari penelitian ini bukan hanya pada kualitas citra yang dihasilkan, tetapi pada cara mengevaluasinya. Selain metrik kuantitatif, penelitian tersebut melakukan uji kualitatif yang melibatkan empat orang ahli radiologi. Para ahli tersebut diminta untuk menilai citra secara *blind* dan memberikan komentar spesifik mengenai artefak yang ditemukan, seperti kontras tulang yang tidak realistis dan tekstur *grainy*. Penelitian ini secara konseptual sangat kuat dan relevan karena merupakan contoh nyata dari pendekatan *expert-in-the-loop* yang akan diadopsi dalam penelitian ini. Relevansinya terletak pada penggunaan penilaian ahli sebagai pilar evaluasi utama dan identifikasi spesifik terhadap artefak visual. Kesenjangan penelitian yang akan diisi oleh penelitian ini adalah menerapkan kerangka kerja evaluasi berbasis ahli yang telah terbukti berhasil di citra radiologi ini ke dalam domain spesifik citra mikroskopis bakteri Gram, yang memiliki karakteristik visual dan tantangan diagnostik yang unik.

BAB 3 METODOLOGI

3.1 DESKRIPSI SOLUSI

Kelemahan mendasar dari augmentasi data konvensional adalah ketidakmampuannya untuk menghasilkan variasi data yang realistis secara biologis tanpa mengorbankan integritas fitur diagnostik. Teknik transformatif sederhana seperti rotasi, flipping, atau perubahan fotometrik hanya menghasilkan modifikasi terbatas dari data yang ada dan seringkali gagal mencerminkan keragaman kompleks yang ditemukan di dunia nyata [6]. Lebih krusial lagi, pada citra mikroskopis pewarnaan Gram, transformasi yang tidak terkontrol justru berisiko merusak fitur pembeda utama. Sebagai contoh, augmentasi fotometrik seperti perubahan kecerahan atau kontras yang ekstrem dapat mengaburkan perbedaan antara warna ungu dan merah, sebuah efek yang secara digital meniru dekolonisasi yang tidak tepat yang sering menjadi sumber kesalahan dalam proses pewarnaan manual [2]. Hal ini menyebabkan citra hasil augmentasi kehilangan nilai diagnostiknya. Sementara itu, transformasi geometris seperti rotasi dan zoom dapat menghasilkan artefak visual dan *blurring* akibat interpolasi piksel yang berpotensi membuat model keliru dalam mempelajari morfologi sel yang sebenarnya. Keterbatasan ini menegaskan perlunya pendekatan augmentasi yang lebih canggih.

Menjawab tantangan tersebut, penelitian ini mengusulkan solusi augmentasi generatif menggunakan cGAN. Berbeda secara fundamental dengan metode konvensional, cGAN tidak hanya mentransformasi citra yang ada, tetapi mempelajari distribusi data asli untuk menghasilkan sampel yang sepenuhnya baru namun tetap konsisten pada karakteristik kelasnya. Penggunaan kondisional menjadi kunci, di mana proses generasi data dapat diarahkan secara spesifik menggunakan label Gram-positif atau Gram-negatif. Dengan demikian, cGAN dapat secara terarah menghasilkan citra sintetis yang tidak hanya beragam dan realistis, tetapi juga secara strategis dapat digunakan untuk mengatasi masalah kelangkaan atau ketidakseimbangan data pada kelas tertentu.

Keunggulan utama solusi ini terletak pada mekanisme pelatihan adversarial yang unik. Jaringan Generator pada cGAN tidak beroperasi secara acak, melainkan dilatih secara sistematis. Jaringan Generator tersebut secara terus-menerus ditantang oleh jaringan Diskriminator untuk menghasilkan citra yang secara statistik tidak dapat dibedakan dari data asli pada kelas yang ditentukan. Proses ini memaksa Generator untuk mempelajari dan meniru fitur-fitur visual esensial yang menjadi dasar pembeda, seperti retensi warna dan morfologi sel. Kelayakan pendekatan ini didukung kuat oleh keberhasilan penelitian lain yang menunjukkan kemampuan GAN dalam meniru transformasi citra yang kompleks, seperti pada aplikasi pewarnaan virtual [2]. Kemampuan GAN mereplikasi proses fisika-kimia yang rumit dalam pewarnaan menunjukkan kapasitasnya untuk memodelkan hubungan sebab-akibat visual yang kompleks. Dalam konteks ini, sebab adalah perbedaan struktur dinding sel bakteri dan akibat adalah retensi warna yang khas. Dengan demikian, argumen ini mendukung hipotesis bahwa cGAN dalam penelitian ini memiliki potensi untuk mempelajari dan mereplikasi fitur-fitur visual tersebut. Artinya, data sintetis yang dihasilkan tidak hanya akan terlihat realistis, tetapi juga memiliki fitur diagnostik yang konsisten dengan kelasnya, mengatasi kelemahan utama dari augmentasi konvensional. Solusi berbasis cGAN ini menawarkan cara yang lebih fundamental untuk memperkaya dataset. Tujuannya bukan sekadar menambah jumlah data,

melainkan menghasilkan aset dataset sintetis yang valid secara klinis dan dapat dipercaya oleh ahli, sehingga layak digunakan untuk berbagai aplikasi hilir, termasuk pelatihan model *Deep Learning* di masa depan.

3.2 DESAIN SISTEM

3.2.1 DESAIN PENELITIAN

3.2.1.1 Pendekatan Penelitian

Penelitian ini mengadopsi pendekatan evaluasi kualitatif terstruktur yang divalidasi secara statistik, yang berpusat pada penilaian oleh *expert panel*. Kerangka kerja ini secara fundamental lebih kuat daripada evaluasi oleh seorang penilai tunggal, karena bertujuan untuk menghasilkan kesimpulan yang objektif dan dapat digeneralisasi, bukan sekadar opini perorangan.

Inti dari pendekatan ini adalah adaptasi dari *Visual Turing Test* yang diperkaya. Sebuah panel yang terdiri dari minimal tiga analis laboratorium akan melakukan *blind evaluation* terhadap serangkaian citra campuran. Namun, alih-alih hanya memberikan label biner asli atau palsu, para ahli akan memberikan penilaian kuantitatif menggunakan skala Likert pada tiga dimensi kualitas yang telah ditetapkan.

Langkah paling krusial dalam pendekatan ini adalah validasi instrumen evaluasi itu sendiri. Sebelum menarik kesimpulan apa pun tentang kualitas citra, penelitian ini akan terlebih dahulu mengukur tingkat kesepakatan di antara para ahli menggunakan analisis statistik *Inter-Rater Reliability*. Hanya setelah reliabilitas instrumen terbukti tinggi, data penilaian dari panel akan diagregasi dan dianalisis untuk menguji hipotesis penelitian. Pendekatan dua tahap ini—pertama validasi metode, kemudian penggunaan metode—memastikan bahwa hasil penelitian dibangun di atas fondasi metodologis yang kokoh dan dapat dipertanggungjawabkan secara ilmiah.

3.2.1.2 Variabel dan Hipotesis Penelitian

Variabel dalam penelitian ini didefinisikan secara operasional untuk memastikan pengukuran yang jelas dan konsisten dalam kerangka kerja evaluasi oleh *expert panel*.

- **Variabel Independen:** Sumber citra, yang terdiri dari dua level: (1) Citra bakteri asli dari Expert-Testing Set dan (2) Citra bakteri sintetis yang dihasilkan oleh model cGAN.
- **Variabel Dependen:** Kualitas citra, yang diukur melalui serangkaian metrik berjenjang:
 1. **Reliabilitas Antar-Penilai (IRR):** IRR merupakan variabel dependen utama pada tahap validasi metodologi. Variabel ini mengukur tingkat konsistensi atau kesepakatan di antara para penilai dalam panel. Diukur menggunakan statistik yang sesuai.
 2. **Penilaian Kualitatif Panel:** Setelah IRR terbukti tinggi, skor rata-rata agregat dari seluruh *expert panel* akan dihitung. Dimensi yang dinilai menggunakan Skala Likert 1-5 mencakup:
 - **Realisme Visual:** Seberapa mirip citra dengan citra mikroskopis nyata yang biasa ditemui dalam praktik.

- **Kelayakan Diagnostik:** Apakah karakteristik / ciri-ciri penting, seperti warna Gram, morfologi bakteri, cukup jelas dan akurat untuk keperluan identifikasi.
 - **Ketiadaan Artefak:** Apakah terdapat anomali visual, seperti distorsi, *noise*, bentuk tidak wajar, yang tidak ada pada citra aslinya.
3. **Akurasi Pembedaan Panel:** Persentase rata-rata keberhasilan seluruh panel dalam menebak label citra selama sesi *Visual Turing Test*.

Berdasarkan kerangka tersebut, hipotesis penelitian dirumuskan sebagai berikut:

- **Tujuan Metodologis Utama:** Menetapkan bahwa instrumen evaluasi kualitatif yang dirancang memiliki IRR yang tinggi ketika digunakan oleh *expert panel*. Hal tersebut merupakan prasyarat sebelum hipotesis lain dapat diuji.
- **Hipotesis 1 (H_1 - Kualitas Diagnostik):** Dengan asumsi reliabilitas telah tercapai, citra sintetis yang dihasilkan oleh model cGAN akan dinilai memiliki kualitas yang tinggi. Hal ini ditunjukkan dengan skor rata-rata panel yang tidak berbeda secara signifikan dari skor untuk citra asli pada ketiga dimensi penilaian.
- **Hipotesis 2 (H_2 - Indistinguishability):** Dengan asumsi reliabilitas telah tercapai, citra sintetis akan secara visual tidak dapat dibedakan dari citra asli. Hal ini ditunjukkan dengan akurasi pembedaan rata-rata panel yang tidak signifikan lebih baik dari tingkat tebakan acak.

3.2.2 OBJEK DAN SUMBER DATA

3.2.2.1 Populasi dan Sampel Penelitian

- **Populasi Target:** Populasi target dalam penelitian ini adalah seluruh citra mikroskopis digital hasil prosedur pewarnaan Gram yang secara jelas menampilkan morfologi bakteri Gram-positif dan Gram-negatif.
- **Populasi Terjangkau:** Populasi terjangkau yang digunakan dalam penelitian ini adalah dataset publik Digital Image of Bacterial Species (DIBaS). Dataset ini disusun oleh *Chair of Microbiology* di Universitas Jagiellonian, Krakow, Polandia. DIBaS merupakan dataset standar yang berisi total 669 citra mikroskopis digital dengan format warna RGB. Karakteristik data dalam populasi terjangkau ini meliputi:
 - **Keragaman Spesies:** Dataset mencakup 33 genus dan spesies bakteri yang berbeda.
 - **Resolusi Tinggi:** Setiap citra memiliki resolusi asli 2048×1532 piksel, memberikan detail morfologi yang sangat tinggi.
 - **Akuisisi Terstandar:** Citra diambil menggunakan mikroskop biologis Olympus CX31 dengan kamera SC30, menggunakan lensa objektif 100x.
- **Sampel Penelitian:** Sampel penelitian ini meliputi keseluruhan citra dari dataset DIBaS. Namun, karena resolusi asli citra (2048×1532) terlalu besar untuk diproses secara langsung oleh model Deep Learning dengan keterbatasan memori GPU, maka unit sampel yang digunakan dalam eksperimen bukanlah citra utuh, melainkan potongan citra.

3.2.2.2 Penentuan Sampel untuk Evaluasi Ahli

Untuk melaksanakan evaluasi kualitatif oleh ahli, sebuah set pengujian khusus akan dirancang. Selain diminta untuk menebak label citra untuk mengukur tingkat diskriminasi seperti pada *Visual Turing Test* klasik, tugas utama analis adalah memberikan skor untuk setiap citra berdasarkan tiga kriteria yang telah ditentukan.

- **Komposisi:** Set pengujian akan terdiri dari campuran citra bakteri asli dan citra sintetis.
- **Jumlah:** Untuk mendapatkan analisis statistik yang bermakna, akan disiapkan total 50 citra, yang terdiri dari 25 citra asli dan 25 citra sintetis. Komposisi ini akan dirahasiakan dari analis / *blind evaluation*.
- **Tujuan:** Analis laboratorium akan diminta untuk:
 1. Memberi label pada setiap citra.
 2. Memberikan skor Skala Likert 1-5 untuk setiap citra berdasarkan tiga kriteria: Realisme Visual, Kelayakan Diagnostik, dan Ketiadaan Artefak.

Data yang terkumpul dari proses ini akan digunakan secara langsung untuk menguji hipotesis penelitian.

3.2.2.3 Teknik Sampling untuk Pelatihan dan Evaluasi

Untuk memastikan proses pelatihan model generatif dan validasi oleh ahli berjalan secara objektif dan tidak bias, dataset akan dibagi menggunakan teknik stratified random sampling. Pendekatan ini dipilih untuk menjaga agar proporsi kelas tetap konsisten di setiap himpunan data yang dibentuk. Menjaga distribusi kelas yang representatif merupakan praktik fundamental dalam pengembangan model *Deep Learning* untuk citra medis, di mana ketidakseimbangan data sering terjadi [1], [3].

Dataset akan dibagi menjadi dua himpunan utama dengan peran yang berbeda:

1. **Training Set:** Sebesar 76.5% dari total data (4.574 citra). Himpunan ini digunakan secara eksklusif untuk melatih model cGAN. Dengan porsi data terbesar, model diharapkan dapat mempelajari distribusi dan variasi fitur visual bakteri secara komprehensif, mulai dari struktur sel hingga karakteristik warna pewarnaan.
2. **Validation Set:** Sebesar 11.8% dari total data (704 citra). Himpunan ini digunakan secara internal selama proses pelatihan untuk memantau konvergensi model dan mengevaluasi kinerja sementara, serta mencegah terjadinya overfitting sebelum model diuji lebih lanjut.
3. **Test Set:** Sebesar 11.7% dari total data. Himpunan ini diisolasi sepenuhnya dan tidak pernah dilihat oleh model cGAN selama proses pelatihan. Himpunan ini berfungsi sebagai sumber citra asli yang akan disajikan kepada analis laboratorium dalam sesi evaluasi kualitatif.

Pemisahan yang tegas ini sangat krusial. Dengan menggunakan himpunan data yang terpisah untuk pengujian oleh ahli, penelitian ini dapat menjamin bahwa evaluasi yang diberikan benar-benar mengukur kemampuan generalisasi model cGAN dalam menghasilkan citra yang realistis, bukan sekadar mereplikasi data yang pernah dilihatnya. Pendekatan evaluasi menggunakan data tak terlihat yang divalidasi oleh ahli manusia merupakan gold standard untuk menilai kualitas citra medis sintetis, seperti yang ditunjukkan dalam penelitian sintesis citra MRI oleh Kalantar et al. [14] dan evaluasi citra perfusi miokardial oleh Higaki et

al. [12]. Oleh karena itu, teknik sampling ini tidak hanya mendukung proses pelatihan, tetapi juga menjadi fondasi untuk validitas metodologi evaluasi kualitatif yang diusulkan.

3.2.2.4 Sumber Data

A. Asal Data

Dataset yang digunakan adalah Digital Image of Bacterial Species (DIBaS). Dataset ini dipublikasikan oleh Chair of Microbiology di Universitas Jagiellonian, Krakow, Polandia. Pemilihan dataset ini didasarkan pada kredibilitas sumber akademis dan kualitas citra yang telah terstandarisasi untuk penelitian mikrobiologi berbasis komputer.

B. Spesifikasi Akuisisi Citra

Berdasarkan dokumentasi dataset DIBaS, seluruh citra diakuisisi menggunakan perangkat keras dengan spesifikasi tinggi untuk memastikan detail morfologi bakteri tertangkap dengan jelas. Spesifikasi akuisisi data asli adalah sebagai berikut:

1. Mikroskop: Olympus CX31 Upright Biological Microscope.
2. Kamera: Olympus SC30.
3. Perbesaran: Lensa objektif 100x.
4. Pewarnaan: Sampel diwarnai menggunakan metode pewarnaan Gram standar.

C. Komposisi Dataset

Berikut adalah komposisi citra dari dataset yang akan dipakai untuk eksperimen

Atribut	Spesifikasi
Sumber Data	Public Dataset (DIBaS) - Universitas Jagiellonian
Jumlah Total Citra	669 Citra
Jumlah Citra Gram-Positif	194 Citra
Jumlah Citra Gram-Negatif	475 Citra
Ketersediaan	Public

Tabel 3.1 Komposisi Dataset DIBaS

3.2.3 PROSEDUR PENELITIAN

Prosedur penelitian dirancang sebagai serangkaian tahapan yang sistematis dan berurutan untuk memastikan validitas dan reliabilitas hasil. Alur ini mencakup tiga fase utama: (1) persiapan data yang cermat, (2) pelatihan model generatif, dan (3) pelaksanaan evaluasi oleh *expert panel* yang menjadi inti dari kontribusi metodologis penelitian ini.

3.2.3.1 Pengumpulan dan Pra-pemrosesan Data

Tahap ini bertujuan untuk menyiapkan dataset yang bersih dan terstandarisasi.

1. Pengumpulan Data

Penelitian ini menggunakan dataset publik DIBaS yang terdiri dari 669 citra mikroskopis berkualitas tinggi. Citra dikelompokkan berdasarkan karakteristik dinding selnya menjadi dua kategori utama: Gram-positif dan Gram-negatif.

2. **Ekstraksi Patch**

Resolusi asli citra dalam dataset adalah 2048×1532 piksel. Mengingat keterbatasan memori GPU dan kebutuhan model untuk mempelajari fitur detail tekstur bakteri, penggunaan citra resolusi penuh tidak efisien. Alih-alih melakukan resizing langsung yang dapat merusak detail morfologi (seperti bentuk batang atau bulat bakteri), penelitian ini menerapkan teknik patch extraction. Setiap citra asli dipotong menjadi sub-citra (patches) berukuran 256×256 piksel. Teknik ini memberikan dua keuntungan strategis:

- **Retensi Informasi:** Mempertahankan resolusi asli pada area lokal, sehingga detail visual bakteri tetap tajam.
- **Augmentasi Data:** Meningkatkan jumlah sampel data secara signifikan dari 669 citra menjadi total 5.976 patch, yang sangat membantu dalam mencegah overfitting pada model generatif.

3. **Pembagian Data**

Dataset yang telah bersih akan dibagi menggunakan teknik stratified random sampling. Pendekatan ini dipilih untuk menjaga agar proporsi kelas tetap konsisten di setiap himpunan data, sebuah praktik fundamental untuk mencegah bias dalam pengembangan model pada citra medis [1], [3]. Dataset akan dibagi menjadi dua himpunan utama:

- **Training Set (76.5%):** Digunakan untuk melatih bobot model cGAN.
- **Validation Set (11.8%):** Digunakan untuk memantau performa model selama pelatihan.
- **Test Set (11.7%):** Disisihkan sepenuhnya sebagai data murni untuk evaluasi akhir oleh panel ahli.

3.2.3.2 Pelatihan cGAN dan Generasi Citra Sintetis

Tahap ini berfokus pada implementasi solusi augmentasi data.

1. **Implementasi cGAN:** Model cGAN akan dibangun menggunakan arsitektur yang telah terbukti efektif untuk tugas translasi citra-ke-citra, yaitu generator berbasis U-Net dan diskriminator berbasis PatchGAN [9].
2. **Generasi Terkondisi:** Keunggulan utama cGAN adalah kemampuannya untuk mengarahkan proses generasi. Dengan memberikan label kelas sebagai input kondisional, generator akan menghasilkan citra yang tidak hanya realistis tetapi juga sesuai dengan kelas yang diinginkan. Hal ini memungkinkan augmentasi yang terarah, terutama untuk menyeimbangkan jumlah data antar kelas.
3. **Pelatihan cGAN:** Model cGAN akan dilatih hingga konvergen. Konfigurasi hyperparameter akan didasarkan pada studi terkait yang telah terbukti berhasil, seperti yang disajikan pada **Tabel 3.1**.

Hyperparameter	Nilai	Justifikasi
Optimizer	Adam	Efektif dan umum digunakan untuk melatih model GAN.
Learning Rate	0.0002	Nilai yang umum digunakan dan terbukti stabil untuk pelatihan GAN.
Beta 1 (Adam)	0.5	Parameter momentum yang membantu menstabilkan pelatihan.
Batch Size	16 - 32	Disesuaikan dengan kapasitas memori GPU, nilai yang lebih kecil seringkali lebih stabil untuk GAN.
Jumlah Epoch	200 - 500	Cukup untuk mencapai konvergensi tanpa overfitting yang berlebihan.

Tabel 3.2 Contoh Konfigurasi Hyperparameter Model cGAN

Konfigurasi hyperparameter ini dipilih berdasarkan praktik yang telah terbukti berhasil dan stabil dalam penelitian augmentasi data citra medis menggunakan cGAN oleh Qadir et al. [7].

3.2.3.3 Perancangan Instrumen dan Pelaksanaan Evaluasi Ahli

Tahap ini adalah inti dari kontribusi metodologis penelitian, menggantikan metrik kuantitatif otomatis dengan validasi oleh manusia. Metrik otomatis seperti FID seringkali gagal menangkap validitas diagnostik dan dapat memberikan skor yang terlalu optimis meskipun ada kecacatan klinis yang krusial [10]. Oleh karena itu, pendekatan *expert-in-the-loop* menjadi *gold standard* [11].

1. **Perancangan Kuesioner:** Sebuah kuesioner terstruktur akan dirancang untuk mengkuantifikasi penilaian subjektif dari analis laboratorium. Instrumen ini akan mengukur tiga dimensi evaluasi kualitas yang umum digunakan dalam literatur sintesis citra medis [13]:
 - **Realisme Visual:** Menilai seberapa mirip citra sintetis dengan citra asli yang biasa ditemui dalam praktik sehari-hari.

- **Kelayakan Diagnostik:** Menilai apakah karakteristik yang penting cukup jelas dan akurat untuk keperluan identifikasi.
- **Ketiadaan Artefak:** Menilai keberadaan anomali visual yang tidak ada pada citra asli, yang berpotensi menyebabkan misdiagnosis [14].

Setiap kriteria akan dinilai menggunakan Skala Likert 1-5 (1: Sangat Buruk, 5: Sangat Baik).

2. Pelaksanaan Evaluasi:

- **Partisipan:** Sebuah *expert panel* yang terdiri dari minimal tiga analis laboratorium mikrobiologi akan direkrut sebagai penilai. Penggunaan dari *expert panel* adalah prasyarat untuk mengukur reliabilitas dan memastikan hasil yang dapat digeneralisasi.
- **Persiapan Set Uji:** Sebuah set pengujian yang seimbang dan praktis akan disiapkan dengan total maksimal 50 citra. Prosedurnya adalah sebagai berikut: sebanyak maksimal 25 citra asli akan dipilih secara acak dari himpunan Expert-Testing Set. Kemudian, sejumlah citra sintetis yang sama persis akan dihasilkan oleh model cGAN. Misalnya, jika 25 citra asli dipilih, maka 25 citra sintetis akan dihasilkan, sehingga totalnya adalah 50 citra gabungan. Jika *Expert-Testing Set* hanya berisi 20 citra, maka 20 citra asli tersebut akan digunakan dan 20 citra sintetis akan dihasilkan, sehingga totalnya adalah 40 citra gabungan. Penggabungan dengan rasio 1:1 ini menciptakan set *blind test* yang adil untuk disajikan kepada ahli.
- **Prosedur Blind Evaluation:** Dataset gabungan akan disajikan kepada setiap anggota panel secara terpisah. Prosedur ini bersifat *double-blind*, maksudnya yaitu, (1) para panelis tidak mengetahui label asli dari setiap citra, dan (2) mereka melakukan penilaian secara independen tanpa berdiskusi atau mengetahui penilaian dari anggota panel lainnya.
- **Tugas Analis:** Untuk setiap citra, analis akan diminta untuk:
 - a. Memberi label tebakan: asli atau sintetis.
 - b. Mengisi kuesioner penilaian berdasarkan tiga kriteria di atas.

3.2.4 ANALISIS DATA

Data yang terkumpul dari kuesioner akan dianalisis secara kuantitatif untuk menguji hipotesis penelitian.

3.2.4.1 Tahap 1: Validasi Reliabilitas Instrumen Penilaian

Tujuan utama dari tahap ini adalah untuk menetapkan secara statistik bahwa instrumen evaluasi yang digunakan menghasilkan penilaian yang konsisten di antara semua anggota *expert panel*. Tanpa bukti reliabilitas, setiap analisis selanjutnya akan kehilangan dasar ilmiahnya. Oleh karena itu, langkah ini adalah prasyarat yang tidak dapat ditawar.

1. Analisis Reliabilitas untuk Tugas Visual Turing Test

- **Metode:** Untuk data hasil tebakan asli atau sintetis, yang bersifat nominal, akan digunakan statistik Fleiss' Kappa.
- **Kriteria Keberhasilan:** Instrumen dianggap reliabel jika mencapai tingkat kesepakatan substansial ($Kappa > 0.61$) atau lebih tinggi.

2. Analisis Reliabilitas untuk Skor Kuesioner:

- **Metode:** Untuk data skor Skala Likert (1-5) pada tiga kriteria kualitas, yang bersifat ordinal, akan digunakan statistik *Intraclass Correlation Coefficient* (ICC).
- **Kriteria Keberhasilan:** Instrumen dianggap reliabel jika mencapai tingkat kesepakatan baik (ICC > 0.75) atau lebih tinggi.

Jika kedua kriteria keberhasilan di atas terpenuhi, data dari *expert panel* dapat dianggap valid dan reliabel untuk dianalisis pada tahap berikutnya.

3.2.4.2 Tahap 2: Pengujian Hipotesis Penelitian

Setelah instrumen terbukti reliabel, data dari seluruh panelis akan dianalisis untuk menguji hipotesis H_1 dan H_2 .

1. Analisis untuk Hipotesis 1 (H_1 - Kualitas Diagnostik):

- **Metode:** Untuk setiap citra, skor rata-rata dari seluruh panelis akan dihitung untuk masing-masing dari tiga kriteria kualitas. Selanjutnya, akan dilakukan *Mann-Whitney U Test* untuk membandingkan skor rata-rata antara kelompok citra asli dan kelompok citra sintetis.
- **Kriteria Keberhasilan:** Hipotesis H_1 dianggap terdukung jika tidak terdapat perbedaan yang signifikan secara statistik ($p > 0.05$).

2. Analisis untuk Hipotesis 2 (H_2 - Indistinguishability):

- **Metode:** Akurasi pembedaan untuk setiap panelis akan dihitung. Kemudian, akurasi rata-rata dari seluruh panel akan dihitung.
- **Kriteria Keberhasilan:** Hipotesis H_2 dianggap terdukung jika akurasi pembedaan rata-rata panel tidak berbeda secara signifikan dari 50%.


3.2.4.3 Analisis Komparatif

Sebagai analisis pelengkap, skor FID akan dihitung dan disandingkan dengan hasil evaluasi *expert panel*. Tujuannya bukan untuk mencari korelasi, melainkan untuk secara empiris mendemonstrasikan potensi adanya celah validasi, di mana skor FID yang baik mungkin tidak selaras dengan penilaian kualitas diagnostik oleh ahli.

3.2.5 Diagram Sistem

3.2.5.1 Diagram Alur

Diagram alur pada **Gambar 3.2** menyajikan kerangka kerja metodologis penelitian secara visual dan sistematis. Alur ini secara logis terbagi menjadi tiga fase utama yang saling berurutan: (1) Persiapan Data Awal, (2) Pelatihan Model cGAN dan Sintesis Citra, dan (3) Evaluasi Kualitas Berbasis Ahli. Setiap fase dirancang untuk mencapai tujuan inti penelitian, yaitu menghasilkan dan memvalidasi kualitas citra bakteri sintetis dari perspektif ahli laboratorium.



Gambar 3.1. Diagram Alur

1. Tahap Persiapan Data Awal

Fase ini bertujuan untuk menyiapkan himpunan data yang terstandarisasi dan berkualitas tinggi sebagai fondasi untuk pelatihan model dan evaluasi.

A. Dataset

Proses dimulai dengan akuisisi himpunan data citra mikroskopis bakteri Gram yang telah terverifikasi. Kualitas dan keragaman dari dataset awal ini sangat krusial karena menjadi satu-satunya *ground truth* bagi model cGAN untuk mempelajari distribusi karakteristik visual yang relevan.

B. Preprocessing

Langkah ini bertujuan untuk membersihkan dan menstandarisasi data citra mentah guna memastikan konsistensi dan menghilangkan variabilitas yang tidak relevan. Proses ini mencakup beberapa teknik, seperti resizing untuk menyeragamkan ukuran seluruh citra.

C. Pemisahan Data Berdasarkan Kelas

Pada tahap ini, dataset yang telah melalui preprocessing diorganisir ke dalam himpunan-himpunan data yang sesuai dengan kelasnya. Setiap citra akan dilabeli dan

dipisahkan ke dalam dua kelompok data yang distingtif: Gram-positif dan Gram-negatif. Langkah ini bersifat fundamental bagi arsitektur cGAN, karena label kelas inilah yang akan digunakan sebagai *conditional input* untuk mengarahkan proses generasi citra. Distribusi data awal antar kelas yang diidentifikasi pada tahap ini akan menjadi dasar analisis di Bab 4 untuk menunjukkan bagaimana cGAN berpotensi mengatasi masalah *class imbalance*.

2. Tahap Pelatihan cGAN

Fase ini merupakan inti dari implementasi teknis, di mana model generatif dilatih untuk menghasilkan data sintetis.

A. Input Noise Acak dan Kondisi Kelas

Tahap ini menyediakan input fundamental bagi jaringan Generator untuk memulai proses sintesis citra. Prosesnya melibatkan pembangkitan vektor *noise* acak, yang umumnya diambil dari distribusi Gaussian, yang kemudian digabungkan dengan representasi dari label kelas. Hasil dari proses ini adalah noise acak berfungsi sebagai sumber keacakan yang memastikan keragaman pada citra yang dihasilkan, sementara informasi kondisi kelas mengarahkan Generator untuk menghasilkan citra yang secara visual sesuai dengan kategori yang diinginkan.

B. Jaringan Generator

Dalam penelitian ini, jaringan Generator akan menggunakan arsitektur U-Net untuk mensintesis citra bakteri Gram-positif dan Gram-negatif yang baru. Pemilihan arsitektur U-Net didasarkan pada kemampuannya yang telah terbukti dalam menghasilkan citra medis berkualitas tinggi dengan detail yang tajam. Arsitektur U-Net, dengan mekanisme *skip connections* yang khas, mampu mempertahankan informasi detail berfrekuensi tinggi ini selama proses generasi. Kemampuan ini memastikan bahwa citra sintetis yang dihasilkan tidak hanya terlihat realistis secara global, tetapi juga akurat secara mikroskopis, yang merupakan syarat utama untuk data augmentasi yang efektif. Penggunaan U-Net untuk sintesis citra medis yang andal telah divalidasi dalam penelitian sebelumnya [7].

C. Jaringan Diskriminator

Untuk memastikan Generator U-Net menghasilkan citra dengan tingkat realisme yang tinggi, jaringan Diskriminator akan menggunakan arsitektur PatchGAN. Arsitektur ini dipilih karena pendekatannya yang berfokus pada evaluasi lokal. Daripada menilai seluruh citra secara global, PatchGAN menilai realisme pada level potongan-potongan kecil (*patches*). Pendekatan ini sangat relevan untuk citra bakteri, karena memaksa Generator untuk memperhatikan detail-detail halus seperti tekstur dinding sel dan konsistensi warna pewarnaan di seluruh area citra. Dengan demikian, PatchGAN mendorong terciptanya citra yang tidak hanya meyakinkan secara struktur, tetapi juga memiliki detail lokal yang akurat. Kombinasi U-Net dan PatchGAN ini telah terbukti berhasil meningkatkan kualitas sintesis citra medis [7].

D. Proses Pelatihan Adversarial dan Fungsi Loss

Proses ini merupakan mekanisme optimisasi kompetitif di mana Generator dan Diskriminator dilatih secara simultan. Generator diperbarui untuk meminimalkan Generator Loss (LG), yang mengindikasikan kemampuannya dalam menipu Diskriminator, sementara Diskriminator diperbarui untuk meminimalkan *Discriminator Loss*, yang merefleksikan kemampuannya dalam mengidentifikasi citra palsu. Proses ini diatur oleh fungsi *loss adversarial* untuk memastikan kemiripan struktural antara citra asli dan sintetis.

3. Evaluasi Berbasis Ahli

Fase ini merupakan puncak dari kerangka kerja penelitian dan menjadi pilar utama untuk memvalidasi hipotesis yang diajukan. Berbeda dengan evaluasi berbasis metrik otomatis yang seringkali gagal menangkap nuansa klinis [10], fase ini menggunakan *gold standard*, yaitu penilaian oleh ahli manusia, untuk menjawab pertanyaan fundamental: "Apakah citra sintetis yang dihasilkan tidak hanya terlihat nyata, tetapi juga dapat dipercaya dan berguna untuk tujuan diagnostik?" [11]. Alur kerja pada fase ini dirancang secara sistematis untuk memastikan objektivitas dan validitas hasil, seperti yang diilustrasikan pada diagram.

A. Input

Proses evaluasi dimulai dengan dua himpunan data yang berbeda sebagai input:

- **Synthetic Dataset:** Dataset ini merupakan hasil akhir dari fase Pelatihan cGAN. Himpunan ini berisi citra-citra bakteri yang sepenuhnya baru dan dihasilkan oleh model Generator.
- **Real Dataset:** Himpunan ini merupakan *Expert-Testing Set* yang telah diisolasi sejak awal. Penggunaan data yang tak terlihat oleh model ini sangat krusial untuk menguji kemampuan generalisasi model. Hal ini memastikan bahwa penelitian ini tidak hanya menguji kemampuan model untuk meniru data latihnya, melainkan kemampuannya untuk menghasilkan citra yang realistis secara umum.

B. Pembentukan Dataset Gabungan

Langkah selanjutnya adalah membuat dataset gabungan untuk pengujian yang adil, objektif, dan bebas bias.

- **Apa yang dilakukan:** Sejumlah sampel diambil secara acak dari Synthetic Dataset. Jumlah sampel yang sama persis juga diambil secara acak dari *Expert-Testing Set*. Kedua set sampel ini kemudian digabungkan menjadi satu himpunan data tunggal, yaitu Dataset gabungan, dan urutannya diacak.
- **Mengapa ini penting:** Proses ini adalah inti dari prosedur *blind evaluation*. Dengan menciptakan rasio 1:1 yang seimbang antara citra asli dan sintetis, penelitian mencegah analisis mengembangkan bias tebakan. Pengacakan urutan dan penyembunyian label asli memastikan bahwa analisis akan menilai setiap citra murni berdasarkan kualitas visual dan diagnostiknya, tanpa dipengaruhi oleh pengetahuan apakah citra tersebut asli atau buatan.

C. Pelaksanaan Evaluasi oleh Laboratory Analysts

Dataset gabungan yang telah disiapkan kemudian disajikan kepada partisipan ahli, yaitu analis laboratorium mikrobiologi. Tugas mereka dipecah menjadi dua untuk mengukur dua aspek kualitas yang berbeda secara terpisah, yaitu *indistinguishability* dan *diagnostic quality*.

- Apa yang dilakukan: Untuk setiap citra yang ditampilkan, analis diminta untuk melakukan dua tugas:
 1. Tugas *Visual Turing Test*: Memberikan tebakan biner dengan memberi label "Asli" atau "Sintetis". Tugas ini secara langsung menguji Hipotesis 2, yang bertujuan mengukur apakah citra sintetis secara visual tidak dapat dibedakan dari citra asli.
 2. Tugas Pengisian Kuesioner: Memberikan skor kuantitatif pada tiga kriteria yang telah dirancang sebelumnya: Realisme Visual, Kelayakan Diagnostik, dan Ketidadaan Artefak. Tugas ini menguji Hipotesis 1 (H_1) dan memberikan pemahaman yang lebih dalam daripada *Visual Turing Test*.
- Mengapa ini penting: Pemisahan kedua tugas ini secara metodologis sangat kuat. Sebuah citra mungkin lolos dari *Visual Turing Test*, tetapi bisa jadi memiliki kualitas diagnostik yang lebih rendah. Dengan mengukur dimensi-dimensi ini secara eksplisit, penelitian ini dapat menjawab pertanyaan yang lebih bernuansa dan relevan secara klinis, seperti yang direkomendasikan dalam literatur evaluasi citra medis sintetis [13, 14].


D. Output

Hasil dari proses evaluasi oleh analis ini adalah kumpulan data mentah yang terstruktur, yang akan menjadi bahan bakar untuk analisis statistik di tahap selanjutnya. Output ini terdiri dari:

1. Kumpulan label tebakan *Visual Turing Test* untuk setiap citra.
2. Kumpulan skor Likert untuk setiap citra pada ketiga dimensi evaluasi.

3.2.5.2 Diagram Use Case

Diagram *use case* bertujuan untuk mendefinisikan interaksi antara pengguna dengan sistem yang akan dikembangkan. Tahapan ini krusial untuk memastikan bahwa fungsionalitas yang dibangun selaras dengan tujuan penelitian dan dapat menjawab permasalahan yang telah diidentifikasi pada Bab 1. Kebutuhan ini divisualisasikan menggunakan diagram untuk memberikan gambaran yang jelas mengenai ruang lingkup sistem.



Gambar 3.2. Diagram use case sistem

Gambar 3.3 mengilustrasikan diagram *use case* dari sistem yang akan dibangun. Terdapat tiga aktor utama yang berinteraksi dengan sistem, yaitu Admin, Analis, dan Dokter. Setiap aktor memiliki peran dan hak akses yang berbeda-beda. Secara umum, semua aktor harus melakukan proses Login ke Sistem terlebih dahulu sebelum dapat mengakses fungsi lainnya, yang dimodelkan dengan hubungan <<include>>.

Berikut adalah penjelasan rinci untuk setiap *use case* berdasarkan aktor yang terlibat:

1. Admin

○ Kelola Data Pasien

Aktor Admin bertanggung jawab untuk mengelola data demografis pasien yang sampel bakterinya akan diperiksa. Fungsi ini mencakup menambah, mengubah, dan menghapus data pasien untuk memastikan setiap hasil analisis terhubung dengan identitas pasien yang benar.

2. Analis

○ Unggah & Klasifikasi Citra Bakteri

Use case ini merupakan fungsi inti bagi Analis.. Analis dapat mengunggah citra mikroskopis bakteri hasil pewarnaan Gram. Sistem kemudian akan memproses citra tersebut menggunakan model CNN yang telah dilatih untuk memberikan hasil klasifikasi awal, yaitu Gram-positif atau Gram-negatif, beserta informasi bentuk dan warna yang terdeteksi. Analis juga dapat memilih untuk menggunakan model CNN dengan data augmentasi dari GAN atau CNN saja.

○ Kelola Pelatihan Model

Analis memiliki izin untuk mengelola siklus hidup model kecerdasan buatan. Hal ini mencakup memicu proses augmentasi data menggunakan cGAN untuk menghasilkan data sintesis baru dan melatih ulang model klasifikasi CNN dengan dataset hasil augmentasi.

○ Melihat Riwayat Hasil Klasifikasi

Analis memiliki akses untuk melihat seluruh riwayat hasil klasifikasi yang telah dilakukan sistem.

3. Dokter

○ Melihat Riwayat Hasil Klasifikasi

Dokter juga memiliki akses untuk melihat seluruh riwayat hasil klasifikasi yang telah dilakukan oleh sistem.

○ Memvalidasi / Reanotasi Hasil

Use case ini merupakan <<extend>> dari *use case* **Melihat Riwayat Hasil Klasifikasi**. Artinya, setelah melihat sebuah hasil, Dokter memiliki opsi untuk melakukan validasi atau melakukan reanotasi. Fitur ini sangat krusial sebagai mekanisme *crosscheck* untuk memastikan akurasi diagnosis.

- **Mengakses Dasbor Laporan**

Dokter dapat mengakses dasbor yang menyajikan laporan visual mengenai data hasil klasifikasi. Laporan ini dapat berupa ringkasan statistik, seperti jumlah total kasus bakteri Gram-positif dan Gram-negatif dalam periode waktu tertentu, untuk memantau tren infeksi.

3.2.6 RENCANA PENGUJIAN

Rencana pengujian dirancang secara spesifik untuk memvalidasi hipotesis penelitian melalui metodologi evaluasi kualitatif oleh ahli. Pengujian ini tidak mengukur kinerja model klasifikasi, melainkan berfokus pada penilaian kualitas, realisme, dan validitas diagnostik dari citra sintetis yang dihasilkan oleh model cGAN. Pengujian akan dilaksanakan dalam satu fase utama, yaitu Validasi Kualitas Citra Sintetis oleh Ahli. Fase ini bertujuan untuk mengumpulkan data kuantitatif dari penilaian subjektif sebuah *expert panel* laboratorium mikrobiologi. Skenario pengujian yang akan dilakukan dirangkum secara rinci pada tabel di bawah ini.

(halaman sengaja dikosongkan)

Validasi Kualitas Citra Sintetis oleh Ahli

Hipotesis	Tujuan Pengujian	Metode Pengujian	Data yang Dianalisis	Metrik Statistik	Kriteria Keberhasilan
Prasyarat	Memvalidasi reliabilitas instrumen penilaian kualitatif.	Analisis konsistensi antarpenilai.	1. Label tebakan. 2. Skor Likert untuk setiap sub-kriteria kualitas.	1. Fleiss' Kappa 2. ICC	Instrumen dianggap reliabel jika: 1. Kappa > 0.6. 2. ICC > 0.75.
H₁	Mengukur apakah citra sintetis memiliki kualitas diagnostik yang setara dengan citra asli, menurut penilaian ahli.	Uji komparatif skor kualitas.	Skor rata-rata agregat panel untuk setiap kriteria pada kelompok citra Asli vs. Sintetis.	<i>Mann-Whitney U Test</i>	H ₁ terdukung jika tidak ada perbedaan yang signifikan secara statistik antara skor kelompok citra asli dan sintetis.
H₂	Mengukur apakah citra sintetis secara visual tidak dapat dibedakan dari citra asli oleh ahli.	<i>Visual Turing Test.</i>	Akurasi pembedaan rata-rata dari seluruh <i>expert panel</i> .	<i>One-Sample t-test.</i>	H ₂ terdukung jika akurasi rata-rata panel tidak berbeda secara signifikan dari 50%.

Tabel 3.3 Skenario uji coba

(halaman sengaja dikosongkan)

BAB 4

EKSPERIMEN DAN ANALISIS

4.1 Parameter Eksperimen

Proses pelatihan model cGAN dilakukan menggunakan framework TensorFlow dengan konfigurasi parameter sebagaimana tercantum pada Tabel 4.1. Nilai-nilai pada tabel tersebut tidak dipilih secara acak, tetapi mempertimbangkan karakteristik pelatihan GAN yang cenderung tidak stabil, keterbatasan sumber daya komputasi (khususnya kapasitas VRAM GPU yang hanya 4 GB), serta rekomendasi umum pada penelitian-penelitian sebelumnya yang menggunakan arsitektur serupa.

No.	Parameter	Nilai
1.	Optimizer	Adam
2.	Learning Rate	0.0001
4.	beta	0.5
5.	Batch Size	8
6.	Jumlah Epoch	300

Tabel 4.1 Parameter Pelatihan Model cGAN

Penggunaan optimizer Adam dipilih karena algoritma ini secara praktis terbukti lebih stabil untuk pelatihan model adversarial dibandingkan optimizer berbasis momentum klasik seperti SGD. Adam mampu menyesuaikan laju pembelajaran secara adaptif pada tiap parameter, sehingga membantu mengurangi osilasi besar pada update bobot yang sering terjadi pada pelatihan GAN. Dengan demikian, pemilihan Adam ditujukan untuk mempercepat proses konvergensi tanpa membuat pelatihan menjadi terlalu sensitif terhadap perubahan gradien.

Nilai learning rate sebesar 0,0001 dipilih sebagai kompromi antara kecepatan konvergensi dan stabilitas pelatihan. Learning rate yang terlalu besar berpotensi menyebabkan pelatihan GAN menjadi tidak stabil, misalnya ditandai dengan loss yang berosilasi secara ekstrem atau bahkan menghasilkan nilai NaN. Sebaliknya, learning rate yang terlalu kecil membuat proses pelatihan menjadi sangat lambat dan membutuhkan epoch yang jauh lebih banyak untuk mencapai kualitas citra yang memadai. Oleh karena itu, nilai 0,0001 dipandang cukup konservatif untuk menjaga stabilitas pelatihan, namun masih cukup besar agar model dapat belajar secara progresif dalam rentang 300 epoch.

Parameter $\beta = 0,5$ pada Adam dipilih karena nilai ini merupakan praktik umum pada pelatihan GAN untuk mengurangi efek “momentum” yang terlalu kuat. Nilai β yang lebih tinggi (misalnya 0,9) cenderung membuat estimator momen pertama menjadi terlalu “lambat beradaptasi” terhadap perubahan distribusi gradien, sementara pada pelatihan GAN distribusi gradien generator dan discriminator dapat berubah cukup cepat. Dengan menggunakan $\beta = 0,5$, kontribusi gradien historis dibuat lebih terbatas sehingga update bobot dapat lebih responsif terhadap kondisi terbaru, yang pada akhirnya membantu meningkatkan stabilitas interaksi antara generator dan discriminator.

Batch size sebesar 8 dipilih dengan mempertimbangkan dua hal utama: keterbatasan memori GPU dan stabilitas gradien. Dari sisi komputasi, kapasitas VRAM 4 GB membatasi ukuran batch yang dapat digunakan ketika memproses citra beresolusi relatif tinggi dan model dengan jumlah parameter yang cukup besar. Batch size yang lebih besar menyebabkan kebutuhan memori meningkat secara signifikan dan berpotensi menimbulkan out of memory error. Dari sisi optimisasi, batch size kecil memang menghasilkan gradien yang lebih “berisik”, namun pada pelatihan GAN hal ini justru dapat berperan sebagai bentuk regularisasi alami dan membantu eksplorasi ruang solusi yang lebih beragam. Dengan demikian, nilai batch size 8 dipandang sebagai titik tengah yang realistis antara keterbatasan perangkat keras dan kebutuhan untuk menjaga kualitas pembaruan bobot.

Jumlah epoch sebanyak 300 ditetapkan untuk memberikan waktu pelatihan yang cukup bagi model agar dapat mempelajari distribusi data bakteri secara bertahap. Pelatihan GAN pada umumnya membutuhkan epoch yang lebih banyak dibandingkan model diskriminatif biasa karena adanya dinamika dua jaringan (generator dan discriminator) yang harus mencapai keseimbangan. Jumlah 300 epoch dipandang memadai untuk mengamati pola penurunan loss, stabilisasi nilai adversarial loss, serta peningkatan kualitas visual citra sintetis secara bertahap. Selain itu, jumlah epoch ini juga mempertimbangkan waktu komputasi yang tersedia sehingga pelatihan tetap realistis untuk diselesaikan pada perangkat dengan spesifikasi GPU terbatas.

Secara keseluruhan, kombinasi optimizer Adam, learning rate 0,0001, $\beta = 0,5$, batch size 8, dan jumlah epoch 300 dirancang sebagai konfigurasi yang seimbang antara stabilitas pelatihan, kualitas citra yang dihasilkan, dan keterbatasan sumber daya komputasi yang digunakan dalam penelitian ini.

4.2 Karakteristik Data

Data yang digunakan dalam penelitian ini bersumber dari dataset publik Digital Image of Bacterial Species (DIBaS). Karakteristik dan pengolahan dataset ini menjadi salah satu komponen penting dalam rancangan eksperimen, karena secara langsung memengaruhi stabilitas pelatihan model cGAN, kemampuan generalisasi model, serta relevansi hasil terhadap tujuan penelitian, yaitu pemodelan citra bakteri Gram-Positif dan Gram-Negatif.

Pemilihan sumber data, cara pengelompokan kelas, ukuran patch, serta proporsi pembagian data ke dalam himpunan training, validation, dan test, seluruhnya merupakan keputusan desain eksperimen yang disesuaikan dengan keterbatasan dataset publik, kapasitas komputasi, dan kebutuhan evaluasi model.

4.2.1 Sumber Data Asli

Dataset DIBaS dipilih karena memenuhi beberapa pertimbangan praktis dan metodologis berikut:

1. Ketersediaan publik dan kelengkapan anotasi

DIBaS merupakan salah satu dataset citra bakteri yang tersedia secara publik dan dilengkapi dengan informasi spesies yang jelas. Hal ini penting untuk memastikan bahwa eksperimen dapat direproduksi oleh peneliti lain tanpa bergantung pada data klinis tertutup. Selain itu, ketersediaan dataset publik dengan label bakteri yang rapi masih relatif terbatas, sehingga DIBaS menjadi kandidat yang logis untuk digunakan sebagai dasar eksperimen.

2. Keragaman spesies sebagai dasar variasi morfologi

Dataset ini mencakup 33 spesies bakteri dengan sekitar 20 citra per spesies. Meskipun jumlah citra per spesies relatif kecil untuk pelatihan model generatif pada level spesies, keragaman spesies tersebut menghadirkan variasi bentuk, struktur, dan pola pewarnaan yang kaya. Variasi ini dimanfaatkan bukan untuk klasifikasi hingga level spesies, tetapi sebagai sumber pola morfologis yang cukup beragam ketika spesies-spesies tersebut kemudian digabungkan ke dalam dua kelas Gram utama.

3. Resolusi citra tinggi untuk mendukung ekstraksi patch

Seluruh citra memiliki resolusi asli 2048×1532 piksel dalam format RGB. Resolusi tinggi ini dipandang menguntungkan untuk dua alasan:

- Memungkinkan ekstraksi beberapa patch beresolusi 256×256 piksel dari satu citra tanpa kehilangan terlalu banyak detail morfologi sel, dan
- Memberikan fleksibilitas dalam memilih strategi cropping (misalnya fokus pada area yang kaya objek sel bakteri, bukan hanya latar belakang).

Dengan kata lain, resolusi tinggi DIBaS tidak hanya meningkatkan kualitas visual, tetapi juga berfungsi sebagai “modal awal” untuk memperbanyak jumlah sampel melalui ekstraksi patch.

Secara keseluruhan, DIBaS dipilih bukan semata-mata karena kualitas citranya yang baik, tetapi juga karena kombinasi faktor ketersediaan publik, keragaman spesies, dan resolusi yang mendukung strategi augmentasi berbasis patch yang digunakan dalam penelitian ini.

4.2.2 Pra-pemrosesan dan Pengelompokan Kelas

Langkah pra-pemrosesan dan pengelompokan kelas yang diterapkan pada dataset DIBaS dirancang untuk menyelaraskan data dengan tujuan penelitian sekaligus mengatasi keterbatasan ukuran dataset asli:

1. Pengelompokan 33 spesies menjadi 2 kelas Gram

Alih-alih mempertahankan 33 kelas spesies yang masing-masing hanya memiliki sekitar 20 citra, penelitian ini mengelompokkan ulang seluruh spesies ke dalam dua kelas utama: Gram-Positif dan Gram-Negatif. Keputusan ini diambil dengan beberapa pertimbangan:

- Fokus penelitian memang berada pada perbedaan karakteristik Gram, bukan identitas spesies secara individual.
- Jumlah citra per kelas menjadi jauh lebih besar setelah pengelompokan, sehingga lebih realistis untuk melatih model generatif yang membutuhkan distribusi data yang cukup padat per kelas.
- Dengan hanya dua kelas, kondisi (label) pada cGAN menjadi lebih sederhana, sehingga proses pelatihan lebih stabil dan interpretasi hasil menjadi lebih langsung: apakah model dapat menangkap pola morfologi khas Gram-Positif vs Gram-Negatif.

2. Ekstraksi patch 256×256 piksel dari citra resolusi tinggi

Citra asli beresolusi 2048×1532 piksel kemudian dipecah menjadi patch berukuran 256×256 piksel. Ukuran ini dipilih sebagai kompromi antara:

- **Informasi morfologi yang cukup kaya:** 256×256 piksel masih cukup besar untuk menangkap pola bentuk, ukuran, dan distribusi sel bakteri di dalam bidang pandang

mikroskop, bukan hanya potongan objek yang terlalu kecil atau terlalu banyak latar belakang.

- **Keterbatasan memori GPU:** dengan kapasitas VRAM 4 GB, penggunaan patch yang terlalu besar akan membuat batch size harus sangat kecil atau bahkan memicu out of memory. Ukuran 256×256 lebih bersahabat secara komputasi, sehingga memungkinkan penggunaan batch size yang masih masuk akal.
- **Standar praktis di penelitian GAN:** banyak arsitektur GAN dan varian cGAN yang secara umum dirancang untuk bekerja baik pada resolusi sekitar 128–256 piksel. Dengan memilih 256×256 , penelitian ini mengikuti praktik umum tersebut sehingga arsitektur jaringan dan konfigurasi pelatihan dapat disesuaikan dengan lebih mudah.

Proses ekstraksi patch ini sekaligus berfungsi sebagai bentuk augmentasi jumlah data. Dari 669 citra sumber, dihasilkan total 5.976 patch, sehingga rata-rata satu citra menghasilkan beberapa patch yang berkontribusi memperkaya distribusi data latih.

3. Penyesuaian terhadap fokus area yang informatif

Dengan memecah citra menjadi patch, peneliti memperoleh kontrol lebih baik untuk memusatkan data pada area yang secara visual kaya informasi dan mengurangi bagian yang terlalu didominasi latar belakang. Hal ini penting untuk GAN, karena generator “belajar” dari pola-pola yang sering muncul pada data latih. Semakin sedikit patch yang hanya berisi background, semakin efektif proses pembelajaran fitur morfologi bakteri.

Dengan demikian, seluruh langkah pra-pemrosesan pengelompokan kelas berbasis Gram dan ekstraksi patch 256×256 piksel dirancang untuk meningkatkan densitas informasi dan ketersediaan sampel pada tiap kelas, sambil tetap menjaga kebutuhan komputasi dalam batas kemampuan perangkat keras.

4.2.3 Distribusi Dataset Eksperimen

Setelah proses ekstraksi patch, diperoleh total 5.976 citra yang kemudian dibagi ke dalam tiga himpunan data: training, validation, dan test sebagaimana ditunjukkan pada Tabel 4.2. Pembagian ini juga merupakan bagian dari desain eksperimen, bukan sekadar pembagian acak tanpa pertimbangan.

Himpunan Data	Jumlah Citra	Persentase
Training Set	4.574	76.5%
Validation Set	704	11.8%
Test Set	698	11.7%
Total	5.976	100%

Tabel 4.2 Distribusi Dataset Berdasarkan Himpunan Data

Porsi terbesar dialokasikan untuk training set karena pelatihan cGAN sangat bergantung pada banyaknya variasi sampel yang tersedia untuk generator dan discriminator. Dengan dataset awal yang tidak terlalu besar, memperbesar porsi training menjadi sekitar tiga

per empat dari total data dipandang perlu agar model dapat mempelajari distribusi Gram-Positif dan Gram-Negatif dengan lebih baik.

Validation set digunakan untuk memantau performa model selama pelatihan, seperti memeriksa indikasi overfitting atau ketidakstabilan pelatihan. Porsi sekitar 10–15% dianggap cukup untuk memberikan gambaran yang representatif tanpa mengurangi terlalu banyak data latih.

Test set disisihkan sejak awal sebagai himpunan data yang tidak disentuh selama proses pelatihan maupun penyesuaian hyperparameter. Porsinya dibuat hampir sama dengan validation set agar evaluasi akhir terhadap kualitas citra sintetis dan performa model (misalnya jika digunakan classifier pendukung) tidak terlalu dipengaruhi oleh fluktuasi jumlah sampel.

Kombinasi 76,5% : 11,8% : 11,7% ini pada prinsipnya mengikuti pola umum “sekitar 70–80% untuk training dan sisanya untuk validation + test”, tetapi dengan sedikit penyesuaian untuk memaksimalkan jumlah data latih pada skenario dataset berukuran menengah seperti DIBaS.

Kelas	Jumlah Citra	Persentase
Gram-Positif	2.190	47.9%
Gram-Negatif	2.384	52.1%
Total Data Latih	4.574	100%

Tabel 4.3 Distribusi Data Latih Berdasarkan Kelas

Pada himpunan data latih, jumlah patch Gram-Positif adalah 2.190 (47,9%) dan Gram-Negatif 2.384 (52,1%). Beberapa poin penting dari konfigurasi ini:

- **Keseimbangan kelas yang relatif baik**

Rasio 48:52 menunjukkan bahwa kelas Gram-Positif dan Gram-Negatif relatif seimbang. Hal ini penting untuk mengurangi bias model terhadap salah satu kelas, baik pada tahap pelatihan cGAN maupun ketika citra sintetis nantinya dinilai menggunakan model klasifikasi tambahan. Dengan distribusi yang hampir seimbang, generator tidak “terdorong” untuk lebih sering menghasilkan salah satu kelas saja.

- **Mengurangi risiko mode collapse spesifik kelas**

Pada pelatihan GAN, khususnya dengan kondisi kelas, ketimpangan jumlah data dapat menyebabkan generator cenderung hanya menguasai distribusi dari kelas mayoritas. Dengan perbedaan yang kecil antara jumlah citra Gram-Positif dan Gram-Negatif, risiko ini dibuat lebih rendah, sehingga generator memiliki peluang yang lebih baik untuk mempelajari distribusi kedua kelas secara lebih seimbang.



- **Konsistensi proporsi kelas pada validation dan test set**

Pembagian data dilakukan sedemikian rupa agar proporsi Gram-Positif dan Gram-Negatif pada validation dan test set mengikuti pola yang mirip dengan training set. Dengan cara ini, performa yang diobservasi pada validation dan test set lebih mudah diinterpretasikan karena tidak terdistorsi oleh perubahan distribusi kelas.

Secara keseluruhan, karakteristik dan konfigurasi data mulai dari pemilihan DIBaS, pengelompokan kelas menjadi Gram-Positif dan Gram-Negatif, penggunaan patch 256×256 , hingga pembagian data yang menjaga keseimbangan kelas dirancang untuk menciptakan kondisi pelatihan cGAN yang stabil, realistis secara komputasi, dan relevan dengan tujuan penelitian, yaitu menghasilkan citra bakteri sintetis yang representatif untuk kedua kelompok Gram.

4.2.4 Contoh Dataset

Berikut adalah contoh citra dari dataset yang menjadi target pembelajaran model Generator:

Kelas	Contoh Citra
Gram-Positif	
Gram-Negatif	

Tabel 4.4 Contoh Citra dari Dataset

4.3 Tempat Ujicoba

Pelaksanaan penelitian dan uji coba sistem ini dilakukan di dua lokasi utama, yang terbagi berdasarkan tahapan pengembangan sistem:

1. Pengembangan dan Pelatihan Model

Proses pengembangan perangkat lunak, termasuk implementasi kode, pra-pemrosesan data, serta pelatihan model cGAN, dilaksanakan di Laboratorium Knowledge Engineering, Gedung Pascasarjana Lantai 8, Politeknik Elektronika Negeri Surabaya.

Meskipun dilakukan di lingkungan laboratorium, infrastruktur komputasi utama yang digunakan adalah perangkat laptop pribadi penulis yang dibawa ke laboratorium tersebut. Lingkungan laboratorium dipilih karena menyediakan fasilitas pendukung, jaringan internet

yang stabil, serta suasana yang kondusif untuk diskusi teknis dan pemantauan proses pelatihan model model training yang memakan waktu cukup lama.

2. Evaluasi Kualitas Citra oleh Ahli

Tahapan evaluasi kualitatif, yang melibatkan penilaian realisme dan kualitas citra sintesis, direncanakan akan bekerja sama dengan mitra medis. Berdasarkan sumber data yang digunakan, uji coba validasi ini akan dilaksanakan di Laboratorium Mikrobiologi Klinik, RSUD Dr. Soetomo Surabaya.

Di lokasi ini, panel ahli yang terdiri dari dokter spesialis mikrobiologi klinik dan analis laboratorium akan melakukan *Visual Turing Test* dan pengisian kuesioner penilaian untuk memverifikasi apakah citra bakteri hasil augmentasi GAN memiliki karakteristik visual yang setara dengan citra asli dan layak digunakan untuk keperluan diagnostik.

4.4 Waktu Ujicoba

Kegiatan eksperimen dan uji coba pada penelitian ini dilaksanakan secara bertahap dalam rentang waktu kurang lebih [DURASI], terhitung mulai dari bulan [BULAN AWAL] [TAHUN] hingga [BULAN AKHIR] [TAHUN]. Waktu pelaksanaan ini dirancang agar setiap tahapan penelitian mendapatkan porsi evaluasi yang cukup mendalam. Secara rinci, alokasi waktu uji coba dibagi menjadi tiga fase utama sebagai berikut:

1. Tahap Persiapan dan Pra-pemrosesan Data Dilaksanakan pada bulan [BULAN PERTAMA].

Pada tahap ini, fokus kegiatan adalah pengumpulan dataset DIBaS, pemilahan citra berdasarkan kategori Gram, serta pelaksanaan proses ekstraksi patch (pemotongan citra) untuk mempersiapkan data latih yang optimal.

2. Tahap Pelatihan dan Optimasi Model Dilaksanakan mulai bulan [BULAN KEDUA] hingga [BULAN KETIGA].

Fase ini merupakan tahapan yang paling intensif, di mana model cGAN dilatih berulang kali. Penulis melakukan pemantauan terhadap grafik loss dan melakukan *fine-tuning* untuk memastikan model mencapai konvergensi dan mampu menghasilkan citra yang realistis.

3. Tahap Evaluasi dan Validasi Ahli Dilaksanakan pada bulan [BULAN TERAKHIR].

Setelah model dianggap stabil, kegiatan difokuskan pada pengambilan data validasi bersama para ahli di Rumah Sakit. Kegiatan ini meliputi pelaksanaan Visual Turing Test, pengisian kuesioner penilaian kualitas, serta analisis akhir terhadap data hasil uji coba tersebut.

4.5 Spesifikasi Peralatan Ujicoba

Seluruh kegiatan eksperimen, mulai dari pra-pemrosesan data hingga pelatihan model cGAN, dilakukan menggunakan perangkat komputasi pribadi dengan spesifikasi *hardware* dan *software* yang terintegrasi. Berikut adalah rincian spesifikasi peralatan yang digunakan:

4.5.1 Hardware

Spesifikasi perangkat keras memegang peranan vital dalam kecepatan dan efisiensi pelatihan model Deep Learning, terutama pada GPU. Tabel 4.5 menampilkan rincian perangkat keras yang digunakan.

No.	Parameter	Spesifikasi
1.	Tipe Perangkat	Laptop
2.	Prosesor (CPU)	Intel® Core™ i5-10500H CPU @ 2.50GHz
3.	Memori (RAM)	16 GB DDR4
4.	Kartu Grafis (GPU)	NVIDIA GeForce GTX 1650 with Max-Q Design (4GB VRAM)
5.	Penyimpanan	SSD NVMe 1TB

Tabel 4.5 Spesifikasi Perangkat Keras

4.5.2 Software

Lingkungan pengembangan perangkat lunak dikonfigurasi menggunakan sistem operasi berbasis Linux untuk memaksimalkan kinerja manajemen memori dan kompatibilitas library. Tabel 4.2 menampilkan rincian perangkat lunak yang digunakan.

No.	Parameter	Spesifikasi
1.	Sistem Operasi	Ubuntu 24.04.3 LTS (Noble Numbat)
2.	Bahasa Pemrograman	Python 3.11
3.	Framework Deep Learning	TensorFlow 2.15.0
4.	Driver GPU	NVIDIA Driver & CUDA Toolkit
5.	Library Pengolahan Citra	OpenCV-Python-Headless, Pillow, Scikit-Image
6.	Library Analisis Data	NumPy, Pandas, Scikit-Learn
7.	Manajemen Eksperimen	MLflow, DVC (Data Version Control)

Tabel 4.6 Spesifikasi Perangkat Lunak

4.6 Hasil Eksperimen dan Analisis Sementara

Hingga saat laporan ini disusun, proses pelatihan model cGAN telah mencapai Epoch 55 dari target 300 epoch. Berikut adalah hasil yang didapatkan.

4.6.1 Metrik Pelatihan

Data metrik pelatihan yang tercatat melalui MLflow hingga epoch 130:


Metrik	Rentang Nilai	Rata-rata
Discriminator Loss	-0.002 s.d. -0.0006	~ -0.001
Generator Loss	2.0 s.d. 4.4	~ 4.0

Tabel 4.7 Rentang Nilai Function Loss

Pada awal pelatihan terlihat lonjakan nilai loss discriminator yang sangat tinggi, kemudian turun tajam dan segera mendekati nol dalam beberapa langkah pertama. Setelah fase awal ini, nilai discriminator loss bergerak pada rentang yang sangat sempit, yaitu sekitar -0.002 sampai -0.0006 dengan rata-rata mendekati -0.001. Pola ini menunjukkan bahwa setelah penyesuaian awal, discriminator relatif cepat menemukan keadaan yang stabil terhadap distribusi citra real dan citra sintetis yang dihasilkan generator. Dengan kata lain, perubahan parameter pada discriminator menjadi semakin kecil sehingga kurva merah pada Gambar 4.1 tampak hampir menempel pada sumbu nol. Kondisi ini dapat diinterpretasikan bahwa pada fase ini discriminator sudah cukup “nyaman” membedakan data real dan hasil generator, dan tidak lagi melakukan koreksi gradien yang besar.

Sebaliknya, generator loss menunjukkan dinamika yang lebih bervariasi. Setelah fase awal, nilai generator loss berada pada rentang sekitar 2.0 sampai 4.4 dengan rata-rata mendekati 4.0. Pada Gambar 4.1 terlihat bahwa kurva generator loss (garis biru) sempat turun pada awal pelatihan, kemudian berangsur naik dan cenderung berfluktuasi di kisaran 2 sampai 3 sebelum akhirnya meningkat lagi mendekati 4.4 pada akhir epoch yang diamati. Pola ini menunjukkan bahwa generator masih aktif menyesuaikan parameter untuk mengejar kemampuan discriminator. Nilai loss yang tidak turun secara monoton menggambarkan adanya tarik menarik antara kedua jaringan: setiap kali generator membaik dan menghasilkan citra yang lebih realistis, discriminator kembali menyesuaikan diri, sehingga generator harus terus “belajar ulang” untuk mengecoh discriminator.


Perbedaan karakteristik kedua kurva ini mengindikasikan bahwa pada fase pelatihan yang sedang berjalan, discriminator sudah lebih cepat mencapai kondisi stabil dibandingkan generator. Hal ini wajar mengingat discriminator memecahkan tugas yang relatif lebih mudah, yaitu membedakan real dan sintetis, sedangkan generator harus mempelajari distribusi citra bakteri Gram-Positif dan Gram-Negatif secara keseluruhan. Selama nilai loss keduanya masih berada pada rentang yang terbatas dan tidak menunjukkan ledakan nilai, proses pelatihan dapat dikatakan masih berjalan secara numerik stabil, meskipun kualitas citra sintetis yang dihasilkan generator pada tahap ini belum dapat dianggap optimal.






Gambar 4.1 Grafik Training Loss (Epoch 1-55)

4.6.2 Sampel Citra Sintetis

Berikut adalah sampel citra sintesis yang dihasilkan Generator pada berbagai tahap epoch, disusun dalam tabel untuk memudahkan perbandingan progres visual. Tabel 4.8 tidak hanya berfungsi sebagai dokumentasi hasil, tetapi juga sebagai indikator kualitatif mengenai sejauh mana model mulai mengenali pola warna dan tekstur yang menyerupai citra bakteri pada data latih.

Epoch	Sampel Citra
1	

10	
30	
50	

Tabel 4.8 Sampel Epoch

Pada epoch 1, citra yang dihasilkan masih didominasi pola acak dengan gradasi warna yang lembut dan tidak terstruktur. Area warna ungu, pink, dan hijau muncul sebagai bercak yang menyebar tanpa batas yang jelas antara foreground dan background. Pada tahap ini, generator pada dasarnya masih mencoba meniru distribusi warna global dari dataset, sehingga keluaran lebih mirip “noise yang dihaluskan” daripada struktur biologis yang bermakna.

Memasuki epoch 10, mulai terlihat adanya perubahan ke arah pola yang sedikit lebih terorganisasi. Blok warna pink dan ungu tampak membentuk gumpalan yang lebih besar dengan batas yang lebih tegas terhadap latar belakang, meskipun teksturnya masih sangat halus dan belum menunjukkan detail internal. Pola ini mengindikasikan bahwa generator mulai mempelajari perbedaan kasar antara area yang mewakili objek dan area latar belakang, tetapi belum sampai pada tahap pembentukan bentuk sel bakteri yang lebih kompleks.

Pada epoch 30, citra sintesis menampilkan gumpalan warna yang semakin kompleks dan tumpang tindih. Beberapa patch memperlihatkan distribusi objek yang lebih menyebar di seluruh bidang citra, dengan variasi ukuran dan bentuk gumpalan yang lebih beragam. Meskipun demikian, struktur yang terbentuk masih menyerupai pola blob organik dan belum dapat diidentifikasi sebagai bentuk batang, kokus, atau pola agregasi khas bakteri Gram-Positif maupun Gram-Negatif. Tahap ini menunjukkan bahwa model mulai menangkap pola tekstur dan sebaran area berwarna, tetapi belum berhasil memodelkan morfologi halus.

Pada epoch 50, citra yang dihasilkan sudah menampilkan tekstur yang lebih kaya dan kontras warna yang lebih tegas antara area objek dan latar belakang. Beberapa patch menampilkan gumpalan yang tampak lebih padat dan terlokalisasi, serta variasi intensitas warna yang lebih jelas di dalam satu gumpalan. Namun, pola yang muncul masih berupa massa amorf yang menyebar, belum membentuk kontur sel bakteri yang jelas maupun struktur rantai atau kelompok yang lazim diamati pada citra mikroskopis bakteri. Dengan kata lain, generator baru mencapai tahap pembentukan tekstur dan komposisi warna global, bukan bentuk seluler yang spesifik.

4.6.3 Status Implementasi Metrik Evaluasi

Metrik evaluasi kuantitatif dan evaluasi kualitatif belum diimplementasikan pada tahap ini karena model masih belum konvergen.

4.7 Analisis Hasil Eksperimen

Bagian ini menyajikan analisis mendalam terhadap hasil eksperimen yang telah ditampilkan pada Sub-bab 4.6. Analisis difokuskan pada interpretasi dinamika metrik pelatihan dan kualitas visual citra sintesis untuk menilai sejauh mana arsitektur model yang digunakan mulai mendekati tujuan penelitian serta apakah arah pelatihan saat ini sudah berada pada jalur yang benar.

4.7.1 Analisis Dinamika Pelatihan

Keberhasilan pelatihan model GAN sangat bergantung pada keseimbangan kompetitif antara Generator dan Discriminator. Berdasarkan grafik loss dan rangkuman metrik pada Sub-bab 4.6, dapat diamati bahwa sejak awal pelatihan Discriminator menunjukkan penurunan loss yang sangat cepat hingga berada pada rentang sekitar -0.002 sampai -0.0006 dengan rata-rata sekitar -0.001. Nilai ini relatif kecil dan stabil sehingga kurva Discriminator Loss tampak hampir konstan di sekitar nol setelah beberapa langkah pertama.

Sebaliknya, Generator Loss berada pada rentang kurang lebih 2.0 sampai 4.4 dengan kecenderungan meningkat menjelang epoch ke-55. Pola ini menunjukkan bahwa meskipun Generator sempat mengalami penurunan loss di awal pelatihan, seiring waktu penalti yang diterima Generator justru membesar. Kombinasi Discriminator Loss yang sangat kecil dan Generator Loss yang meningkat ini merupakan indikasi kuat terjadinya fenomena Discriminator overpowering, yaitu kondisi ketika Discriminator belajar jauh lebih cepat dan menjadi terlalu unggul dalam membedakan citra asli dan citra sintesis.

Dalam kondisi seperti ini, gradien yang diterima Generator cenderung menjadi sangat kecil atau tidak informatif sehingga pembaruan bobot Generator menjadi kurang efektif. Generator tetap berusaha memperbaiki hasil, tetapi informasi koreksi yang diterima setiap

iterasi tidak cukup kaya untuk mendorong terbentuknya struktur citra yang lebih kompleks. Hal ini konsisten dengan temuan pada Sub-bab 4.6, di mana kualitas citra sintesis masih didominasi pola abstrak meskipun nilai loss Numerik tampak stabil.

Dengan kata lain, dinamika pelatihan pada fase awal ini menggambarkan pelatihan yang secara numerik stabil, tetapi belum mencapai keseimbangan kompetitif yang ideal antara kedua jaringan. Discriminator terlalu cepat mencapai kinerja tinggi, sementara Generator tertinggal dan kesulitan mengejar, sehingga proses pembelajaran fitur visual yang lebih halus terhambat.

4.7.2 Analisis Kualitatif Citra

Analisis kualitatif terhadap sampel citra sintesis pada epoch 1, 10, 30, dan 50 menunjukkan pola perkembangan tertentu yang sejalan dengan dinamika loss. Pada epoch awal, citra yang dihasilkan sebagian besar berupa gumpalan warna dengan kontur yang lembut dan sebaran acak, tanpa adanya bentuk yang menyerupai sel bakteri. Seiring bertambahnya epoch, pola warna mulai tampak lebih terorganisasi dan area objek menjadi lebih jelas terpisah dari latar belakang, namun masih dalam bentuk blob abstrak.

Pada epoch ke-50, tekstur yang dihasilkan memang terlihat lebih kaya dan terdapat perbedaan intensitas warna yang lebih tegas, tetapi struktur yang muncul masih berupa massa amorf yang menyebar. Belum ditemukan indikasi bentuk morfologi khas bakteri, seperti pola batang, kokus, atau susunan kelompok sel yang lazim pada citra mikroskopis. Hal ini mendukung interpretasi bahwa Generator baru mencapai tahap mempelajari distribusi statistik global, terutama terkait kombinasi warna dan kontras, tetapi belum berhasil menangkap fitur lokal berukuran kecil yang menentukan bentuk sel bakteri.

Di sisi lain, palet warna yang dihasilkan sudah relatif konsisten dengan karakteristik pewarnaan Gram pada data asli. Dominasi warna ungu dan pink serta kontras dengan latar belakang yang lebih pucat menunjukkan bahwa Generator mulai mempelajari karakteristik warna yang sesuai dengan citra Gram-Positif dan Gram-Negatif. Temuan ini dapat dipandang sebagai indikasi awal bahwa model bergerak ke arah yang benar, meskipun belum mencapai kualitas struktural yang diharapkan.

4.7.3 Kesimpulan Interim terhadap Hipotesis

Jika dikaitkan dengan hipotesis penelitian, hasil pada epoch ke-55 ini belum cukup kuat untuk memberikan jawaban akhir. Kualitas citra sintesis yang masih abstrak membuatnya belum layak untuk dievaluasi oleh ahli mikrobiologi, baik dari sisi kemiripan morfologi maupun potensi penggunaannya sebagai data augmentasi. Dengan kata lain, bukti empiris saat ini belum memadai untuk menguji hipotesis H1 dan H2 yang berkaitan dengan kemampuan model dalam menghasilkan citra bakteri yang realistis dan dampaknya terhadap kinerja model klasifikasi.

Meskipun demikian, beberapa indikasi positif sudah mulai terlihat. Pertama, model telah mempelajari palet warna yang relevan dengan pewarnaan Gram sehingga aspek warna tampak menjanjikan untuk terus dikembangkan. Kedua, dinamika loss yang relatif stabil menunjukkan bahwa pelatihan tidak mengalami kegagalan numerik seperti eksplosi loss atau nilai NaN. Kedua hal ini dapat dianggap sebagai prasyarat yang baik sebelum memasuki fase pelatihan yang lebih panjang dan mendekati konvergensi.

Dengan mempertimbangkan bahwa eksperimen baru menyelesaikan sekitar 18 persen dari total rencana epoch, kesimpulan pada tahap ini perlu diposisikan sebagai kesimpulan sementara. Diperlukan kelanjutan pelatihan dan mungkin penyesuaian hyperparameter agar dapat menilai secara lebih meyakinkan apakah arsitektur yang diusulkan benar-benar mampu memenuhi hipotesis penelitian.

4.7.4 Rencana Lanjutan

Berdasarkan analisis sementara di atas, beberapa langkah lanjutan direncanakan sebagai berikut:

1. Melanjutkan pelatihan hingga mendekati konvergensi

Pelatihan akan diteruskan hingga mendekati target 300 epoch sambil terus memantau dinamika Generator Loss dan Discriminator Loss. Jika fenomena Discriminator overpowering tetap bertahan, akan dipertimbangkan penyesuaian hyperparameter tertentu (misalnya laju pembelajaran atau rasio update antara Generator dan Discriminator) sesuai rancangan pada Bab 3.

2. Penilaian kuantitatif menggunakan FID

Setelah model mencapai kondisi yang dianggap stabil, kualitas citra sintesis akan diukur menggunakan FID. Nilai FID yang lebih rendah akan menunjukkan bahwa distribusi fitur citra sintesis semakin mendekati distribusi fitur citra asli. Pengukuran ini menjadi dasar kuantitatif pertama untuk menilai apakah perpanjangan pelatihan dan penyesuaian parameter berhasil meningkatkan kualitas citra.

3. Penilaian kualitatif oleh panel ahli

Sejalan dengan penilaian kuantitatif, sampel citra yang telah mencapai kualitas visual tertentu akan dikumpulkan dan diserahkan kepada panel ahli mikrobiologi. Mereka akan diminta menilai sejauh mana citra sintetis menyerupai citra bakteri nyata dari sisi morfologi, tekstur, dan pola pewarnaan Gram. Hasil penilaian ini akan melengkapi analisis numerik dan memberikan perspektif praktis terkait kelayakan penggunaan citra sintesis dalam konteks laboratorium.

4. Pengujian hipotesis H1 dan H2

Setelah tersedia metrik FID dan hasil penilaian ahli, hipotesis H1 dan H2 akan diuji sesuai prosedur yang dijelaskan pada Bab 3. Tahapan ini dapat mencakup, misalnya, evaluasi kinerja model klasifikasi dengan dan tanpa augmentasi citra sintesis, serta analisis perbedaan signifikan kinerja yang dihasilkan. Hanya setelah tahap ini dilalui, efektivitas penuh pendekatan generatif yang diusulkan dapat dinilai secara menyeluruh.

Dengan rencana lanjutan tersebut, diharapkan proses pelatihan berikutnya tidak hanya memperbaiki kualitas visual citra sintesis, tetapi juga menghasilkan bukti empiris yang cukup kuat untuk menjawab hipotesis penelitian secara sistematis.

BAB 5

PENUTUP

Bab ini merangkum keseluruhan proses dan temuan penelitian yang telah dipaparkan pada Bab 1 sampai Bab 4, serta memberikan saran untuk pengembangan lebih lanjut. Secara umum, bab penutup terdiri atas subbab kesimpulan dan saran sesuai dengan struktur yang telah ditentukan program studi.

5.1 Kesimpulan

Penelitian ini berangkat dari masalah keterbatasan jumlah dan ketersediaan citra mikroskopis bakteri yang teranotasi dengan baik untuk kebutuhan pelatihan model Deep Learning, khususnya pada kasus klasifikasi bakteri Gram-Positif dan Gram-Negatif. Kekurangan data membuat model klasifikasi rentan overfitting dan sulit digeneralisasikan ke variasi kasus di lapangan. Untuk menjawab permasalahan tersebut, proyek akhir ini mengusulkan pemanfaatan model Conditional Generative Adversarial Network (cGAN) sebagai alat untuk menghasilkan citra sintetis bakteri yang dapat digunakan sebagai kandidat data augmentasi.

5.2 Saran

Berdasarkan keterbatasan yang ditemukan pada perancangan dan eksperimen, beberapa saran pengembangan dan peningkatan solusi dapat dirumuskan sebagai berikut.

1. Melanjutkan dan menyempurnakan pelatihan model

Pelatihan perlu dilanjutkan hingga mendekati target 300 epoch atau sampai indikator konvergensi tercapai. Selama proses tersebut, perlu dipantau tren Generator Loss dan Discriminator Loss secara lebih rinci

2. Pengayaan data dan strategi sampling

Penggunaan dataset DIBaS memberikan titik awal yang baik, tetapi jumlah citra asli yang terbatas membuat variasi morfologi yang terekam juga terbatas. Untuk meningkatkan kemampuan generalisasi, disarankan:

- Menambah sumber dataset lain yang sejenis apabila tersedia,
- Bekerja sama dengan laboratorium atau rumah sakit untuk memperoleh citra mikroskopis nyata yang lebih beragam,.

(halaman sengaja dikosongkan)

DAFTAR PUSTAKA

- [1] V. Shwetha, K. Prasad, C. Mukhopadhyay, and B. Banerjee, "Cycle Generative Adversarial Aetwork approach for normalization of Gram-stain images for bacteria detection," *Intell Based Med*, vol. 9, Jan. 2024, doi: 10.1016/j.ibmed.2024.100138.
- [2] Ç. Işıl *et al.*, "Virtual Gram staining of label-free bacteria using dark-field microscopy and deep learning," 2025. [Online]. Available: <https://www.science.org>
- [3] V. Shwetha, K. Prasad, C. Mukhopadhyay, and B. Banerjee, "Data augmentation for Gram-stain images based on Vector Quantized Variational AutoEncoder," *Neurocomputing*, vol. 600, Oct. 2024, doi: 10.1016/j.neucom.2024.128123.
- [4] M. F. Siegel, "Efficient Deep Learning at Inference Time for Gram Stained Image Classification."
- [5] Y. Jin, W. Chang, and B. Ko, "Generating Chest X-Ray Progression of Pneumonia Using Conditional Cycle Generative Adversarial Networks," *IEEE Access*, vol. 11, pp. 88152–88160, 2023, doi: 10.1109/ACCESS.2023.3305994.
- [6] D. A. B and V. Paul, "Enhancing Pneumonia Detection through GAN-based Data Augmentation and Fine-tuned Transfer Learning."
- [7] J. A. Qadir, S. K. Jameel, and J. Majidpour, "Covid-19 detection and overcome the scarcity of chest X-Ray datasets based on transfer learning and GAN model," in *International Conference on Communication and Information Technology, ICICT 2021*, Institute of Electrical and Electronics Engineers Inc., Jun. 2021, pp. 104–109. doi: 10.1109/ICICT52195.2021.9568468.
- [8] M. Macenko, M. Niethammer, J. S. Marron, D. Borland, J. T. Woosley, X. Guan, C. Schmitt, and N. E. Thomas, "A method for normalizing histology slides for quantitative analysis," in 2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro, 2009, pp. 1107–1110. doi: 10.1109/ISBI.2009.5193250.
- [9] P. Isola, J.-Y. Zhu, T. Zhou, and A. A. Efros, "Image-to-Image Translation with Conditional Adversarial Networks," in 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 5967–5976. doi: 10.1109/CVPR.2017.632.
- [10] Y. Deo, et al., "Metrics that Matter: Evaluating Image Quality Metrics for Medical Image Generation," arXiv preprint arXiv:2405.07175, 2024.
- [11] A. Makhlof, M. Maayah, N. Abughanam, and C. Catal, "The use of generative adversarial networks in medical image augmentation," *Neural Computing and Applications*, vol. 35, pp. 24055–24068, 2023.
- [12] A. Higaki, Y. Kawada, G. Hiasa, T. Yamada, and H. Okayama, "Using a Visual Turing Test to Evaluate the Realism of Generative Adversarial Network (GAN)-Based Synthesized Myocardial Perfusion Images," *Cureus*, vol. 14, no. 10, p. e30646, 2022.
- [13] N. Ntampakis, et al., "Introducing SPINE: A Holistic Approach to Synthetic Pulmonary Imaging Evaluation Through End-to-End Data and Model Management," *IEEE Open Journal of Engineering in Medicine and Biology*, vol. 5, pp. 576-588, 2024.

- [14] R. Kalantar, et al., “CT-Based Pelvic T1-Weighted MR Image Synthesis Using UNet, UNet++ and Cycle-Consistent Generative Adversarial Network (Cycle-GAN),” *Frontiers in Oncology*, vol. 11, p. 665807, 2021.