



**PROGRES
PROYEK AKHIR**

**SENTIMEN ANALISIS BERBASIS ASPEK PADA
PERUMDA AIR MINUM SURYA SEMBADA
SURABAYA MENGGUNAKAN KOMPUTASI
KORELASI**

Dicky Syarif Renaldi
NRP. 3322600009

DOSEN PEMBIMBING
Entin Martiana K, S.Kom., M.Kom.
NIP. 197505302003121001

Aliridho Barakbah S.Kom, Ph.D
NIP. 197308162001121001

**PROGRAM STUDI SARJANA TERAPAN
SAINS DATA TERAPAN
DEPARTEMEN TEKNIK INFORMATIKA DAN
KOMPUTER
POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2025**

“Halaman Ini Sengaja Dikosongkan”

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

PDAM (Perusahaan Daerah Air Minum) merupakan usaha milik daerah yang berfokus pada penyediaan dan distribusi air bersih serta air minum bagi masyarakat. Mengingat air merupakan kebutuhan esensial bagi kehidupan seluruh makhluk hidup, ketersediaannya memiliki peranan krusial dalam menunjang kesejahteraan dan kemakmuran rakyat. Pasokan air yang memadai turut berkontribusi dalam mendorong laju pembangunan di berbagai sektor masyarakat. Sebagai bentuk implementasinya, pemenuhan sebagian besar kebutuhan air bersih di Indonesia dilakukan oleh PDAM yang tersebar di seluruh provinsi, kabupaten, dan kota. Melalui berbagai program, baik di wilayah perkotaan maupun pedesaan, PDAM bertujuan memberikan layanan penyediaan air bersih yang layak dan sehat bagi masyarakat. Layanan ini ditujukan untuk memenuhi kebutuhan rumah tangga dan sektor industri, sekaligus mendukung peningkatan kesehatan masyarakat dan pertumbuhan ekonomi.

Pada pasal UUD 1945 Pasal 33 menyatakan bahwa “Bumi, air dan kekayaan alam yang terkandung di dalamnya dikuasai oleh negara dan dipergunakan untuk sebesar-besarnya kemakmuran rakyat” [8]. Pasal tersebut menjadi dasar filosofis dalam menentukan arah pengelolaan sumber daya alam oleh negara, yang ditujukan sepenuhnya untuk kesejahteraan rakyat. Pengelolaan ini harus dilandasi oleh prinsip keadilan sosial dan keberlanjutan lingkungan, sesuai dengan semangat demokrasi ekonomi yang menjamin kedaulatan negara dalam pemanfaatan sumber daya demi kemakmuran bersama.

Sebagai perusahaan penyedia air yang digunakan oleh seluruh masyarakat, PDAM diwajibkan untuk menjaga kualitas layanan dan pelayanan agar mampu bertahan serta tetap mendapat kepercayaan konsumen. Upaya memberikan pelayanan yang baik akan meminimalisir keluhan yang masuk pada instansi. Fluktuasi jumlah pengaduan ini menjadi data krusial yang merefleksikan performa pelayanan PDAM, sehingga penting untuk dianalisis lebih lanjut guna memahami efektivitas layanan yang diberikan.

Namun, dalam praktiknya, berbagai aduan pelanggan yang disampaikan melalui kanal digital seperti media sosial sering kali didominasi oleh opini negatif, seperti keluhan terhadap air yang tidak mengalir, kualitas air yang keruh, kebocoran, maupun keterlambatan penanganan

gangguan. Kondisi ini menunjukkan adanya kesenjangan antara ekspektasi pelanggan dengan layanan yang diberikan PDAM. Tingginya opini negatif tersebut menandakan urgensi untuk dilakukan analisis yang lebih mendalam terhadap keluhan pelanggan agar PDAM dapat mengidentifikasi aspek layanan yang paling sering menjadi sumber permasalahan dan memperbaikinya secara tepat sasaran[DR1].

1.2 PERMASALAHAN

Ragam layanan yang disediakan oleh PDAM sering kali memunculkan berbagai keluhan, baik terkait dengan kualitas pelayanan maupun jasa yang diberikan. Meskipun PDAM telah memberikan media berupa website untuk mengajukan pengaduan dalam mengetahui kualitas jasa atau layanan mereka dengan cara melihat aktivitas pelanggan, namun nyatanya masih banyak pelanggan yang melakukan pengaduan pada kolom komentar postingan Instagram PDAM Surya Sembada.



Gambar 1. 1. Postingan pada Instagram PDAM Surya Sembada

Pada Gambar 1.1 merupakan salah satu postingan pada Instagram PDAM Surya Sembada pada tanggal 17 Februari 2025 yang membahas mengenai perbaikan pipa bocor diameter 450mm di Jl Made, Lakarsantri. Meskipun PDAM telah menyediakan website dan aplikasi sebagai wadah untuk pelanggan melaporkan pengaduan mengenai layanan yang ada di PDAM, masih banyak pelanggan yang melakukan pengaduan melalui kolom komentar pada postingan Instagram PDAM Surya Sembada.

Dengan banyaknya pelanggan PDAM yang melakukan pengaduan pada setiap kolom komentar akun Instagram PDAM Surya Sembada, membuat analisis data pengaduan menjadi tidak efektif. Kesulitan dalam melakukan pembagian pengaduan ke dalam aspek-aspek layanan yang telah ditentukan di dalam website menjadi hambatan utama, terutama karena data yang masuk sangat beragam dan ditulis dalam bahasa yang tidak terstruktur. Selain itu, memahami makna atau kesimpulan dari sudut pandang masing-masing pelanggan juga menjadi tantangan tersendiri. Oleh karena itu, tidak hanya dibutuhkan pemetaan komentar berdasarkan aspek layanan, tetapi juga analisis sentimen untuk mengetahui sikap atau perasaan pelanggan terhadap masing-masing aspek tersebut. Tanpa adanya pemahaman yang jelas mengenai aspek mana yang paling banyak dikeluhkan dan bagaimana sentimen pelanggan terhadap aspek tersebut, proses pengambilan keputusan akan terhambat dan dapat berdampak pada pemahaman y[DR2]ang keliru mengenai kualitas layanan serta tingkat kepuasan pelanggan terhadap PDAM.

1.3 TUJUAN

Penelitian ini bertujuan untuk mengembangkan sebuah pendekatan baru dalam menganalisis komentar masyarakat terkait layanan PDAM Surya Sembada yang disampaikan melalui media sosial, khususnya Instagram. Pendekatan yang digunakan difokuskan pada analisis sentimen berbasis aspek, di mana setiap komentar pengguna akan dipetakan ke dalam aspek layanan tertentu, seperti air kotor/bau, kebocoran, meter (macet/buram), pemakaian, air tidak keluar, perubahan kode tarif, hingga kebocoran pipa.

Untuk mengelompokkan komentar ke dalam aspek-aspek tersebut, penelitian ini menggunakan metode korelasi antar teks yang dihitung melalui teknik *cosine similarity*. Melalui metode ini, sistem dapat mengenali hubungan antara kata-kata dalam komentar dengan kata-kata kunci yang mewakili tiap aspek, lalu menentukan aspek mana yang paling relevan untuk setiap komentar. Proses ini dilakukan secara otomatis tanpa memerlukan pelatihan model. Selain itu, penggunaan *cosine similarity* dinilai lebih akurat dan efisien dibandingkan dengan pendekatan berbasis *machine learning*, terutama dalam konteks data komentar yang bersifat pendek dan tidak terstruktur.

Setelah komentar dikelompokkan ke dalam aspek tertentu, langkah selanjutnya adalah menganalisis sentimen dari masing-masing komentar tersebut. Analisis ini dilakukan menggunakan pendekatan *rule-based*, yaitu dengan mendeteksi kata-kata yang memiliki

muatan sentimen positif, negatif, atau netral. Dengan cara ini, sistem dapat mengetahui bagaimana sikap atau perasaan masyarakat terhadap aspek layanan yang mereka keluhkan.

1.4 MANFAAT

Penelitian ini memberikan manfaat dalam memudahkan pemahaman terhadap berbagai bentuk susunan kalimat dalam komentar pengguna media sosial, khususnya yang berkaitan dengan pengaduan layanan. Dengan menggunakan pendekatan *correlation computing* berbasis *cosine similarity*, komentar dapat dikelompokkan secara otomatis ke dalam aspek-aspek layanan PDAM yang relevan dan menjadikan proses klasifikasi lebih efisien.

Selain itu, analisis sentimen berbasis aturan (rule-based) memungkinkan pendeteksian makna sentimen dari setiap komentar, baik itu bernada positif, negatif, ataupun netral. Hasil ini memudahkan PDAM dalam memahami isi pengaduan dan opini pelanggan dengan hasil yang lebih akurat.

Pengelompokan komentar berdasarkan aspek layanan juga membantu PDAM dalam mengidentifikasi jenis pengaduan yang paling banyak disampaikan oleh masyarakat. Dengan informasi tersebut, PDAM dapat melakukan evaluasi kinerja dan merancang perbaikan pelayanan yang lebih terarah sesuai dengan kebutuhan pelanggan.

Melalui penelitian ini, diharapkan dapat dibangun sebuah sistem yang mampu membantu pihak PDAM memahami keluhan dan opini masyarakat secara lebih terstruktur. Dengan mengetahui aspek yang paling sering dikomentari serta sentimennya, PDAM dapat merespons kebutuhan masyarakat secara lebih bijak dan sesuai dengan harapan pelanggan.

1.5 SISTEMATIKA PENULISAN

Jelaskan tentang sistematika pembahasan dalam buku proyek akhir yang meliputi :

Bab 1 Pendahuluan

Bab ini menjelaskan latar belakang permasalahan yang mendasari dilakukannya penelitian, rumusan masalah yang akan dijawab, tujuan dari penelitian, manfaat yang diharapkan dari hasil penelitian, serta sistematika

penulisan dari keseluruhan laporan. Bab ini menjadi pondasi awal untuk memahami arah dan ruang lingkup penelitian.

Bab 2 Kajian Pustaka

Bab ini memuat kajian teoritis dan penelitian terdahulu yang relevan. Di dalamnya dibahas konsep dasar mengenai PDAM, media sosial sebagai sumber data opini publik, sentiment analysis, aspect-based sentiment analysis (ABSA), metode *correlation computing* yang digunakan untuk klasifikasi aspek, serta *rule based* yang digunakan untuk analisis sentimen. Bab ini juga mengulas beberapa penelitian terdahulu sebagai landasan dan pembandingan pendekatan yang digunakan dalam penelitian ini.

Bab 3 Desain Sistem

Bab ini menjelaskan rancangan sistem yang digunakan dalam penelitian. Termasuk di dalamnya adalah arsitektur sistem, alur proses analisis, metode ekstraksi data dari Instagram, preprocessing teks, TF-IDF, metode *correlation computing* yang digunakan untuk klasifikasi aspek, serta *rule based* yang digunakan untuk analisis sentimen. Desain sistem secara umum juga disertakan di bab ini..

Bab 4 Eksperimen dan Analisis

Jelaskan tentang apa saja yang dibahas pada Bab 4. Penjelasan memuat bagian-bagian penting pada Eksperimen dan Analisis.

Bab 5 Penutup

Jelaskan tentang apa saja yang dibahas pada Bab 5. Penjelasan memuat bagian-bagian penting pada Penutup.

BAB 2

KAJIAN PUSTAKA

Dengan banyaknya pelanggan PDAM yang melakukan pengaduan pada setiap kolom komentar akun Instagram PDAM Surya Sembada, membuat analisa data pengaduan menjadi tidak efektif. Kesulitan dalam melakukan pembagian pengaduan menjadi aspek-aspek yang telah ditentukan di dalam website serta mendapatkan makna atau kesimpulan dari perbedaan sudut pandang manusia adalah hambatan untuk proses pengambilan keputusan serta memengaruhi pemahaman mengenai sejauh mana kualitas pelayanan PDAM dan tingkat kepuasan pelanggan terhadap layanan yang telah diberikan. Pada bab ini akan dibahas kajian teori mengenai pengaduan layanan PDAM dan beberapa penelitian berusaha menyelesaikan masalah menggunakan pendekatan *aspect based sentiment analysis*.

2.1 DESKRIPSI PERMASALAHAN

Sebagai perusahaan yang bertanggung jawab dalam penyediaan air bersih untuk masyarakat, PDAM memiliki kewajiban untuk memastikan bahwa layanan yang diberikan berjalan optimal dan memuaskan. Namun, pada kenyataannya, keluhan dari pelanggan masih kerap muncul, terutama melalui media sosial seperti Instagram. Meskipun PDAM telah menyediakan kanal pengaduan resmi, banyak pelanggan yang tetap memilih menyampaikan keluhan secara langsung di kolom komentar media sosial karena dianggap lebih cepat dan mudah dijangkau.

Permasalahan muncul ketika komentar-komentar tersebut menumpuk dan tidak terstruktur, sehingga sulit untuk dianalisis secara manual. Keluhan pelanggan juga sangat bervariasi dalam gaya bahasa, sering kali menggunakan singkatan, bahasa informal, atau bahkan emosi. Kondisi ini menyulitkan PDAM untuk memahami secara jelas aspek layanan mana yang paling sering dikeluhkan, serta bagaimana sentimen pelanggan terhadap aspek tersebut.

Untuk mengatasi hal ini, diperlukan sebuah sistem yang mampu memproses komentar-komentar pelanggan secara otomatis. Berdasarkan desain sistem yang ditampilkan pada Gambar 3.1, proses dimulai dari pengambilan data komentar menggunakan Instaloader, dilanjutkan dengan tahapan *preprocessing* seperti pembersihan data, tokenisasi, normalisasi, hingga stemming. Selanjutnya, data akan melalui tahap perhitungan TF-IDF, kemudian diklasifikasikan berdasarkan aspek layanan seperti air tidak keluar, tagihan, atau kebocoran. Setelah aspek ditemukan, dilakukan analisis sentimen untuk mengetahui apakah komentar [DR3] tersebut bernada positif, negatif, atau netral. Hasil akhirnya divalidasi dan

divisualisasikan agar dapat dimanfaatkan oleh PDAM dalam mengevaluasi dan meningkatkan kualitas layanan.

Dengan adanya sistem otomatis berbasis klasifikasi aspek dan analisis sentimen ini, PDAM diharapkan dapat memahami keluhan pelanggan dengan lebih cepat, akurat, dan menyeluruh sehingga pengambilan keputusan dapat dilakukan secara tepat dan berbasis data..

2.2 TEORI PENUNJANG[DR4]

Berikut adalah beberapa teori penunjang yang berhubungan dengan penelitian ini:

2.2.1 Aspect Based Sentiment Analysis (ABSA)

Aspect-Based Sentiment Analysis (ABSA) adalah pendekatan analisis sentimen yang fokus pada aspek-aspek spesifik dalam teks. Setiap aspek diekstraksi dan dianalisis sentimennya secara terpisah, lalu digabungkan untuk menentukan sentimen keseluruhan dari teks [8]. ABSA dapat diterapkan di berbagai bidang seperti ulasan produk, media sosial, dan layanan publik. ABSA bekerja pada tiga tingkat analisis: dokumen, kalimat, dan entitas, dengan tujuan mengidentifikasi polaritas sentimen (positif, negatif, netral) terhadap aspek-aspek spesifik. Pendekatan ini memungkinkan pemahaman yang lebih mendalam dan terfokus terhadap opini pengguna dalam teks.

2.2.2 Correlation Computing

Correlation computing adalah metode yang digunakan untuk mengukur sejauh mana dua entitas dalam teks, misalnya kata-kata atau frasa yang berkaitan satu sama lain. Dalam konteks analisis berbasis aspek, teknik ini berguna untuk menentukan seberapa erat hubungan antara komentar pengguna dan aspek layanan tertentu yang ingin dianalisis, seperti kualitas air atau layanan pelanggan.

Pada penelitian ini, metode *cosine similarity* digunakan untuk menghitung kedekatan atau hubungan antara kata dalam komentar dengan kata kunci tiap aspek. *Cosine similarity* sendiri merupakan salah satu bentuk perhitungan korelasi yang sederhana namun efektif, karena mampu mengidentifikasi seberapa kuat dua vektor (representasi kata) saling terkait secara numerik.

Algoritma korelasi teks yang menggabungkan ekstraksi event terstruktur dan representasi vektor terbukti mampu mengukur hubungan antar teks secara efektif melalui pemetaan vektor

dan teknik klasterisasi. Pendekatan ini memberikan wawasan yang lebih mendalam dalam proses ekstraksi informasi dari data berbasis teks [1].

Dengan menerapkan korelasi komputasi berbasis *cosine similarity*, penelitian ini dapat secara otomatis memetakan komentar masyarakat ke aspek layanan PDAM yang relevan tanpa perlu melatih model pembelajaran mesin, menjadikannya pendekatan yang efisien dan ringan secara komputasi.

2.2.3 Cosine Similarity

Cosine similarity adalah algoritma yang digunakan untuk mengukur seberapa mirip dua buah teks dengan menghitung sudut antara dua vektor, misalnya vektor A dan B. Vektor ini bisa merepresentasikan kata, kalimat, paragraf, atau bahkan satu dokumen penuh. Semakin kecil sudut antara kedua vektor, maka nilai *cosine*-nya akan semakin mendekati 1, yang menandakan tingkat kemiripan yang tinggi. Ketika algoritma ini diterapkan pada data teks, *cosine similarity* dapat membantu menilai seberapa mirip isi dari dua dokumen atau kalimat secara matematis [2].

$$\cos \theta = \frac{A \cdot B}{||A|| ||B||} \quad (2.1)$$

Keterangan:

- $\cos \theta$: Kesamaan antara dua vektor A dan B. Nilainya berada di antara -1 hingga 1, tetapi konteks teks biasanya berkisar antara 0 (tidak mirip) hingga 1 (sangat mirip).
- $A \cdot B$: *Dot product* antara vektor A dan vektor B. Ini menunjukkan jumlah perkalian antara komponen-komponen yang bersesuaian dari kedua vektor
- $||A||$: Panjang atau *magnitude* dari vektor A, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor A.
- $||B||$: Panjang atau *magnitude* dari vektor B, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor B.

2.2.4 Rule Based

Pendekatan *rule based* dalam analisis sentimen merupakan metode yang mengandalkan serangkaian aturan atau pola linguistik yang telah ditentukan sebelumnya untuk mengklasifikasikan emosi dalam sebuah teks. Sistem ini bekerja dengan mencocokkan kata-

kata dalam komentar atau dokumen dengan *rule* yang telah dibuat, seperti kata positif (baik, bagus) atau negatif (buruk, mengecewakan), kemudian menghitung skor untuk menentukan apakah sentimen teks tersebut positif, negatif, atau netral.

2.2.5 Web Scraping

Web scraping merupakan salah satu metode pengumpulan data yang digunakan untuk mengekstraksi informasi dari halaman web yang dibangun menggunakan bahasa markup seperti HTML atau XHTML. Meskipun halaman web umumnya dirancang untuk dibaca oleh manusia, teknik *web scraping* memungkinkan sistem atau perangkat lunak otomatis untuk menelusuri, menyalin, dan menyimpan informasi secara sistematis dari situs web tersebut [3]. Teknik ini sangat berguna dalam pengumpulan data tekstual berskala besar seperti komentar pengguna, ulasan produk, atau opini publik di media sosial.

Dalam konteks teknis, proses *scraping* bekerja dengan cara mengakses alamat URL tertentu, mengambil struktur halaman yang dimuat, dan mengekstrak bagian tertentu dari dokumen seperti teks dalam elemen HTML tertentu yang sesuai dengan tujuan analisis. Proses ini dapat dilakukan menggunakan berbagai bahasa pemrograman, seperti Python, dengan menggunakan *library* seperti BeautifulSoup, Selenium, atau Instaloader untuk platform *social media* seperti Instagram.

Perbedaan antara *web scraping* dan *web crawling* juga penting untuk dipahami. Web scraping bersifat spesifik dan diarahkan untuk mengambil informasi dari halaman web, sedangkan *crawling* dirancang untuk menjelajah banyak halaman melalui tautan dan mengambil informasi umum dari berbagai sumber secara luas [3]. Untuk keperluan penelitian ini, pendekatan *scraping* lebih sesuai karena fokus data berada pada komentar pengguna dalam akun Instagram PDAM Surya Sembada, yang perlu dikumpulkan secara spesifik berdasarkan waktu dan konten.

Dengan memanfaatkan teknik *scraping*, penelitian ini dapat memperoleh data komentar pelanggan secara efisien dan masif, yang kemudian menjadi dasar penting dalam melakukan analisis aspek dan sentimen.

2.2.6 Text Preprocessing

Text preprocessing adalah langkah awal yang dilakukan untuk merapikan data teks mentah yang masih berantakan menjadi format yang lebih rapi dan konsisten. Tujuan utamanya adalah

agar data tersebut bisa dipahami dan diproses dengan baik. Proses ini biasanya dibantu oleh berbagai *library* pemrosesan teks yang tersedia di Python dan proses-proses tersebut adalah:

A. Drop Duplicate

Dalam pengolahan data teks, khususnya data hasil *scraping* dari media sosial, sering ditemukan komentar yang sama muncul lebih dari satu kali. Keberadaan data ganda dapat mengganggu proses analisis karena memberi bobot yang tidak semestinya pada informasi tertentu.

Langkah *drop duplicate* bertujuan untuk menghapus komentar yang identik agar data yang dianalisis benar-benar mewakili opini yang beragam dari pengguna. Dengan hanya mempertahankan data unik, hasil analisis menjadi lebih akurat dan tidak bias terhadap komentar yang berulang.

B. Cleansing Data

Tahap *cleansing* data dilakukan untuk membersihkan data dari karakter-karakter yang tidak relevan terhadap proses klasifikasi. Data dari media sosial seperti Instagram sering kali mengandung banyak *noise*, seperti singkatan, angka yang menggantikan huruf, mention (@), hashtag (#), tautan HTML (seperti <http://...>).

C. Case Folding

Tahapan *case folding* dilakukan dengan mengubah semua huruf dalam data menjadi huruf kecil. Ini penting karena dalam analisis sentimen, perbedaan huruf besar dan kecil tidak mempengaruhi makna kata. Misalnya, kata “Hitung” dan “hitung” akan diperlakukan sama, sehingga hasil analisis menjadi lebih konsisten dan tidak membedakan kata hanya berdasarkan format penulisannya.

D. Tokenizing

Tokenizing adalah salah satu tahap penting dalam proses analisis teks. Secara sederhana, *tokenizing* berarti memecah kalimat atau paragraf menjadi bagian-bagian kecil yang disebut token yang berupa kata atau frasa. Tahap ini penting karena memungkinkan sistem untuk memahami dan mengolah teks dalam bentuk yang lebih terstruktur.

Dalam konteks analisis sentimen, *tokenizing* membantu sistem mengenali kata-kata penting yang mengandung emosi atau opini. Misalnya, dalam sebuah komentar pengguna seperti

"pelayanannya sangat buruk", proses *tokenizing* akan memecah kalimat tersebut menjadi ["pelayanannya", "sangat", "buruk"], sehingga sistem bisa mengidentifikasi kata “buruk” sebagai indikator sentimen negatif.

Beberapa penelitian menunjukkan bahwa pendekatan *tokenizing* bisa mempengaruhi hasil analisis secara signifikan. Erkan dan Güngör, dalam studi mereka, membandingkan berbagai metode tokenisasi dan menemukan bahwa metode sub-kata seperti WordPiece atau SentencePiece cenderung menghasilkan performa yang lebih baik dalam klasifikasi sentimen, karena mampu menangani variasi kata yang lebih kompleks [4]. Ini sangat berguna terutama ketika teks mengandung kata tidak baku, singkatan, atau bahasa media sosial yang tidak standar.

E. Normalization

Normalization atau formalisasi teks adalah proses mengubah teks alami yang tidak terstruktur menjadi bentuk yang lebih terstruktur dan dapat diproses secara otomatis oleh komputer. Dalam konteks analisis bahasa alami, formalisasi ini penting karena memungkinkan sistem untuk mengenali makna, pola, dan struktur dari teks yang kompleks.

Secara sederhana, ketika seseorang menulis komentar menggunakan bahasa yang tidak baku dan tidak sesuai dengan struktur KBBI (Kamus Besar Bahasa Indonesia), sistem cenderung tidak bisa langsung memahami maksudnya jika teks tersebut dibiarkan dalam bentuk mentah. Proses ini mempermudah sistem dalam menilai, mengelompokkan, dan mengambil keputusan berbasis data.

Transformasi teks dari bentuk naratif ke format numerik seperti vektor diperlukan agar teks tersebut dapat digunakan dalam algoritma pembelajaran mesin maupun sistem berbasis aturan, mengingat komputer bekerja berdasarkan representasi simbolik atau angka, bukan bahasa alami manusia [5]. Hal ini karena komputer tidak memahami bahasa manusia secara langsung mereka membutuhkan representasi angka atau simbol yang bisa dihitung dan dianalisis.

Tabel 2. 1. Daftar Kata Pada Kamus Lokal

Informal	Formal	Informal	Formal
takon	tanya	banget	sangat
rek	teman	buk	ibu

Informal	Formal	Informal	Formal
lyn	angkutan umum	buesar	besar
niku	itu	dadi	jadi
warnae	warnanya	gag, ga, g, gk	tidak
iki	ini	monggo	silahkan

F. Stopword Removal

Stop-words adalah kata-kata yang sering digunakan dalam bahasa sehari-hari, namun tidak memiliki makna yang penting dalam analisis teks. Pada tahap ini, kata-kata seperti “yang”, “di”, “ke”, dan sejenisnya dihapus dari teks. Tujuannya adalah untuk menyederhanakan isi teks dan lebih menyoroti kata-kata yang benar-benar membawa informasi penting bagi analisis [6].

G. Stemming

Stemming adalah proses untuk mengubah kata yang memiliki imbuhan menjadi bentuk dasarnya. Tujuan utamanya adalah mengurangi jumlah variasi kata yang muncul tanpa mengubah makna dari kata tersebut [6]. Misalnya, kata "membantu" akan dikembalikan ke bentuk dasar "bantu". Namun, tidak semua kata perlu diubah, contohnya kata "unduh" dalam kalimat "unduh kartu vaksin", karena kata tersebut sudah merupakan bentuk dasar.

2.2.7 Data Split

Data split adalah proses membagi *dataset* menjadi beberapa bagian sesuai kebutuhan penelitian, umumnya menjadi *data training* dan *data testing*. *Data training* digunakan untuk membentuk pola atau aturan pada sistem, sedangkan data testing digunakan untuk menguji kinerja sistem terhadap data yang tidak dipakai pada saat pembentukan model [7]. Dengan adanya pemisahan ini, hasil pengujian dapat memberikan gambaran yang lebih objektif terhadap kemampuan sistem dalam menangani data baru.

Pada penelitian berbasis teks, pembagian data juga penting untuk menjaga proses eksperimen tetap terarah dan terukur. Beberapa penelitian menunjukkan bahwa komposisi pembagian data dapat dibuat dalam beberapa rasio, seperti 50:50, 70:30, 80:20, atau 90:10,

sesuai dengan kebutuhan eksperimen dan karakteristik data yang digunakan [8]. Oleh karena itu, data split menjadi salah satu dasar penting dalam penyusunan alur eksperimen, karena berpengaruh terhadap proses pelatihan, pengujian, dan evaluasi hasil sistem.

2.2.8. Segmentasi Teks

Segmentasi teks adalah proses membagi teks menjadi bagian-bagian yang lebih kecil, seperti kalimat, klausa, atau segmen makna, agar isi teks lebih mudah dianalisis. Dalam pengolahan bahasa alami, segmentasi teks membantu sistem memahami struktur informasi di dalam suatu kalimat, terutama ketika satu teks memuat lebih dari satu topik atau lebih dari satu opini [9].

Pada penelitian aspect-based sentiment analysis, segmentasi teks menjadi penting karena opini pengguna sering kali tidak disampaikan secara tunggal, melainkan terdiri dari beberapa bagian yang membahas aspek berbeda dalam satu komentar. Dengan memecah teks ke dalam segmen yang lebih fokus, hubungan antara aspek dan opini dapat dikenali dengan lebih jelas, sehingga proses analisis menjadi lebih terarah [10], [11].

Dalam konteks penelitian ini, segmentasi teks digunakan untuk membagi komentar pelanggan yang telah melalui tahap normalisasi menjadi beberapa bagian berdasarkan kata hubung atau konjungsi. Tahap ini dilakukan agar komentar yang mengandung lebih dari satu keluhan, misalnya mengenai air tidak mengalir dan tagihan, dapat dipisahkan terlebih dahulu sebelum masuk ke proses tokenisasi, stemming, dan klasifikasi multi aspek. Dengan demikian, segmentasi teks menjadi landasan penting untuk membantu sistem mengenali konteks keluhan secara lebih spesifik dan terstruktur.

2.2.9 TF-IDF

Setelah data melalui tahap *preprocessing*, langkah selanjutnya adalah proses perhitungan TF-IDF. Tahap ini sangat penting karena berfungsi untuk mengubah teks menjadi representasi numerik yang bisa dipahami oleh algoritma klasifikasi. TF-IDF bekerja dengan memberikan bobot pada setiap kata berdasarkan seberapa sering kata tersebut muncul dalam satu dokumen dibandingkan dengan seluruh dokumen dalam dataset, pembobotan ini membantu sistem mengenali kata-kata yang benar-benar penting dalam membedakan satu dokumen dengan yang lain [12].

$$TF \times IDF(d, t) = TF(d, t) \times \log \frac{N}{df(t)} \quad (2.2)$$

Keterangan:

TF : Merupakan nilai dari term frequency

IDF(d,t) : Merupakan nilai dari inverse document frequency

(d,t): Merupakan banyaknya term t pada dokumen d

N : Jumlah dari semua kumpulan dokumen

df(t): Merupakan jumlah dokumen yang memiliki term t

2.2.10 Validasi

Tahapan ini bertujuan untuk mengevaluasi seberapa baik metode klasifikasi yang digunakan dalam sistem. Salah satu cara umum untuk mengukurnya adalah dengan menghitung nilai akurasi, yaitu membandingkan jumlah prediksi yang benar dengan jumlah data keseluruhan.

Semakin tinggi nilai akurasi yang diperoleh, berarti metode tersebut semakin sesuai dengan karakteristik data yang digunakan, sehingga hasil prediksinya pun lebih mendekati kondisi sebenarnya. Sebaliknya, jika nilai akurasinya rendah, maka metode yang digunakan kemungkinan kurang cocok dengan data, dan hasil prediksinya pun cenderung tidak menggambarkan kenyataan.

$$Accuracy = \frac{\sum pb}{num_{data}} \quad (2.3)$$

Keterangan:

pb : Hasil klasifikasi (prediksi) yang sesuai dengan kelas sebenarnya

num_data : Jumlah data keseluruhan

Meskipun akurasi sering digunakan untuk menilai kinerja sistem klasifikasi, nilai ini saja terkadang belum cukup untuk mengetahui penyebab rendahnya performa model. Hanya melihat akurasi tidak bisa langsung menunjukkan letak kesalahan atau penyimpangan data yang terjadi. Oleh karena itu, dalam penelitian ini juga digunakan dua metrik tambahan, yaitu

recall dan *precision*, untuk mendapatkan gambaran yang lebih detail tentang kinerja klasifikasi terhadap masing-masing kelas.

Recall mengukur seberapa banyak data yang benar-benar relevan berhasil ditemukan oleh sistem dari seluruh data yang seharusnya termasuk dalam suatu kelas. Sederhananya, *recall* menunjukkan seberapa baik sistem dalam menemukan data yang tepat. Sementara itu, *precision* mengukur seberapa akurat hasil prediksi sistem, yaitu seberapa besar dari semua data yang diprediksi masuk ke suatu kelas ternyata benar-benar relevan. Dengan kata lain, *precision* menunjukkan seberapa tepat sistem dalam memilih data yang benar.

$$recall = \frac{\sum pb}{\sum total_{kelas}} \quad (2.4)$$

$$precision = \frac{\sum pb}{\sum total_{pisah}} \quad (2.5)$$

Keterangan:

total_kelas : Jumlah keseluruhan data pada kelas tertentu

total_pisah : Jumlah data yang dipisahkan *classifier* sebagai anggota kelas tertentu

Untuk menghitung nilai *recall* dan *precision*, kita bisa menggunakan bantuan *confusion matrix*, seperti yang ditampilkan pada Tabel 2.2. Dalam *confusion matrix*, terdapat empat istilah penting yang perlu dipahami:

1. **True Positive (TP)**: Data diprediksi benar dan memang benar.
2. **True Negative (TN)**: Data diprediksi salah dan memang salah.
3. **False Positive (FP)**: Data diprediksi benar, tapi sebenarnya salah.
4. **False Negative (FN)**: Data diprediksi salah, padahal sebenarnya benar.

Nilai *recall* dihitung dengan membandingkan jumlah TP dengan total TP dan FN. Artinya, *recall* menunjukkan seberapa banyak data benar yang berhasil ditemukan oleh sistem dari semua data yang seharusnya benar.

Sedangkan *precision* dihitung dengan membandingkan jumlah TP dengan total TP dan FP. Ini menunjukkan seberapa akurat prediksi sistem dalam menentukan data yang benar dari semua yang diprediksi sebagai benar.

Tabel 2. 2. *Confusion Matrix*

		<i>Kelas Prediksi</i>	
		<i>TRUE</i>	<i>FALSE</i>
<i>Kelas Sebenarnya</i>	<i>TRUE</i>	TP (<i>True Positive</i>)	FP (<i>False Positive</i>)
	<i>FALSE</i>	FN (<i>False Negative</i>)	TN (<i>True Negative</i>)

$$recall = \frac{TP}{TP + FN} \quad (2.6)$$

$$precision = \frac{TP}{TP + FP} \quad (2.7)$$

Keterangan:

TP (True Positive) :Jumlah data dari kelas yang diprediksi benar dan hasilnya benar

FN (False Negative): Jumlah data dari kelas yang diprediksi salah atau hasilnya benar

FP (False Positive): Jumlah data dari kelas yang diprediksi salah dan hasilnya salah

2.2.11 Dashboard

Dashboard adalah tampilan antarmuka yang digunakan untuk menyajikan informasi penting secara ringkas, terstruktur, dan mudah dipahami. Dalam konteks sistem informasi, dashboard membantu pengguna melihat gambaran umum data melalui ringkasan angka, tabel, dan visualisasi sehingga proses pemantauan dapat dilakukan dengan lebih cepat. Dashboard tidak hanya berfungsi sebagai media tampilan, tetapi juga sebagai sarana untuk membantu pengguna memahami kondisi data dan menemukan informasi yang relevan untuk kebutuhan analisis.

Perkembangan *dashboard* juga menunjukkan bahwa *dashboard* modern tidak lagi hanya menampilkan data secara statis, tetapi sudah mengarah pada bentuk yang lebih interaktif. Pengguna dapat membaca ringkasan informasi, menelusuri pola tertentu, dan berinteraksi

dengan data untuk memperoleh pemahaman yang lebih mendalam. Penelitian lain juga menunjukkan bahwa desain dashboard yang baik perlu memperhatikan susunan komponen, hubungan antarvisualisasi, serta kemudahan pengguna dalam menafsirkan isi dashboard. Selain itu, dashboard yang baik juga perlu mendukung kejelasan sumber informasi dan konteks data agar hasil yang ditampilkan dapat dipercaya dan digunakan sebagai dasar pemantauan maupun pengambilan keputusan.

Berdasarkan penjelasan tersebut, dashboard dalam penelitian ini digunakan sebagai media untuk menampilkan hasil analisis komentar pelanggan PDAM Surya Sembada secara lebih informatif. Melalui dashboard, hasil analisis aspek dan sentimen dapat disajikan dalam bentuk ringkasan dan visualisasi sehingga memudahkan pengguna dalam melakukan *monitoring* terhadap pola keluhan pelanggan.

2.2.12 Streamlit

Streamlit adalah *framework* berbasis Python yang digunakan untuk membangun aplikasi data secara interaktif dengan cara yang relatif sederhana. Melalui Streamlit, pengembang dapat menampilkan teks, tabel, grafik, formulir input, dan berbagai komponen visual lainnya langsung dari kode Python tanpa harus membangun antarmuka *website* secara manual. Dengan pendekatan ini, proses pembuatan aplikasi analisis data menjadi lebih cepat dan lebih mudah dipahami, terutama untuk kebutuhan visualisasi dan penyajian hasil pengolahan data [13].

Selain digunakan untuk menampilkan data, Streamlit juga mendukung pengembangan aplikasi yang bersifat dinamis dan interaktif. Pengguna dapat berinteraksi dengan sistem melalui berbagai komponen seperti tombol, kolom input, pilihan menu, dan filter data. Dokumentasi resmi Streamlit menjelaskan bahwa *framework* ini dirancang agar proses pengembangan aplikasi dapat dilakukan mulai dari tahap pembuatan, pengembangan, hingga deployment dalam satu alur kerja yang terintegrasi [13]. Karakteristik ini membuat Streamlit cocok digunakan untuk membangun dashboard analisis, karena mampu menghubungkan proses pengolahan data dengan tampilan hasil secara langsung dan responsif.

Berdasarkan penjelasan tersebut, Streamlit dalam penelitian ini digunakan sebagai *framework* untuk membangun dashboard hasil analisis komentar pelanggan PDAM Surya Sembada. Penggunaan Streamlit dipilih karena mendukung pembuatan tampilan yang interaktif, mudah diintegrasikan dengan proses analisis berbasis Python, dan sesuai untuk kebutuhan penyajian hasil analisis aspek dan sentimen dalam bentuk dashboard.

2.2.13 SQLite

SQLite adalah sistem manajemen basis data relasional yang bersifat ringan dan digunakan untuk menyimpan data dalam sebuah file database. Berbeda dengan sistem basis data *client-server*, SQLite dapat digunakan secara langsung di dalam aplikasi tanpa memerlukan proses instalasi server terpisah. Karakteristik ini membuat SQLite banyak digunakan pada aplikasi yang membutuhkan penyimpanan data secara sederhana, cepat, dan efisien [14].

Selain ringan, SQLite juga mendukung berbagai fitur penting dalam pengelolaan basis data, seperti penggunaan SQL, transaksi, indeks, dan pengaturan struktur tabel. Dokumentasi resmi SQLite juga menjelaskan bahwa SQLite dapat digunakan pada berbagai situasi pengembangan aplikasi, terutama ketika kebutuhan penyimpanan data tidak terlalu kompleks tetapi tetap memerlukan pengelolaan data yang terstruktur [14]. Karena seluruh data disimpan dalam satu file database, proses integrasi dengan aplikasi juga menjadi lebih mudah dan praktis.

Berdasarkan penjelasan tersebut, SQLite dalam penelitian ini digunakan sebagai media penyimpanan data komentar dan hasil analisis yang ditampilkan pada *dashboard*. Penggunaan SQLite dipilih karena cukup ringan, mudah diintegrasikan dengan aplikasi berbasis Python, serta sesuai untuk kebutuhan penyimpanan data pada sistem monitoring hasil analisis aspek dan sentimen.

2.3 PENELITIAN TERKAIT

Penelitian mengenai *aspect-based sentiment analysis* terus berkembang dan sebenarnya cukup banyak dipublikasi. Berbagai pendekatan telah digunakan untuk menyelesaikan permasalahan serupa, mulai dari metode *machine learning* dan *deep learning* hingga menggunakan pendekatan *rule-based*. Meskipun permasalahan yang dihadapi relatif sama yaitu mengidentifikasi aspek dan menentukan sentimen dalam komentar pengguna, namun masing-masing penelitian memiliki pendekatan yang berbeda-beda. Bagian ini membahas beberapa penelitian terkait yang menjadi landasan dalam merancang sistem *aspect based sentiment analysis* berbasis *correlation computing*. Berikut adalah detail mengenai penelitian-penelitian yang telah dilakukan sebelumnya:

2.3.1 Analysis Sentiment to Religious Based Issues Netizen Comments on President Jokowi's Instagram Using the Naive Bayes Classifier Method

Ramadhani dan Widyaningrum (2024) melakukan analisis sentimen terhadap komentar publik di Instagram Presiden Joko Widodo yang berkaitan dengan isu keagamaan, seperti ucapan Selamat Natal dan kunjungan ke gereja. Penelitian ini bertujuan untuk mengukur opini publik terhadap isu sensitif berbasis agama di Indonesia, menggunakan algoritma *Naive Bayes* untuk mengklasifikasikan sentimen menjadi positif dan negatif. Dataset berjumlah 2.600 komentar, yang 1.309 di antaranya dilabeli secara manual oleh ahli komunikasi dan linguistik sebagai data latih.

Tahapan *preprocessing* melibatkan pembersihan data dan normalisasi sebelum dilakukan pelatihan model. Hasil pelatihan model dengan data latih menunjukkan tingkat akurasi sebesar 97,63%, yang termasuk sangat tinggi untuk konteks analisis sentimen berbasis opini publik. Dari 1.291 data uji yang belum diklasifikasikan, ditemukan bahwa 70,56% komentar ber sentimen positif dan 29,44% negatif. Penelitian ini menunjukkan bahwa *Naive Bayes* sangat efektif dalam mengklasifikasi opini publik terhadap konten pemerintah di media sosial, serta bisa diadaptasi untuk analisis sentimen pada sektor pelayanan publik lainnya seperti PDAM [15].

2.3.2 Sentiment Analysis of Student Satisfaction on Telkom University Language Center (LaC) Service on Instagram Using the RNN Method

Pada jurnal ini melakukan penelitian terhadap komentar mahasiswa di akun Instagram *Language Center* (LaC) Telkom University untuk mengetahui tingkat kepuasan terhadap layanan tersebut. Penelitian ini bertujuan untuk mengklasifikasikan sentimen mahasiswa menjadi positif, negatif, dan netral dengan memanfaatkan metode *Recurrent Neural Network* (RNN), yang dikenal efektif dalam memahami konteks sekuensial dari teks. Dataset diperoleh langsung dari komentar di unggahan akun resmi LaC.

Dalam tahap *preprocessing*, dilakukan pembersihan data melalui *case folding*, *tokenization*, dan *stopwords removal*. Setelah itu, data diklasifikasikan menggunakan arsitektur RNN dan dievaluasi menggunakan *confusion matrix*. Hasil yang diperoleh menunjukkan akurasi sebesar 79%, membuktikan bahwa RNN mampu menangkap nuansa opini dalam komentar Instagram meskipun ditulis dalam bahasa informal atau tidak terstruktur. Studi ini memberikan bukti kuat

bahwa pendekatan deep learning dapat diterapkan secara efektif untuk menilai kepuasan pelanggan berbasis media sosial [16].

2.3.3 Sentiment Analysis on Social Media Instagram of Depression Issues Using Naive Bayes Method

Penelitian ini melakukan analisis sentimen terhadap komentar publik terkait isu depresi di media sosial Instagram. Penelitian ini bertujuan untuk memahami opini masyarakat terhadap isu kesehatan mental menggunakan metode *Naïve Bayes* (NB). Dataset terdiri dari 1.300 komentar yang dikumpulkan melalui web crawling dengan kata kunci terkait depresi dan kesehatan mental. Data ini kemudian diklasifikasikan secara manual menjadi positif, negatif, dan netral oleh para ahli sebelum dilakukan pelatihan model. Analisis dilakukan dengan mengembangkan aplikasi yang mampu menampilkan visualisasi hasil analisis dalam bentuk grafik batang dan *pie*.

Tahapan *preprocessing* mencakup pembersihan teks dari simbol-simbol tidak penting, normalisasi, dan penghapusan stopword. Setelah itu, data dianalisis menggunakan algoritma NB yang menghasilkan akurasi prediksi sebesar 82,55%. Penelitian ini menegaskan efektivitas NB dalam menangani data komentar publik pada isu sosial yang sensitif, terutama karena keakuratannya yang tinggi meskipun pada data berbahasa informal. Sistem ini juga berpotensi menjadi alat pendukung pengambilan keputusan dalam isu-isu kesehatan publik berbasis opini netizen [17].

2.3.4 Sentiment Analysis to Assess Customer Retention on Instagram Social Media Using Naive Bayes Classifier and Support Vector Machine

Pada jurnal ini meneliti komentar pelanggan terhadap akun Instagram bisnis lokal bernama Mr. Cream Puff untuk mengevaluasi potensi retensi pelanggan melalui analisis sentimen. Tujuan utama penelitian ini adalah memahami bagaimana opini pelanggan dapat mempengaruhi strategi Customer Relationship Management (CRM) dalam konteks media sosial. Dataset dikumpulkan dari komentar publik di Instagram dan dianalisis menggunakan dua algoritma pembelajaran mesin: *Naïve Bayes* dan *Support Vector Machine* (SVM).

Komentar yang dikumpulkan kemudian melalui proses *preprocessing* berupa normalisasi, penghapusan tanda baca, dan stopword removal. Hasil analisis menunjukkan bahwa SVM memiliki performa lebih tinggi dibandingkan *Naïve Bayes*, dengan akurasi 76,59% berbanding

74,81%. Temuan ini memperlihatkan bahwa pemanfaatan sentimen pelanggan dari Instagram tidak hanya relevan untuk perusahaan komersial, tetapi juga bisa diterapkan dalam pelayanan publik, seperti PDAM, untuk memahami persepsi pelanggan secara lebih terstruktur dan responsif [18].

2.3.5 Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data Using Machine Learning

Jurnal ini melakukan penelitian untuk mengidentifikasi aspek keluhan publik dan sentimen dari data pengaduan masyarakat Indonesia yang diperoleh dari situs ulas.surakarta.go.id. Penelitian ini berfokus pada penerapan *Aspect-Based Sentiment Analysis* (ABSA) menggunakan pendekatan machine learning untuk memetakan komentar ke dalam aspek layanan seperti pendidikan, bantuan sosial, dan ketenagakerjaan. Tujuannya adalah untuk membantu pemerintah dalam mempercepat pengambilan keputusan berbasis isu-isu yang paling banyak dikritik masyarakat.

Metode *preprocessing* yang digunakan dalam penelitian ini mencakup tokenisasi, penghapusan stopwords, dan konversi teks ke dalam bentuk numerik menggunakan teknik representasi fitur. Tiga algoritma yang diuji adalah *Support Vector Machine* (SVM), *Complement Naive Bayes*, dan *Decision Tree*. Dari ketiganya, SVM menunjukkan performa terbaik dengan akurasi sebesar 85,65%, lebih tinggi dibandingkan metode lainnya. Hasil ini menegaskan bahwa pendekatan machine learning dapat secara efektif memisahkan sentimen dan aspek dari komentar masyarakat [19].

Dari keseluruhan penelitian terkait, terdapat beberapa perbedaan dalam pengumpulan dataset, tahap preprocessing dan metode penelitian yang digunakan. Perbedaan ini dapat dilihat pada Tabel 2.3 di bawah ini.

Tabel 2. 3 Perbandingan Penelitian Terkait

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
1	<i>Analysis Sentiment to Religious Based Issues Netizen</i>	Komentar Instagram	Cleansing, Tokenization, Case Folding, Filtering	Naive Bayes	97.63%

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
	<i>Comments on President Jokowi's Instagram Using the Naive Bayes Classifier Method</i>				
2	<i>Sentiment Analysis of Student Satisfaction on Telkom University Language Center (LaC) Service on Instagram Using the RNN Method</i>	Komentar Instagram	<i>Case Folding, Data Cleaning, Stopwords Removal, Tokenization</i>	RNN	79%
3	<i>Sentiment Analysis on Social Media Instagram of Depression Issues Using NB Method</i>	Data dari komentar Instagram dengan hastag #MentalHealth dan #Depression	Data Cleaning, Case Folding, Tokenization, Stopword, Stemming	Lexicon Based, Naive Bayes	82.55%
4	<i>Sentiment Analysis to</i>	Komentar Instagram	Normalisasi, penghapusan	SVM, Naive	76.59% (SVM),

No	Judul	Dataset	Preprocessing	Metode Penelitian	Hasil Akurasi
	<i>Assess Customer Retention on Instagram Social Media Using Naive Bayes Classifier and Support Vector Machine</i>		tanda baca, dan stopword removal	Bayes	74,81% (Naive Bayes)
5	<i>Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data Using Machine Learning</i>	Aspirasi publik dari website ulas.surakarta.go.id	tokenisasi, penghapusan stopwords, dan konversi teks ke dalam bentuk numerik	SVM, Naive Bayes, Decision Tree	85.65% (SVM), 81% (Naive Bayes), 82.77% (Decision Tree)
6	<i>Aspect Based Sentiment Analysis Menggunakan Correlation Computing</i>	Komentar Instagram	<i>Drop duplicate, cleaning data, case folding, tokenizing, normalization, stopword removal, stemming</i>	<i>Cosine similarity, rule based</i>	Skenario 1: 69.46% Skenario 2: 71.07% Skenario 3: 68.76% Skenario 4: 67.71%

BAB 3

DESAIN SISTEM

3.1 DESKRIPSI SOLUSI


Solusi yang ditawarkan dalam penelitian ini adalah pengembangan sistem *aspect-based sentiment analysis* yang mampu mengelompokkan komentar masyarakat terhadap layanan PDAM Surya Sembada ke dalam aspek-aspek tertentu secara otomatis, kemudian menentukan sentimen dari setiap komentar tersebut. Sistem ini dirancang untuk membantu PDAM memahami keluhan dan opini publik secara lebih terstruktur, akurat, dan efisien tanpa memerlukan pelatihan model machine learning yang kompleks.

Fitur utama dari sistem ini adalah pemetaan aspek menggunakan metode *correlation computing* berbasis *cosine similarity*. Setiap komentar yang masuk akan direpresentasikan dalam bentuk vektor kata, kemudian dihitung tingkat kemiripannya dengan daftar kata kunci yang telah didefinisikan untuk setiap aspek layanan. Dengan menggunakan *cosine similarity*, sistem dapat mengenali keterkaitan antara isi komentar dan aspek tertentu secara matematis. Pendekatan ini dipilih karena memiliki keunggulan dalam kesederhanaan perhitungan dan tidak membutuhkan data latih, sehingga cocok untuk kasus dengan keterbatasan dataset.

Fitur kedua adalah analisis sentimen menggunakan *rule based*. Setelah komentar dikelompokkan ke dalam aspek yang sesuai, sistem akan memeriksa kata-kata dalam komentar tersebut dan mencocokkannya dengan aturan-aturan yang telah dibuat (positif, negatif, atau netral). Sistem kemudian menentukan sikap atau emosi yang terkandung dalam komentar terhadap aspek yang bersangkutan. Keuntungan pendekatan ini adalah transparansi dan kemudahan dalam penyesuaian daftar kata dan aturan dapat diperluas atau dimodifikasi sesuai kebutuhan tanpa mempengaruhi kinerja sistem secara keseluruhan.

Dengan dua fitur utama ini, sistem diharapkan mampu menghasilkan analisis yang tidak hanya mengenali topik yang dibahas oleh masyarakat, tetapi juga memahami bagaimana perasaan mereka terhadap aspek tersebut. Hal ini sangat penting dalam konteks pelayanan publik, karena membantu pihak PDAM dalam mengambil keputusan berbasis data, merespons keluhan secara tepat, dan meningkatkan kualitas layanan secara berkelanjutan.

3.2 DESAIN SISTEM



Gambar 3. 1. Desain Sistem

3.2.1 Scraping Instagram Comment

Data yang digunakan pada penelitian ini merupakan komentar aduan pelanggan dari sosial media Instagram milik PDAM Surya Sembada. Data komentar diambil menggunakan *library python* yaitu Instaloader. Seluruh data hasil *crawling* disimpan dalam format Excel CSV (*Comma Separated Value*).

3.2.2 Preprocessing

Tahap *preprocessing* data adalah langkah kritis dalam mempersiapkan data untuk analisis. Pada tahap *preprocessing*, data yang diperoleh diolah untuk menemukan informasi yang diperlukan dan membuang data yang tidak berguna untuk analisis. Data transformasi melibatkan beberapa tahap, yaitu: *drop duplicates*, *cleansing data*, *case folding*, *tokenizing*, *normalization*, *stopword removal*, dan *stemming*.

1. Drop Duplicates

Drop duplicate bertujuan untuk menghapus komentar yang identik agar data yang dianalisis benar-benar mewakili opini yang beragam dari pengguna. Dengan hanya mempertahankan data unik, hasil analisis menjadi lebih akurat dan tidak bias terhadap komentar yang berulang.

2. Cleansing Data

Cleansing dalam tahap *preprocessing* melibatkan langkah-langkah untuk membersihkan teks dari elemen-elemen yang tidak relevan atau mengganggu dalam analisis teks. Ini termasuk:

- Penghapusan karakter khusus: Menghapus karakter khusus seperti *mention* (@), *hashtag* (#), tautan HTML (<http://...>).
- Penghapusan karakter angka: Menghapus angka dari teks, kecuali jika angka tersebut penting.

Namun terdapat pengecualian pada simbol *dot* (.), *comma* (,), tanda seru (!), dan tanda tanya (?). Simbol ini tidak dihapus agar tidak menghilangkan konteks dari kalimat pada saat *sentiment analysis*.

3. Case Folding

Case folding adalah proses mengubah semua huruf menjadi huruf kecil atau huruf besar. Pada penelitian ini, *case folding* yang dilakukan yaitu mengubah seluruh dataset menjadi huruf kecil.

4. Stopword Removal

Stopword removal adalah proses menghapus kata-kata yang dianggap tidak penting dalam analisis, seperti kata sambung atau kata umum yang sering muncul. Tujuannya adalah menyaring kata-kata yang tidak memberikan banyak makna agar yang tersisa hanya kata-kata yang benar-benar relevan untuk pelatihan data. Contoh kata-kata yang biasanya dihapus antara lain ‘di’, ‘yang’, ‘dan’, ‘ke’, serta kata-kata lain yang ada dalam daftar stopwords yang telah disiapkan.

5. Normalization

Pada tahap ini kata-kata yang tidak sesuai dengan kaidah Bahasa Indonesia diubah menjadi kata-kata yang sesuai dengan kaidah Bahasa Indonesia.

6. Segmentasi Teks

Pada tahap ini, sistem melakukan pemecahan komentar menjadi beberapa segmen kalimat berdasarkan konjungsi yang telah didaftarkan sebelumnya. Tujuan dari proses ini adalah agar satu komentar yang memuat lebih dari satu keluhan atau lebih dari satu konteks pembahasan tidak langsung diproses sebagai satu kalimat utuh, melainkan dipisahkan menjadi beberapa bagian yang lebih spesifik. Dengan cara ini, setiap segmen dapat mewakili satu konteks pembahasan yang lebih jelas sehingga mempermudah proses pengolahan pada tahap berikutnya.

Proses segmentasi teks dimulai dengan membaca daftar konjungsi yang digunakan sebagai pemisah segmen. Setelah itu, sistem memeriksa teks komentar hasil *preprocessing* sebelumnya untuk mencari seluruh konjungsi yang muncul di dalam kalimat. Jika ditemukan satu atau lebih konjungsi yang sesuai, maka teks akan dipotong berdasarkan posisi masing-masing konjungsi tersebut, sehingga jumlah segmen yang dihasilkan akan mengikuti jumlah konjungsi yang terdeteksi di dalam komentar. Sebaliknya, jika tidak ditemukan konjungsi yang terdaftar, maka komentar akan tetap disimpan sebagai satu segmen utuh.

Melalui proses ini, komentar yang awalnya panjang dan membahas beberapa hal sekaligus dapat dipecah menjadi bagian-bagian kalimat yang lebih terfokus. Hasil segmentasi ini kemudian digunakan sebagai masukan pada proses berikutnya, karena setiap segmen dianggap lebih representatif dalam menggambarkan satu topik keluhan pelanggan. Dengan demikian, segmentasi teks berperan penting dalam membantu sistem memahami struktur komentar secara lebih rinci sebelum dilakukan pengolahan aspek maupun sentimen.

7. Tokenizing

Setelah proses segmentasi teks selesai, langkah berikutnya adalah tokenisasi. Pada tahap ini, teks akan dipecah menjadi bagian-bagian kecil seperti kata atau token, sehingga lebih mudah untuk dianalisis atau diproses lebih lanjut.

8. Stemming

Di tahap akhir *preprocessing*, dilakukan proses stemming, yaitu mengubah setiap kata dalam teks menjadi bentuk dasarnya dengan cara menghapus imbuhan. Imbuhan yang dihilangkan bisa berupa awalan, akhiran, sisipan, atau kombinasi dari awalan dan akhiran. Dalam penelitian ini, proses *stemming* dilakukan menggunakan *library* Python bernama Sastrawi.

3.2.3 Data Split

Pada penelitian ini, proses data split dilakukan setelah tahap *preprocessing* selesai. Data dibagi menjadi dua bagian, yaitu *data train* dan *data test*. *Data train* dibentuk dari komentar yang tidak mengalami segmentasi atau hanya memiliki satu segmen kalimat, yaitu data yang nilai *sentence_2*-nya kosong. Dengan cara ini, data train hanya berisi komentar yang mewakili satu konteks utama sehingga dapat digunakan sebagai acuan awal dalam proses pembelajaran pola aspek.

Sementara itu, *data test* menggunakan seluruh data yang tersedia, baik komentar yang hanya memiliki satu segmen maupun komentar yang terpecah menjadi dua segmen. Pendekatan ini dipilih karena tujuan utama penelitian adalah menguji kemampuan sistem dalam mengenali aspek pada seluruh komentar, termasuk komentar *multi-aspect*.


3.2.4 TF-IDF

TF-IDF (*Term Frequency–Inverse Document Frequency*) bekerja dengan memberikan bobot pada setiap kata berdasarkan seberapa sering kata tersebut muncul dalam satu dokumen dibandingkan dengan seluruh dokumen dalam dataset, pembobotan ini membantu sistem mengenali kata-kata yang benar-benar penting dalam membedakan satu dokumen dengan yang lain.

3.2.5 Aspect Based Menggunakan Cosine Similarity

Pada tahap ini dilakukan klasifikasi berdasarkan aspek. Metode yang digunakan dalam tahap ini adalah *cosine similarity*. Algoritma ini akan mengukur seberapa mirip dua buah teks dengan menghitung sudut antara dua vektor. Vektor ini bisa merepresentasikan kata, kalimat, paragraf, atau bahkan satu dokumen penuh. Semakin kecil sudut antara dua vektor, maka *cosine*-nya akan semakin mendekati 1, yang menandakan tingkat kemiripan yang tinggi. Ketika algoritma ini diterapkan pada data teks, *cosine similarity* dapat membantu menilai seberapa mirip isi dari dua dokumen atau kalimat secara matematis.

3.2.6 Sentiment Analysis Menggunakan Rule Based



Gambar 3. 2. Desain Sistem *Sentiment Analysis*

Sistem analisis sentimen yang akan dikembangkan dalam penelitian ini menggunakan pendekatan *rule based*. Dalam metode ini, peneliti menetapkan sejumlah aturan untuk menganalisis kombinasi kata berdasarkan jenis katanya di dalam konten media sosial. Setiap kata dalam komentar akan diperiksa jenis katanya (*part of speech*) untuk melihat apakah ada rangkaian kata yang cocok dengan aturan yang telah dibuat. Jika ditemukan rangkaian yang sesuai, sistem akan menggabungkan dan menghitung nilai sentimennya berdasarkan aturan tersebut.

Setelah semua rangkaian kata yang cocok diproses, sistem kemudian akan menjumlahkan nilai sentimen dari seluruh kata yang ada dalam konten. Hasil akhir dari penjumlahan ini akan menentukan sentimen komentar tersebut. Jika nilainya lebih dari nol, maka sentimennya dianggap positif; jika nol berarti netral; dan jika kurang dari nol maka dikategorikan sebagai sentimen negatif. Berikut adalah aturan *part of speech* pada *sentiment analysis* pada penelitian ini:

A. Adjektif Tunggal

Jika dalam suatu kalimat terdapat kata sifat (adjektif) tanpa adanya kata kerja (verb) atau kata depan (preposisi), maka nilai sentimen kalimat tersebut akan mengikuti nilai dari kata sifat yang muncul. Misalnya pada kalimat:

“saya kecewa”

Kata “saya” tidak termasuk dalam aturan karena merupakan kata benda (nomina), sehingga tidak diperhitungkan. Yang akan dianalisis adalah kata “kecewa”, karena sesuai dengan aturan sebagai kata sifat. Kata “kecewa” memiliki nilai sentimen -1, sehingga nilai ini akan menjadi representasi dari sentimen keseluruhan kalimat.

B. Verb Tunggal

Jika sebuah kalimat mengandung kata kerja (verba) tanpa disertai kata sifat (adjektif) atau kata depan (preposisi), maka nilai sentimen kalimat tersebut akan mengikuti nilai dari kata kerja tersebut. Sebagai contoh, dalam kalimat

“pelayanan PDAM merugikan saya”

Kata “merugikan” adalah verba yang memiliki nilai sentimen -1. Sementara itu, kata “pelayanan” dan “PDAM” tidak tercantum dalam kamus sentimen, dan kata “saya” adalah nomina yang juga tidak termasuk dalam aturan. Oleh karena itu, sentimen kalimat ini ditentukan oleh kata “merugikan”, sehingga nilai sentimennya adalah -1 atau bersifat negatif.

C. Preposisi + Adjektif

Jika sebuah kalimat memiliki kata sifat (adjektif) yang muncul setelah kata depan (preposisi), maka nilai sentimen kalimat tersebut dihitung menggunakan aturan *AND operator*. Tabel 3.1 menunjukkan kombinasi nilai antara preposisi dan adjektif beserta hasil akhirnya.

Tabel 3. 1. *AND Operator*

Preporisisi	Adjektif	Nilai
1	1	1
1	-1	-1
-1	1	-1

Preporisisi	Adjektif	Nilai
-1	-1	1

Sebagai contoh, dalam kalimat “penanganan aduan saya kenapa sangat lama ya min?”, kata “sangat” merupakan preposisi dengan nilai sentimen 1, sedangkan kata “lama” adalah adjektif dengan nilai sentimen -1. Berdasarkan aturan dalam tabel AND operator, kombinasi preposisi bernilai 1 dan adjektif bernilai -1 akan menghasilkan nilai sentimen -1. Maka, kalimat tersebut dikategorikan sebagai sentimen negatif.

D. Preposisi + Verb

Jika dalam sebuah kalimat terdapat kata kerja (verba) yang muncul setelah kata depan (preposisi), maka nilai sentimen kalimat tersebut dihitung menggunakan aturan *AND operator*. Sebagai contoh

“air di rumah saya sudah mati 3 hari, kenapa PDAM tidak menangani dengan cepat”

Kata “tidak” berfungsi sebagai preposisi dengan nilai sentimen -1, sedangkan kata “menangani” merupakan verba dengan nilai sentimen 1 (berasal dari kata dasar “tangani”). Berdasarkan aturan pada tabel AND operator, kombinasi nilai -1 (preposisi) dan 1 (verba) menghasilkan nilai sentimen -1. Oleh karena itu, kalimat ini dikategorikan sebagai sentimen negatif.

E. Verb + Adjektif

Aturan *NAND operator* digunakan untuk menentukan nilai sentimen dari kalimat yang mengandung kata kerja (verb) yang diikuti oleh kata sifat (adjektif). Cara perhitungannya dijelaskan dalam Tabel 3.2, yang menunjukkan kombinasi nilai dari kedua jenis kata tersebut dan hasil akhirnya.

Tabel 3. 2. *NAND Operator*

Verb	Adjektif	Nilai
1	1	1
1	-1	-1
-1	1	-1
-1	-1	-1

Sebagai contoh, pada kalimat:

“saya rasa kinerja PDAM bagus dan tanggap”

kata “kinerja” merupakan verba dengan nilai sentimen 1, dan kata “bagus” adalah adjektif juga dengan nilai sentimen 1. Kombinasi ini sesuai dengan aturan dalam tabel *NAND operator*, sehingga menghasilkan nilai sentimen 1. Selain itu, ada kata “tanggap” yang juga merupakan adjektif dengan nilai sentimen 1, dan termasuk dalam aturan adjektif tunggal. Karena terdapat dua aturan yang terpenuhi dalam kalimat ini, nilainya dijumlahkan: 1 (dari kombinasi verb-adjektif) + 1 (dari adjektif tunggal) = 2 . Karena hasilnya lebih dari nol, maka sentimen kalimat ini dikategorikan sebagai positif.

F. Preposisi + Verb + Adjektif

Dalam beberapa kasus, sebuah kalimat bisa mengandung preposisi, verba, dan adjektif secara bersamaan. Untuk menentukan nilai sentimen dari kalimat seperti ini, sistem akan melakukan dua tahap perhitungan. Pertama, nilai dari kata kerja (verba) dan kata sifat (adjektif) dihitung menggunakan *NAND operator*, seperti yang dijelaskan pada Tabel 3.2. Kedua, hasil dari perhitungan tersebut kemudian digabungkan dengan nilai preposisi menggunakan *AND operator*, sesuai dengan Tabel 3.1. Sebagai contoh, dalam kalimat

“PDAM tidak paham dengan baik, apa sebenarnya kebutuhan pelanggan”

Kata “tidak” merupakan preposisi dengan nilai sentimen -1, “paham” adalah verba dengan nilai 1, dan “baik” adalah adjektif dengan nilai 1. Karena ketiganya termasuk dalam aturan kombinasi, maka langkah pertama adalah menghitung “paham” dan “baik” dengan *NAND operator*, yaitu $1 \text{ NAND } 1$ menghasilkan nilai 1. Selanjutnya, nilai dari preposisi “tidak” (-1) dihitung bersama hasil sebelumnya (1) dengan *AND operator*, yaitu $-1 \text{ AND } 1 = -1$. Maka, sentimen dari kalimat ini secara keseluruhan adalah negatif dengan nilai -1.

G. Frasa

Aturan frasa digunakan untuk mengidentifikasi gabungan beberapa kata yang membentuk satu kesatuan makna dan memiliki nilai sentimen tersendiri. Berbeda dengan aturan berbasis *Part of Speech* (POS) yang menganalisis setiap kata secara terpisah, aturan ini memperlakukan beberapa kata sebagai satu unit makna yang tidak dapat dipisahkan. Oleh karena itu, nilai sentimen frasa akan dihitung sebagai satu kesatuan dan tidak berdasarkan nilai sentimen masing-masing kata penyusunnya.

Aturan frasa menggunakan kamus frasa yang berisi daftar frasa beserta nilai sentimennya. Kamus tersebut disusun berdasarkan frasa-frasa yang sering muncul pada data pengaduan pelanggan dan telah diberikan label sentimen sesuai makna yang terkandung di dalamnya. Setiap entri dalam kamus terdiri atas sebuah frasa dan nilai sentimen yang merepresentasikan makna keseluruhan frasa tersebut. Dengan adanya kamus frasa, sistem dapat mengenali suatu ekspresi sebagai satu kesatuan makna tanpa harus menghitung sentimen setiap kata penyusunnya secara terpisah.

Penelitian ini mengembangkan aturan frasa sehingga mampu mengenali frasa dengan panjang yang bervariasi sesuai dengan daftar yang terdapat pada kamus frasa. Dengan demikian, sistem dapat mendeteksi frasa yang terdiri atas dua kata, tiga kata, maupun lebih dari tiga kata selama frasa tersebut terdapat dalam kamus.

Sebagai contoh, pada kamus frasa terdapat entri:

Tabel 3. 3. Contoh Kamus Frasa

Frasa	Nilai Sentimen
tidak ada respon	-1
tidak ada tanggapan	-1
tindak lanjut	0
terima kasih	1

Ketika sistem menemukan salah satu frasa seperti contoh pada Tabel 3.3 di dalam komentar, maka sistem akan langsung mengambil nilai sentimen dari kamus frasa tanpa menghitung sentimen masing-masing kata secara terpisah.

Sebagai contoh, pada komentar:

“Sudah tiga hari tidak ada respon dari petugas”

Sistem akan melakukan pencocokan terhadap seluruh kombinasi kata yang terdapat pada komentar dengan daftar frasa yang tersimpan pada kamus. Dari proses tersebut ditemukan frasa:

“tidak ada respon”

Karena frasa tersebut, komentar tersebut memperoleh kontribusi sentimen negatif dari frasa yang ditemukan.

Contoh lain dapat dilihat pada komentar:

“Sudah tiga hari tidak ada respon dari petugas”

Sistem akan melakukan pencocokan terhadap seluruh kombinasi kata yang terdapat pada komentar dengan daftar frasa yang tersimpan pada kamus. Dari proses tersebut ditemukan frasa:

“tidak ada respon”

Karena frasa tersebut terdapat dalam kamus frasa dan memiliki nilai sentimen -1, maka perhitungan sentimennya dilakukan sebagai berikut:

Sentimen = Sentimen(tidak ada respon)

Sentimen = -1

Dengan demikian, komentar tersebut memperoleh kontribusi sentimen negatif dari frasa yang ditemukan.

Setelah suatu frasa berhasil dikenali dan diberikan nilai sentimen, frasa tersebut akan dihapus dari kalimat sebelum proses analisis berikutnya dilakukan. Tujuan dari proses ini adalah untuk menghindari perhitungan ganda pada kata-kata yang telah menjadi bagian dari frasa.

Sebagai contoh, pada komentar:

“tidak ada respon dari petugas”

Frasa “tidak ada respon” akan terlebih dahulu diberikan nilai sentimen berdasarkan kamus frasa. Setelah itu, frasa tersebut dihapus dari kalimat sehingga kata “tidak”, “ada”, dan “respon” tidak lagi dihitung oleh aturan lain. Dengan demikian, setiap frasa hanya memberikan kontribusi satu kali terhadap nilai sentimen akhir.

Selain itu, penelitian ini juga mempertimbangkan keberadaan kata negasi yang muncul sebelum suatu frasa.

Tabel 3. 4. Kata Negasi yang Didaftarkan Pada Program

Kata Negasi
tidak
tak
bukan
bukan
ga
ngga

Apabila salah satu kata negasi seperti contoh pada Tabel 3.4 muncul sebelum frasa yang ditemukan, maka nilai sentimen frasa akan disesuaikan menggunakan operator *AND*. Mekanisme ini bertujuan untuk menangkap perubahan makna yang disebabkan oleh keberadaan negasi.

Sebagai contoh, apabila terdapat suatu frasa yang bernilai positif namun didahului oleh kata negasi, maka nilai sentimen yang dihasilkan dapat berubah menjadi negatif sesuai hasil perhitungan operator yang digunakan.

Secara umum, aturan frasa digunakan untuk menangkap makna sentimen yang tidak dapat direpresentasikan dengan baik apabila setiap kata dianalisis secara terpisah. Dengan memanfaatkan kamus frasa, sistem mampu mengenali berbagai ekspresi yang sering muncul dalam komentar pengaduan pelanggan dan memberikan nilai sentimen yang lebih sesuai dengan makna sebenarnya dari komentar tersebut

H. Frasa Negatif Kuat

Pada komentar pengaduan pelanggan sering ditemukan frasa-frasa tertentu yang secara langsung menunjukkan adanya permasalahan layanan. Frasa seperti ini umumnya telah memiliki makna negatif yang kuat sehingga dapat merepresentasikan keluhan pelanggan tanpa

perlu dilakukan analisis struktur kalimat yang lebih kompleks. Oleh karena itu, penelitian ini menambahkan aturan ini untuk mendeteksi frasa negatif kuat yang sering muncul pada data pengaduan.

Aturan ini menggunakan sebuah kamus frasa negatif kuat yang berisi kumpulan frasa yang telah diidentifikasi memiliki keterkaitan dengan permasalahan layanan. Berbeda dengan kamus frasa pada aturan Frasa yang digunakan untuk memberikan nilai sentimen terhadap suatu frasa, kamus frasa negatif kuat digunakan untuk mendeteksi keberadaan indikasi keluhan yang bersifat tegas pada suatu komentar.

Beberapa contoh frasa yang terdapat dalam kamus frasa negatif kuat adalah sebagai berikut:

Tabel 3. 5. Contoh Kamus Frasa Negatif Kuat

Frasa Negatif Kuat
tidak ada respon
tidak ada tanggapan
tidak ada tindak lanjut
air tidak mengalir
air mati
air tidak keluar
tagihan melonjak
meter rusak
meter mati
air keruh
kebocoran pipa

Apabila salah satu frasa pada Tabel 3.5 ditemukan pada komentar, maka sistem akan menganggap komentar tersebut memiliki indikasi sentimen negatif yang kuat

Sebagai contoh pada komentar:

“Sudah tiga hari air tidak mengalir”

Sistem akan melakukan pencocokan terhadap seluruh frasa yang terdapat pada kamus frasa negatif kuat. Dari proses tersebut ditemukan frasa:

“air tidak mengalir”

Karena frasa tersebut terdapat dalam kamus frasa negatif kuat, maka sistem mengidentifikasi komentar tersebut sebagai komentar yang mengandung indikasi keluhan yang kuat.

Selain menggunakan kamus frasa negatif kuat, aturan ini juga memanfaatkan daftar kata negatif kuat yang sering muncul pada komentar pengaduan pelanggan. Beberapa kata yang termasuk dalam daftar tersebut antara lain:

Tabel 3. 6. Daftar Kata Negatif Kuat

Kata Negatif Kuat
mati
keruh
rusak
bocor
macet
parah
lambat
telat
susah
buntu
buruk
melonjak

Sebagai contoh, pada komentar:

“meter pelanggan rusak”

Kata “rusak” termasuk ke dalam daftar kata negatif kuat sehingga sistem akan mengidentifikasi komentar tersebut sebagai komentar yang mengandung indikasi sentimen negatif.

Atura frasa negatif kuat digunakan sebelum proses penentuan sentimen akhir dilakukan. Tujuan dari aturan ini adalah untuk memastikan bahwa komentar yang mengandung keluhan yang jelas tidak dikategorikan sebagai komentar netral hanya karena memiliki struktur kalimat berupa pertanyaan atau tidak memenuhi kombinasi aturan *Part of Speech* tertentu.

Sebagai contoh, pada komentar:

“kenapa air mati?”

Meskipun komentar tersebut berbentuk pertanyaan, sistem tetap mendeteksi frasa “air mati” yang terdapat dalam kamus frasa negatif kuat. Oleh karena itu, komentar tersebut tetap dianggap mengandung sentimen negatif dan tidak dikategorikan sebagai pertanyaan netral.

Dengan demikian, aturan frasa negatif kuat berfungsi untuk meningkatkan kemampuan sistem dalam mengenali keluhan pelanggan yang memiliki indikasi permasalahan layanan secara jelas.

I. Komentar Berbentuk Pertanyaan

Pada media sosial, tidak semua komentar yang mengandung kata-kata tertentu menunjukkan adanya sentimen positif maupun negatif. Sebagian komentar hanya berupa pertanyaan yang diajukan pelanggan untuk memperoleh informasi mengenai layanan. Apabila komentar seperti ini langsung dianalisis menggunakan aturan sentimen berbasis *Part of Speech*, terdapat kemungkinan komentar tersebut akan memperoleh nilai sentimen yang tidak sesuai dengan maksud sebenarnya. Oleh karena itu, penelitian ini menambahkan aturan ini untuk mengidentifikasi komentar yang berbentuk pertanyaan dan mengkategorikannya sebagai sentimen netral.

Aturan ini bekerja dengan mendeteksi keberadaan tanda tanya (?) maupun kata tanya yang umum digunakan dalam percakapan sehari-hari. Beberapa kata tanya yang digunakan dalam penelitian antara lain:

Tabel 3. 7. Contoh Kata Tanya

Kata Tanya
apa
apakah
bagaimana
gimana
kenapa
kapan
siapa
berapa
kah

Apabila komentar mengandung tanda tanya atau salah satu kata tanya pada Tabel 3.7, maka sistem akan menganggap komentar tersebut sebagai komentar berbentuk pertanyaan.

Sebagai contoh:

“bagaimana cara mengecek tagihan air?”

Komentar tersebut mengandung kata tanya “bagaimana” dan tanda tanya (?) sehingga sistem mengidentifikasinya sebagai sebuah pertanyaan. Karena tidak ditemukan indikasi keluhan

maupun frasa negatif kuat pada komentar tersebut, maka komentar akan diberikan nilai sentimen netral.

Namun demikian, tidak semua komentar berbentuk pertanyaan dapat langsung dianggap netral. Dalam beberapa kasus, pelanggan menyampaikan keluhan dalam bentuk kalimat tanya. Oleh karena itu, sebelum memberikan label netral, sistem terlebih dahulu memeriksa keberadaan frasa negatif kuat yang telah dijelaskan pada aturan Frasa Negatif Kuat.

Sebagai contoh, pada komentar:

“kenapa air mati sejak kemarin?”

Komentar tersebut mengandung kata tanya “kenapa” sehingga secara struktur merupakan kalimat tanya. Akan tetapi, sistem juga menemukan frasa “air mati” yang termasuk ke dalam kamus frasa negatif kuat. Karena ditemukan indikasi keluhan yang kuat, maka komentar tersebut tidak dikategorikan sebagai sentimen netral dan tetap diproses sebagai komentar yang mengandung sentimen negatif.

Secara umum, aturan ini digunakan untuk membedakan komentar yang benar-benar bertujuan meminta informasi dengan komentar yang berisi keluhan pelanggan. Dengan adanya aturan ini, sistem dapat mengurangi kesalahan klasifikasi pada komentar berbentuk pertanyaan sehingga hasil analisis sentimen menjadi lebih akurat.

J. Complaint Context Penalty

Pada data pengaduan pelanggan, tidak semua keluhan dapat dikenali hanya berdasarkan keberadaan kata atau frasa yang memiliki nilai sentimen negatif. Dalam beberapa kasus, pelanggan menyampaikan keluhan menggunakan kalimat permintaan, laporan, atau tindak lanjut yang secara struktur tidak selalu mengandung kata-kata negatif. Oleh karena itu, penelitian ini menambahkan aturan *complaint context penalty* untuk mendeteksi konteks keluhan yang berkaitan dengan permasalahan layanan.

Aturan ini bekerja dengan mengidentifikasi kemunculan kata-kata yang umumnya digunakan pelanggan ketika menyampaikan pengaduan. Beberapa kata yang digunakan sebagai indikator keluhan antara lain:

Tabel 3. 8. Contoh Daftar Kata Pengaduan

Kata Pengaduan
keluh
komplain
adu
lapor
mohon
tolong
cek
tindak

Selain itu, sistem juga menggunakan daftar kata yang berkaitan dengan permasalahan layanan seperti:

Tabel 3. 9. Contoh Daftar Kata Permasalahan Layanan

Kata Permasalahan Layanan
Air
Meter
Tagihan
Tarif
Bocor
Keruh
Kotor
mati

Apabila kata-kata yang menunjukkan keluhan muncul bersamaan dengan kata-kata yang berkaitan dengan permasalahan layanan, maka sistem akan memberikan penalti sentimen sebesar -1. Tujuan dari pemberian penalti ini adalah untuk memperkuat indikasi bahwa komentar tersebut merupakan sebuah keluhan.

Sebagai contoh, pada komentar:

“mohon cek air di rumah saya karena tidak keluar”

Komentar tersebut mengandung kata “mohon” dan “cek” yang menunjukkan adanya pengaduan pelanggan. Selain itu terdapat kata “air” dan “keluar” yang berkaitan dengan permasalahan layanan. Karena kedua kondisi tersebut terpenuhi, maka sistem memberikan penalti sentimen sebesar -1.

Perhitungan sentimen dilakukan sebagai berikut:

$$\text{Sentimen} = -1$$

Sehingga komentar tersebut memperoleh tambahan sentimen negatif meskipun tidak seluruh kata dalam komentar memiliki nilai sentimen negatif pada kamus.

Aturan ini juga digunakan untuk mendeteksi adanya negasi yang muncul bersamaan dengan kata-kata yang berkaitan dengan layanan.

Sebagai contoh:

“air tidak keluar sejak kemarin”

Pada komentar tersebut terdapat kata negasi “tidak” dan kata layanan “keluar”. Kombinasi tersebut menunjukkan adanya kondisi layanan yang bermasalah sehingga sistem memberikan penalti sentimen sebesar -1.

Selain mendeteksi konteks keluhan dan negasi, aturan ini juga memeriksa beberapa pola keterlambatan penanganan yang sering muncul pada komentar pelanggan. Pola tersebut antara lain:

Tabel 3. 10. Contoh Daftar Pola Keterlambatan

Pola Keterlambatan
sampai sekarang
belum ada
tidak ada
tidak keluar

Sebagai contoh:

“sampai sekarang belum ada tindak lanjut”

Komentar tersebut menunjukkan adanya keterlambatan penanganan pengaduan. Oleh karena itu, sistem memberikan penalti sentimen sebesar -1 karena pola tersebut merepresentasikan ketidakpuasan pelanggan terhadap layanan.

Aturan ini juga digunakan untuk mendeteksi keluhan yang berkaitan dengan tagihan atau biaya layanan. Beberapa kata yang digunakan antara lain:

Tabel 3. 11. Contoh Daftar Kata Keluhan Tagihan

Kata Keluhan Tagihan
tagihan
tarif
biaya
bayar
kode

Kata-kata tersebut kemudian dicocokkan dengan kata yang menunjukkan adanya perubahan tidak wajar seperti:

Tabel 3. 12. Contoh Daftar Kata Perubahan Tidak Wajar

Kata Perubahan Tidak Wajar
naik
lonjak
drastis
ubah

Sebagai contoh:

“tagihan bulan ini melonjak drastis”

Pada komentar tersebut ditemukan kata “tagihan”, “melonjak”, dan “drastis”. Kombinasi tersebut menunjukkan adanya keluhan terkait tagihan sehingga sistem memberikan penalti sentimen negatif.

Secara umum, aturan *complaint context penalty* digunakan untuk memperkuat indentifikasi komentar yang mengandung keluhan pelanggan. Berbeda dengan aturan sebelumnya yang berokus pada nilai sentimen kata atau frasa tertentu, aturan ini mempertimbangkan konteks pengaduan yang terdapat pada komentar. Dengan adanya aturan ini, sistem dapat mengenali berbagai bentuk keluhan pelanggan yang tidak selalu mengandung kata-kata negatif secara eksplisit, sehingga hasil klasifikasi sentimen dapat menjadi lebih akurat

K. Posisi “Terima Kasih” (Aturan Pendukung)

Pada komentar pelanggan, frasa “*terima kasih*” umumnya digunakan sebagai bentuk apresiasi terhadap layanan yang telah diberikan. Namun demikian, keberadaan frasa tersebut tidak selalu menunjukkan sentimen positif terhadap keseluruhan komentar. Dalam beberapa kasus, frasa “*terima kasih*” hanya digunakan sebagai penutup kalimat atau bentuk kesopanan setelah pelanggan menyampaikan keluhan. Oleh karena itu, penelitian ini menggunakan aturan pendukung yang mempertimbangkan posisi kemunculan frasa “*terima kasih*” dalam komentar.

Aturan ini diterapkan dengan memeriksa apakah frasa “*terima kasih*” atau “*terimakasih*” muncul pada awal klausa pertama dalam komentar. Apabila frasa tersebut berada pada posisi awal, maka sistem akan memberikan tambahan nilai sentimen positif sebesar 1. Sebaliknya, apabila frasa tersebut muncul di tengah atau di akhir komentar, maka frasa tersebut tidak akan memberikan tambahan nilai sentimen.

Sebagai contoh, pada komentar:

“terima kasih atas respon cepat dari petugas”

Frasa “terima kasih” muncul pada awal komentar sehingga sistem memberikan tambahan nilai sentimen positif sebesar 1.

Selanjutnya, kata “terima” dan “kasih” tidak lagi diproses pada tahap analisis berikutnya sehingga tidak terjadi perhitungan berulang terhadap frasa yang sama

Contoh lain dapat dilihat pada komentar:

“air sudah mengalir kembali, terima kasih”

Pada komentar tersebut frasa “terima kasih” muncul di bagian akhir kalimat. Meskipun frasa tersebut menunjukkan apresiasi pelanggan, sistem tidak memberikan nilai sentimen karena posisinya tidak berada pada awal klausa pertama.

Dengan demikian, nilai sentimen komentar akan ditentukan oleh aturan lain yang aktif pada kalimat tersebut.

Sebagai contoh lain:

“tolong segera diperbaiki, terima kasih”

Pada komentar tersebut frasa “terima kasih” muncul sebagai penutup kalimat setelah adanya permintaan atau pengaduan pelanggan. Oleh karena itu, sistem tidak memberikan tambahan nilai sentimen positif karena frasa tersebut lebih berfungsi sebagai ungkapan kesopanan daripada representasi kepuasan terhadap layanan.

Aturan posisi “terima kasih” merupakan aturan pendukung yang bekerja bersama aturan Frasa. Pada proses analisis, sistem terlebih dahulu menggunakan aturan 7 (frasa) untuk

melakukan pencocokan frasa terhadap kamus frasa yang tersedia. Apabila frasa yang ditemukan adalah “terima kasih” atau “terimakasih”, maka sistem akan melakukan pemeriksaan tambahan terhadap posisi kemunculan frasa tersebut dalam komentar. Dengan demikian, aturan ini tidak berdiri sendiri dalam menentukan sentimen, melainkan berfungsi sebagai mekanisme tambahan yang memperkaya proses analisis pada aturan 7 (frasa). Melalui mekanisme ini, sistem dapat membedakan penggunaan frasa “terima kasih” yang benar-benar menunjukkan apresiasi pelanggan dengan penggunaan frasa yang hanya berfungsi sebagai ungkapan kesopanan pada bagian tengah atau akhir komentar.

Dalam proses analisis sentimen, aturan ini dijalankan setelah frasa berhasil dikenali oleh aturan 7 (frasa). Apabila frasa “terima kasih” ditemukan pada awal klausa pertama, sistem akan memberikan tambahan nilai sentimen positif terlebih dahulu. Setelah itu proses analisis akan dilanjutkan menggunakan aturan berbasis *Part of Speech* maupun aturan lainnya yang terdapat dalam sistem.


Dengan adanya aturan ini, sistem dapat memberikan representasi sentimen yang lebih sesuai terhadap komentar pelanggan, terutama pada komentar yang mengandung ungkapan apresiasi di awal kalimat tanpa mengabaikan keberadaan informasi lain yang terdapat pada komentar tersebut.

3.2.8 Dashboard

Dashboard merupakan bagian antarmuka yang dirancang untuk menampilkan hasil pengolahan data komentar pelanggan PDAM Surya Sembada secara lebih ringkas, terstruktur, dan mudah dipahami. Pada *dashboard* ini, pengguna dapat melihat ringkasan hasil analisis, visualisasi aspek dan sentimen, tren data komentar, tabel data komentar, serta melakukan input data untuk kebutuhan pengujian sistem. Dengan adanya dashboard ini, hasil dari proses *aspect based sentiment analysis* tidak hanya berhenti pada tahap perhitungan, tetapi juga dapat disajikan dalam bentuk tampilan yang lebih informatif sehingga memudahkan pengguna dalam melakukan pemantauan dan interpretasi hasil analisis.

Dashboard pada penelitian ini dikembangkan menggunakan framework Streamlit karena mampu mendukung pembuatan aplikasi analisis data secara interaktif dengan tampilan yang sederhana dan mudah diakses. Sementara itu, penyimpanan data menggunakan *database* SQLite yang berfungsi untuk menyimpan data komentar beserta hasil analisisnya agar dapat ditampilkan kembali pada halaman *dashboard*. Penggunaan Streamlit dan SQLite dipilih

karena cukup ringan, mudah diintegrasikan dengan proses analisis yang telah dibuat, serta sesuai untuk kebutuhan pengembangan aplikasi *monitoring* hasil analisis aspek dan sentimen.



Gambar 3. 3. Tampilan *Landing Page Dashboard*

Gambar 3.3 menunjukkan tampilan *dashboard* yang digunakan sebagai *media monitoring* hasil analisis komentar pelanggan PDAM Surya Sembada. Secara umum, *dashboard* ini menampilkan ringkasan jumlah komentar, distribusi sentimen, dan persebaran aspek layanan pada halaman utama, kemudian dilengkapi dengan fitur analisis per aspek, pemantauan tren sentimen dan aspek berdasarkan periode tertentu, penelusuran tabel data komentar secara lengkap beserta hasil segmentasinya, serta fasilitas input data baru untuk diproses oleh sistem. Dengan susunan tersebut, dashboard tidak hanya berfungsi sebagai tampilan hasil analisis, tetapi juga sebagai sarana untuk membaca pola keluhan pelanggan, menelusuri detail data, dan mendukung proses pemantauan layanan secara lebih cepat dan terstruktur.

3.2.7 Validasi

Untuk mengetahui seberapa baik kinerja sistem atau metode klasifikasi yang digunakan, dilakukan pengukuran menggunakan tiga metrik utama, yaitu *accuracy*, *recall*, dan *precision*.

Nilai *accuracy* dihitung dengan membandingkan jumlah prediksi yang benar terhadap total seluruh data yang diuji. Semakin tinggi nilainya, maka semakin baik hasil klasifikasi yang dilakukan oleh sistem. Namun, hanya mengandalkan nilai akurasi saja tidak cukup untuk mendeteksi adanya kesalahan atau ketidaksesuaian data.

Oleh karena itu, *recall* dan *precision* juga dihitung. ***Recall*** mengukur seberapa banyak data yang benar-benar relevan berhasil ditemukan oleh sistem dari seluruh data relevan yang tersedia. Sedangkan *precision* mengukur ketepatan sistem dalam memprediksi, yaitu berapa banyak dari data yang diprediksi sebagai benar ternyata memang benar.

BAB 4

EKSPERIMEN DAN ANALISIS

Bab ini membahas proses eksperimen dan analisis kinerja sistem yang dikembangkan untuk melakukan *multi aspect based classification* dan *sentiment analysis* pada komentar pelanggan PDAM Surya Sembada. Uraian pada bab ini mencakup parameter eksperimen, karakteristik data, serta hasil analisis dari setiap tahap, mulai dari *text preprocessing*, segmentasi teks, perhitungan TF-IDF, *multi aspect based classification* dengan *cosine similarity*, hingga *sentiment analysis* menggunakan *rule based*. Eksperimen ini dilakukan untuk mengetahui kemampuan sistem dalam mengenali aspek layanan dan sentimen komentar pelanggan secara lebih tepat dan terstruktur.

4.1 PARAMETER EKSPERIMEN

Pada bab ini, parameter eksperimen digunakan untuk mengukur keberhasilan sistem yang telah dikembangkan pada setiap tahapan proses. Pengujian dilakukan tidak hanya pada hasil akhir, tetapi juga pada alur pengolahan data mulai dari *text preprocessing*, *data split*, perhitungan TF-IDF, *aspect based* menggunakan *cosine similarity*, hingga *sentiment analysis* menggunakan *rule based*. Dengan demikian, setiap tahap dapat dievaluasi secara lebih terstruktur sesuai dengan fungsinya masing-masing.

Tahap awal yang diuji adalah *text preprocessing*. Pada tahap ini, data diproses melalui beberapa langkah, yaitu *drop duplicate*, *cleansing data*, *case folding*, *stopword removal*, *normalization*, segmentasi teks, *tokenizing*, dan *stemming*. Pada proses segmentasi teks, komentar dipecah menjadi beberapa segmen berdasarkan konjungsi yang telah didaftarkan pada sistem. Selama di dalam satu komentar terdapat konjungsi yang sesuai, maka komentar tersebut akan dipisahkan menjadi beberapa bagian kalimat sesuai jumlah konjungsi yang ditemukan. Proses ini dilakukan agar komentar yang memuat lebih dari satu keluhan atau lebih dari satu konteks pembahasan dapat diolah menjadi segmen-segmen yang lebih spesifik sebelum masuk ke tahap berikutnya.

Setelah *preprocessing* selesai, dilakukan pengujian *data split* dan perhitungan TF-IDF. Pada bagian *data split*, terdapat dua skenario eksperimen. Skenario pertama menggunakan *data train* berupa komentar yang tidak tersegmentasi dan *data test* berupa komentar yang telah tersegmentasi. Skenario kedua juga menggunakan *data train* berupa komentar yang tidak

tersegmentasi, tetapi *data test* menggunakan 100% data. Dua skenario ini digunakan untuk melihat perbedaan performa sistem ketika diuji pada data hasil segmentasi saja dan ketika diuji pada seluruh data yang tersedia. Sementara itu, pada tahap TF-IDF sistem diuji untuk memastikan bahwa teks hasil *preprocessing* berhasil diubah menjadi representasi numerik dalam bentuk vektor yang dapat digunakan pada proses pengolahan berikutnya.

Setelah bobot TF-IDF diperoleh, tahap berikutnya adalah penggolongan aspek (*aspect based*) menggunakan *cosine similarity*. Pada tahap ini, setiap segmen komentar direpresentasikan sebagai vektor TF-IDF, kemudian dibandingkan dengan *data train* untuk mencari tingkat kemiripan tertinggi. Aspek dari *data train* yang memiliki nilai *cosine similarity* paling besar akan digunakan sebagai acuan dalam menentukan aspek pada segmen komentar yang diuji. Melalui pengujian ini, dapat diketahui sejauh mana sistem mampu mengenali aspek keluhan pelanggan berdasarkan kedekatan pola kata antara *data test* dan *data train*.

Tahap berikutnya berfokus pada *sentiment analysis* menggunakan *rule based*. Pada tahap ini, setiap segmen komentar dianalisis menggunakan aturan yang terdapat pada sistem dengan memanfaatkan kamus *polarity* dan *part of speech* (POS) untuk menghasilkan skor sentimen, skor normalisasi, dan label sentimen akhir. Label yang dihasilkan dikelompokkan ke dalam kategori positif (1), netral (0), atau negatif (-1). Keberhasilan sistem pada tahap ini diukur dari kemampuannya dalam memberikan label sentimen yang sesuai dengan *true sentiment* pada data yang telah diberi anotasi. Dengan susunan parameter eksperimen tersebut, evaluasi sistem dapat dilakukan secara lebih jelas mulai dari proses awal hingga hasil akhir.

4.2 KARATERISTIK DATA

Data yang digunakan dalam penelitian ini berupa komentar pelanggan PDAM Surya Sembada pada akun Instagram resmi @pdamsuryasembada. Pengambilan data dilakukan dengan teknik *scraping* menggunakan *library* python Instaloader. Data yang diperoleh berupa teks komentar pelanggan yang bersifat tidak terstruktur, menggunakan bahasa Indonesia sehari-hari, serta mengandung variasi penulisan seperti singkatan, kata tidak baku, emotikon, dan komentar dengan lebih dari satu konteks keluhan dalam satu kalimat. Karakteristik data seperti ini dipilih karena dapat menggambarkan kondisi nyata interaksi pelanggan di media sosial, sehingga sesuai untuk digunakan dalam pengujian sistem *aspect based* dan *sentiment analysis* yang dikembangkan.

Proses pengambilan data dilakukan sebanyak dua kali dengan tujuan yang berbeda. *Scraping* pertama dilakukan pada komentar dengan periode Oktober 2023 hingga November 2025. Pada periode ini diperoleh sebanyak 18.683 data. Data ini digunakan pada tahap pengujian model, yaitu untuk penggolongan aspek menggunakan *cosine similarity* dan *sentiment analysis* menggunakan *rule based*. Selanjutnya, *scraping* kedua dilakukan pada komentar dengan periode Januari 2026 hingga Juni 2026. Pada periode ini diperoleh sebanyak 1.671 data. Data ini digunakan untuk melakukan *testing* pada model yang telah diintegrasikan ke dalam *dashboard*. Pembagian pengambilan data menjadi dua periode dilakukan agar data untuk pengujian model dan data untuk implementasi *dashboard* tetap dapat dibedakan, sehingga proses evaluasi sistem menjadi lebih terarah dan sesuai dengan kebutuhan masing-masing tahap.

4.3 TEMPAT UJICOB

Pengujian dilakukan di rumah dan di Laboratorium *Knowledge Engineering* (knowing) PENS menggunakan Visual Studio Code.

4.4 WAKTU UJICOB

Uji coba dilaksanakan mulai dari awal bulan Agustus 2025 hingga awal bulan Juni 2026.

4.5 SPESIFIKASI PERALATAN UJICOB

Pada proses pembuatan dilakukan pada laptop pribadi. Spesifikasi laptop serta *software* yang digunakan ditunjukkan pada tabel berikut:

Tabel 4. 1. Informasi *Hardware*

Deskripsi	Spesifikasi
Model Laptop	ASUS TUF Gaming F15 FX506HC_FX506HC
<i>Processor</i>	11th Gen Intel(R) Core(TM) i5-11400H @ 2.70GHz (12 CPUs), ~2.7GHz
RAM	16 GB
SSD	512 GB
<i>Graphics</i>	NVIDIA GeForce RTX 2050 Laptop GPU
<i>Operating System</i>	Microsoft Windows 11 Home

Tabel 4. 2. Informasi *Software*

Deskripsi	Spesifikasi
Python	<i>Version</i> 3.11.2
<i>Library</i>	pandas, numpy, NLTK, Sastrawi, Sklearn,
<i>Code Editor</i>	Visual Studio Code

4.6 HASIL EKSPERIMEN

4.6.1 *Text Preprocessing*

Pada tahap *preprocessing* dataset, langkah utama yang diterapkan untuk memastikan kualitas dan konsistensi data sebelum digunakan. Pada tahap ini meliputi 8 proses sistematis yang dirancang untuk mengoptimalkan data yang akan digunakan. Berikut adalah tahapan dari *preprocessing* yang dilakukan:

Tabel 4. 3. Input dan Output *Text Preprocessing*

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
<i>Case Folding</i>	Halo kak, saya sudah pernah komplain disini, saya sudah melaporkan meteran rusak per tanggal 23 Januari 2025, petugas lapangan datang 2X untuk mengecek meteran. TAPI SAMPAI SEKARANG BELUM ADA PENGGANTIAN?????		halo kak, saya sudah pernah komplain disini, saya sudah melaporkan meteran rusak per tanggal 23 januari 2025, petugas lapangan datang 2x untuk mengecek meteran. tapi sampai sekarang belum ada penggantian?????	

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
	Min kalau puteran PDAM dol itu sya ngadu kesiapa ya		min kalau puteran pdam dol itu sya ngadu kesiapa ya	
<i>Normalization</i>	halo kak, saya sudah pernah komplain disini, saya sudah melaporkan meteran rusak per tanggal 23 januari 2025, petugas lapangan datang 2x untuk mengecek meteran. tapi sampai sekarang belum ada penggantian?????		halo kakak. Saya sudah pernah komplain disini, saya sudah melaporkan meteran rusak per tanggal januari, petugas lapangan datang untuk cek meteran, tapi sampai sekarang belum ada pergantian?	
	min kalau puteran pdam dol itu sya ngadu kesiapa ya		admin kalau keran pdam rusak itu saya mengadu ke siapa ya	
<i>Stop Word Removal</i>	halo kakak. Saya sudah pernah komplain disini, saya sudah melaporkan meteran rusak per tanggal januari, petugas lapangan datang untuk cek meteran, tapi		halo kakak , sudah komplain disini , sudah melaporkan meter rusak tanggal januari , petugas lapangan datang cek meter	

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
	sampai sekarang belum ada pergantian?		. tapi sampai sekarang belum ada pergantian ?	
	admin kalau keran pdam rusak itu saya mengadu ke siapa ya		admin keran pdam rusak mengadu ke siapa	
Segmentasi Teks	halo kakak , sudah komplain disini , sudah melaporkan meter rusak tanggal januari , petugas lapangan datang cek meter . tapi sampai sekarang belum ada pergantian ?.		halo kakak , sudah komplain disini , sudah melaporkan meter rusak tanggal januari , petugas lapangan datang cek meter .	tapi sampai sekarang belum ada pergantian ?
	admin keran pdam rusak mengadu ke siapa		admin keran pdam rusak mengadu ke siapa	
Tokenizing	halo kakak , sudah komplain disini , sudah melaporkan meter rusak tanggal januari , petugas lapangan datang cek meter .	tapi sampai sekarang belum ada pergantian ?	['halo', 'kakak', ',', 'sudah', 'komplain', 'disini', ',', 'sudah', 'melaporkan', 'meter', 'rusak', 'tanggal', 'januari', ',', 'petugas', 'lapangan',	['tapi', 'sampai', 'sekarang', 'belum', 'ada', 'pergantian', '?']

Proses	Input		Output	
	Kalimat 1	Kalimat 2	Kalimat 1	Kalimat 2
			'datang', 'cek', 'meter', '.']	
	admin keran pdam rusak mengadu ke siapa		['admin', 'keran', 'pdam', 'rusak', 'mengadu', 'ke', 'siapa']	[]
Stemming	['halo', 'kakak', ',', 'sudah', 'komplain', 'disini', ',', 'sudah', 'melaporkan', 'meter', 'rusak', 'tanggal', 'januari', ',', 'petugas', 'lapangan', 'datang', 'cek', 'meter', '.']	['tapi', 'sampai', 'sekarang', 'belum', 'ada', 'pergantian', '?']	['halo', 'kakak', ,', 'sudah', 'komplain', 'sini', ',', 'sudah', 'lapor', 'meter', 'rusak', 'tanggal', 'januari', ',', 'tugas', 'lapang', 'datang', 'cek', 'meter', '.']	['tapi', 'sampai', 'sekarang', 'belum', 'ada', 'ganti', '?']
	['admin', 'keran', 'pdam', 'rusak', 'mengadu', 'ke', 'siapa']	[]	['admin', 'keran', 'pdam', 'rusak', 'adu', 'ke', 'siapa']	[]

1. Drop Duplicates

Pada tahap ini penulis menghapus data yang terduplikasi. Dari data yang dimiliki oleh penulis, terdapat 2 data duplikat yang telah dihapus.

2. Cleansing Data

Setelah dilakukan *drop duplicate*, data dibersihkan dari emoji, karakter khusus (contoh: *mention* (@), *hashtag* (#)), menghapus angka. Namun terdapat pengecualian pada simbol *dot* (.), *comma* (,), tanda seru (!), dan tanda tanya (?). Simbol ini tidak dihapus agar tidak menghilangkan konteks dari kalimat pada saat *sentiment analysis*.

3. Case Folding

Berdasarkan Tabel 4.3, dapat diketahui bahwa proses pengubahan semua karakter alfabet menjadi huruf kecil (*case-folding*) dapat memberikan keluaran yang sesuai, dimana semua karakter alfabet dalam data akan diubah menjadi huruf kecil.

4. Normalization

Dari Tabel 4.3, dapat dilihat proses *normalization* dapat memberikan keluaran yang sesuai ekspektasi, dimana kata-kata yang disingkat dapat diubah menjadi kata-kata yang sesuai dengan kaidah Bahasa Indonesia.

Proses *normalization* dilakukan dengan mencocokkan setiap kata pada data dengan daftar kata tidak baku (*slang word dictionary*) yang telah didefinisikan sebelumnya. Kata tidak baku bisa berupa slang, bahasa daerah, singkatan kata, dan typo. Jika ditemukan kecocokan, maka kata pada teks akan diganti dengan padanan kata baku yang terdapat di dalam *dictionary*. Penyusunan *slang word dictionary* dilakukan dengan menggabungkan dua sumber, yaitu daftar kata tidak baku yang diperoleh dari repositori di GitHub dan hasil observasi terhadap teks pada dataset komentar pelanggan. Dengan demikian, *dictionary* yang digunakan lebih kontekstual terhadap gaya bahasa pengguna dalam dataset.

Tabel 4. 4. Contoh Pasangan Kata *Slang Word Dictionary*

Kata Tidak Baku	Kata Baku
Skrng	Sekarang
Ksntor	Kantor
Banyu	Air

Tabel 4.4 diatas adalah contoh beberapa pasangan kata dalam *slang word dictionary*. Melalui proses ini, teks yang semula berisi bentuk singkatan, slang, bahasa daerah, dan typo diubah menjadi bentuk formal.

5. Stop Word Removal

Dari Tabel 4.3, dapat dilihat bahwa proses *stop word removal* dapat memberikan keluaran yang sesuai ekspektasi, dimana kata-kata yang dianggap tidak penting seperti kata sambung atau kata umum yang sering muncul (contoh: ‘di’, ‘yang’, ‘ke’) dihapus. Proses *stop word removal* dilakukan dengan mencocokkan setiap kata pada data komentar dengan kumpulan

kata pada *stop word list*. *Stop word list* ini berisi daftar kata umum dalam Bahasa Indonesia yang tidak memiliki makna penting dalam konteks analisis sentimen, seperti kata sambung, kata depan, dan kata ganti. Apabila kata pada data komentar cocok dengan kata yang terdapat pada *stop word list*, maka kata tersebut akan dihapus dari teks. Daftar *stop word list* yang digunakan diperoleh dari repositori di GitHub, yang kemudian disesuaikan dengan konteks Bahasa Indonesia agar proses pembersihan data menjadi lebih akurat. Dengan penerapan metode ini, hanya kata-kata bermakna yang relevan terhadap analisis dapat dipertahankan, sehingga meningkatkan efisiensi dan akurasi pada tahap analisis berikutnya.

Tabel 4. 5. Contoh *Stop Word*

<i>Stop Word</i>
Boleh
Ke
Yang
Di

Tabel 4.5 diatas adalah contoh beberapa *stop word* pada *stop word list* yang dijadikan rujukan pada proses *stop word removal*.

6. Segmentasi Teks

Dari hasil pengujian pada Tabel 4.3, proses segmentasi teks dapat memberikan keluaran yang sesuai dengan ekspektasi, yaitu komentar berhasil dipisahkan menjadi beberapa segmen berdasarkan seluruh konjungsi yang terdeteksi pada satu komentar. Sistem terlebih dahulu memuat daftar konjungsi, kemudian mencari semua konjungsi yang muncul pada teks hasil normalisasi. Setelah itu, teks dipotong menjadi beberapa bagian sesuai posisi masing-masing konjungsi, sehingga satu komentar yang membahas lebih dari satu konteks keluhan dapat dipecah menjadi beberapa segmen kalimat yang lebih spesifik. Jika pada komentar tidak ditemukan konjungsi yang terdaftar, maka komentar tersebut tetap disimpan sebagai satu segmen utuh.

Tabel 4. 6. Daftar Konjungsi Segmentasi Teks

Konjungsi
Sedang
Sedangkan
Lalu

Tapi
Karena
Tetapi
Padahal
Akan
Sehingga

Tabel 4.6 di atas adalah daftar konjungsi yang didaftarkan untuk memisahkan satu komentar menjadi beberapa segmen agar setiap bagian kalimat dapat diproses secara lebih fokus. Kata-kata tersebut dipilih karena sering muncul sebagai penghubung antarbagian kalimat pada komentar pelanggan, sehingga dapat membantu sistem mengenali perpindahan konteks di dalam satu komentar.

Dari total 18.683 komentar, terdapat 2.489 komentar yang mengandung konjungsi. Setelah proses segmentasi dilakukan, jumlah data yang semula 18.683 komentar bertambah menjadi 21.682 data segmen. Hasil evaluasi menunjukkan bahwa seluruh komentar berhasil dipisahkan dengan benar, sehingga jumlah komentar benar adalah 18.683 dengan akurasi segmentasi sebesar 100,00%. Hasil ini menunjukkan bahwa proses segmentasi teks mampu memecah komentar yang memiliki lebih dari satu konteks keluhan menjadi beberapa bagian yang lebih terstruktur untuk diproses pada tahap berikutnya.

7. *Tokenizing*

Dari Tabel 4.3, dapat dilihat bahwa proses *tokenizing* dapat memberikan keluaran yang sesuai ekspektasi, dimana teks akan dipecah menjadi per kata yang kemudian disimpan dalam bentuk *array*.

8. *Stemming*

Dari Tabel 4.3, dapat dilihat bahwa proses *stemming* dapat memberikan keluaran yang sesuai ekspektasi, dimana setiap kata dalam teks diubah menjadi bentuk dasarnya dengan menghapus imbuhan. Imbuhan yang dihilangkan dapat berupa awalan, akhiran, sisipan, atau kombinasi dari awalan dan akhiran. Proses *stemming* ini dilakukan dengan memanfaatkan *library* Sastrawi, yang merupakan *tools stemmer* Bahasa Indonesia. *Library* ini secara otomatis mengenali struktur morfologis kata dan mengubahnya menjadi bentuk dasar yang baku. Penggunaan Sastrawi memungkinkan hasil *stemming* menjadi lebih akurat dan konsisten,

terutama dalam konteks Bahasa Indonesia yang memiliki banyak variasi imbuhan dan bentuk kata.

4.6.2 Data Split

Pada tahap *data split*, pembagian data dilakukan secara khusus untuk proses *aspect based* menggunakan *cosine similarity*. Pada kedua skenario pengujian, data train tetap menggunakan komentar yang tidak tersegmentasi, yaitu komentar yang hanya memiliki satu segmen atau hanya muncul satu kali pada *comment_id*. Data seperti ini dipilih sebagai data train karena setiap komentar masih mewakili satu konteks utama, sehingga lebih sesuai digunakan sebagai acuan pembandingan dalam proses pencarian kemiripan aspek.

1. Skenario 1 (Data Train: Data Tidak Tersegmentasi | Data Test: Data Tersegmentasi)

Pada skenario pertama, data test hanya menggunakan komentar yang telah tersegmentasi. Dengan pembagian ini, sistem diuji pada komentar yang memang mengandung lebih dari satu konteks keluhan, sehingga dapat terlihat kemampuan sistem dalam mengenali aspek pada setiap segmen hasil pemecahan komentar. Dari proses tersebut diperoleh sebanyak 15.273 *data train* dan 5.092 *data test* yang berasal dari 2.264 *comment_id* tersegmentasi.

2. Skenario 2 (Data Train: Data Tidak Tersegmentasi | Data Test: 100% Data)

Pada skenario kedua, data test menggunakan 100% data, yaitu gabungan antara komentar yang tidak tersegmentasi dan komentar yang tersegmentasi. Skenario ini digunakan untuk melihat performa sistem pada keseluruhan data yang tersedia, sehingga hasil pengujian dapat menggambarkan kondisi penggunaan yang lebih umum. Pada skenario ini digunakan 15.273 *data train* dan 20.365 *data test* yang berasal dari 17.537 *comment_id*.

Dua skenario ini digunakan karena masing-masing memiliki tujuan pengujian yang berbeda. Skenario pertama difokuskan untuk melihat kemampuan sistem pada komentar yang telah dipecah menjadi beberapa segmen, sedangkan skenario kedua digunakan untuk melihat performa sistem pada campuran seluruh data. Dengan demikian, hasil pengujian tidak hanya menunjukkan kemampuan sistem pada komentar multi-konteks, tetapi juga pada kondisi data yang lebih luas.

4.6.3 TF-IDF

Pengujian TF-IDF dilakukan untuk memastikan bahwa sistem berhasil mengubah teks hasil *preprocessing* menjadi representasi numerik dalam bentuk vektor. Pada penelitian ini, teks yang telah melalui tahap *normalization*, segmentasi teks, *tokenizing*, *stopword removal*, dan *stemming* tidak langsung digunakan untuk klasifikasi, tetapi terlebih dahulu diubah menjadi bobot TF-IDF. Dengan cara ini, setiap kata tidak hanya dinilai dari kemunculannya di dalam satu kalimat, tetapi juga dari tingkat kepentingannya terhadap keseluruhan *data train*. Kata yang sering muncul pada satu kalimat namun tidak terlalu umum pada seluruh dokumen akan memperoleh bobot yang lebih besar, sehingga dapat lebih membantu sistem dalam membedakan konteks keluhan yang sedang dibahas.

Pada implementasinya, pembentukan fitur TF-IDF dilakukan menggunakan *data train aspect based* yang berasal dari komentar tidak tersegmentasi. *Vectorizer* membentuk fitur dari *unigram*, *bigram*, hingga *trigram*, sehingga sistem tidak hanya membaca kata tunggal, tetapi juga rangkaian kata yang berurutan. Selain itu, hanya kata atau frasa yang muncul minimal dua kali pada *data train* yang dimasukkan ke dalam *vocabulary*. Pengaturan ini membuat fitur yang digunakan menjadi lebih stabil, karena kata yang terlalu jarang muncul tidak langsung dijadikan acuan. Hasil dari proses ini adalah setiap segmen komentar memiliki vektor bobot desimal yang kemudian dipakai pada tahap perhitungan *cosine similarity*.

Tabel 4. 7. Sampel Data Perhitungan TF-IDF

	Input	Vektor
Sentence 1	‘halo	0.188832
	‘kakak’	0.159211
	‘sudah’	0.250183
	‘komplain’	0.266583
	‘sini’	0.266583
	‘lapor’	0.197567
	‘meter’	0.228670
	‘rusak’	0.195649
	‘tanggal’	0.176925
	‘januari’	0.208985

	Input	Vektor
	‘tugas’	0.181757
	‘lapang’	0.234902
	‘datang’	0.208985
	‘cek’	0.175809
<i>Sentence 2</i>	‘tapi’	-
	‘sampai’	0.277065
	‘sekarang’	0.336865
	‘belum’	0.308036
	‘ada’	0.227220
	‘ganti’	0.344197

Contoh pengujian diambil dari komentar dengan `comment_id` 41 yang setelah melalui segmentasi menghasilkan dua kalimat seperti pada Tabel 4.7. Bobot yang lebih tinggi pada beberapa frasa tersebut menunjukkan bahwa konteks keterlambatan penanganan dan belum adanya pergantian berhasil ditangkap dengan cukup jelas oleh sistem.

Tidak semua kata pada kalimat otomatis masuk ke dalam vektor. Pada contoh *sentence_2*, kata *tapi* tidak memperoleh bobot karena tidak termasuk ke dalam *vocabulary* yang dibentuk *vectorizer* dari *data train*. Hal ini dapat terjadi karena kata tersebut tidak memenuhi syarat kemunculan minimal pada *data train* atau tidak terbentuk sebagai fitur akhir yang dipakai sistem. Sebaliknya, kata seperti *sampai* dan *sekarang* dapat masuk ke dalam perhitungan karena keduanya muncul dalam pola data yang cukup relevan dan memenuhi pembentukan fitur TF-IDF. Dengan demikian, hasil vektorisasi tidak hanya bergantung pada kata yang muncul di data uji, tetapi juga sangat dipengaruhi oleh *vocabulary* yang berhasil dipelajari dari *data train*.

Berdasarkan hasil tersebut, dapat dilihat bahwa proses TF-IDF pada sistem telah berjalan dengan baik karena mampu mengubah teks komentar menjadi bobot numerik yang merepresentasikan kata-kata penting pada setiap segmen. Representasi ini menjadi dasar utama pada tahap klasifikasi aspek, karena *cosine similarity* tidak membandingkan teks mentah secara langsung, melainkan membandingkan kedekatan antar vektor TF-IDF. Semakin sesuai bobot kata antara data uji dan data train, maka semakin besar pula peluang sistem untuk memilih aspek yang tepat.

Berdasarkan Tabel 4.7, terlihat bahwa proses pemvektorisasian menggunakan metode Frekuensi Istilah Frekuensi Dokumen Terbalik (*Term Frequency-Inverse Document Frequency* atau TF-IDF) telah berjalan dengan baik. Hal ini terbukti dari keberhasilan sistem dalam membentuk vektor dari masukan teks yang diberikan.

4.6.4 Aspect Based **Menggunakan Cosine Similarity**[DR5]

Tabel 4.8 Daftar Aspek yang Digunakan

Aspek yang Digunakan
Air Tidak Mengalir
Meteran (Macet/Bermasalah)
Harga
Pelayanan
Pemasangan
Air Kotor/Bau
Kebocoran
Pemakaian
Perubahan Kode Tarif
Lainnya

Pada tahap ini penulis menentukan 10 aspek seperti pada Tabel 4.8 berdasarkan:

- Aspek yang ada pada aplikasi CIS milik PDAM (Aspek: Air Kotor/Bau, Kebocoran, Meteran (Macet/Bermasalah), Air Tidak Mengalir, Pemakaian, Perubahan Kode Tarif)
- Pendapat penulis setelah membaca data yang dimiliki (Aspek: Pemasangan, Pelayanan, Harga, Lainnya)

Pada tahap ini, setiap segmen komentar yang telah melalui *preprocessing* diubah terlebih dahulu ke dalam bentuk vektor TF-IDF, kemudian dibandingkan dengan seluruh *data train* menggunakan *cosine similarity*. *Data train* berasal dari komentar yang tidak tersegmentasi sehingga setiap baris masih mewakili satu konteks utama dan lebih sesuai dijadikan acuan aspek. Sementara itu, data test berasal dari komentar yang telah tersegmentasi, sehingga setiap segmen dapat diuji secara terpisah sesuai konteks keluhannya.

Pembentukan vektor dilakukan menggunakan *TfidfVectorizer* dengan parameter *ngram_range*=(1,3) dan *min_df*=2. Parameter *ngram_range*=(1,3) digunakan agar sistem tidak hanya membaca kata tunggal, tetapi juga frasa dua kata dan tiga kata yang berurutan. Hal ini penting karena pada komentar pelanggan, konteks keluhan sering lebih jelas jika dibaca dalam bentuk frasa seperti meter rusak, air tidak mengalir, atau sampai sekarang belum. Sementara itu, *min_df*=2 digunakan agar hanya kata atau frasa yang muncul minimal pada dua dokumen *train* yang dipertahankan sebagai fitur. Dengan cara ini, *vocabulary* yang terbentuk menjadi lebih stabil dan tidak terlalu dipengaruhi oleh kata yang hanya muncul satu kali.

Setelah vektor *data train* terbentuk, setiap segmen pada *data test* diubah ke bentuk vektor dengan *vocabulary* yang sama. Selanjutnya, sistem menghitung *cosine similarity* antara satu segmen *data test* dengan seluruh *data train*. *Data train* dengan nilai *similarity* tertinggi akan menjadi acuan prediksi aspek untuk segmen tersebut. Dengan mekanisme ini, aspek dipilih berdasarkan kedekatan pola kata dan frasa antara *data test* dengan *data test*.

Pada implementasinya digunakan dua threshold, yaitu *PRIMARY_THRESHOLD* sebesar 0,60 dan *LAINNYA_THRESHOLD* sebesar 0,18. Nilai 0,60 digunakan sebagai penanda bahwa kemiripan antara segmen dan *data train* sudah kuat. Sementara itu, nilai 0,18 digunakan sebagai batas bawah agar komentar yang kemiripannya terlalu lemah tidak dipaksakan masuk ke aspek tertentu, tetapi diarahkan ke aspek Lainnya. Setiap segmen diproses secara mandiri. Artinya, kalimat 1 dan kalimat 2 tidak saling memengaruhi *threshold* maupun hasil prediksinya. Masing-masing segmen hanya dibandingkan dengan seluruh *data train*, lalu dipilih aspek dengan *similarity* tertinggi pada segmen tersebut.

Untuk klasifikasi satu aspek, perhitungan *cosine similarity* dilakukan antara vektor segmen pertama dengan seluruh vektor *data train*. Persamaan yang digunakan dapat dituliskan sebagai berikut:

$$\text{Sim}(S1, Di) = \frac{(S1 \cdot Di)}{([S1] \times [Di])} \quad (4.1)$$

Keterangan:

- *Sim*(*S1*, *Di*): Nilai *cosine similarity* antara kalimat 1 dan *data train* ke-*i*.
- *S1*: Vektor TF-IDF dari kalimat 1.

- D_i : Vektor TF-IDF dari *data train* ke- i .
- $S1 \cdot D_i$: *Dot product* antara dua vektor, yaitu hasil perkalian bobot TF-IDF pada fitur yang sama.
- $|S1|$: Panjang atau *magnitude* dari vektor kalimat 1, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor kalimat 1.
- $|D_i|$: Panjang atau *magnitude* dari vektor *data train* ke- i , dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *data train* ke i .

Pada implementasi program, nilai *similarity* dihitung untuk setiap segmen terhadap seluruh *data train*. Setelah itu dipilih satu *data train* dengan *similarity* tertinggi. Jika nilai tertinggi tersebut lebih kecil dari 0,18, maka segmen diarahkan ke aspek Lainnya. Sebaliknya, jika nilainya sama dengan atau lebih besar dari 0,18, maka aspek dari *data train* dengan nilai tertinggi digunakan sebagai hasil prediksi segmen tersebut.

Untuk komentar yang memiliki dua segmen, proses yang sama juga dilakukan pada kalimat 2. Dengan demikian, perhitungannya menjadi:

$$\text{Sim}(S1, D_i) = \frac{(S1 \cdot D_i)}{(|S1| \times |D_i|)} \quad (4.2)$$

$$\text{Sim}(S2, D_i) = \frac{(S2 \cdot D_i)}{(|S2| \times |D_i|)} \quad (4.3)$$

Keterangan:

- $\text{Sim}(S2, D_i)$: Nilai *cosine similarity* antara kalimat 2 dan *data train* ke- i .
- $S2$: Vektor TF-IDF dari kalimat 2.
- D_i : Vektor TF-IDF dari *data train* ke- i .
- $S2 \cdot D_i$: *Dot product* antara dua vektor, yaitu hasil perkalian bobot TF-IDF pada fitur yang sama.
- $|S2|$: Panjang atau *magnitude* dari vektor kalimat 2, dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor kalimat 2.
- $|D_i|$: Panjang atau *magnitude* dari vektor *data train* ke- i , dihitung sebagai akar kuadrat dari jumlah kuadrat semua elemen dalam vektor *data train* ke- i .

Kalimat 1 dan kalimat 2 diperlakukan sebagai dua *data test* yang berdiri sendiri. Oleh karena itu, hasil prediksi akhir komentar diperoleh dengan menggabungkan hasil prediksi dari masing-masing segmen, bukan dengan membandingkan kalimat 1 dan kalimat 2 satu sama lain.

Tabel 4. 9. Kata yang Digunakan Dalam Perhitungan *Similarity* Kalimat 1

	Kata-Kata
<i>Sentence 1</i>	['meter', 'rusak', 'meter rusak']
<i>Data Train</i>	['meter', 'rusak', 'meter rusak']

Tabel 4. 10. Perhitungan TF-IDF Kalimat 1 dan *Data Train*

	meter	rusak	meter rusak
<i>Sentence 1</i>	0.228670	0.195649	0.215946
<i>Data Train</i>	0.409546	0.580603	0.703683

Tabel 4.9 adalah kalimat yang digunakan pada contoh perhitungan *similarity* kalimat 1 dan Tabel 4.10 adalah hasil perhitungan TF-IDF kalimat 1 dan *data train*. Pada contoh ini, fitur yang paling berpengaruh adalah meter, rusak, dan meter rusak karena fitur tersebut sama-sama muncul pada *data test* dan *data train* dengan *similarity* tertinggi.

Maka perhitungan *cosine similarity* untuk kalimat 1 adalah sebagai berikut

$$\text{Sim}(S1, D1180) = \frac{((0.228670 \times 0.409546) + (0.195649 \times 0.580603) + (0.215946 \times 0.703683))}{\sqrt{0.228670^2 \times 0.195649^2 \times 0.215946^2} \times \sqrt{0.409546^2 \times 0.580603^2 \times 0.703683^2}} \quad (4.4)$$

$$\text{Sim}(S1, D1180) = 0.745022 \quad (4.5)$$

Nilai *similarity* sebesar 0.745022 lebih besar dari *threshold* utama 0.60, sehingga kalimat 1 diprediksi sebagai aspek Meteran (Macet/Bermasalah)

Tabel 4. 11. Kata-Kata yang Digunakan Dalam Perhitungan *similarity sentence_2*

	Kata-Kata
<i>Sentence 2</i>	['tapi', 'sampai', 'sekarang', 'sampai sekarang', 'tapi sampai']

<i>Data Train</i>	['tapi', 'sampai', 'sekarang', 'sampai sekarang', 'tapi sampai']
-------------------	---

Tabel 4. 12. Perhitungan TF-IDF *Sentence 2* dan *Data Train*

	tapi	sampai	sekarang
<i>Sentence_2</i>	0.293084	0.144491	0.177580
<i>Data Train</i>	0.476043	0.234690	0.288435

	sampai sekarang	tapi sampai
<i>Sentence_2</i>	0.202282	0.447009
<i>Data Train</i>	0.328557	0.726056

Tabel 4.11 adalah kalimat yang digunakan pada contoh perhitungan *similarity* kalimat 2 dan Tabel 4.12 adalah hasil perhitungan TF-IDF kalimat 2 dan *data train*. Pada contoh ini, bobot terbesar muncul pada fitur tapi sampai dan sampai sekarang, sehingga frasa menjadi penentu penting dalam mengenali konteks pelayanan pada segmen kedua.

Maka perhitungan *cosine similarity* untuk kalimat 2 adalah sebagai berikut:

$$\begin{aligned}
 \text{Sim}(S2, D34) = & \frac{((0.293084 \times 0.476043) + (0.144491 \times 0.234690) + \\
 & (0.177580 \times 0.288435) + (0.202282 \times 0.328557) + \\
 & (0.447009 \times 0.726056))}{\sqrt{0.293084^2 \times 0.144491^2 \times 0.177580^2 \times 0.202282^2} \\
 & \times \sqrt{0.476043^2 \times 0.234690^2 \times 0.288435^2 \times 0.328557^2} \\
 & \times \sqrt{0.447009^2}} \quad (4.6)
 \end{aligned}$$

$$\text{Sim}(S2, D34) = 0.615668 \quad (4.7)$$

Nilai similarity sebesar 0,615668 lebih besar dari *threshold* utama 0,60, sehingga kalimat 2 diprediksi sebagai aspek Pelayanan. Karena hasil prediksi kalimat 1 dan kalimat 2 berbeda, maka hasil akhir komentar ini menjadi dua aspek, yaitu Meteran (Macet/Bermasalah) dan Pelayanan.

4.6.5 Evaluasi Aspect Based

A. Skenario 1 (Data Train: Data Tidak Tersegmentasi | Data Test: Data Tersegmentasi)


1. Percobaan pertama (ngram=(1,3), Primary Threshold = 0.60, Lainnya Threshold = 0.18)

Pada percobaan pertama skenario 1, sistem memperoleh 3.784 prediksi benar dan 1.308 prediksi salah, dengan akurasi sebesar 74,31% serta rata-rata *F1 Score* sebesar 0,7052. Hasil ini menunjukkan bahwa model sudah cukup baik dalam mengenali aspek pada data tersegmentasi, meskipun pemisahan antar aspek yang konteksnya berdekatan masih menjadi tantangan.

Tabel 4. 13. Evaluasi Per Aspek Skenario 1 Percobaan Pertama

Aspek	Precision	Recall	F1 Score
Air Kotor/Bau	0.6632	0.5953	0.6275
Air Tidak Mengalir	0.7932	0.7795	0.7863
Harga	0.8132	0.6994	0.752
Kebocoran	0.6931	0.6863	0.6897
Lainnya	0.6742	0.847	0.7508
Meteran (Macet/Bermasalah	0.6915	0.7263	0.7084
Pelayanan	0.8421	0.6278	0.7193
Pemakaian	0.7018	0.4444	0.5442
Pemasangan	0.6225	0.6812	0.6505
Perubahan Kode Tarif	1	0.7	0.8235

Berdasarkan Tabel 4.13, performa terbaik terlihat pada aspek Perubahan Kode Tarif dengan *F1 Score* 0,8235 dan Air Tidak Mengalir dengan *F1 Score* 0,7863. Aspek Harga, Lainnya, dan Pelayanan juga menunjukkan hasil yang cukup baik. Namun, aspek Pemakaian masih memiliki *F1 Score* terendah, yaitu 0,5442, sehingga menjadi aspek yang paling sulit dikenali. Secara umum, hasil evaluasi per aspek menunjukkan bahwa model lebih stabil pada aspek yang memiliki pola kata lebih khas dan lebih sering muncul pada data.



Gambar 4. 1. *Confussion Matrix* Skenario 1 Percobaan Pertama

Berdasarkan Gambar 4.1, sebagian besar prediksi benar berada pada diagonal utama, terutama pada aspek Air Tidak Mengalir, Lainnya, Pelayanan, dan Harga. Kesalahan yang paling menonjol terlihat pada perpindahan prediksi dari Air Tidak Mengalir dan Pelayanan ke aspek Lainnya. Hal ini menunjukkan bahwa pada beberapa segmen, konteks keluhan masih terlalu umum sehingga sistem lebih mudah mengarahkannya ke aspek Lainnya. Dengan demikian, *confussion matrix* memperlihatkan bahwa model sudah cukup baik dalam mengenali pola aspek utama, tetapi masih mengalami kesulitan pada segmen yang singkat atau memiliki makna yang saling tumpang tindih.


2. Percobaan kedua (ngram=(1,2), Primary Threshold = 0.60, lainnya threshold = 0.18)

Pada percobaan kedua skenario 1, sistem memperoleh 3.606 prediksi benar dan 1.476 prediksi salah, dengan akurasi sebesar 70,82% serta rata-rata *F1 Score* sebesar 0,6813. Hasil ini lebih rendah dibanding percobaan pertama, sehingga dapat dilihat bahwa penggunaan *unigram* dan *bigram* saja belum cukup kuat untuk menangkap konteks pada data tersegmentasi sebaik ngram sampai trigram.

Tabel 4. 14. Evaluasi Per Aspek Skenario 1 Percobaan Kedua

Aspek	Precision	Recall	F1 Score
Air Kotor/Bau	0.6578	0.5721	0.6119
Air Tidak Mengalir	0.7357	0.7342	0.735
Harga	0.793	0.6805	0.3725
Kebocoran	0.7079	0.6176	0.6597
Lainnya	0.6423	0.8043	0.7142
Meteran (Macet/Bermasalah	0.6902	0.7095	0.6997
Pelayanan	0.7982	0.5987	0.6842
Pemakaian	0.6833	0.4556	0.5467
Pemasangan	0.6438	0.6812	0.662
Perubahan Kode Tarif	0.8485	0.7	0.7671

Berdasarkan Tabel 4.14, performa terbaik tetap terlihat pada aspek Perubahan Kode Tarif dengan *F1 Score* 0,7671 dan Air Tidak Mengalir dengan *F1 Score* 0,7350. Aspek Harga, Lainnya, dan Meteran (Macet/Bermasalah) juga masih menunjukkan hasil yang cukup baik. Namun, beberapa aspek seperti Pelayanan, Kebocoran, dan Air Kotor/Bau mengalami penurunan dibanding percobaan pertama. Aspek Pemakaian masih menjadi aspek dengan hasil terendah, dengan *F1 Score* 0,5467. Secara umum, hasil ini menunjukkan bahwa tanpa trigram, model masih dapat mengenali pola utama, tetapi ketepatannya menurun pada aspek yang membutuhkan konteks frasa yang lebih lengkap.



Gambar 4. 2. *Confussion Matrix* Skenario 1 Percobaan Kedua

Berdasarkan Gambar 4.2, sebagian besar prediksi benar masih berada pada diagonal utama, terutama pada aspek Air Tidak Mengalir, Lainnya, Pelayanan, dan Harga. Namun, kesalahan prediksi ke aspek Lainnya masih cukup besar, terutama dari Air Tidak Mengalir dan Pelayanan. Pola ini menunjukkan bahwa beberapa segmen komentar masih terlalu umum sehingga lebih mudah ditarik ke aspek Lainnya. Dibanding percobaan pertama, confusion matrix pada percobaan ini menunjukkan pemisahan antar aspek yang sedikit lebih lemah, sehingga dapat dipahami bahwa penggunaan ngram sampai bigram saja belum sekuat ngram sampai trigram dalam membaca konteks keluhan pelanggan

B. Skenario 2 (Data Train: Data Tidak Tersegmentasi | Data Test: 100% Data)

1. Percobaan pertama (ngram=(1,3), Primary Threshold = 0.60, lainnya threshold = 0.18)


Pada percobaan pertama skenario 2, sistem memperoleh 19.003 prediksi benar dan 1.362 prediksi salah, dengan akurasi sebesar 93,31% serta rata-rata F1 *Score* sebesar 0,8841. Hal ini menunjukkan bahwa model sangat baik dalam mengenali aspek ketika data test menggunakan

seluruh data, yaitu gabungan komentar tidak tersegmentasi dan komentar tersegmentasi. Pada kondisi ini, banyak data uji yang masih memiliki pola sangat dekat dengan data train, sehingga sistem lebih mudah menemukan aspek yang sesuai.

Tabel 4. 15. Evaluasi Per Aspek Skenario 2 Percobaan Pertama

Aspek	Precision	Recall	F1 Score
Air Kotor/Bau	0.9082	0.8808	0.8943
Air Tidak Mengalir	0.9617	0.9577	0.9597
Harga	0.9187	0.858	0.8873
Kebocoran	0.898	0.8951	0.8966
Lainnya	0.9192	0.9649	0.9415
Meteran (Macet/Bermasalah)	0.8694	0.8874	0.8783
Pelayanan	0.9252	0.8305	0.8753
Pemakaian	0.8468	0.6528	0.7373
Pemasangan	0.8837	0.9078	0.8956
Perubahan Kode Tarif	1	0.7778	0.875

Berdasarkan Tabel 4.15, hampir seluruh aspek menunjukkan performa yang tinggi. Aspek Air Tidak Mengalir memiliki *F1 Score* sebesar 0,9597, Lainnya sebesar 0,9415, Air Kotor/Bau sebesar 0,8943, Kebocoran sebesar 0,8966, dan Pemasangan sebesar 0,8956. Aspek Harga, Pelayanan, dan Meteran (Macet/Bermasalah) juga menunjukkan hasil yang baik dengan *F1 Score* di atas 0,87. Sementara itu, aspek Pemakaian masih menjadi aspek dengan nilai terendah, yaitu 0,7373, walaupun nilainya tetap lebih baik dibanding hasil pada skenario 1. Secara umum, hasil evaluasi per aspek menunjukkan bahwa model sudah sangat stabil pada sebagian besar aspek ketika diuji pada 100% data.



Gambar 4.3. *Confussion Matrix* Skenario 2 Percobaan Pertama

Berdasarkan Gambar 4.3, *confusion matrix* menunjukkan diagonal utama yang sangat dominan pada hampir seluruh aspek. Nilai diagonal yang besar terlihat jelas pada Air Tidak Mengalir, Lainnya, Pelayanan, Harga, dan Pemasangan. Pola ini menunjukkan bahwa mayoritas komentar berhasil diprediksi ke aspek yang benar. Meskipun masih terdapat beberapa kesalahan prediksi, perpindahan antar kelas terlihat jauh lebih kecil dibanding skenario 1. Kesalahan yang masih cukup terlihat tetap terjadi pada beberapa komentar Air Tidak Mengalir dan Pelayanan yang bergeser ke Lainnya, tetapi jumlahnya tidak terlalu besar dibanding total prediksi benar. Dengan demikian, *confusion matrix* pada skenario 2 memperlihatkan bahwa model mampu membedakan aspek dengan sangat baik ketika data uji memiliki distribusi yang lebih dekat dengan data train.

2. Percobaan kedua (ngram=(1,2), Primary Threshold = 0.60, lainnya threshold = 0.18)


Pada percobaan kedua skenario 2, sistem memperoleh 18.825 prediksi benar dan 1.540 prediksi salah, dengan akurasi sebesar 92,44% serta rata-rata *F1 Score* sebesar 0,8749. Hasil

ini menunjukkan bahwa model tetap memiliki performa yang sangat baik ketika data test menggunakan 100% data. Artinya, penggunaan unigram dan bigram saja sudah cukup mampu menangkap pola aspek pada sebagian besar komentar pelanggan.

Tabel 4. 16. Evaluasi Per Aspek Skenario 2 Percobaan Kedua

Aspek	Precision	Recall	F1 Score
Air Kotor/Bau	0.9088	0.874	0.8911
Air Tidak Mengalir	0.9506	0.9492	0.9499
Harga	0.91	0.8491	0.8785
Kebocoran	0.911	0.8721	0.8911
Lainnya	0.9118	0.9563	0.9335
Meteran (Macet/Bermasalah)	0.8705	0.8805	0.8754
Pelayanan	0.9088	0.8177	0.8609
Pemakaian	0.8333	0.6597	0.7364
Pemasangan	0.8928	0.9078	0.9002
Perubahan Kode Tarif	0.8936	0.7778	0.8317

Berdasarkan Tabel 4.16, hampir seluruh aspek tetap menunjukkan performa yang tinggi. Aspek Air Tidak Mengalir memiliki *F1 Score* sebesar 0,9499, Lainnya sebesar 0,9335, Air Kotor/Bau sebesar 0,8911, Kebocoran sebesar 0,8911, dan Pemasangan sebesar 0,9002. Aspek Harga, Pelayanan, dan Meteran (Macet/Bermasalah) juga menunjukkan hasil yang baik dengan *F1 Score* di atas 0,87. Sementara itu, aspek Pemakaian kembali menjadi aspek dengan nilai terendah, yaitu 0,7364, walaupun nilainya masih cukup baik. Secara umum, hasil evaluasi per aspek menunjukkan bahwa model sudah stabil dalam mengenali sebagian besar aspek pada data uji.



Gambar 4. 4. *Confussion Matrix* Skenario 2 Percobaan Pertama

Berdasarkan Gambar 4.4, *confussion matrix* menunjukkan diagonal utama yang tetap dominan pada hampir seluruh aspek. Nilai diagonal yang besar terlihat pada Air Tidak Mengalir, Lainnya, Pelayanan, Harga, dan Pemasangan, yang menandakan bahwa sebagian besar komentar berhasil diprediksi ke aspek yang benar. Beberapa kesalahan prediksi masih terlihat pada perpindahan komentar Air Tidak Mengalir dan Pelayanan ke aspek Lainnya, serta pada sebagian kecil komentar Lainnya yang bergeser ke Air Tidak Mengalir. Pola ini menunjukkan bahwa model sudah cukup baik dalam membedakan aspek-aspek utama, meskipun pada komentar yang lebih umum sistem masih cenderung mengarah ke aspek Lainnya. Secara keseluruhan, *confussion matrix* pada percobaan ini memperlihatkan bahwa hasil klasifikasi sudah sangat baik dan penyebaran kesalahan antaraspek relatif kecil.

C. Kesimpulan

Berdasarkan hasil evaluasi pada skenario 1, percobaan terbaik diperoleh pada percobaan pertama dengan parameter $ngram=(1,3)$, Primary Threshold = 0.60, dan lainnya threshold = 0.18. Percobaan ini menghasilkan akurasi sebesar 74,31% dan rata-rata F1 Score sebesar 0,7052, lebih baik dibanding percobaan kedua yang menggunakan $ngram=(1,2)$. Hasil ini menunjukkan bahwa pada data test yang seluruhnya berupa komentar tersegmentasi, penggunaan trigram membantu sistem menangkap konteks keluhan dengan lebih lengkap. Frasa tiga kata dapat memberi makna yang lebih spesifik dibanding unigram atau bigram saja, sehingga sistem lebih mudah membedakan segmen yang konteksnya mirip, misalnya antara Pelayanan, Lainnya, dan Air Tidak Mengalir. Karena data pada skenario ini berisi segmen-segmen yang lebih pendek dan lebih sensitif terhadap kehilangan konteks, keberadaan trigram membuat representasi teks menjadi lebih kuat dan membantu meningkatkan ketepatan klasifikasi.

Sementara itu, pada skenario 2 percobaan terbaik juga diperoleh pada percobaan pertama dengan parameter $ngram=(1,3)$, Primary Threshold = 0.60, dan lainnya threshold = 0.18. Percobaan ini menghasilkan akurasi sebesar 93,31% dan rata-rata F1 Score sebesar 0,8841, lebih baik dibanding percobaan kedua yang menggunakan $ngram=(1,2)$. Hasil tersebut menunjukkan bahwa pada data test 100%, penggunaan trigram tetap memberikan hasil paling optimal karena sistem dapat membaca hubungan antar kata secara lebih utuh dan lebih kontekstual. Selain itu, pada skenario ini data test tidak hanya berisi komentar tersegmentasi, tetapi juga komentar tidak tersegmentasi yang pola katanya lebih dekat dengan data train. Kondisi tersebut membuat sistem lebih mudah menemukan pasangan teks yang mirip. Ketika informasi trigram ditambahkan, kecocokan antara data uji dan data train menjadi lebih tajam, sehingga prediksi aspek dapat dilakukan dengan lebih akurat pada sebagian besar komentar.

4.6.6 Sentiment Analysis Menggunakan Rule Based[DR6]

Pada tahap ini, analisis sentimen dilakukan menggunakan pendekatan *rule based* dengan memanfaatkan aturan kombinasi *part of speech* (POS) dan kamus polarity yang telah disusun. Berbeda dengan proses klasifikasi aspek yang menggunakan teks hasil *stemming*, pada analisis sentimen penelitian ini digunakan kolom *normalized_text* sebagai input utama. Pemilihan *normalized_text* dilakukan agar makna kata-kata domain seperti pengajuan, peremajaan, dan tindak lanjut tetap terjaga dan tidak berubah akibat proses *stemming*.

Alur proses *sentiment analysis* dimulai dengan mengambil teks yang telah dinormalisasi, kemudian teks dibersihkan dan dipecah menjadi beberapa bagian kalimat berdasarkan tanda baca seperti titik, koma, tanda seru, dan tanda tanya. Setelah itu, sistem melakukan pengecekan frasa, pencocokan kata ke kamus POS, dan perhitungan nilai sentimen berdasarkan aturan yang sesuai. Nilai sentimen dari setiap bagian kalimat kemudian dijumlahkan untuk memperoleh skor sentimen akhir pada satu komentar. Jika skor akhir lebih besar dari nol maka komentar diberi label Positif, jika sama dengan nol maka diberi label Netral, dan jika lebih kecil dari nol maka diberi label Negatif.

Pada implementasinya, sistem juga menerapkan beberapa penyesuaian tambahan. Pertama, jika sebuah komentar berbentuk pertanyaan dan tidak memiliki sinyal negatif yang kuat, maka komentar tersebut cenderung diberi nilai netral. Kedua, sistem mengenali beberapa frasa negatif yang kuat seperti tidak ada respon, tidak ada tanggapan, air tidak mengalir, air mati, air tidak keluar, tagihan melonjak, dan frasa sejenis agar keluhan pelanggan yang bersifat tegas dapat langsung diberi penalti sentimen negatif. Ketiga, sistem juga menambahkan *complaint context penalty* ketika dalam satu kalimat ditemukan kata-kata keluhan seperti complain, adu, lapor, mohon, atau tolong yang muncul bersama kata-kata masalah layanan seperti air, meter, tagihan, bocor, keruh, mati, rusak, atau lonjak. Penyesuaian ini dibuat agar pola pengaduan pelanggan dapat lebih mudah dikenali oleh sistem.

Dalam program, terdapat dua operator utama yang digunakan. Operator *AND* dipakai pada pasangan preposisi dan kata berikutnya. Jika salah satu nilai adalah 0, maka hasilnya mengikuti penjumlahan biasa. Namun jika kedua nilai tidak 0, maka hasilnya menjadi 1 jika tandanya sama dan -1 jika tandanya berbeda. Sementara itu, operator *NAND* dipakai pada pasangan verba dan adjektiva. Jika salah satu nilainya 0, maka hasilnya juga berupa penjumlahan biasa. Namun jika kedua nilai tidak 0, maka hasilnya menjadi 1 jika jumlah keduanya positif dan -1 jika jumlah keduanya tidak positif.

1. Adjektiva Tunggal

Aturan pertama adalah adjektiva tunggal. Jika pada kalimat ditemukan kata sifat yang memiliki nilai sentimen dan tidak terlibat dalam kombinasi aturan lain, maka nilai sentimennya langsung diambil sebagai nilai sentimen kalimat.

Contoh yang diambil dari data adalah klausa lama pada komentar:

“pergantian meter bayar via indomaret, bayar via indomaret h masuk, h masuk jadwalkan kunjungan. lama, air sudah bocor deras tanggung pemilik rumah. lama prosesnya??.”

Pada klausa ini, kata “lama” termasuk Adjektiva dengan nilai -1, sehingga perhitungannya adalah

$$\begin{aligned} score &= sentiment(lama) \\ score &= -1. \end{aligned}$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen negatif.

2. Verba Tunggal

Aturan kedua adalah verba tunggal. Jika pada kalimat ditemukan kata kerja yang memiliki nilai sentimen dan tidak berpasangan dengan aturan lain, maka nilai sentimennya langsung digunakan.

Contoh dari data adalah klausa bayar pada komentar

“ada perbaikan ta. air keluar rumah kecil kadang tidak. nyala. bayar.”

Pada klausa ini, kata “bayar” termasuk Verba dengan nilai -1, sehingga perhitungannya adalah

$$\begin{aligned} score &= sentiment(bayar) \\ score &= -1. \end{aligned}$$

Hasil akhirnya adalah sentimen negatif.

3. Preposisi + Adjektiva

Aturan ketiga adalah kombinasi preposisi dan adjektiva. Contoh dari data adalah klausa [“air”, “dalam”, “keruh”] yang berasal dari komentar

“airnya dalam keruh, hampir air beras.”

Pada klausa ini, kata “dalam” termasuk Preposisi dengan nilai 1, sedangkan kata “keruh” termasuk Adjektiva dengan nilai -1. Maka nilai pasangan tersebut dihitung dengan $AND(1, -1) = -1$. Selain itu, kata “air” pada klausa ini juga memiliki nilai -1 di dalam kamus, sehingga total skor kalimat menjadi

$$score = sentiment(air) + AND(dalam, keruh)$$

$$score = -1 + (-1) = -2.$$

Oleh karena itu, klausa ini dikategorikan sebagai sentimen negatif.

4. Preposisi + Verba

Aturan keempat adalah kombinasi preposisi dan verba. Pada implementasi program, pola ini banyak muncul dalam bentuk negasi seperti [“tidak”, “ada”, “atau”, “tidak”, “keluar”].

Contoh dari data adalah klausa pemasangan tidak ada kelanjutan survey yang berasal dari komentar.

“pemasangan tidak ada kelanjutan survey. padahal katanya komplain pelayanan pelanggan whatsapp. sedangkan whatsapp tidak ada tanggapan.”

Pada klausa ini, model juga memberikan *complaint context penalty* sebesar -1 karena terdapat konteks keluhan layanan. Setelah itu, kata tidak diberi nilai -1, sedangkan kata ada bernilai 0. Maka skor yang diperoleh adalah

$$score = complaint\ penalty + sentiment(tidak) + sentiment(ada)$$

$$score = -1 + (-1) + 0$$

$$score = -2.$$

Dengan demikian, klausa ini dikategorikan sebagai sentimen negatif.

5. Verba + Adjektiva

Aturan kelima adalah kombinasi verba dan adjektiva. Contoh dari data dapat dilihat pada klausa [“padahal”, “bayar”, “mahal”, “tapi”, “air”, “keruh”, “bau”], yang berasal dari komentar

“air pdam surabaya pusat penyaku keruh air sumur. padahal bayarnya mahal tapi airnya keruh bau.”

Pada bagian [“bayar”, “mahal”], kata “bayar” termasuk Verba dengan nilai -1 dan kata “mahal” termasuk Adjektiva dengan nilai -1. Maka nilai pasangan tersebut dihitung dengan $NAND(-1, -1) = -1$. Pada klausa lengkap ini, sistem juga menemukan frasa “air keruh” yang bernilai -1 serta kata bau yang bernilai -1, sehingga total skor klausa menjadi

$$score = NAND(bayar, mahal) + sentiment(air\ keruh) + sentiment(bau)$$

$$score = 1 + (-1) + (-1)$$

$$score = -3.$$

Oleh karena itu, klausa ini dikategorikan sebagai sentimen negatif.

6. Preposisi + Verba + Adjektiva

Aturan keenam adalah kombinasi preposisi, verba, dan adjektiva. Contoh dari data adalah klausa

“air tidak keluar mati.”

Secara konsep, pola ini memuat preposisi “tidak”, verba “keluar”, dan adjektiva “mati”. Jika dihitung berdasarkan susunan aturannya, pasangan verba adjektiva dihitung terlebih dahulu, kemudian digabungkan dengan preposisi. Namun, pada implementasi program saat ini, pola “tidak keluar” sudah terdeteksi sebagai frasa negatif kuat dengan nilai -1. Setelah itu, kata mati masih dihitung sebagai adjektiva tunggal dengan nilai -1. Maka total skor klausa tersebut adalah

$$score = sentiment(tidak\ keluar) + sentiment(mati)$$

$$score = -1 + (-1)$$

$$score = -2.$$

Dengan demikian, klausa ini dikategorikan sebagai sentimen negatif.

7. Frasa

Aturan ketujuh adalah Frasa. Pada penelitian ini, frasa didefinisikan sebagai gabungan beberapa kata yang membentuk satu makna utuh dan telah tersimpan pada kamus frasa. Berbeda dengan aturan berbasis *Part of Speech* yang menganalisis setiap kata secara terpisah, aturan ini memperlakukan frasa sebagai satu kesatuan sehingga nilai sentimennya diambil langsung dari kamus frasa yang digunakan oleh sistem.

Contoh dari data adalah klausa:

“sedang whatsapp tidak ada tanggapan”

Tabel 4. 17. Perhitungan sentimen per kata/Klausa Aturan Frasa

Kata/Klausa	POS	Sentimen
sedang	Konjungsi	0
whatsapp	Nomina	0
tidak ada tanggapan	Frasa	-1

Berdasarkan Tabel 4.17 frasa “tidak ada tanggapan” yang terdapat pada kamus frasa dengan nilai sentimen -1. Karena frasa telah dikenali sebagai satu kesatuan makna, maka kata [“tidak”, “ada”, “tanggapan”] tidak dihitung secara terpisah.

Perhitungan sentimen pada klausa tersebut adalah:

$$score = sentiment(sedang) + sentiment(whatsapp) + sentiment(tidak ada tanggapan)$$

$$score = 0 + 0 + (-1)$$

$$score = -1$$

Oleh karena itu, klausa tersebut dikategorikan sebagai sentimen negatif.

Berdasarkan kedua contoh tersebut, dapat dilihat bahwa aturan Frasa tidak hanya menghitung nilai sentimen dari frasa yang ditemukan, tetapi juga tetap mengakumulasi nilai sentimen dari kata lain yang terdapat pada klausa. Dengan demikian, skor sentimen akhir diperoleh dari penjumlahan seluruh kontribusi kata dan frasa yang berhasil dikenali oleh sistem. Hal ini memungkinkan sistem menghasilkan representasi sentimen yang lebih sesuai dengan isi komentar pelanggan.

8. Frasa Negatif Kuat

Aturan kedelapan adalah Frasa Negatif Kuat. Aturan ini digunakan untuk mendeteksi frasa-frasa yang memiliki indikasi keluhan yang kuat terhadap layanan. Berbeda dengan aturan Frasa yang mengambil nilai sentimen dari kamus frasa, aturan ini menggunakan kamus frasa negatif kuat untuk mengidentifikasi komentar yang mengandung permasalahan layanan secara jelas. Beberapa contoh frasa yang terdapat pada kamus tersebut antara lain [“air mati”, “air tidak keluar”, “meter rusak”, “air keruh”, “tagihan melonjak”].

Contoh dari data adalah klausa:

“padahal bayarnya mahal tapi airnya keruh bau”

Tabel 4. 18. Perhitungan sentimen per kata/Klausa Aturan Frasa Negatif Kuat

Kata/Klausa	POS	Sentimen
padahal	Konjungsi	0
bayarnya + mahal	Verba + Adjektiva	$NAND(-1,-1) = -1$
tapi	Konjungsi	0
air keruh	Frasa Negatif Kuat	-1
bau	Adjektiva	-1

Pada klausa ini, sistem menemukan frasa “air keruh” yang termasuk dalam kamus frasa negatif kuat. Frasa tersebut menunjukkan adanya permasalahan kualitas layanan sehingga sistem mengidentifikasinya sebagai keluhan yang memiliki indikasi sentimen negatif yang kuat. Selain itu berdasarkan Tabel 4.18, kata *bayar* termasuk Verba dengan nilai sentimen -1 dan kata *mahal* termasuk Adjektiva dengan nilai sentimen -1. Kedua kata tersebut membentuk aturan Verba + Adjektiva sehingga menghasilkan nilai $NAND(-1, -1) = -1$.

Perhitungan sentimen pada klausa tersebut adalah:

$$\begin{aligned} score &= sentiment(NAND(bayar,mahal)) + sentiment(air\ keruh) + sentiment(bau) \\ score &= -1 + (-1) + (-1) \\ score &= -3 \end{aligned}$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen negatif.

Berdasarkan contoh tersebut, dapat dilihat bahwa aturan frasa negatif kuat digunakan untuk mengenali pola-pola keluhan yang secara langsung menunjukkan adanya permasalahan layanan. Frasa yang terdeteksi melalui aturan ini memberikan kontribusi sentimen negatif yang kuat, sedangkan kata-kata lain yang terdapat pada klausa tetap dihitung sesuai aturan yang berlaku. Oleh karena itu, skor sentimen akhir diperoleh dari penjumlahan seluruh kontribusi sentimen yang dihasilkan oleh aturan frasa negatif kuat maupun aturan *sentiment analysis* lainnya.

9. Komentar Berbentuk Pertanyaan

Aturan kesembilan adalah komentar berbentuk pertanyaan. Aturan ini digunakan untuk mengidentifikasi komentar yang berbentuk pertanyaan dan mengkategorikannya sebagai

sentimen netral apabila tidak ditemukan indikasi keluhan yang kuat. Aturan ini ditambahkan karena pada data komentar pelanggan terdapat banyak pertanyaan yang bertujuan untuk memperoleh informasi mengenai layanan, sehingga tidak selalu mencerminkan sentimen positif maupun negatif.

Sistem mengidentifikasi kalimat tanya berdasarkan keberadaan tanda tanya (?) maupun kata tanya. Apabila komentar memenuhi karakteristik tersebut, sistem akan melakukan pemeriksaan terhadap keberadaan frasa negatif kuat yang telah dijelaskan pada aturan ke-8. Jika tidak ditemukan frasa negatif kuat, maka komentar akan langsung diberikan nilai sentimen netral.

Contoh dari data adalah klausa:

“bagaimana cara mengurus pemasangan baru sambungan rumah?”

Pada klausa ini, sistem menemukan kata tanya “bagaimana” yang menunjukkan bahwa komentar tersebut merupakan sebuah pertanyaan. Selanjutnya sistem memeriksa keberadaan frasa negatif kuat dan tidak menemukan indikasi keluhan pada klausa tersebut. Kata [“mengurus”, “pemasangan”, “baru”, “sambungan”, “rumah”] juga tidak menghasilkan nilai sentimen yang menunjukkan kepuasan maupun ketidakpuasan pelanggan terhadap layanan.

Perhitungan sentimen pada klausa tersebut adalah:

$$score = 0$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen netral.

Contoh lain dari data klausa adalah:

“kenapa air mati dari kemarin?”

Tabel 4. 19. Perhitungan sentimen per kata/Klausa Aturan Komentar Berbentuk Pertanyaan

Kata/Klausa	POS	Sentimen
kenapa	Kata tanya	0
air mati	Frasa Negatif Kuat	-1

Kata/Klausa	POS	Sentimen
dari	Preposisi	0
kemarin	Adverbia	0

Berdasarkan Tabel 4.19, pada klausa ini sistem menemukan kata tanya “kenapa” yang menunjukkan bahwa komentar tersebut merupakan sebuah pertanyaan. Namun demikian, sistem juga menemukan frasa “air mati” yang termasuk dalam kamus frasa negatif kuat. Oleh karena itu, klausa tersebut tidak memenuhi syarat untuk dinetralkan menjadi sentimen netral.

Perhitungan sentimen pada klausa tersebut adalah:

$$score = sentiment(kenapa) + sentiment(air\ mati) + sentiment(dari) + sentiment(kemarin)$$

$$score = 0 + (-1) + 0 + 0$$

$$score = -1$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen negatif.

Berdasarkan kedua contoh tersebut, dapat dilihat bahwa aturan ke-9 tidak secara otomatis mengubah seluruh kalimat tanya menjadi sentimen netral. Sistem terlebih dahulu memeriksa keberadaan frasa negatif kuat yang menunjukkan adanya keluhan layanan. Apabila tidak ditemukan indikasi keluhan, maka komentar akan dikategorikan sebagai netral. Sebaliknya, apabila ditemukan frasa negatif kuat, maka komentar tetap diproses sebagai komentar yang mengandung sentimen negatif. Dengan demikian, aturan ini mampu membedakan pertanyaan yang bersifat informatif dengan pertanyaan yang sebenarnya merupakan bentuk keluhan pelanggan terhadap layanan.

10. *Complaint Context Penalty*

Aturan kesepuluh adalah *Complaint Context Penalty*. Aturan ini digunakan untuk mendeteksi konteks keluhan yang tidak selalu dapat dikenali melalui nilai sentimen kata maupun frasa negatif kuat. Pada beberapa kasus, pelanggan menyampaikan keluhan dalam bentuk permintaan bantuan, laporan gangguan, atau permohonan tindak lanjut. Meskipun komentar tersebut tidak selalu mengandung kata-kata yang bernilai sentimen negatif, konteks yang disampaikan tetap menunjukkan adanya ketidakpuasan terhadap layanan.

Aturan ini bekerja dengan mengidentifikasi kemunculan kata-kata yang berkaitan dengan pengaduan seperti pada Tabel 3.8. Selain itu, sistem juga memeriksa keberadaan kata-kata yang berkaitan dengan permasalahan layanan seperti pada Tabel 3.9. Apabila kedua kondisi tersebut ditemukan dalam satu klausa, maka sistem akan memberikan *complaint context penalty* sebesar -1.

Contoh dari data adalah klausa:

“pemasangan tidak ada kelanjutan survey”

Tabel 4. 20. Perhitungan sentimen per kata/Klausa Aturan *Complain Context Penalty*

Kata/Klausa	POS	Sentimen
Pemasangan	Nomina	0
Tidak ada kelanjutan	Frasa	-1
survey	Nomina	0

Berdasarkan Tabel 4.20 pada klausa ini, sistem menemukan konteks pengaduan yang menunjukkan bahwa proses pemasangan belum memperoleh tindak lanjut setelah dilakukan survei. Oleh karena itu, sistem memberikan *complaint context penalty* sebesar -1. Selain itu, sistem juga menemukan frasa “tidak ada kelanjutan” yang terdapat pada kamus frasa dengan nilai sentimen -1.

Perhitungan sentimen pada klausa tersebut adalah:

$$score = sentiment(pemasangan) + sentiment(tidak ada kelanjutan) + sentiment(survey) + complain penalty$$

$$score = 0 + (-1) + 0 + (-1)$$

$$score = -2$$

Dengan demikian, klausa tersebut dikategorikan sebagai sentimen negatif.

Berdasarkan contoh tersebut, dapat dilihat bahwa aturan ke-10 digunakan untuk memperkuat identifikasi komentar yang mengandung keluhan pelanggan. Aturan ini tidak menggantikan aturan sentimen yang lain, melainkan memberikan tambahan penalti ketika sistem menemukan konteks pengaduan yang berkaitan dengan permasalahan layanan. Oleh

karena itu, komentar yang menunjukkan adanya keluhan atau permintaan tindak lanjut dapat direpresentasikan dengan lebih baik dalam proses analisis sentimen, sehingga hasil klasifikasi menjadi lebih sesuai dengan maksud yang disampaikan oleh pelanggan.

4.6.7 Evaluasi Sentiment Analysis

Evaluasi dilakukan untuk mengukur kinerja metode *sentiment analysis* menggunakan *rule based* dalam mengklasifikasikan sentimen komentar ke dalam tiga kategori, yaitu negatif, netral, dan positif. Pengukuran dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Selain itu, evaluasi juga dilakukan menggunakan *confusion matrix* untuk melihat distribusi prediksi yang dihasilkan oleh sistem.

Berdasarkan hasil pengujian, jumlah data yang digunakan dalam proses evaluasi sebanyak 20.363 data. Dari jumlah tersebut, sistem berhasil melakukan prediksi dengan benar pada 16.817 data, sedangkan sebanyak 3.546 data mengalami kesalahan klasifikasi. Hasil evaluasi menunjukkan bahwa metode *rule based* yang digunakan memperoleh nilai akurasi sebesar 82,59% dengan *error rate* sebesar 17,41%. Selain itu, diperoleh nilai *F1-score* keseluruhan sebesar 0,8269. Hasil tersebut menunjukkan bahwa aturan yang dirancang mampu mengklasifikasikan sentimen komentar dengan tingkat performa yang cukup baik.

Tabel 4. 20. Distribusi Data Aktual dan Prediksi dari Tiap Sentimen

Sentimen	Jumlah Aktual	Jumlah Prediksi
Negatif (-1)	11.128	10.176
Netral (0)	6.568	6.910
Positif (1)	2.667	3.227

Pada Tabel 4.20 menunjukkan bahwa sentimen negatif merupakan sentimen yang paling dominan dengan jumlah 11.128 data, diikuti kelas netral sebanyak 6.568 data dan kelas positif sebanyak 2.667 data. Sementara itu, distribusi hasil prediksi menunjukkan bahwa sistem menghasilkan 10.176 prediksi negatif, 6.910 prediksi netral, dan 3.277 prediksi positif. Distribusi tersebut menunjukkan bahwa sistem masih mampu mengikuti pola distribusi data aktual meskipun terdapat beberapa perbedaan jumlah pada masing-masing sentimen.


Tabel 4. 20. Distribusi Data Aktual dan Prediksi dari Tiap Sentimen

Sentiment	<i>Precision</i>	<i>Recall</i>	<i>F1 Score</i>
Negatif (-1)	0.8901	0.814	0.8504
Netral (0)	0.7745	0.8149	0.7942
Positif (1)	0.7345	0.9025	0.8099

Berdasarkan Tabel 4.20 menunjukkan bahwa sentimen negatif memperoleh nilai *precision* sebesar 0,8901, *recall* sebesar 0,8140, dan *F1-score* sebesar 0,8504. Nilai tersebut menunjukkan bahwa sebagian besar komentar yang diprediksi sebagai negatif memang benar merupakan komentar negatif. Namun demikian, masih terdapat beberapa komentar negatif yang diprediksi sebagai netral maupun positif.

Pada sentimen netral diperoleh nilai *precision* sebesar 0,7745, *recall* sebesar 0,8149, dan *F1-score* sebesar 0,7942. Hasil ini menunjukkan bahwa sistem cukup baik dalam mengenali komentar yang bersifat informatif atau tidak mengandung sentimen yang jelas. Akan tetapi, sebagian komentar netral masih terklasifikasi sebagai negatif karena mengandung kata-kata yang memiliki kecenderungan sentimen tertentu.

Sementara itu, sentimen positif memperoleh nilai *precision* sebesar 0,7345, *recall* sebesar 0,9025, dan *F1-score* sebesar 0,8099. Nilai *recall* yang tinggi menunjukkan bahwa sebagian besar komentar positif berhasil dikenali oleh sistem. Namun, nilai *precision* yang lebih rendah dibandingkan sentimen negatif menunjukkan bahwa masih terdapat komentar negatif maupun netral yang diprediksi sebagai positif.



Gambar 4. 5. *Confussion Matrix Sentiment Analysis Menggunakan Rule Based*

Untuk memperoleh gambaran yang lebih rinci mengenai hasil klasifikasi, digunakan *confusion matrix* seperti yang ditunjukkan pada Gambar 4.5. Berdasarkan *confusion matrix*, sebanyak 9.058 komentar negatif berhasil diklasifikasikan dengan benar sebagai negatif. Namun, terdapat 1.464 komentar negatif yang diprediksi sebagai netral dan 606 komentar negatif yang diprediksi sebagai positif. Hal ini menunjukkan bahwa beberapa komentar negatif memiliki karakteristik yang menyerupai komentar netral atau positif sehingga sulit dibedakan oleh sistem.

Pada kelas netral, sebanyak 5.352 komentar berhasil diklasifikasikan dengan benar sebagai netral. Sementara itu, 952 komentar netral diprediksi sebagai negatif dan 264 komentar netral diprediksi sebagai positif. Kesalahan klasifikasi pada kelas netral umumnya terjadi karena komentar mengandung kata-kata yang memiliki nilai sentimen tertentu meskipun secara keseluruhan komentar tersebut tidak menunjukkan opini yang jelas.

Kelas positif menunjukkan hasil yang cukup baik dengan 2.407 komentar berhasil diprediksi dengan benar sebagai positif. Selain itu, hanya terdapat 166 komentar positif yang diprediksi sebagai negatif dan 94 komentar positif yang diprediksi sebagai netral. Jumlah kesalahan yang relatif kecil ini sejalan dengan nilai *recall* kelas positif yang mencapai 90,25%, sehingga menunjukkan bahwa sistem mampu mengenali sebagian besar komentar positif dengan baik.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa metode *sentiment analysis* menggunakan *rule based* yang dikembangkan mampu memberikan performa klasifikasi yang baik dengan akurasi sebesar 82,59% dan *F1-score* sebesar 0,8269. Penambahan aturan seperti Frasa Negatif Kuat, Komentar Berbentuk Pertanyaan, dan *Complaint Context Penalty* membantu sistem dalam mengenali karakteristik komentar pengaduan pelanggan secara lebih tepat. Meskipun demikian, masih terdapat sejumlah kesalahan klasifikasi terutama pada komentar yang memiliki karakteristik campuran antara sentimen negatif dan netral, sehingga menjadi tantangan dalam proses *sentiment analysis* menggunakan *rule based*.

4.6.8 Dashboard

Hasil implementasi sistem *aspect based sentiment analysis* pada penelitian ini disajikan melalui sebuah dashboard berbasis web yang dikembangkan menggunakan framework Streamlit. Dashboard ini berfungsi sebagai media visualisasi dan monitoring hasil analisis komentar pelanggan PDAM Surya Sembada sehingga pengguna dapat melihat ringkasan hasil analisis, distribusi aspek dan sentimen, tren komentar berdasarkan periode tertentu, detail data

komentar, serta melakukan pengujian data baru secara lebih mudah dan terstruktur. Dashboard yang dikembangkan menggunakan tiga sumber data, yaitu *Trial – Train Data*, *Trial – Test Data*, dan *User Data*. *Trial – Train Data* merupakan data yang digunakan pada proses pelatihan model klasifikasi aspek, sedangkan *Trial – Test Data* merupakan data yang digunakan pada proses pengujian model klasifikasi aspek. Kedua data tersebut juga digunakan dalam proses pengujian model *sentiment analysis* selama tahap pengembangan sistem. Sementara itu, *User Data* merupakan data komentar yang diinputkan langsung oleh pengguna melalui *dashboard*. Setiap komentar yang dimasukkan akan diproses secara otomatis oleh sistem melalui tahapan segmentasi, klasifikasi aspek, dan klasifikasi sentimen, kemudian hasilnya disimpan dan ditampilkan pada dashboard. Dashboard ini terdiri dari beberapa halaman utama, yaitu *Login Page*, *Overview Page*, *Analisis Aspek*, *Sentiments & Aspects Trends*, *Tabel Data Komentar*, dan *Input Data*, yang masing-masing memiliki fungsi sesuai dengan kebutuhan pengguna dalam mengakses hasil analisis yang dihasilkan oleh sistem.

A. Halaman Login




Gambar 4. 6. Tampilan Halaman Login *Dashboard*

Halaman Login merupakan halaman awal yang ditampilkan saat pengguna mengakses dashboard ABSA Insight. Halaman ini berfungsi sebagai mekanisme autentikasi untuk memastikan bahwa hanya pengguna yang memiliki hak akses yang dapat menggunakan fitur-fitur pada dashboard. Pada halaman ini tersedia kolom *Username* dan *Password* serta tombol Login untuk melakukan verifikasi akun. Apabila data yang dimasukkan sesuai, pengguna akan diarahkan ke halaman utama dashboard. Tampilan halaman login dapat dilihat pada Gambar

4.6, yang menampilkan logo aplikasi, nama sistem, serta formulir login dengan desain yang sederhana dan mudah digunakan.

B. Halaman Overview (Landing Page)



Gambar 4. 7. Tampilan Halaman *Overview (Landing Page) Dashboard*

Pada Gambar 4.7 adalah tampilan halaman Overview. Halaman ini merupakan halaman utama yang ditampilkan setelah pengguna berhasil melakukan login ke dalam sistem. Halaman ini berfungsi untuk menyajikan ringkasan hasil *aspect based sentiment analysis* secara cepat dan komprehensif sehingga pengguna dapat memperoleh gambaran umum mengenai kondisi layanan PDAM Surya Sembada berdasarkan komentar pelanggan.


Pada halaman ini ditampilkan beberapa informasi utama, seperti jumlah total komentar yang dianalisis, distribusi sentimen positif, netral, dan negatif, serta aspek layanan yang paling sering dibahas oleh pelanggan (*top aspect*). Selain itu, halaman ini juga menampilkan visualisasi distribusi sentimen dalam bentuk diagram lingkaran, daftar aspek layanan yang paling banyak muncul, serta grafik distribusi aspek yang menunjukkan jumlah komentar pada masing-masing kategori aspek.

Pengguna dapat memilih sumber data yang ingin ditampilkan melalui fitur Sumber Data yang tersedia pada bagian atas halaman. Terdapat tiga pilihan sumber data, yaitu *Trial – Train Data*, *Trial – Test Data*, dan *User Data*. *Trial – Train Data* digunakan untuk menampilkan hasil analisis pada data pelatihan model klasifikasi aspek, *Trial – Test Data* digunakan untuk menampilkan hasil analisis pada data pengujian model, sedangkan *User Data* digunakan untuk menampilkan hasil analisis dari komentar yang diinputkan langsung oleh pengguna melalui


dashboard. Dengan adanya fitur ini, pengguna dapat berpindah antar sumber data dan membandingkan hasil analisis yang dihasilkan oleh sistem secara lebih mudah.

Melalui berbagai ringkasan dan visualisasi yang disediakan, halaman *Overview* berfungsi sebagai pusat informasi utama yang membantu pengguna memahami kondisi umum distribusi aspek dan sentimen sebelum melakukan analisis yang lebih rinci pada halaman dashboard lainnya.


C. Halaman Analisis Aspek




Gambar 4. 8. Tampilan Halaman Analisis Aspek 1 *Dashbaord*



Gambar 4. 9. Tampilan Halaman Analisis Aspek 2 *Dashbaord*



Gambar 4. 10. Tampilan Halaman Analisis Aspek 3 *Dashbaord*



Gambar 4. 11. Tampilan Halaman Analisis Aspek 4 *Dashbaord*

Halaman Analisis Aspek digunakan untuk menampilkan hasil analisis secara lebih rinci pada setiap kategori aspek yang berhasil diidentifikasi oleh sistem. Pada halaman ini, pengguna dapat memilih sumber data yang ingin dianalisis melalui fitur Sumber Data yang tersedia pada bagian atas halaman, yaitu *Trial – Train Data*, *Trial – Test Data*, atau *User Data*. Setelah sumber data dipilih, seluruh visualisasi dan informasi yang ditampilkan akan disesuaikan dengan data yang dipilih oleh pengguna.

Tampilan halaman Analisis Aspek dapat dilihat pada Gambar 4.8, Gambar 4.9, Gambar 4.10, Gambar 4.11. Pada bagian atas halaman ditampilkan visualisasi distribusi aspek dalam bentuk


diagram lingkaran yang menunjukkan proporsi kemunculan masing-masing aspek pada data yang dipilih. Selain itu, ditampilkan pula persentase kemunculan setiap aspek sehingga pengguna dapat dengan mudah mengetahui aspek yang paling banyak dibahas oleh pelanggan.

Pada bagian Analisis Per Aspek, sistem menampilkan ringkasan informasi untuk setiap aspek yang berhasil diidentifikasi. Informasi yang ditampilkan meliputi jumlah kemunculan (*mentions*), kategori sentimen dominan (*most sentiment*), rata-rata skor sentimen (*average sentiment score*), serta jumlah data positif, netral, dan negatif pada masing-masing aspek. Informasi tersebut disajikan dalam bentuk kartu (*card*) sehingga memudahkan pengguna dalam membandingkan performa sentimen antar aspek layanan.


Selain visualisasi per aspek, halaman ini juga menyediakan bagian Matriks Analisis Mendalam yang menampilkan ringkasan statistik seluruh aspek dalam bentuk tabel. Tabel tersebut berisi nama aspek, frekuensi kemunculan, sentimen dominan, dan rata-rata skor sentimen untuk setiap aspek. Melalui tabel ini, pengguna dapat memperoleh informasi secara lebih terstruktur dan melakukan perbandingan antar aspek dengan lebih mudah.

Dengan adanya halaman Analisis Aspek, pengguna tidak hanya dapat mengetahui aspek yang paling sering muncul dalam komentar pelanggan, tetapi juga dapat memahami kecenderungan sentimen pada setiap aspek layanan secara lebih rinci sehingga dapat digunakan sebagai bahan evaluasi dan pengambilan keputusan.

D. Halaman Sentiments & Aspects Trends



Gambar 4. 12. Tampilan Halaman *Sentiments & Aspects Trends* 1 Dashbaord



Gambar 4. 13. Tampilan Halaman *Sentiments & Aspects Trends 2 Dashbaord*



Gambar 4. 14. Tampilan Halaman *Sentiments & Aspects Trends 3 Dashbaord*

Halaman *Sentiments & Aspects Trends* digunakan untuk menampilkan perkembangan sentimen dan aspek layanan berdasarkan periode waktu tertentu. Berbeda dengan halaman sebelumnya, halaman ini hanya menampilkan data yang berasal dari User Data, sehingga visualisasi yang ditampilkan merepresentasikan hasil analisis dari komentar yang diinputkan langsung oleh pengguna melalui dashboard. Tampilan halaman *Sentiments & Aspects Trends* dapat dilihat pada Gambar 4.12, Gambar 4.13, Gambar 4.14.

Pada halaman ini, pengguna dapat memilih mode visualisasi tren berdasarkan bulan atau tahun. Apabila mode Per Bulan dipilih, pengguna dapat menentukan bulan yang ingin ditampilkan sehingga sistem akan menampilkan tren sentimen dan aspek pada periode bulan tersebut. Sementara itu, apabila mode Per Tahun dipilih, pengguna dapat menentukan tahun yang ingin dianalisis sehingga sistem akan menampilkan tren berdasarkan keseluruhan data pada tahun yang dipilih.


Pada bagian atas halaman ditampilkan ringkasan jumlah ulasan beserta persentase sentimen positif, netral, dan negatif pada periode yang dipilih. Selanjutnya, grafik Tren Persebaran Sentimen digunakan untuk menunjukkan perubahan jumlah komentar positif, netral, dan negatif sepanjang periode waktu yang dianalisis. Grafik ini membantu pengguna dalam mengidentifikasi peningkatan atau penurunan sentimen pelanggan dari waktu ke waktu.

Selain itu, halaman ini juga menampilkan grafik Tren Persebaran Aspek yang menggambarkan perubahan jumlah kemunculan setiap aspek layanan pada periode yang dipilih. Melalui grafik tersebut, pengguna dapat mengetahui aspek yang paling sering dibahas pelanggan serta melihat perubahan pola kemunculannya dari waktu ke waktu.

Pada bagian bawah halaman ditampilkan beberapa visualisasi tambahan, yaitu Distribusi Aspek, Sentimen per Aspek, Tren Aspek Mingguan, dan *Heatmap* Sentimen Negatif. Distribusi Aspek menunjukkan jumlah kemunculan masing-masing aspek, sedangkan Sentimen per Aspek menampilkan komposisi sentimen positif, netral, dan negatif pada setiap aspek. Selanjutnya, Tren Aspek Mingguan digunakan untuk membandingkan volume kemunculan aspek antara minggu berjalan dan minggu sebelumnya. Adapun *Heatmap* Sentimen Negatif digunakan untuk menampilkan intensitas komentar negatif berdasarkan hari dan periode waktu tertentu sehingga pengguna dapat mengidentifikasi waktu-waktu yang memiliki tingkat keluhan pelanggan yang tinggi.

Dengan adanya halaman *Sentiments & Aspects Trends*, pengguna dapat memantau perubahan sentimen dan aspek layanan secara berkala, sehingga pola keluhan maupun perubahan persepsi pelanggan terhadap layanan PDAM Surya Sembada dapat dianalisis dengan lebih mudah dan informatif.

E. Halaman Tabel Data Komentar



ABSA Insight

Tabel Data Komentar Lengkap

Sumber data: Trial - Test Data | Export CSV

TOTAL DATA: 2,264 | TOTAL DATA TERSEGMENTASI: 2,264 | TOTAL DATA TIDAK TERSEGMENTASI: 0


Masukkan keyword... | Semua Aspek | Semua Sentimen

Previous | 1 | Go | Page 1 of 510 | Next

Menampilkan 1-10 dari 5,092 entri

ID	KOMENTAR LENGKAP	TEKS TERSEGEM	ASPEK	SENTIMEN
#0001	Pemasangan baru tidak ada kelanjutan setelah survey. Padahal katanya bisa komplain cs lewat wa.sedan...	Pemasangan baru tidak ada kelanjutan setelah survei...	Pemasangan	Negatif
#0001	Pemasangan baru tidak ada kelanjutan setelah survey. Padahal katanya bisa komplain cs lewat wa.sedan...	Pemasangan baru tidak ada kelanjutan setelah survei...	Pelayanan	Negatif

Gambar 4. 15. Tampilan Halaman Tabel Data Komentar 1 *Dashbaord*



ABSA Insight

Detail Komentar ID: #0001

KOMENTAR ASLI

"Pemasangan baru tidak ada kelanjutan setelah survey. Padahal katanya bisa komplain cs lewat wa.sedangkan di wa gak ada tanggapan...."

SEGMENTASI ASPECT-BASED ANALYSIS

Segment	ASPEK	SENTIMEN
Segment 1 "pemasangan baru tidak ada kelanjutan survey."	Pemasangan	Negatif
Segment 2 "padahal katanya komplain pelayanan pelanggan whatsapp."	Pelayanan	Negatif
Segment 3 "sedangkan whatsapp tidak ada tanggapan."	Pelayanan	Negatif

Gambar 4. 16. Tampilan Halaman Tabel Data Komentar 2 *Dashbaord*



Gambar 4. 17. Tampilan Halaman Tabel Data Komentar 3 *Dashbaord*

Halaman Tabel Data Komentar digunakan untuk menampilkan seluruh data komentar beserta hasil proses *aspect based sentiment analysis* yang telah dilakukan oleh sistem. Tampilan halaman ini dapat dilihat pada Gambar 4.15, Gambar 4.16, Gambar 4.17. Pada halaman ini, pengguna dapat memilih sumber data yang ingin ditampilkan melalui fitur Sumber Data, yaitu *Trial – Train Data*, *Trial – Test Data*, atau *User Data*. Selain itu, pengguna juga dapat mengeksport data yang sedang ditampilkan ke dalam format CSV melalui tombol *Export CSV*.

Untuk memudahkan proses penelusuran data, halaman ini menyediakan fitur *Search by Keyword*, Filter Aspek, dan Filter Sentimen. Fitur pencarian memungkinkan pengguna mencari komentar berdasarkan kata kunci tertentu, sedangkan filter aspek dan sentimen digunakan untuk menampilkan data sesuai kategori aspek maupun kategori sentimen yang dipilih. Ketiga fitur tersebut dapat digunakan pada seluruh sumber data yang tersedia.

Pada bagian utama halaman ditampilkan tabel yang berisi informasi hasil analisis, seperti komentar lengkap, teks hasil segmentasi, aspek yang teridentifikasi, serta hasil klasifikasi sentimen. Selain itu, sistem juga menyediakan fitur navigasi halaman (*pagination*) sehingga pengguna dapat berpindah antar halaman data dengan lebih mudah ketika jumlah data yang ditampilkan cukup banyak.

Khusus pada saat pengguna memilih *User Data*, sistem akan menampilkan fitur tambahan berupa filter rentang tanggal yang dapat digunakan untuk menyaring data berdasarkan periode waktu tertentu. Dengan fitur ini, pengguna dapat menampilkan komentar yang diinputkan pada rentang tanggal yang sesuai dengan kebutuhan analisis.

Selain itu, pada User Data tersedia fitur *expand* detail komentar yang dapat diakses melalui tombol *View* pada setiap baris data. Ketika fitur ini dibuka, sistem akan menampilkan informasi tambahan yang terdiri dari *Post URL*, *Tanggal Posting*, *Username*, dan *Tanggal Input*. Selanjutnya, sistem juga menampilkan komentar asli beserta hasil segmentasi yang dihasilkan oleh proses *aspect based sentiment analysis*. Setiap segmen ditampilkan bersama hasil prediksi aspek dan hasil prediksi sentimennya, sehingga pengguna dapat melihat secara rinci bagaimana sistem melakukan analisis terhadap komentar yang dipilih.

Pada bagian bawah halaman juga ditampilkan visualisasi Sentimen per Aspek yang menunjukkan komposisi sentimen positif, netral, dan negatif pada setiap aspek layanan berdasarkan data yang sedang ditampilkan. Visualisasi ini membantu pengguna memperoleh gambaran umum mengenai distribusi sentimen pada masing-masing aspek tanpa harus melakukan pemeriksaan data secara satu per satu.

Dengan adanya halaman Tabel Data Komentar, pengguna dapat melakukan penelusuran, penyaringan, serta pemeriksaan hasil analisis secara lebih rinci sehingga proses validasi dan interpretasi hasil *aspect based sentiment analysis* dapat dilakukan dengan lebih mudah.

F. Halaman Input Data

ABSA Insight

Input Data

Populate your dashboard with new insights. Upload CSV untuk menyimpan hasil ke database, atau uji satu komentar secara manual tanpa menyimpan data.

CSV Dataset Upload

Upload File CSV

200KB per file • CSV

Download Sample CSV

Data Requirements

CSV wajib memiliki kolom berikut:

postId
comment_text
ownerUsername
date
month

Process CSV

Manual Entry

Manual entry berfungsi untuk testing satu komentar tanpa menyimpan hasil ke database. Hasil analisis akan ditampilkan di bawah setelah tombol ditekan.

Tulis komentar yang ingin diuji di sini...

Analyze Submission

Input History

tanggal_input	total_data	total_segmented_data	total_not_segmented_data	total_padam_comment_drop
2026-06-09 08:53:19		1671	160	1161
				2

Gambar 4. 18. Tampilan Halaman *Input Data Dashbaord*

Halaman *Input Data* digunakan sebagai media untuk memasukkan data baru ke dalam sistem sekaligus melakukan pengujian model yang telah dibangun. Tampilan halaman Input Data dapat dilihat pada Gambar 4.18. Pada halaman ini tersedia dua metode *input data*, yaitu

melalui unggahan berkas CSV (*CSV Dataset Upload*) dan melalui pengujian komentar secara manual (*Manual Entry*).

Pada fitur *CSV Dataset Upload*, pengguna dapat mengunggah data komentar dalam format CSV untuk diproses oleh sistem. Agar dapat diproses dengan benar, file yang diunggah harus mengikuti struktur kolom yang telah ditentukan oleh sistem. Untuk membantu pengguna memahami format data yang diperlukan, sistem menyediakan fitur *Download Sample CSV* yang berisi contoh dataset beserta struktur kolom yang harus digunakan. Apabila file yang diunggah tidak sesuai dengan format atau kolom yang dipersyaratkan, maka sistem akan menampilkan pesan *error* dan proses analisis tidak akan dilanjutkan.

Setelah data berhasil diunggah, sistem akan menjalankan seluruh tahapan pengolahan data secara otomatis yang meliputi *preprocessing*, segmentasi teks, *data split*, pembobotan menggunakan TF-IDF, klasifikasi aspek menggunakan metode *Cosine Similarity*, serta klasifikasi sentimen menggunakan metode *Rule Based*. Hasil akhir dari proses tersebut berupa prediksi aspek dan prediksi sentimen untuk setiap segmen komentar yang berhasil dianalisis. Selanjutnya, data komentar yang diunggah beserta hasil prediksinya akan disimpan ke dalam database sehingga dapat ditampilkan dan dianalisis lebih lanjut melalui halaman *dashboard* lainnya.

comment_id	segmented_text	predicted_aspect	final_sentiment_label
1	air mati	Air Tidak Mengalir	Negatif
1	bayar mahal	Harga	Negatif

Gambar 4. 19. Tampilan Halaman *Input Data* Contoh Hasil Manual Entry

Selain unggahan CSV, halaman ini juga menyediakan fitur *Manual Entry* yang digunakan untuk melakukan pengujian terhadap satu komentar secara langsung. Pengguna cukup memasukkan sebuah komentar pada kolom yang tersedia kemudian menekan tombol *Analyze*

Submission. Sistem akan memproses komentar tersebut menggunakan tahapan yang sama seperti pada proses analisis data utama, kemudian menampilkan hasil segmentasi, prediksi aspek, dan prediksi sentimen untuk setiap segmen komentar. Contoh hasil pengujian menggunakan fitur *Manual Entry* dapat dilihat pada Gambar 4.12.

Berbeda dengan proses unggahan CSV, hasil analisis yang diperoleh melalui fitur *Manual Entry* tidak akan disimpan ke dalam *database*. Fitur ini disediakan sebagai sarana pengujian model secara cepat sehingga pengguna dapat mengetahui hasil klasifikasi aspek dan sentimen dari suatu komentar tanpa harus menambahkan data tersebut ke dalam sistem. Dengan demikian, halaman Input Data berfungsi sebagai sarana untuk menambahkan data baru sekaligus melakukan validasi dan pengujian hasil analisis yang dihasilkan oleh model.

4.7 ANALISIS HASIL EKSPERIMEN[DR7]

Analisis hasil eksperimen dilakukan untuk mengkaji lebih lanjut performa metode yang diusulkan dalam penelitian ini berdasarkan hasil evaluasi yang telah diperoleh pada tahap pengujian. Evaluasi yang telah dilakukan menunjukkan bahwa metode *aspect based classification* menggunakan TF-IDF dan *Cosine Similarity* serta metode *sentiment analysis* menggunakan *rule based* mampu menghasilkan performa yang baik dalam mengidentifikasi aspek dan sentimen pada komentar pelanggan PDAM Surya Sembada. Oleh karena itu, pada subbab ini dilakukan analisis yang lebih mendalam terhadap hasil evaluasi tersebut untuk mengetahui faktor-faktor yang memengaruhi kinerja model, kelebihan dan keterbatasan metode yang digunakan, serta sejauh mana solusi yang diusulkan mampu menyelesaikan permasalahan identifikasi aspek dan klasifikasi sentimen pada komentar pelanggan. Analisis dibagi menjadi dua bagian utama, yaitu analisis hasil *aspect based classification* dan analisis hasil *sentiment analysis*.

4.7.1 Aspect Based Menggunakan Cosine Similarity

Analisis *aspect based classification* dilakukan untuk mengetahui efektivitas metode TF-IDF dan *Cosine Similarity* dalam mengidentifikasi aspek pada komentar pelanggan PDAM Surya Sembada. Berdasarkan hasil evaluasi yang telah dijelaskan pada Subbab 4.6.5, percobaan terbaik pada kedua skenario diperoleh menggunakan parameter *ngram* (1,3), *Primary Threshold* sebesar 0,60, dan *Lainnya Threshold* sebesar 0,18. Oleh karena itu, analisis pada

subsubbab ini difokuskan pada hasil terbaik dari masing-masing skenario untuk memahami pengaruh perbedaan skenario pengujian terhadap performa klasifikasi aspek.

Perbedaan utama antara kedua skenario terletak pada penggunaan data uji (*test data*). Pada Skenario 1, data uji hanya terdiri atas komentar yang telah melalui proses segmentasi sehingga setiap segmen diuji secara terpisah dan tidak memiliki kemungkinan untuk dibandingkan dengan dirinya sendiri pada data latih. Sementara itu, pada Skenario 2, data uji menggunakan 100% data yang terdiri atas gabungan komentar tersegmentasi dan tidak tersegmentasi. Kondisi ini menyebabkan sebagian data uji memiliki kemungkinan kemiripan yang sangat tinggi dengan data latih karena berasal dari sumber data yang sama. Oleh karena itu, Skenario 2 digunakan untuk menganalisis apakah keberadaan data yang memiliki kemiripan tinggi dengan data latih dapat memengaruhi performa klasifikasi aspek yang dihasilkan oleh metode *Cosine Similarity*.

Melalui analisis kedua skenario tersebut, dapat diketahui bagaimana pengaruh karakteristik data uji terhadap kemampuan model dalam mengenali aspek layanan, sekaligus memberikan gambaran mengenai kondisi pengujian yang lebih mendekati implementasi nyata maupun kondisi pengujian yang lebih terkontrol. Dengan demikian, hasil analisis ini dapat digunakan untuk menilai sejauh mana metode yang diusulkan mampu melakukan klasifikasi aspek secara akurat pada berbagai kondisi data komentar pelanggan.

A. Skenario 1 (Data Train: Data Tidak Tersegmentasi | Data Test: Data Tersegmentasi)

Berdasarkan hasil evaluasi, performa terbaik pada Skenario 1 diperoleh menggunakan parameter *ngram* (1,3), *Primary Threshold* sebesar 0,60, dan *Lainnya Threshold* sebesar 0,18 dengan akurasi 74,31% dan rata-rata *F1-score* 0,7052. Hasil ini menunjukkan bahwa metode TF-IDF dan *Cosine Similarity* mampu melakukan klasifikasi aspek dengan cukup baik meskipun data uji yang digunakan seluruhnya berupa hasil segmentasi komentar.

Karakteristik utama pada skenario ini adalah data uji hanya terdiri dari komentar yang telah tersegmentasi. Akibatnya, setiap data yang diuji memiliki konteks yang lebih pendek dibandingkan komentar asli. Kondisi tersebut membuat proses klasifikasi menjadi lebih sulit karena sistem harus menentukan aspek hanya berdasarkan sebagian informasi yang terdapat pada komentar. Oleh karena itu, hasil yang diperoleh pada skenario ini dapat dianggap lebih merepresentasikan kemampuan model dalam mengenali aspek pada tingkat segmen.

Penggunaan ngram (1,3) menghasilkan performa yang lebih baik dibandingkan *ngram* (1,2) karena mampu mempertahankan konteks frasa hingga tiga kata. Pada domain layanan PDAM, banyak aspek yang direpresentasikan oleh frasa tertentu, seperti "air tidak mengalir", "air kotor bau", atau "meteran tidak jalan". Keberadaan trigram membantu sistem menangkap makna frasa secara lebih utuh sehingga perhitungan kemiripan menggunakan *Cosine Similarity* menjadi lebih akurat.

Berdasarkan evaluasi per aspek, aspek Air Tidak Mengalir memperoleh performa yang tinggi karena memiliki pola kata yang spesifik dan konsisten. Sebaliknya, aspek Pemakaian memperoleh nilai *F1-score* terendah karena kosakata yang digunakan sering memiliki kemiripan dengan aspek lain, seperti Harga atau Pelayanan, sehingga lebih sulit dibedakan oleh sistem. Selain itu, *confusion matrix* menunjukkan bahwa sebagian besar kesalahan klasifikasi mengarah ke aspek Lainnya, yang mengindikasikan bahwa masih terdapat segmen komentar yang terlalu umum atau tidak memiliki kata kunci yang cukup kuat untuk dikaitkan dengan aspek tertentu.

Secara keseluruhan, hasil pada Skenario 1 menunjukkan bahwa metode yang diusulkan mampu melakukan klasifikasi aspek dengan cukup baik pada data hasil segmentasi. Meskipun konteks komentar menjadi lebih pendek setelah proses segmentasi, sistem tetap dapat mengenali sebagian besar aspek layanan dengan tingkat akurasi yang cukup memadai.

B. Skenario 2 (Data Train: Data Tidak Tersegmentasi | Data Test: 100% Data)

Berdasarkan hasil evaluasi, performa terbaik pada Skenario 2 diperoleh menggunakan parameter *ngram* (1,3) dengan akurasi sebesar 93,31% dan rata-rata *F1-score* sebesar 0,8841. Hasil ini lebih tinggi dibandingkan Skenario 1 yang memperoleh akurasi 74,31% dan rata-rata *F1-score* 0,7052. Peningkatan performa tersebut menunjukkan bahwa metode TF-IDF dan *Cosine Similarity* mampu bekerja lebih baik ketika data uji memiliki distribusi yang lebih dekat dengan data latih.

Salah satu faktor yang memengaruhi peningkatan performa tersebut adalah adanya data uji yang juga terdapat pada data latih. Kondisi ini menyebabkan beberapa komentar memiliki tingkat kemiripan yang sangat tinggi terhadap data latih sehingga aspek yang sesuai lebih mudah ditemukan oleh sistem. Namun demikian, hasil evaluasi menunjukkan bahwa masih

terdapat beberapa data yang mengalami kesalahan klasifikasi meskipun dibandingkan dengan data yang sama pada data latih.

Salah satu contohnya adalah komentar:

“dukuh kupang raya belum alir admin”

Komentar tersebut memiliki label sebenarnya Air Tidak Mengalir, tetapi diprediksi sebagai Lainnya dengan nilai *similarity score* sebesar 1,0. Menariknya, komentar yang sama juga terdapat pada data latih dengan label Air Tidak Mengalir. Secara teoritis, kondisi ini seharusnya menghasilkan prediksi yang benar karena data uji dibandingkan dengan data yang identik pada data latih.

Meskipun demikian, kesalahan prediksi tetap dapat terjadi karena proses klasifikasi tidak hanya dipengaruhi oleh tingkat kemiripan dokumen, tetapi juga oleh distribusi kata yang digunakan untuk merepresentasikan aspek. Pada komentar tersebut, sebagian besar kata yang muncul merupakan informasi lokasi seperti *dukuh*, *kupang*, dan *raya*, sedangkan kata yang secara langsung merepresentasikan aspek hanya terdapat pada frasa *belum mengalir*. Akibatnya, representasi TF-IDF yang terbentuk lebih banyak dipengaruhi oleh kata-kata umum yang tidak secara spesifik menggambarkan aspek layanan. Kondisi ini menyebabkan sistem tidak mampu membedakan komentar tersebut secara optimal dan akhirnya mengarahkannya ke aspek Lainnya.

Kasus tersebut menunjukkan bahwa keberadaan data yang sama pada data latih tidak selalu menjamin prediksi yang benar. Metode *Cosine Similarity* tetap bergantung pada kualitas representasi teks yang dihasilkan oleh TF-IDF. Apabila suatu komentar didominasi oleh kata-kata yang kurang representatif terhadap aspek tertentu, maka kesalahan klasifikasi masih dapat terjadi meskipun komentar tersebut memiliki tingkat kemiripan yang sangat tinggi terhadap data latih.

Secara keseluruhan, hasil pada Skenario 2 menunjukkan bahwa metode yang diusulkan mampu melakukan klasifikasi aspek dengan sangat baik ketika data uji memiliki karakteristik yang dekat dengan data latih. Hal ini terlihat dari peningkatan akurasi dan *F1-score* yang cukup signifikan dibandingkan Skenario 1. Namun demikian, hasil analisis juga menunjukkan bahwa kualitas representasi kata dalam komentar tetap menjadi faktor penting yang memengaruhi keberhasilan klasifikasi aspek menggunakan TF-IDF dan *Cosine Similarity*.

4.7.2 Sentiment Analysis Menggunakan Rule Based

Berdasarkan hasil evaluasi yang telah dilakukan, metode *sentiment analysis* menggunakan *rule based* memperoleh akurasi sebesar 82,59% dengan rata-rata *F1-score* sebesar 0,8269. Hasil tersebut menunjukkan bahwa aturan yang dirancang mampu mengidentifikasi sentimen komentar pelanggan dengan cukup baik meskipun karakteristik komentar yang digunakan sangat beragam dan banyak mengandung bahasa informal. Performa yang diperoleh menunjukkan bahwa pendekatan berbasis aturan masih efektif digunakan pada domain komentar layanan pelanggan yang memiliki pola bahasa relatif konsisten.

Salah satu faktor yang berkontribusi terhadap hasil tersebut adalah penggunaan aturan berbasis *Part of Speech* yang memungkinkan sistem mengenali hubungan antar kata dalam suatu komentar. Aturan seperti Adjektiva Tunggal, Verba Tunggal, Preposisi + Adjektiva, Verba + Adjektiva, serta kombinasi aturan lainnya membantu sistem memahami sentimen yang terkandung dalam suatu kalimat secara lebih kontekstual dibandingkan pendekatan yang hanya mengandalkan kamus sentimen. Dengan demikian, sistem tidak hanya mempertimbangkan nilai sentimen suatu kata, tetapi juga hubungan antar kata yang membentuk makna komentar secara keseluruhan.

Selain mempertahankan aturan dari penelitian sebelumnya, penelitian ini juga menambahkan beberapa aturan baru, yaitu Frasa Negatif Kuat, Komentar Berbentuk Pertanyaan, dan *Complaint Context Penalty*. Penambahan aturan tersebut dilakukan karena karakteristik komentar pelanggan PDAM didominasi oleh keluhan layanan yang sering disampaikan dalam bentuk frasa tertentu maupun kalimat tanya. Melalui aturan Frasa Negatif Kuat, sistem dapat mengenali pola keluhan seperti “*air mati*”, “*air tidak keluar*”, atau “*meter rusak*” yang memiliki makna negatif yang lebih kuat dibandingkan kata-kata penyusunnya secara individual. Sementara itu, aturan Question Neutralization membantu sistem membedakan pertanyaan yang bersifat informatif dengan pertanyaan yang mengandung keluhan. Aturan Complaint Context Penalty juga membantu meningkatkan sensitivitas sistem terhadap komentar yang mengandung konteks pengaduan layanan meskipun tidak selalu memiliki kata-kata negatif secara eksplisit.

Berdasarkan hasil *confusion matrix*, sentimen negatif memiliki jumlah data terbesar dan sekaligus menjadi sentimen yang paling sering mengalami kesalahan klasifikasi. Sebagian komentar negatif diprediksi sebagai netral karena mengandung kalimat yang bersifat informatif atau tidak memiliki kata-kata sentimen yang cukup kuat. Selain itu, beberapa komentar negatif

juga diprediksi sebagai positif karena mengandung kombinasi kata positif dan negatif dalam satu komentar. Kondisi ini menunjukkan bahwa meskipun aturan yang digunakan telah mampu menangkap sebagian besar pola sentimen, masih terdapat komentar yang memiliki konteks ambigu sehingga sulit diklasifikasikan secara tepat.

Di sisi lain, sentimen positif memperoleh nilai *recall* yang tinggi. Hal ini menunjukkan bahwa sebagian besar komentar positif berhasil dikenali oleh sistem. Kondisi tersebut terjadi karena komentar positif pada umumnya menggunakan kata-kata apresiasi yang lebih eksplisit, seperti “*bagus*”, “*baik*”, atau “*terima kasih*”, sehingga lebih mudah dikenali oleh aturan yang digunakan. Sebaliknya, komentar negatif sering kali disampaikan dalam bentuk keluhan yang lebih beragam sehingga memiliki variasi pola yang lebih besar dibandingkan komentar positif.

Secara keseluruhan, hasil eksperimen menunjukkan bahwa pendekatan *rule based* yang dikembangkan mampu mengakomodasi karakteristik komentar pelanggan PDAM dengan cukup baik. Penambahan aturan baru yang disesuaikan dengan domain layanan pelanggan terbukti membantu sistem dalam mengenali sentimen secara lebih kontekstual. Meskipun masih terdapat beberapa kesalahan klasifikasi pada komentar yang ambigu atau memiliki sentimen campuran, hasil yang diperoleh menunjukkan bahwa metode yang diusulkan telah mampu menyelesaikan permasalahan klasifikasi sentimen dengan tingkat performa yang baik pada domain penelitian ini.

BAB 5[DR8]

PENUTUP

Bab ini merangkum proses pengembangan sistem yang meliputi pencapaian penelitian hingga saat ini, target yang masih dalam tahap pengerjaan, serta hambatan yang ditemui selama proses penelitian.

5.1 KESIMPULAN

Berdasarkan hasil perancangan, implementasi, pengujian, dan analisis yang telah dilakukan pada penelitian Sentimen Analisis Berbasis Aspek Pada Perumda Air Minum Surya Sembada Surabaya Menggunakan Komputasi Korelasi, dapat diperoleh beberapa kesimpulan sebagai berikut:

1. Penelitian ini berhasil mengembangkan sistem *Aspect Based Sentiment Analysis* (ABSA) yang mampu membantu PDAM Surya Sembada dalam menganalisis komentar pelanggan yang berasal dari media sosial Instagram. Sistem yang dibangun mampu mengatasi permasalahan pengelompokan keluhan pelanggan yang sebelumnya dilakukan secara manual dengan cara memetakan komentar ke dalam aspek-aspek layanan PDAM serta menentukan sentimen dari setiap komentar yang dianalisis.
2. Metode *Correlation Computing* menggunakan TF-IDF dan Cosine Similarity berhasil diterapkan untuk melakukan klasifikasi aspek pada komentar pelanggan. Berdasarkan hasil eksperimen yang dilakukan pada beberapa skenario pengujian, performa terbaik diperoleh pada penggunaan parameter *ngram* (1,3). Hasil tersebut menunjukkan bahwa pendekatan berbasis kemiripan teks mampu mengenali hubungan antara komentar pelanggan dengan aspek layanan yang relevan tanpa memerlukan proses pelatihan model machine learning yang kompleks.
3. Metode *Sentiment Analysis* berbasis *Rule Based* berhasil digunakan untuk mengidentifikasi sentimen positif, negatif, dan netral pada setiap segmen komentar pelanggan. Penggunaan kombinasi aturan berbasis *Part of Speech*, aturan frasa, Frasa Negatif Kuat, Kalimat Berbentuk Pertanyaan, dan *Complaint Context Penalty* mampu meningkatkan kemampuan sistem dalam mengenali pola bahasa yang umum digunakan pelanggan saat menyampaikan keluhan terhadap layanan PDAM.

4. Hasil evaluasi menunjukkan bahwa sistem yang dikembangkan mampu menghasilkan performa klasifikasi aspek dan sentimen yang baik. Pada klasifikasi aspek menggunakan *Cosine Similarity* diperoleh performa terbaik pada skenario pengujian dengan parameter ngram(1,3), sedangkan pada klasifikasi sentimen menggunakan *Rule Based* diperoleh akurasi sebesar 82,59% dengan rata-rata *F1-Score* sebesar 0,8269. Hasil tersebut menunjukkan bahwa metode yang digunakan cukup efektif untuk diterapkan pada data komentar pelanggan PDAM yang bersifat tidak terstruktur.
5. Seluruh proses analisis berhasil diintegrasikan ke dalam *dashboard* berbasis *web* menggunakan Streamlit dan SQLite. *Dashboard* yang dikembangkan mampu menampilkan hasil analisis aspek dan sentimen dalam bentuk visualisasi, tabel komentar, tren sentimen, serta fasilitas input data baru. Dengan adanya dashboard tersebut, pihak PDAM dapat melakukan monitoring terhadap keluhan pelanggan secara lebih cepat, terstruktur, dan berbasis data sehingga dapat membantu proses evaluasi serta peningkatan kualitas layanan.

5.2 SARAN

Meskipun sistem *Aspect Based Sentiment Analysis* yang dikembangkan pada penelitian ini telah mampu melakukan klasifikasi aspek dan analisis sentimen komentar pelanggan PDAM Surya Sembada dengan baik, masih terdapat beberapa keterbatasan yang dapat menjadi peluang pengembangan pada penelitian selanjutnya. Adapun saran yang dapat diberikan adalah sebagai berikut:

1. Pengembangan Metode Klasifikasi Aspek

Pada penelitian ini, klasifikasi aspek dilakukan menggunakan metode *Cosine Similarity* berbasis TF-IDF. Metode ini masih bergantung pada kemiripan kata yang terdapat pada data latih sehingga kurang optimal ketika menghadapi komentar yang menggunakan kosakata baru atau memiliki makna yang serupa tetapi dituliskan dengan kata yang berbeda. Penelitian selanjutnya dapat mengembangkan metode klasifikasi aspek menggunakan pendekatan berbasis *word embedding*, *transformer*, atau model bahasa seperti IndoBERT agar mampu memahami konteks kalimat secara lebih mendalam.

2. Pengembangan Metode Analisis Sentimen

Analisis sentimen pada penelitian ini menggunakan pendekatan *Rule Based* yang bergantung pada kamus sentimen dan aturan yang telah ditentukan sebelumnya. Meskipun mampu memberikan hasil yang cukup baik, metode ini masih memiliki keterbatasan dalam memahami kalimat yang kompleks, ironi, sarkasme, maupun penggunaan bahasa yang terus berkembang di media sosial. Oleh karena itu, penelitian selanjutnya dapat membandingkan atau mengombinasikan pendekatan *Rule Based* dengan metode *Machine Learning* maupun *Deep Learning* untuk meningkatkan performa klasifikasi sentimen.

3. Perluasan Sumber dan Jumlah Dataset

Dataset yang digunakan pada penelitian ini berasal dari komentar Instagram PDAM Surya Sembada. Untuk memperoleh hasil yang lebih representatif terhadap opini pelanggan, penelitian selanjutnya dapat menambahkan sumber data lain seperti aplikasi pengaduan pelanggan, website resmi PDAM, Facebook, X (Twitter), maupun platform media sosial lainnya. Penambahan jumlah data juga dapat membantu meningkatkan variasi komentar yang digunakan dalam proses analisis.

4. Pengembangan Dashboard Monitoring

Dashboard yang dikembangkan saat ini telah mampu menampilkan hasil analisis aspek dan sentimen serta menyediakan fitur pencarian dan penyaringan data. Pada pengembangan berikutnya, dashboard dapat ditambahkan fitur analisis yang lebih komprehensif seperti notifikasi aspek yang mengalami peningkatan keluhan, tren sentimen secara otomatis, serta laporan periodik yang dapat diunduh oleh pihak PDAM untuk mendukung proses evaluasi layanan.

5. Pengembangan Sistem Akuisisi Data Otomatis

Pada penelitian ini proses pengambilan data komentar masih dilakukan melalui proses scraping dan input data secara manual ke dalam sistem. Penelitian selanjutnya dapat mengembangkan mekanisme pengambilan data secara otomatis dan terjadwal sehingga data komentar terbaru dapat langsung diproses dan ditampilkan pada dashboard tanpa memerlukan intervensi pengguna. Dengan demikian, sistem dapat digunakan sebagai media *monitoring* layanan pelanggan secara lebih *real-time*.

DAFTAR PUSTAKA

1. Wu, J., Wang, Y. (2021). A Text Correlation Algorithm for Stock Market News Event Extraction. In: Zeng, J., Qin, P., Jing, W., Song, X., Lu, Z. (eds) Data Science. ICPCSEE 2021. Communications in Computer and Information Science, vol 1452. Springer, Singapore.
2. Chiny M., Chihab M., Bencharef O. and Chihab Y. Netflix Recommendation System based on TF-IDF and Cosine Similarity Algorithms. In *Proceedings of the 2nd International Conference on Big Data, Modelling and Machine Learning - Volume 1: BML*, ISBN 978-989-758-559-3, 2021.
3. Sahria Y. Implementasi Teknik Web Scraping Pada Jurnal SINTA Untuk Analisis Topik Penelitian Kesehatan Indonesia. University Research Colloquium. (pp 297–306), 2022.
4. A. Erkan and T. Güngör, "Analysis of Deep Learning Model Combinations and Tokenization Approaches in Sentiment Classification," *IEEE Access*, vol. 11, pp. 134951–134968, 2023.
5. Zong, C., Xia, R., Zhang, J.. Text Representation. In: Text Data Mining, 2021.
6. Suryatin. Aspect-based Sentiment Analysis pada Aplikasi Pelacakan Kasus Covid-19 (studi kasus: pedulilindungi.id) [Tesis, Universitas Islam Indonesia]. UII Repository, 2023.
7. Ni Putu Gita Naraswati, Rani Nooraeni, Delvira Cindy Rosmilda, Dinda Desinta, Fadhilatul Khairi, dan Riska Damaiyanti. Analisis Sentimen Publik dari Twitter Tentang Kebijakan Penanganan Covid-19 di Indonesia dengan Naive Bayes Classification. Sistemasi: Jurnal Sistem Informasi, Vol. 10, No. 1, hlm. 222-238, 2021. DOI: 10.32520/stmsi.v10i1.1179.
8. Lusiana Efrizoni, Sarjon Defit, Muhammad Tajuddin, dan Anthony Anggrawan. Komparasi Ekstraksi Fitur dalam Klasifikasi Teks Multilabel Menggunakan Algoritma Machine Learning. MATRIK: Jurnal Manajemen, Teknik Informatika dan Rekayasa Komputer, Vol. 21, No. 3, hlm. 653-666, 2022. DOI: 10.30812/matrik.v21i3.1851.
9. Magriyanti, A. A. Maximum Marginal Relevance Berbasis Boolean Model pada Peringkasan Artikel Berita Pendek. Jurnal Ilmiah Teknik Informatika dan Komunikasi, vol. 1, no. 3, pp. 77-88, 2021.
10. Said, F. dan Manik, L. P. Aspect-Based Sentiment Analysis on Indonesian Presidential Election Using Deep Learning. Paradigma, vol. 24, no. 2, pp. 160-167, 2022.

11. Wahyudi, D. dan Sibaroni, Y. Deep Learning for Multi-Aspect Sentiment Analysis of TikTok App using the RNN-LSTM Method. *Building of Informatics, Technology and Science (BITS)*, vol. 4, no. 1, pp. 169-177, 2022.
12. M. H. Wicaksono, M. D. Purbolaksono, dan S. A. Faraby, "Perbandingan Algoritma Machine Learning untuk Analisis Sentimen Berbasis Aspek pada Review Female Daily," *e-Proceeding of Engineering*, vol. 10, no. 3, pp. 3591–3597, Jun. 2023.
13. Snowflake Inc., Streamlit Documentation, <https://docs.streamlit.io/>, Diakses: 1 Juni 2026.
14. SQLite.org, SQLite Documentation, <https://www.sqlite.org/docs.html>, Diakses: 1 Juni 2026.
15. Pradhyksa, D. P. Pengaturan Pendayagunaan Sumber Daya Air dalam Undang-Undang Cipta Kerja dan Korelasinya dengan Pasal 33 UUD 1945. *Ascarya: Journal of Islamic Science, Culture, and Social Studies*, 1(2), 70–92, 2021.
16. L. Kurnia Ramadhani and B. Nurul Widyaningrum, "Analysis Sentiment to Religious Based Issues Netizen Comments on President Jokowi 's Instagram using the Naive Bayes Classifier Method", *Jl*, vol. 9, no. 1, pp. 59-66, Feb. 2024.
17. V. A. S. Putri, A. V. Vitianingsih, R. Hamidan, A, L, Maukar, N. T. Pratitis, "Sentiment Analysis on Social Media Instagram of Depression Issues Using Naïve Bayes Method", *ISI*, vol. 9, no. 2, pp. 802–813, Oct. 2024
18. F. R. Halim, R. Novita, Mustakim and M. Afdal, "Sentiment Analysis to Assess Customer Retention on Instagram Social Media Using Naïve Bayes Classifier and Support Vector Machine," *2024 4th International Conference on Emerging Smart Technologies and Applications (eSmarTA)*, Sana'a, Yemen, 2024.
19. M. A. Khadija, I. S. D. Jayanti and F. U. Nimah, "Towards Smart City: Aspect Based Sentiment Analysis of Indonesian Public Aspiration Complaints Data Using Machine Learning," *2024 7th International Conference on Informatics and Computational Sciences (ICICoS)*, Semarang, Indonesia, 2024